# 1차 프로젝트

목표: 데이터 수집 → 전처리 → 탐색/피처링 → 모델링 → 검증/해석 까지 한 번에 경험하는 실습형 프로젝트

# <일정>

- 프로젝트 기간 동안에도 줌에서 캠 on 상태로 진행합니다.
- **25/12/17 오후 ~ 26/01/05 :** 프로젝트 개발 진행
- **26/01/06 오전:** 프로젝트 발표 및 최종 피드백

# <프로젝트 목록>

| 번호 | 프로젝트 | 핵심 산출물 |
|---|---|---|
| 1 | 주가 지수 데이터 활용 머신러닝·딥러닝 프로젝트 | 예측 모델 + 성능 리포트 |
| 2 | 국내 증시 데이터 기반 시계열 머신러닝·딥러닝 프로젝트 | 시계열 파이프라인 + 검증 결과 |
| 3 | 네이버 주식 웹 페이지 크롤링을 통한 주가 정보 수집 | 크롤러 + 수집 데이터셋 |
| 4 | 주가 데이터 클러스터링을 통한 종목 군집화 및 해석 | 군집 결과 + 해석 노트 |
| 5 | 다양한 지표 기반 모델링으로 주가 변동 방향성 예측 및 검증 | 특성 중요도/해석 + 백테스트 |
| | | |

# <공통 준비 사항>

- 권장 환경: Node.js(크롤링/자동화), Python(분석/모델링)등 중 혼합 사용
- 필수 라이브러리 예시: pandas, numpy, matplotlib/plotly, scikit-learn, (선택) pytorch/keras 등
- 데이터 소스: 공개 API/CSV/웹 페이지, KRX/상장사/지수 데이터 등
- 평가 원칙: 훈련/검증/테스트 분리, 시계열은 시간 순서 유지(미래 정보 누수 방지) 등

- 제출물: 코드(노트북 또는 스크립트) + 결과 리포트(PDF/Markdown) + 재현 방법(README) 등
- ppt, 발표영상 촬영

<목표> : 우리가 배웠던 것이나 잘 쓰고 배울것을 녹여내보자

성능을 끌어올리는 것도 좋지만, 1. 내가 이해하는 것이 목표 2. 수업내용은 중요하지 않음 → 직접 써봐야 함.

10일정도의 시간 →폭발적인 성장 가능성이 있음. 하지만 시간 보내는 것도 가능함.

→ 엄청난 새로운것은 피하자. 트렌드 인것은 타자.

→ Edge AI(ondevice AI), 양자화, 기업(자동화 도구(n8n, genspark, skywalk etc...), MCP)), 생성형 AI잘쓰는 것

→ 처음부터 잘 학습을 시킴 ( 초등→중등→ 고등→다른질문→초등)

- 생성형 AI 잘쓴다! → 1.이게 정말 맞나?(판단) 2. 실제로 이 코드가 효율적인가?
- 코드 모름 → 생성형 AI → 맞는지? 아닌지? → 코드 → 생성형 AI → 코드

# <프로젝트별 상세 안내>

## 1. 주가 지수 데이터 활용 머신러닝·딥러닝 프로젝트

### 개요/목표

- 지수(예: KOSPI, KOSDAQ 등)의 가격/수익률을 이용해 예측 문제를 정의하고, 머신러닝, 딥러닝, 시계열 모델을 비교합니다.
- 회귀(다음 날 수익률 예측) 또는 분류(상승/하락) 중 하나를 선택합니다.

### 데이터 범위(예시)

- 기간: 최소 3년 이상(권장 5-10년), 주기: 일/주 단위
- 변수: 종가, 거래량, 수익률, 이동평균, 변동성(rolling std), RSI/MACD 등 기술지표

### 권장 진행 단계

1. 데이터 수집 및 결측/이상치 처리(휴장일, 이벤트 등)
2. 베이스라인 정의(naive, 단순 이동평균 등) 후 성능 기준선 확보
3. 특성 엔지니어링(지표, lag feature, rolling window, 변동성)
4. 모델 학습(예: XGBoost/RandomForest, LSTM/GRU/Transformer 중 택)
5. 검증(시계열 분할, walk-forward) 및 과적합 점검
6. 결과 해석 및 리포트 작성(성능, 실패 사례, 개선 제안)

### 필수 산출물

- 학습/평가 코드(재현 가능한 실행 방법 포함)
- 모델 성능 비교표(지표, 기간, 설정) 및 그래프(예측 vs 실제)
- 실험 로그(파라미터, 특징량 목록)와 결론 요약

### 평가/검증 포인트

- 시계열 데이터 누수 여부(미래 데이터 사용 금지)
- 동일 기간에서의 베이스라인 대비 개선 폭
- 평가지표 적합성(회귀: MAE/RMSE, 분류: Accuracy/F1/AUC 등)
- 추가로 경제적 관점 지표(간단한 매매 규칙 기반 누적 수익률) 제시 가능

### 확장 아이디어(선택)

- 불확실성 추정(예: 예측 구간/분산) 또는 앙상블
- 레짐(상승장/하락장) 구분 후 조건부 모델링
- 외생 변수(금리, 환율, 원자재 등) 추가

## 2. 국내 증시 데이터 기반 시계열 머신러닝·딥러닝 프로젝트

### 개요/목표

- 여러 종목(또는 섹터 ETF)을 대상으로 시계열 예측 파이프라인을 구축합니다.
- 단일 시계열이 아니라 ‘패널 시계열’ 관점으로 확장(종목별 학습/공통 모델)합니다.

### 데이터 범위(예시)

- 대상: KOSPI/KOSDAQ 상장 종목 중 30~200개 샘플(자유롭게 선택)
- 변수: OHLCV + 기술지표 + (가능 시) 재무/공시/뉴스 감성

### 권장 진행 단계

1. 대상 종목 선정 기준 정의(시가총액, 유동성, 섹터 등)
2. 데이터 정합성 처리(상장폐지/분할/병합, 수정주가)
3. 패널 피처 구성(종목 고유 특성 + 시간 피처 + 시장 공통 피처)
4. 모델링 전략 선택: (A) 종목별 개별 모델 (B) 멀티태스크/공유 모델
5. 검증 설계: 종목 홀드아웃 vs 시간 홀드아웃 vs 둘 다
6. 결과 비교 및 일반화 성능 평가

### 필수 산출물

- 데이터셋 생성 스크립트(종목 리스트, 기간, 전처리 규칙 포함)
- 모델링 파이프라인(학습/검증/테스트 자동화)
- 종목별 성능 분포(박스플롯 등) 및 실패 케이스 분석

### 평가/검증 포인트

- 종목별 성능 편차 원인 분석(변동성/유동성/섹터 차이)
- 학습-검증 분할의 타당성(누수 방지 + 재현성)
- 모델 복잡도 대비 성능 개선(비용 대비 효과)

### 확장 아이디어(선택)

- 섹터/스타일 팩터(가치, 모멘텀 등) 기반 특징량 추가
- 메타러닝/전이학습으로 저데이터 종목 성능 개선
- 데이터 드리프트 감지 및 리트레이닝 전략

## 3. 네이버 주식 웹 페이지 크롤링을 통한 주가 정보 수집

## 개요/목표

- 웹 페이지에서 종목/지수 관련 정보를 수집하여 분석 가능한 데이터셋으로 구축합니다.
- 크롤링 윤리 및 안정적 수집(요청 간격, 실패 복구, 로그)을 포함합니다.

## 데이터 범위(예시)

- 수집 항목 예시: 현재가/전일비/거래량, 호가, 일/주/월 시세, 주요 뉴스 헤드라인(가능 시)
- 저장 형식: CSV/Parquet + 메타데이터(수집 시각, URL, 버전)

## 권장 진행 단계

1. 수집 대상 URL/페이지 구조 분석(HTML 구조, 필요 파라미터)
2. robots.txt 및 서비스 이용 정책 확인 후 합법적 범위 내 수집
3. 요청 속도 제한, 재시도(백오프), 예외 처리 및 로깅 구현
4. 정규화된 스키마로 저장(중복 제거, 타입 변환, 결측 처리)
5. 수집 데이터 품질 점검(샘플링 검증, 필드 유효성 검사)

## 필수 산출물

- 크롤링 스크립트 + 실행 옵션(기간/종목/저장경로)
- 수집 데이터 샘플 파일 + 스키마 설명
- 재현 가능한 실행 안내(README)

## 평가/검증 포인트

- 수집 실패율/재시도 성공률, 요청 제한 준수 여부
- 필드 정확도(일부 샘플 수동 검증)
- 데이터 스키마 일관성(날짜/숫자 파싱, 중복/결측 처리)

## 확장 아이디어(선택)

- 스케줄러(cron) + 증분 수집(incremental) 설계
- 저장소 최적화(Parquet, partitioning) 및 버전 관리
- Contract 테스트(HTML 구조 변경 감지) 도입

# 4. 주가 데이터 클러스터링을 통한 종목 군집화 및 해석(3조)

## 개요/목표

- 종목을 '유사한 움직임/특성' 기준으로 군집화하고, 군집별 특징을 해석합니다.
- 차원축소 + 군집 + 해석(대표 종목, 특징량)을 하나의 스토리로 구성합니다.

## 데이터 범위(예시)

- 입력 특징 예시: 최근 N일 수익률 시계열, 변동성, 거래량 패턴, 기술지표 요약 통계
- 군집 알고리즘: K-means, GMM, Agglomerative, DBSCAN 등

## 권장 진행 단계

1. 군집화에 사용할 특징 정의(시계열 그대로 vs 요약 통계)
2. 스케일링/정규화 및 이상치 처리
3. 차원축소(PCA/UMAP/t-SNE)로 구조 파악
4. 군집화 수행 + 군집 수/파라미터 선택 근거 제시
5. 군집 해석: 군집별 평균 패턴, 섹터 분포, 대표 종목

## 필수 산출물

- 군집 결과(라벨) 포함 데이터셋
- 시각화(2D 임베딩, 군집별 패턴 플롯) 및 해석 리포트
- 군집 안정성/재현성 점검 결과

## 평가/검증 포인트

- 군집 수 선택의 근거(실루엣, BIC/AIC, 안정성 등)
- 기간 변경 시 군집이 유지되는지(robustness)
- 군집의 경제적 의미(섹터/이벤트/공통 요인) 설명

## 확장 아이디어(선택)

- 시장 레짐별 군집 변화 분석
- 동적 클러스터링(rolling window)으로 군집 전이 추적

- 군집을 피처로 사용해 예측 모델 성능 개선

# 5. 다양한 지표 기반 모델링으로 주가 변동 방향성 예측 및 검증

## 개요/목표

- 여러 기술지표/특징량을 투입해 '방향성(상승/하락)'을 예측하고, 검증과 해석까지 수행합니다.
- 단순 정확도뿐 아니라, 검증 설계와 해석(중요 변수, 안정성)을 중점으로 합니다.

## 데이터 범위(예시)

- 타깃 예시: 다음 날(또는 다음 주) 수익률 > 0 여부
- 특징 예시: 모멘텀/추세/변동성/거래량 지표 + lag/rolling 피처

## 권장 진행 단계

1. 타깃 정의(예측 horizon, 임계값) 및 클래스 불균형 점검
2. 피처 후보 생성 후, 누수 방지(시점 정렬) 및 선택
3. 모델 비교(로지스틱/트리/부스팅/딥러닝) + 하이퍼파라미터 튜닝
4. 검증: 시간 순 split + walk-forward, confusion matrix 등
5. 해석: feature importance/SHAP(가능 시)로 기여 요인 정리

## 필수 산출물

- 모델 성능 리포트(기간별 성능, ROC/PR, confusion matrix)
- 해석 결과(중요 변수, 방향성/레짐별 차이)
- 재현 가능한 실행 스크립트/노트북

## 평가/검증 포인트

- 불균형 대응(가중치/샘플링) 효과 비교
- 기간별 성능 변동(드리프트) 및 재학습 필요성
- 과최적화 방지(검증 체계, 튜닝 범위 기록)

### 확장 아이디어(선택)

- 간단한 규칙 기반 백테스트(매수/매도 조건)로 실용성 점검
- 모델 캘리브레이션(확률 예측 신뢰도) 평가
- 앙상블/스태킹으로 성능 안정화

# 부록: 제출 체크리스트

- 데이터 출처/수집 방법 명시(가능하면 링크 및 날짜 포함)
- 전처리 규칙(결측/이상치/스케일링) 문서화
- 시계열 분할 방식 설명(누수 방지 근거 포함)
- 성능 지표 및 해석 결과(그래프/표) 포함
- 재현 방법(실행 명령, 환경, 버전) 포함
- XAI(해석 가능성)을 잘 포함할 것.

# <프로젝트 진척 상황>

프로젝트 진척 상황 (1차) (1)

# 4. 프로젝트 발표

- 일시 : 01월 06일 (10:00) 오전 **진행**
- 프로젝트 발표는 Zoom에서 진행되며, 교육 과정 참여 증빙으로 녹화가 진행됩니다.
- 발표 순서는 랜덤으로 정하여 진행하며, 각 10분씩 발표+피드백을 진행합니다.
- 발표 순서는 발표일 오전에 공지될 예정입니다.

# 5. 팀별 프로젝트 보드

❤️ 1조 : 팀명 (1)

❤️ 2조 : 팀명 (1)

❤️ 3조 : 팀명 (1)

[별첨2-2] 팀별 프로젝트 결과보고서.pptx

# ✔️ 발표자료 안내

> 💡 발표 제출 기한: 발표 전날 자정까지

---

## 📦 제출 결과물

아래 항목 중 **필수 + 선택**으로 제출합니다.

**필수 제출**

1. `README.md`
   - 마크다운( `.md` ) 파일 **원본 그대로 제출**
2. `README.pdf`
   - GitHub 웹페이지를 **PDF로 인쇄**하여 제출
   - 인쇄 대상: **Microsoft Print to PDF**

**선택 제출**

3. **추가 발표자료**

- PPT 파일 또는
- 발표 자료 URL (Notion, Google Slides 등)
- 팀 repository

---

## 📤 제출 방법

- 아래 링크의 **테이블에 업로드**
  - 📎 업로드 항목: **발표 자료**
  - 🔗 제출 테이블: https://www.notion.so/2c6ebaa8982b81f586c9e57a6b66503a?pvs=21

# 📎 (부록)

## 💬 질문하는 방법

질문은 **문제 해결의 절반**입니다.

효율적인 커뮤니케이션을 위해 아래 가이드를 꼭 지켜주세요.

### ✅ 질문 시 체크리스트

질문 전, 아래 항목을 반드시 확인해주세요.

1. **레포지토리에 코드가 반드시 푸시되어 있어야 합니다.**
2. **레포지토리 주소(URL)** 를 함께 공유해주세요.
3. **질문과 관련된 코드의 정확한 위치**를 명시해주세요.
   - 예: `components/Modal.js` — **25번째 줄**
4. **현재 발생한 문제와 시도한 해결 방법**을 구체적으로 작성해주세요.
   - 예:

     > "모달은 열리지만 닫히지 않음.
     >
     > `onClose` 함수를 버튼에 연결했으나 동작하지 않음."

### ⛔ 이런 질문은 피해주세요

- ❌ “왜 안 되는지 모르겠어요 ㅠㅠ”
- ❌ “에러나요 도와주세요”

👉 질문을 **구체적으로 정리할수록**,

답변은 **더 빠르고 정확**해집니다.

## 🧾 코드리뷰 요청 방법

코드리뷰는 **리팩토링 능력과 협업 역량을 키우는 과정**입니다.

리뷰어의 시간을 아껴주는 준비가 중요합니다.

## ✅ 코드리뷰 요청 체크리스트

1. **저자가 고생할수록, 리뷰어는 덜 고생합니다.**
   - 불필요한 파일
   - 테스트용 주석
   - 임시 코드

     → 미리 정리해주세요.
2. **리뷰를 받고 싶은 범위 / 파일 / 라인을 명확히 지정해주세요.**
   - 예:

     > "Home.js에서 useEffect 사용 방식에 대해 리뷰 부탁드립니다."
3. **의도와 개선하고 싶은 포인트를 함께 설명해주세요.**
   - 예:

     > "섹션 분리를 시도했는데, 더 나은 구조가 있는지 궁금합니다."
4. **리뷰 요청 전, 스스로 한 번 더 코드 정리를 진행해주세요.**

---

## 🧭 팀 발표

| 팀 | 팀장 | 팀원 |
|---|---|---|
| 1팀 | | 고일국, 김동호, 김재무, 홍지훈 |
| 2팀 | | 양태영, 박재진, 오은원, 박준호, 고현주 |
| 3팀 | | 박영식, 차건욱, 임동환, 유영민, 최재혁 |