생성형 AI 개요

류영표 강사
ryp1662@gmail.com

Youngpyo Ryu. All rights reserved.
Unauthorized reproduction or distribution is prohibited.

류 영 표

AI & Applied Mathematics Researcher · Lecturer

ryp1662@gmail.com



학력

- 동국대학교 일반대학원 응용수학 석사 수료 (2016-2019)
- 동국대학교 수학과 졸업 (2010-2016)

심사 및 전문가 자문 활동

- 인공지능 학습용 데이터 구축 사업 품질검증 전문가 자문위원 (2023)
- 2023 신뢰할 수 있는 인공지능 개발 안내서(안)_고도화 전문위원
- 2023 자율주행/의료/공공사회 분야 신뢰할 수 있는 인공지능 개발 안내서(안) 자문위원

연구 및 프로젝트

- 부산대학교 병원: 개인 맞춤형 당뇨병 예방·관리 인공지능 시스템 외주 프로젝트 (2022)
- 연세대학교 병원: 영상의학과 FLASK 고도화 연구 (2023, 2024)
- 산업수학 스터디 그룹 (국가수리과학연구소): 피부암/유방암 분류, 유전자 정보 분석
- 폐플라스틱 이미지 객체 검출 경진대회 3위 (2021)
- 동국대학교 수학과 연구원(2025.10 ~ / 양자 AI, XAI 연구 진행 중)

논문

- Quantum computing for the optimization of CT image reconstruction, IEEE ICTC 2022

㈜ 헬로월드랩스 전담교육팀 과장

강의 및 교육 활동

대학 강의

- 고려대학교, 인천대학교, 동양미래대학교, 목포대학교
- 이젠 아카데미: 파이썬/ADSP 과정

기업 교육

- 현대자동차 연구원 대상
- 한화, 하나금융, 한전 KDN, IBK 기업은행, 아가방앤컴퍼니, IM증권

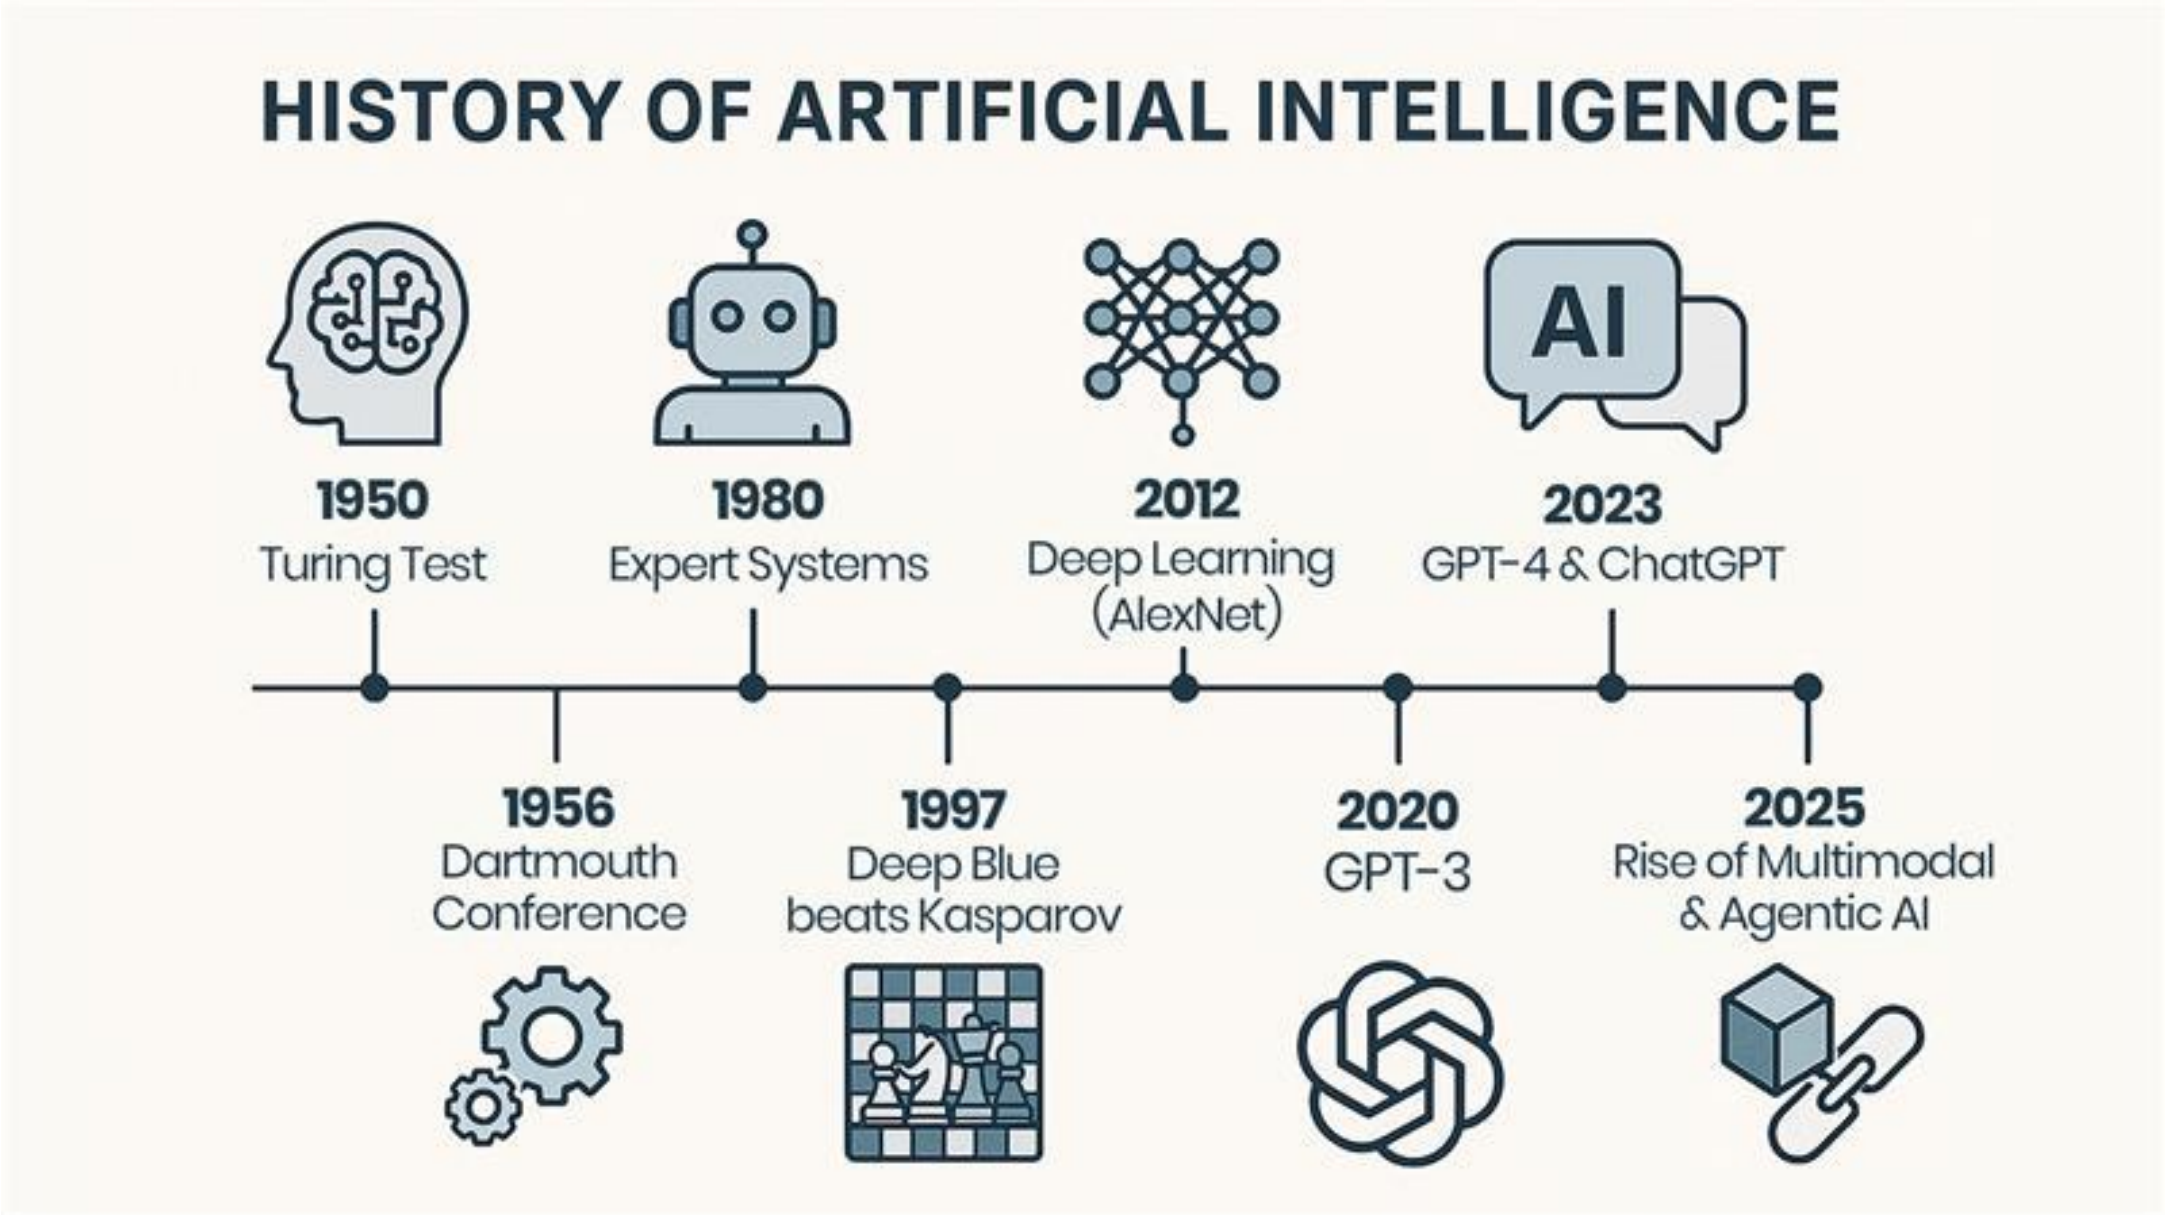
공공/국비 과정

- [Est Camp] AI 퀀트 캠프 1기
- LG 헬로비전 DX 데이터 스쿨 (4기)
- 보건·바이오 AI 활용 전문가 양성과정 (1-3기)
- 공공데이터 청년 인턴 멘토
- 충청 ICT 취창업 역량강화 프로그램 (SQLD)

아카데미 & 부트캠프

- 모두의연구소 Aiffel 퍼실리테이터 (1기)
- Upstage AI Boostcamp 멘토 (1-6기)
- 패스트캠퍼스/멀티캠퍼스 조교 및 멘토
- 공개SW개발자대회 멘토

AI의 발전

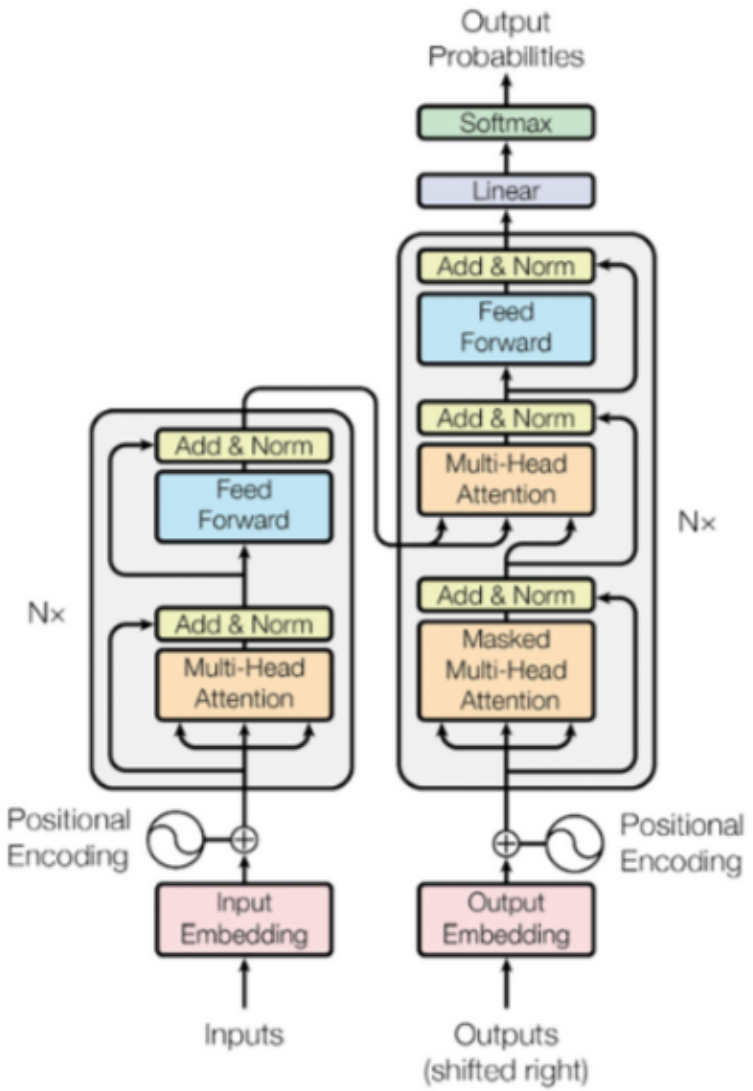


출처 : https://www.linkedin.com/pulse/history-artificial-intelligence-timeline-innovation-from-bansal-cpa-asw6f/

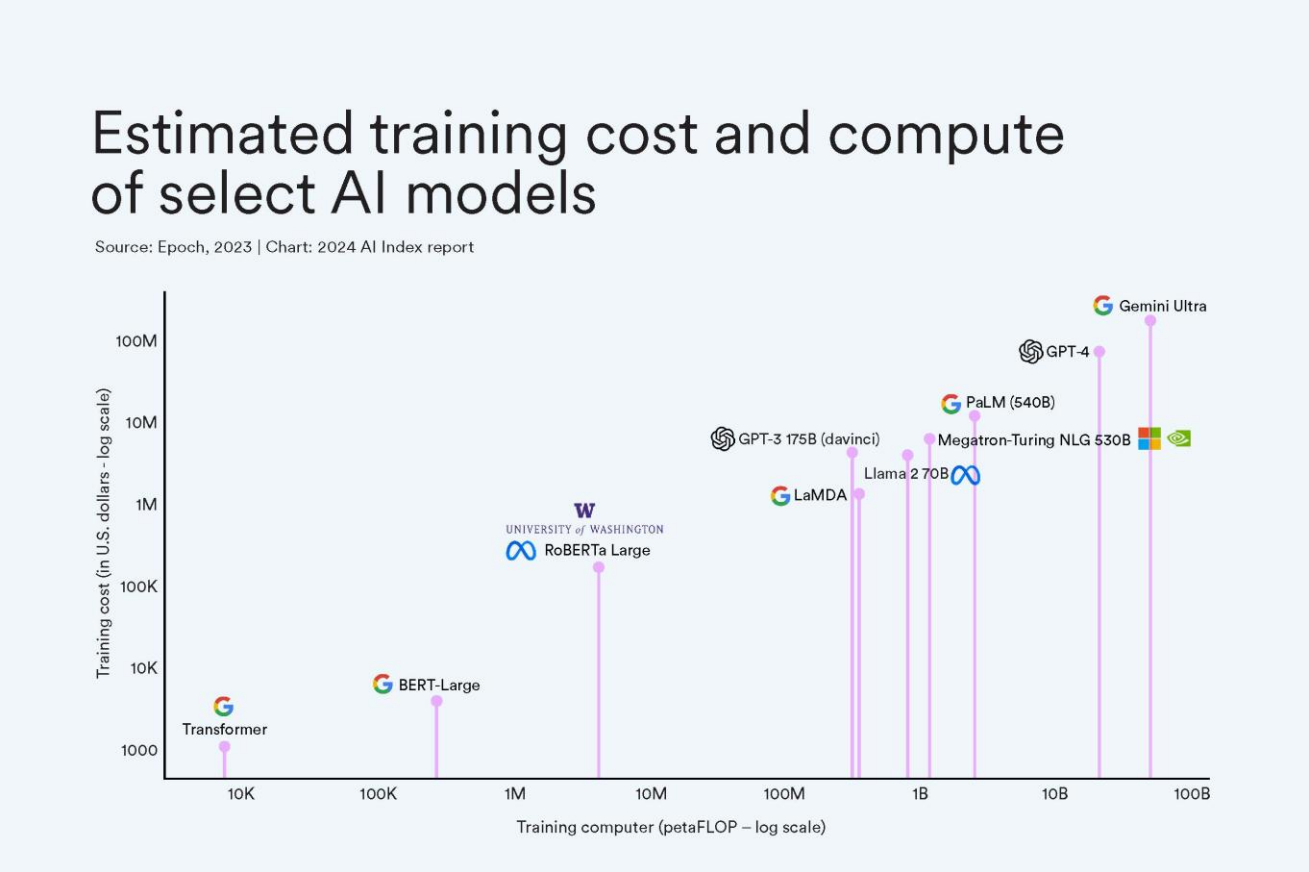
2017, Transformer 등장으로 시작된 AI 패러다임 전환

Transformer

Attention Is All You Need



2018 ~ LLM(Large Language Model)의 폭발적 성장



스케일링 법칙(Scaling Law)

- 모델의 크기(파라미터)와 학습 데이터가 늘어날수록 지능이 향상된다는 법칙이 증명된 시기
- GPT 시리즈 : GPT- 1에서 GPT- 5로 이어지며 인간 수준의 언어 능력을 확보
- ChatGPT 모멘텀 : 2022년, 대화형 인터페이스를 통해 AI가 대중의 일상으로 진입

대규모언어 모델(LLM, Large Language Model)

정의 (Definition)

방대한 텍스트 데이터로 학습되어 인간의 언어를 이해하고 생성하는 초거대 AI 모델입니다.

핵심 기술 (Core Tech)

문맥을 파악하는 트랜스포머(Transformer) 아키텍처와 어텐션 메커니즘을 기반으로 작동합니다.

주요 기능 (Capabilities)

자연어 생성, 문서 요약, 번역, 감정 분석, 코드 작성 등 다양한 지적 작업을 수행합니다.

대표 모델 (Examples)

OpenAI의 GPT-5, Google의 Gemini, Anthropic의 Claude, Meta의 LLaMA 등이 있습니다.



현재: LLM의 3대 핵심 능력



고도화된 추론

단순 검색을 넘어, 복잡한 문제를 단계별로 생각하고 논리적으로 해결하는 추론(Reasoning) 능력을 갖추었습니다.



코드 생성

자연어를 코드로 변환하고, 버그를 수정하며, 전체 시스템 아키텍처를 제안하는 수준에 도달했습니다.



멀티모달

텍스트뿐만 아니라 이미지, 음성, 비디오를 동시에 이해하고 생성하는 통합 지능으로 진화했습니다.

2026: 차세대 LLM과 Agent 시대

GPT-5, Gemini 3 등 거대 모델이 이끄는 업무 자동화 혁신

GPT-5 AGI급 추론 & 멀티모달. 로컬 운영 최적화.

Gemini 3 초대규모 컨텍스트 + 고정밀 Reasoning.

Claude 4.6 논리/수학/코딩 특화. 긴 문서 분석 압도.

Llama 4 오픈소스 최강자. 기업 맞춤형 파인튜닝 용이.

Mistral Large 2 유럽발 혁신. 최고의 가성비와 효율성.



AI Agent 시대 확립

단순한 질문-답변을 넘어,

AI가 스스로 계획하고 업무를 완결하는

진정한 자동화

- SW 개발 자동화 (Copilot Workspace)
- PC 조작 자동화 (Operator AI)
- Multi-Agent 협업 시스템 도입

GPU · 클라우드 비용 폭증

- **GPU 수요 폭증:** 공급 부족 심화로
  비용 30~70% 급등 (2023–2024)
- **LLM API 비용 부담:** 기업 단위 본격 도입 시
  월 수백~수천만 원의 고정 비용 발생
- **대규모 추론 비용:** 모델이 커질수록
  운영 및 유지보수(Inference) 비용 기하급수적 증가
- **PoC 중단 사례 증가:** 클라우드 비용 통제 실패로
  AI 도입 프로젝트(PoC) 중도 포기
- **Cloud Repatriation:** 비용 절감을 위해
  다시 온프레미스로 복귀하는 트렌드 확산



> *"AI는 잘 쓰면 생산성이 3–10배 오르지만,*
> *잘못 쓰면 GPU·API 비용 폭탄으로 오히려 손해가 됩니다."*

AI 거품론과 인프라의 도전

LLM 거품론에 대한 시각

- **LLM 편중 비판:** 관심과 자금이 ChatGPT 같은 범용 LLM에만 집중되어 있어 거품이 끼었다는 회의론 존재.
- **전문화 모델의 필요성:** 모든 문제에 LLM이 최적의 답은 아니며, 작고 전문화된 모델(S-LLM)이 비용 효율적이고 빠르다는 주장 확산.
- **생산성 향상 반론:** 이미 AI 기반 도구가 개발 속도를 20~50% 향상시키는 등, AI가 실질적인 산업 기반 기술을 구축하고 있다는 반론.



▶ **핵심 지적:** 투입 비용 대비 가치 극대화를 위해 경량 버전의 AI 모델개발이 시급.

클라우드 및 인프라 도전 과제

- **GPU 의존성 문제:** AI 개발의 핵심인 엔비디아 GPU에 대한 편중 심화.
- **자체 칩 개발 노력:** 엔비디아 독점을 완화하고 비용을 절감하기 위해 NPU(신경망처리장치) 등 맞춤형 자체 칩개발 경쟁이 전 세계적으로 격화.
- **높은 운영 비용:** LLM 개발 및 맞춤형 시스템 구축의 초기 비용뿐만 아니라, 지속적인 유지보수 및 데이터 학습 비용 통제가 영원한 화두.



▶ 적정 기술(Appropriate Technology) 전략:

무조건적인 초대형 모델 도입 대신, 기업의 환경과 사용 목적에 맞는 경량화된 AI 모델 도입이 핵심.

sLLM (소형 언어 모델) 도입 특정 도메인에 특화된 경량 모델을 사용하여, 범용 LLM보다 빠르고 저렴하게 추론을 처리하고 성능을 최적화합니다.

On-device AI 실행 환경 구축 클라우드 서버를 거치지 않고 기기(Device) 내에서 AI를 직접 처리하여, 민감한 정보의 보안과 클라우드 운영 비용 문제를 동시에 해결.

AI Agents

Top 6 Most Popular Use Cases of AI Agents

Voice Agents

Agents used via voice, often used in customer service



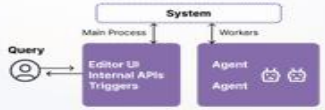
Agentic RAG

Knowledge retrieval based AI Agent workflow



Agentic RAG

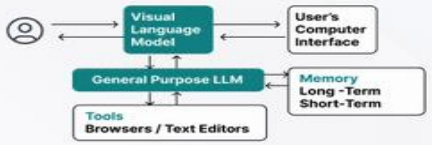
These are AI Agent creation/ development platforms





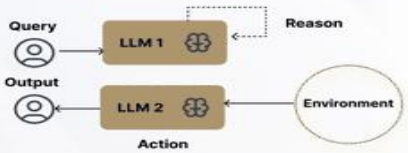
UI Interaction Agents

Versatile agents that can navigate the UI and perform interactions



Coding Agents

AI Agents for building and debugging applications 10x faster

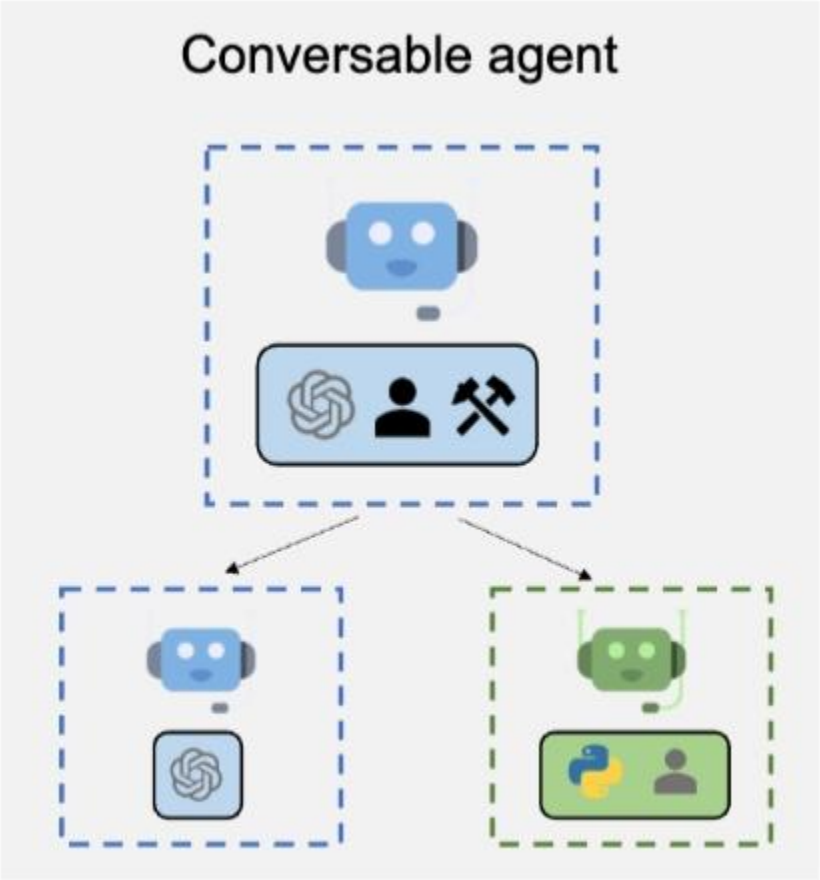


Tool-based Agents

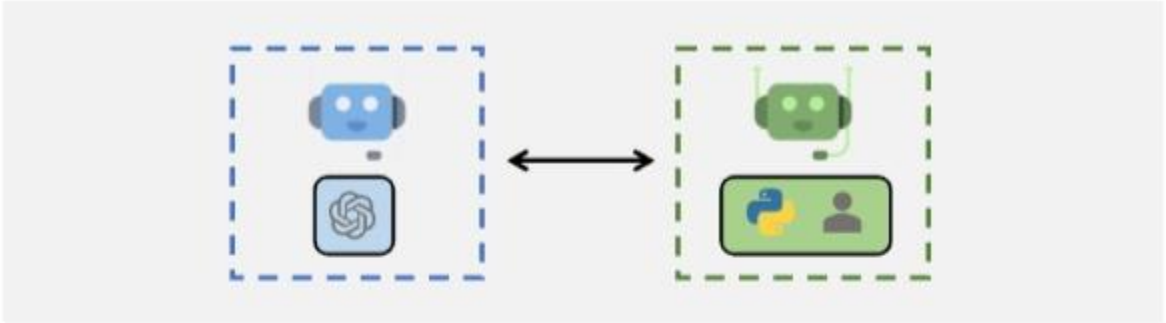
These agents are niche and are based on the tools used per workflow



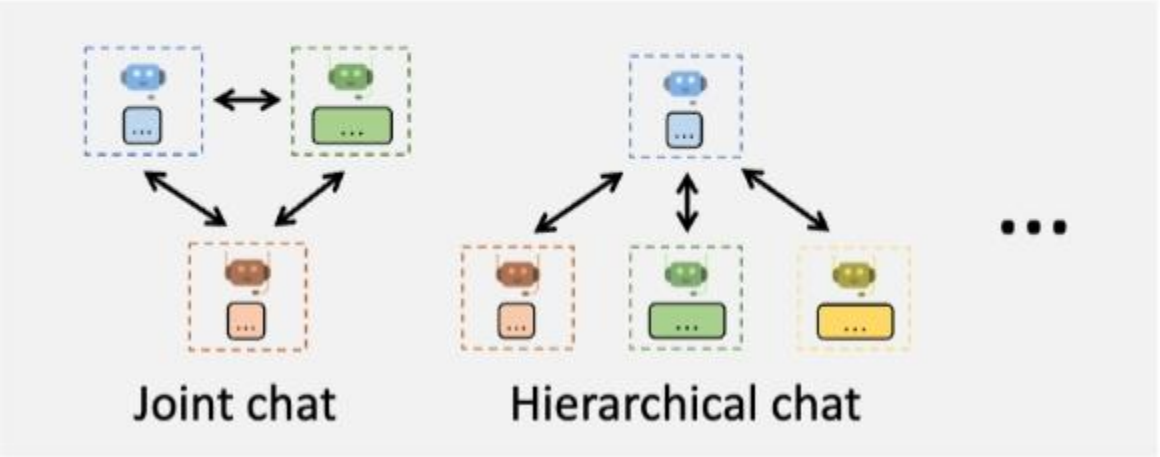
미래: 멀티 에이전트 협업



Agent Customization



Multi-Agent Conversations



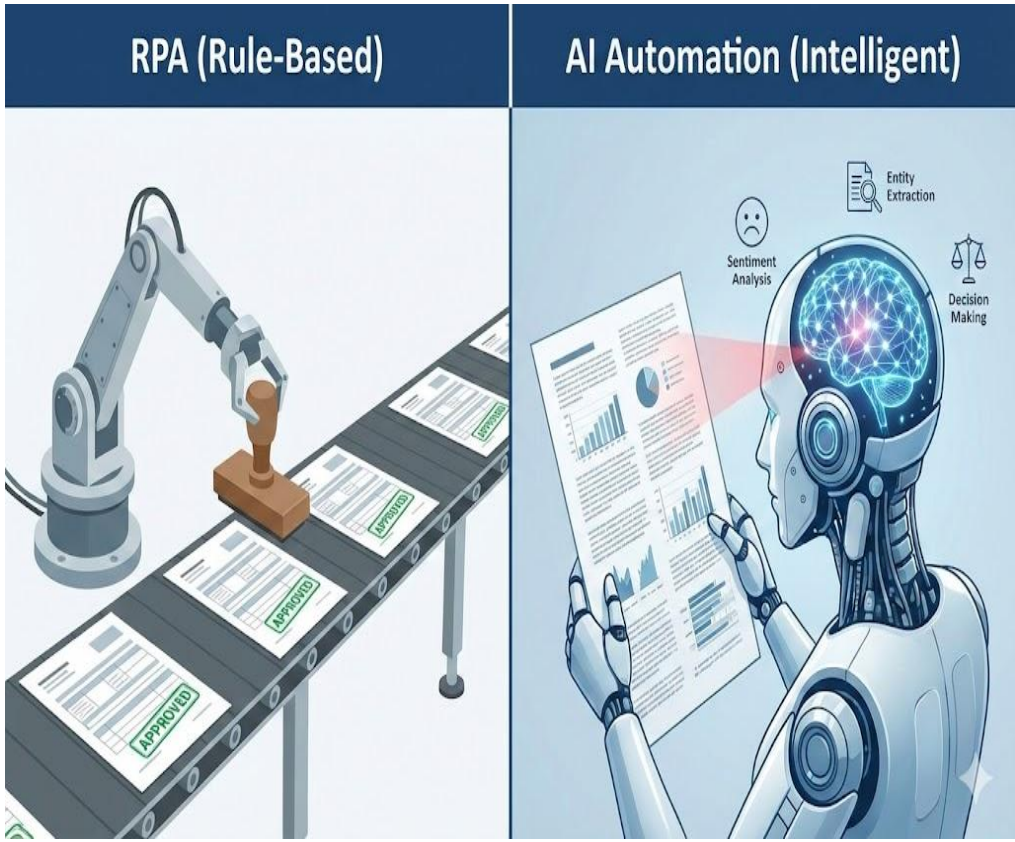
Flexible Conversation Patterns

패러다임의 변화(RPA에서 지능형 자동화로)

- AI 자동화(AI Automation) 란?

  : 머신러닝과 인지 기술을 활용하여, 비정형 데이터(이미지, 텍스트, 음성)를 이해하고 스스로 판단하여 업무를 수행하는 프로세스

- RPA(Robotic Process Automation) : 사람이 반복적으로 수행하는 업무를 소프트웨어 로봇이 대신 자동화하는 기술



- 기존 자동화(RPA) : “시키는 대로 수행” (Rule-Based)

  - 정해진 규칙에 따라 반복 업무 처리(ex. 송장 데이터 입력)

  - 예외 상황 발생 시 사람의 개입 필요

- AI 자동화(Intelligent) : “스스로 판단하고 수행”(Data-Driven)

  - 비정형 데이터(문서, 이미지, 자연어)를 이해하고 분석

  - 맥락을 파악하여 최적의 의사결정 지원

자율 에이전트와 인간의 협업

에이전트 AI(Autonomous Agents):

- 사용자의 목표(Goal)를 이해하고 스스로 계획을 수립하여 실행
- 여러 도구와 시스템을 자율적으로 활용하여 복잡한 업무 완수

인간과 AI의 협업(Human-AI Collaboration):

- 인간은 전략 수립, 창의적 결정, 최종 검토와 같은 고부가가치 업무에 집중
- AI는 데이터 수집, 분석, 초안 분석 등 실행 업무를 전달하는 파트너 역할수행



AI로 진화하는 비즈니스 자동화

1. [기술] 뇌와 손의 결합(The Core)

   - RPA(손) : 정해진 규칙대로 실행

   - AI/ML(뇌) : 데이터를 학습하고 판단

   -> 결과 : 스스로 똑똑하게 “지능형 로봇” 탄생

2. [실행] 전방위 자동화(The Action)

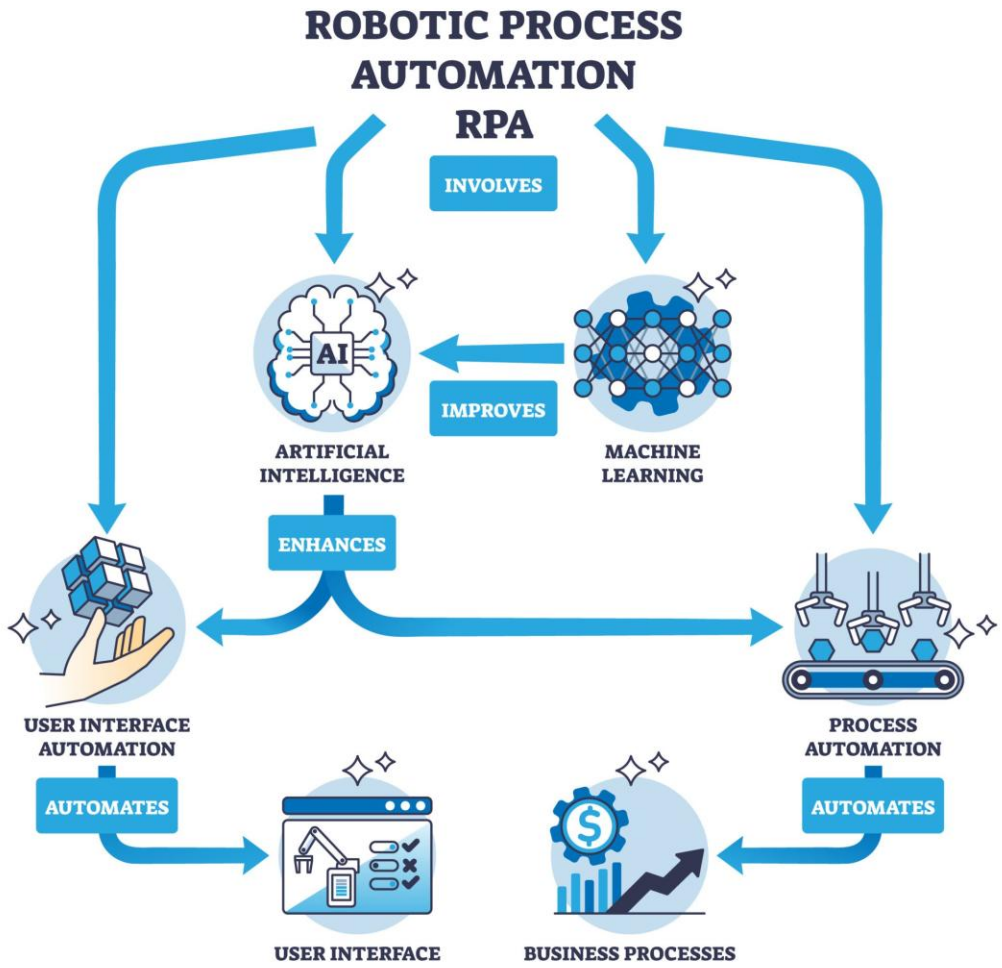
   - UI 자동화 : 클릭, 입력 등 PC 화면 업무 자동화(좌측)

   - 프로세스 자동화 : 복잡한 공정 및 시스템 흐름 자동화(우측)

3. [결과] 비즈니스 가치 창출(The Value)

   - 업무 속도 향상 및 비용 절감

   - 결국 기업의 이익(Profit)과 성장 그래프 상승으로 연결(하단)



AI Agent


Visualization of AI Agent (Agentic AI) in action
Plan → Execute → Tools → Report
Goal: “Organize Next Week’s Client Meeting”
aws
31
X
P
P

AI 시대, 역할의 경계가 무너졌다: 새로운 인재의 조건

최근 시대가 급변하면서 여러가지 인사이트들이 공유되고 있는건 다들 알고 계실겁니다.
그 중 저희쪽에서도 봐야 할 인사이트가 담긴 글이 있어서 공유드리니 꼭 봐주시길 당부드립니다.

😲<"T자형 인재는 죽었다" - AI 시대, 이제 'π형 풀스택 인간'만 살아남는다>
- "코딩 잘하면 끝? 이제는 제품 감각 + 엔지니어링 + 도메인 지식 없으면 도태된다"

AI가 코드를 짜주고 디자인을 뽑아주는 시대. 그런데 왜 아직도 우리 회사엔 PM, 개발자, 디자이너가 따로 있을까? 답은 간단하다. AI가 아무리 똑똑해져도, '무엇을 만들지' 결정하고 '왜 이게 좋은지' 판단하는 건 여전히 사람 몫이기 때문. 문제는, 그 '사람'의 정의가 바뀌고 있다는 것.

Microsoft 수석 프로덕트 엔지니어가 직접 경고하는 역할의 대재편. 이젠 한 가지만 잘해서는 안 된다. 두 가지 전문성에 폭넓은 기반 지식을 갖춘 'π형 인재'가 되거나, 도태되거나 둘 중 하나다.

1. 역할의 경계가 무너지고 있다 🌊

* 과거엔 명확했다 - PM은 기획, 개발자는 코딩, 디자이너는 디자인
* 이제는 "프로덕트 엔지니어"가 등장 - 기획부터 코딩, 배포, 모니터링까지 혼자 다 함
* 예전엔 웹 프레임워크 모르면 프로토타입 못 만들었지만, 지금은 Claude Code로 몇 시간이면 끝
* 저자는 실제로 명함에 "Principal Product Engineer"라고 적혀있음
* Figma 디자인을 몇 시간 만에 작동하는 웹 프로토타입으로 변환하는 게 일상

2. 스킬 상품화의 시대가 왔다 📦

* 예전엔 "디자인을 코드로 옮기는 능력"이 희소했지만 이젠 누구나 가능
* 하지만 이건 나쁜 소식이 아님 - Excel이 회계사를 없앤 게 아니라 더 고차원 업무를 하게 만든 것처럼
* 3D 프린터가 제조업을 파괴하지 않았고, 로봇 수술기가 외과의사를 대체하지 않았듯이
* AI는 증강(augmentation) 도구일 뿐, 전문성과 판단력을 대체하지 못함
* 문제는 '어떤 전문성'이 중요한지가 바뀌고 있다는 것

11월 14일 금요일

3. 창의성과 취향이 새로운 무기다 🎨

* LLM은 수천 개 아이디어를 뽑아내지만, 어떤 게 '진짜 좋은지'는 못 가림
* AI 결과물이 다 똑같이 보이는 이유 - 기존 데이터를 재탕하기 때문
* 둥근 모서리에 보라-파랑 그라데이션... 다 AI 슬롭(slop)의 전형
* 아이폰 이전에도 스마트폰은 있었지만, Apple의 취향이 시장을 바꿈
* 기술적으로 맞는 것과 진짜 매력적인 것의 차이를 구분하는 눈이 필요

4. 소통 능력이 곧 프롬프팅 능력이다 💬

* 더 명확한 요구사항을 작성할수록 더 나은 결과물이 나옴
* GitHub Spec Kit 프로젝트의 핵심 - "Spec-Driven Development"
* 사전 기획의 비용이 LLM의 이해도를 높이고 더 나은 코드를 만듦
* 바이브 코딩(vibe coding)으로는 좋은 제품 못 만듦
* 복잡함을 명확함으로 번역하는 능력이 더 중요해짐

5. 크로스 도메인 지식이 기본이 됐다 🔗

* 모든 분야의 전문가일 필요는 없지만, 조각들이 어떻게 맞물리는지는 알아야 함
* 프론트엔드 엔지니어가 아니어도 프론트엔드를 '충분히' 알아야 함
* Claude Code로 REST API 설정하는 법을 아는 비개발자가 순수 개발자를 앞지름
* 스택 전반의 제약과 트레이드오프를 이해해야 제대로 된 대화 가능
* 최신 도구들이 뭔지 알고 써먹을 줄 알아야 생산성이 나옴

6. AI 증강 스킬은 필수 역량이다 🤖

* 모든 AI/ML 논문을 읽을 필요는 없음
* 언제, 어떻게 AI 도구를 활용하는지만 알면 됨
* LLM이 잘하는 것과 못하는 것을 구분하고, 이를 체인으로 엮는 능력
* 어떤 작업에 어떤 모델이 적절한지 판단하는 감각
* AI 결과물이 맞는지 검증하는 방법을 아는 것

AI 시대, 역할의 경계가 무너졌다: 새로운 인재의 조건

7. 제품 감각이 핵심 차별화 요소다 🎯

11월 14일 금요일

* 무엇을 만들지, 왜 만드는지 아는 게 땜질쟁이와 제품 전문가의 차이
* 고객 피드백 두 조각을 이어붙이지 못하는 PM들 - 그러지 마라
* 기술적으로 인상적이지만 아무도 원하지 않는 걸 만드는 걸 막아주는 스킬
* 사용자에게 기능을 물어볼게 아니라 패턴을 찾아서 솔루션을 만들어야 함
* 작은 버전으로 진짜 가치를 전달하는 것부터 시작

8. 실행 속도가 복리로 쌓인다 ⚡

* 아이디어는 싸다, 출시가 어렵다 - 바이브 코딩으로도 마찬가지
* 바이브 코딩이 수천 개 SaaS 사업을 만들었나? 아니다, 훨씬 적음
* 왜냐면 엔드투엔드로 하는 게 여전히 어렵기 때문
* 빠르게 움직이면서도 '왜' 하는지를 잊지 않는 것
* 언제 밟아야 할지 감각을 키워야 함

9. 학습 민첩성이 생존을 결정한다 📚

* 기술 지식의 반감기가 계속 짧아지고 있음
* 웹 프레임워크는 "피자 먹고 싶어"라고 말하기도 전에 사라짐
* 프레임워크 암기가 아니라 전이 가능한 이해가 필요
* 근본 원리를 다른 곳에 어떻게 적용할지 아는 능력
* 내가 뭘 모르는지 발견하고, 누구에게 물어볼지 아는 것

10. 주도성이 모든 것을 가른다 🚀

* High Agency - "우리가 해결할 거야, 일 시작하자" 태도
* 핑계 없음, 허락 기다리지 않음, 쓸데없는 것에 시간 안 씀
* 장애물이 나타나면 밀어붙이는 불도저가 되어라
* 남이 가르쳐주길 기다리지 말고 스스로 배워라
* 과거에 연연하지 말고 앞으로 나아가라

🥧π형 인재 시대의 도래 - T자형은 끝났다

과거 T자형 인재는 하나의 깊은 전문성에 얕고 넓은 지식을 더한 형태였다. 역할이 명확하고 핸드오프가 깔끔할 때는 괜찮았다. PM은 PM 일, 개발자는 개발자 일.

하지만 지금 일은 훨씬 더 지저분하다. 루프는 타이트하고, 아이디어에서 임팩트까지 가는 가장 빠른 길은 여러 분야를 넘나든다. 이젠 π(파이)형이 답이다.

넓은 기반 - 프론트엔드, 백엔드, 데이터, 디자인, 배포를 충분히 말할 수 있고 결정하고 출시할 수 있는 수준

첫 번째 축 - 제품 감각. 취향, 판단력, 애매한 고객 문제를 명확하고 가치있는 결과물로 바꾸는 능력, 디테일에 대한 깊은 주의

두 번째 축 - 엔지니어링 장인정신. 프로덕션 제약 속에서 안전하고 단순하게 실제로 만드는 스킬

AI는 올바른 것을 선택하고, 잘 다듬고, 실제 환경에서 운영하는 비용은 낮추지 못한다. 그건 당신 몫이다. 모델은 증폭기지 관리자가 아니다. 당신이 의도, 아키텍처, 책임을 소유하는 동안 실행을 가속화할 뿐이다.

미래는 풀스택이다. 지금 올라타라.

출처: "You Need To Become A Full Stack Person" by Ian Vanagas (November 3, 2025)

에이전트의 핵심 작동 원리(The Agent Loop)

"목표를 주면, 스스로 생각하고(ReAct), 도구를 써서 행동하고, 결과를 관찰하여 목표를 달성하는 AI"

순서	단계	예시(Goal: 경쟁사 A 뉴스 요약 보고서)
1	Goal (목표 입력)	"경쟁사 A의 이번 달 뉴스 기사를 요약해서 보고서 써줘."
2	Thought (계획/추론)	"검색 도구가 필요하군. 먼저 검색 키워드를 정하자."
3	Action (도구 사용)	[웹 브라우징 도구 실행] -> 검색 수행
4	Observation (결과 관찰)	검색 결과 확인. 충분한가? (-> 부족하면 2단계로 재순환)
5	Final Answer (완료)	최종 목표 달성 및 보고서 제출

💡 단순한 답변 생성이 아닌, 실행(Action)이 가능한 AI

에이전트 도구, 목적에 따라 어떻게 나뉘는가?

목적과 개발 수준에 따라 크게 세가지로 분류

카테고리	목적	주요특징	예시도구
1. 개발 프레임워크	커스텀 에이전트 설계	개발자가 직접 에이전트를 설계하기 위한 도구 모음	LangChain, LlamaIndex
2. 멀티 에이전트 플랫폼	복잡함 문제 해결	여러 전문 에이전트가 협업하여 복잡한 워크플로우를 처리	MS AutoGen, Crew AI
3. 전문화된 서비스/완제품	특정 직무 대체 및 실행	특정 목표(검색, 코딩 등)를 도구를 써서 자율적으로 실행하는 서비스	Perplexity, Devin, ChatGPT/Gemini의 툴 호출 기능

💡 참고 : ChatGPT, Claude, Gemini 등의 대화형 AI는 내장된 Tool-Use(함수 호출) 기능을 통해 사용자 목표를 실행하는 에이전트의 역할을 수행합니다. Perplexity는 자율적인 검색 에이전트에 해당됨.

서비스 장애

ZDNET Korea 뉴스 지스타2025 인공지능 스테이블코인 IT's

NordVPN 최대 70% 할인
+ Saily eSIM 데이터 증정

AWS 15시간 먹통 후 복구…업계 "소수 클라우드 집중 구조 한계"

DNS 오류로 전 세계 서비스 마비…복원력·다중 리전 분산 전략 필요성 제기

컴퓨팅 | 입력 :2025/10/21 11:02 수정: 2025/10/21 14:06

한정호 기자 | 기자 페이지 구독 기자의 다른기사 보기

[등록하기] 베리타스와 코헤시티의 통합! 11월 27일 레질리언스 웨비나 등록하고 기념품 받으세요!

세계 최대 클라우드 서비스인 아마존웹서비스(AWS)에 대규모 장애가 발생해 전 세계 주요 인터넷 서비스가 마비됐다. 현재 대부분 복구가 완료됐지만 일부 서비스는 여전히 불안정한 상태로, 인터넷 인프라 집중화의 구조적 취약성이 다시 드러났다는 평가가 나온다.

ACC 2025
효율을 넘어 성과로, AI가 바꾸는 새로운 비즈니스 전략
ACC 2025
2025년 12월 11일(목)
사전등록 >

21일 업계와 주요 외신에 따르면 이번 장애는 지난 20일 미국 버지니아 북부 리전(US-EAST-1)에서 발생했다. AWS의 핵심 데이터베이스(DB) 서비스 '다이나모DB'의 도메인 네임 시스템(DNS) 오류가 근본 원인으로 지목됐다.

DNS는 인터넷의 전화번호부 역할을 하는 핵심 인프라로, 주소(URL)를 실제 서버의 IP로 연결해주는 기능을 한다. 이 시스템이 멈추자 수많은 앱과 웹사이트가 데이터 접근을 잃고 동작을 멈췄다.

Cloudflare 시스템 상태

Cloudflare Global Network에 문제가 발생했습니다.

조사 중 - Cloudflare는 여러 고객에게 영향을 미칠 수 있는 문제를 인지하고 조사 중입니다. 더 자세한 정보는 추가 정보가 확보되는 대로 제공해 드리겠습니다.
2025년 11 월 18일 - 11:48 UTC

지원 포털 가용성 문제

조사 중 - 현재 지원 포털 제공업체에 문제가 발생하여 고객이 지원 사례를 확인하거나 답변하는 데 오류가 발생할 수 있습니다. 고객 문의에 대한 답변은 영향을 받지 않으며, 고객은 Cloudflare 대시보드를 통한 라이브 채팅(비즈니스 및 엔터프라이즈)이나 비상 전화(엔터프라이즈)를 통해 문의하실 수 있습니다.
당사는 문제의 전체적인 영향을 파악하고 완화하기 위해 타사 제공업체와 협력하고 있습니다. 더 자세한 내용은 곧 업데이트될 예정입니다.
2025년 11 월 18일 - 11:17 UTC

LAX(로스앤젤레스) 2025-11-18

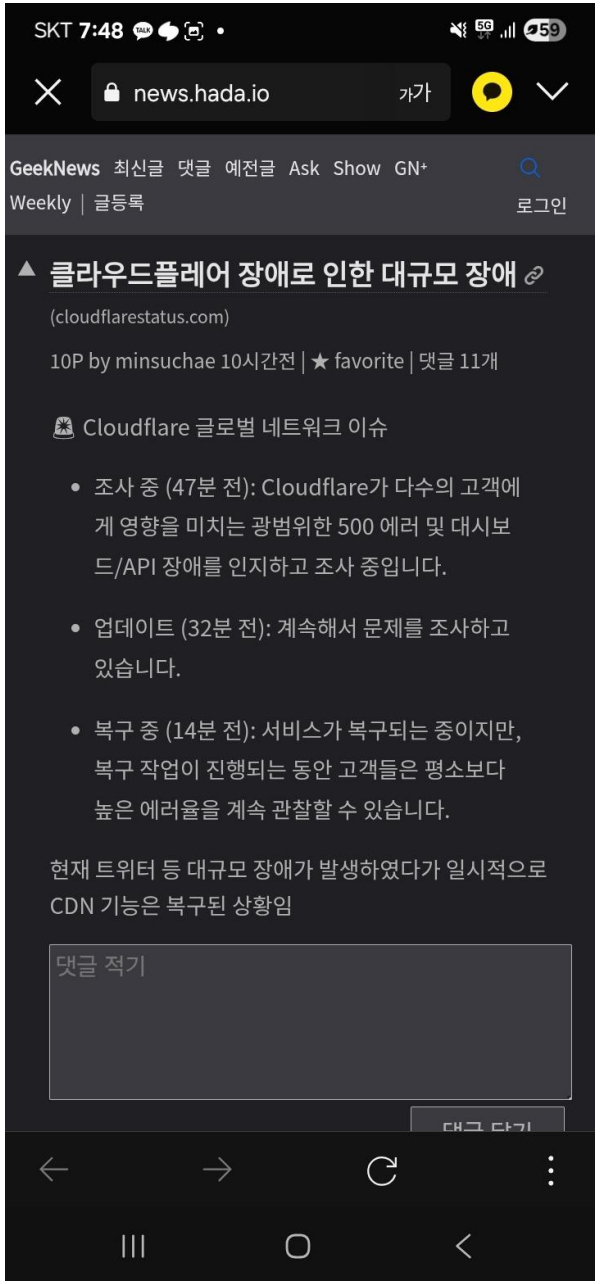
진행 중 - 현재 예정된 유지 관리가 진행 중입니다. 필요한 경우 업데이트를 제공해 드리겠습니다.
2025년 11 월 18일 - 10:00 UTC

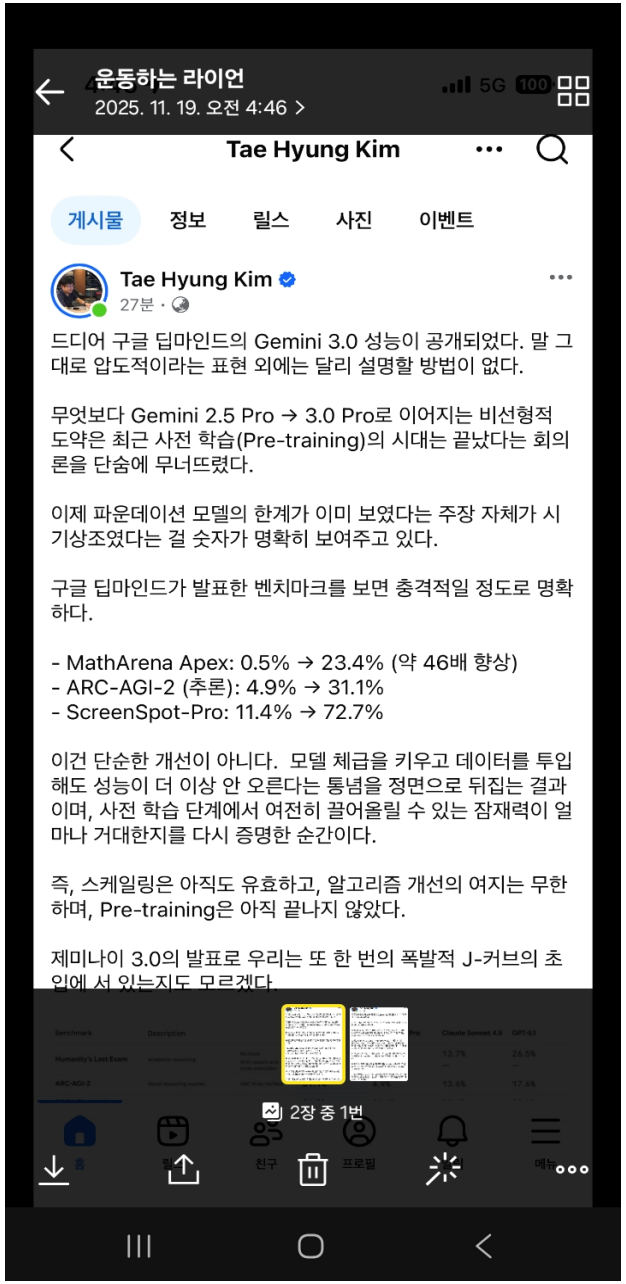
예정 - 2025년 11월 18일 오전 10시에서 오후 2시(UTC) 사이에 LAX(로스앤젤레스) 데이터 센터에서 예정된 유지 관리가 진행됩니다.

이 위치에서 트래픽이 재라우팅될 수 있으므로, 영향을 받는 지역의 최종 사용자는 유지 관리 기간 동안 지연 시간이 약간 증가할 수 있습니다. 이 위치에서 당사에 접속하는 PNI/CNI 고객의 경우, 이 데이터 센터의 네트워크 인터페이스를 일시적으로 사용할 수 없게 될 수 있으므로 유지 관리 기간 동안 트래픽이 다른 곳에서 장애 조치될 것으로 예상해야 합니다.

이제 Cloudflare 대시보드를 통해 이러한 알림을 구독하고 이메일, PagerDuty 및 웹훅(플랜에 따라 다름)을 통해 직접 업데이트를 받을 수 있습니다. https://developers.cloudflare.com/notifications/notification-available/#cloudflare-

서비스 장애


SKT 7:48
news.hada.io
가가
GeekNews 최신글 댓글 예전글 Ask Show GN+
Weekly | 글등록
로그인
클라우드플레어 장애로 인한 대규모 장애
(cloudflarestatus.com)
10P by minsuchae 10시간전 | ★ favorite | 댓글 11개
Cloudflare 글로벌 네트워크 이슈
조사 중 (47분 전): Cloudflare가 다수의 고객에게 영향을 미치는 광범위한 500 에러 및 대시보드/API 장애를 인지하고 조사 중입니다.
업데이트 (32분 전): 계속해서 문제를 조사하고 있습니다.
복구 중 (14분 전): 서비스가 복구되는 중이지만, 복구 작업이 진행되는 동안 고객들은 평소보다 높은 에러율을 계속 관찰할 수 있습니다.
현재 트위터 등 대규모 장애가 발생하였다가 일시적으로 CDN 기능은 복구된 상황임
댓글 적기


운동하는 라이언
2025. 11. 19. 오전 4:46
Tae Hyung Kim
게시물 정보 릴스 사진 이벤트
Tae Hyung Kim
27분 ·
드디어 구글 딥마인드의 Gemini 3.0 성능이 공개되었다. 말 그대로 압도적이라는 표현 외에는 달리 설명할 방법이 없다.
무엇보다 Gemini 2.5 Pro → 3.0 Pro로 이어지는 비선형적 도약은 최근 사전 학습(Pre-training)의 시대는 끝났다는 회의론을 단숨에 무너뜨렸다.
이제 파운데이션 모델의 한계가 이미 보였다는 주장 자체가 시기상조였다는 걸 숫자가 명확히 보여주고 있다.
구글 딥마인드가 발표한 벤치마크를 보면 충격적일 정도로 명확하다.
- MathArena Apex: 0.5% → 23.4% (약 46배 향상)
- ARC-AGI-2 (추론): 4.9% → 31.1%
- ScreenSpot-Pro: 11.4% → 72.7%
이건 단순한 개선이 아니다. 모델 체급을 키우고 데이터를 투입해도 성능이 더 이상 안 오른다는 통념을 정면으로 뒤집는 결과이며, 사전 학습 단계에서 여전히 끌어올릴 수 있는 잠재력이 얼마나 거대한지를 다시 증명한 순간이다.
즉, 스케일링은 아직도 유효하고, 알고리즘 개선의 여지는 무한하며, Pre-training은 아직 끝나지 않았다.
제미나이 3.0의 발표로 우리는 또 한 번의 폭발적 J-커브의 초입에 서 있는지도 모르겠다.
2장 중 1번

3개의 모델

2026-03-10 기준으로 보면, 각사 최신 상위 모델은 **OpenAI GPT-5.4**, **Anthropic Claude Opus 4.6**, **Google Gemini 3.1 Pro**입니다. OpenAI는 GPT-5.4 Thinking을 GPT-5 계열의 최신 reasoning 모델로 소개했고, Anthropic은 Opus 4.6을 가장 복잡한 작업용 최신 세대로, Google은 Gemini 3.1 Pro를 복잡한 작업을 위한 자사 최상위 모델로 설명합니다. OpenAI +2

1) 최신 플래그십 기준 비교

항목	GPT	Claude	Gemini
최신 대표 모델	GPT-5.4 Thinking / Pro OpenAI	Claude Opus 4.6 Claude API Docs +1	Gemini 3.1 Pro Google DeepMi... +1
공식 포지셔닝	전문 지식업무·코딩·에이전트 워크플로 통합형 프런티어 모델 OpenAI	복잡한 작업용 최신 세대, 코딩·추론 강점 Claude API Docs +1	복잡한 작업용 Google 최상위 모델 Google DeepMi...
최대 컨텍스트(공식 표기)	ChatGPT Thinking 256K, Pro 400K, Codex 실험적 1M OpenAI Help C... +1	1M beta Anthropic +1	up to 1M Google DeepMi...

2) 최신 모델 기준 핵심 벤치마크

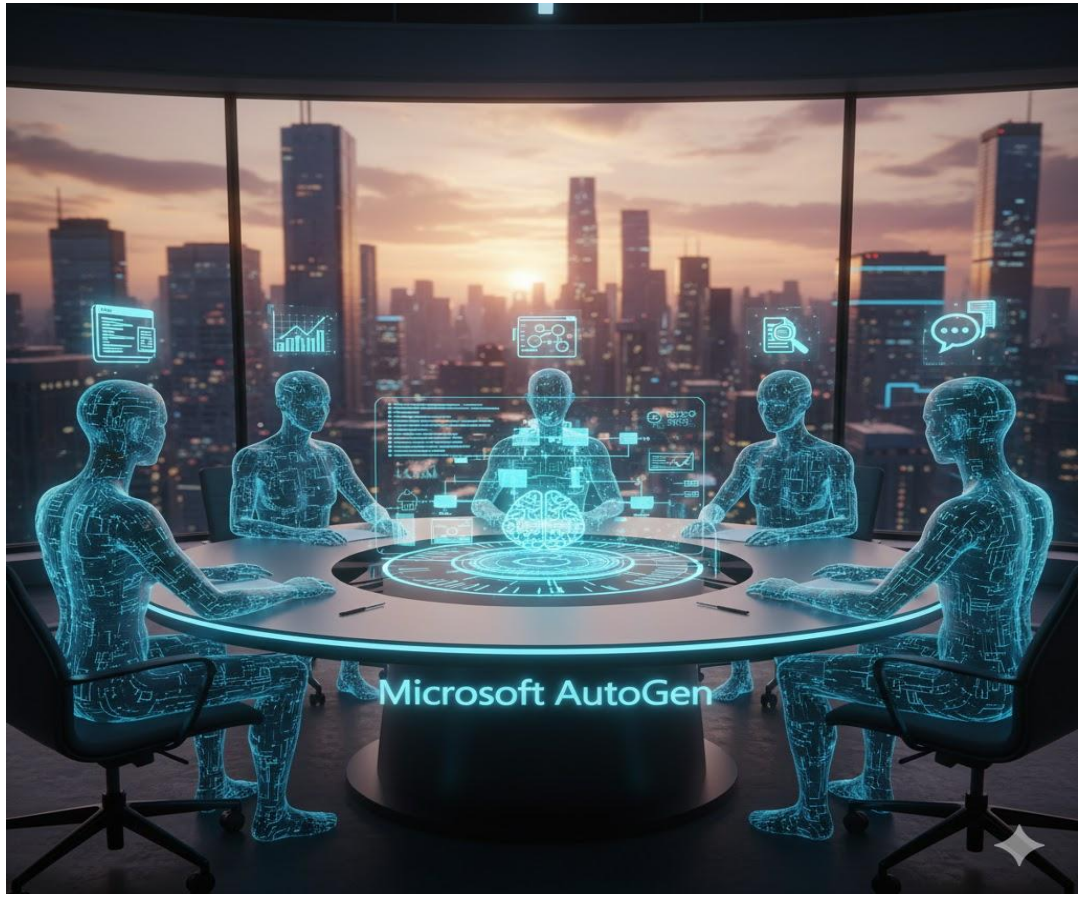
벤치마크	GPT-5.4	Claude Opus 4.6	Gemini 3.1 Pro
GPQA Diamond	92.8% OpenAI	91.3% Google DeepMi...	**94.3%** Google DeepMi...
Humanity's Last Exam (no tools)	39.8% OpenAI	40.0% Google DeepMi...	**44.4%** Google DeepMi...
ARC-AGI-2 (Verified)	73.3% OpenAI	68.8% Google DeepMi...	**77.1%** Google DeepMi...
MMMU-Pro (no tools)	**81.2%** OpenAI	73.9% Google DeepMi...	80.5% Google DeepMi...
Terminal-Bench 2.0	**75.1%** OpenAI	65.4% Google DeepMi...	68.5% Google DeepMi...
OSWorld-Verified	**75.0%** OpenAI	72.7% Anthropic	공개 비교치 확인 못함

Microsoft AutoGen(멀티 에이전트 조율)

- 멀티 에이전트 AI 프레임워크로, 여러 AI Agent가 역할을 나눠 협업하여 자동으로 문제를 해결하는 구조

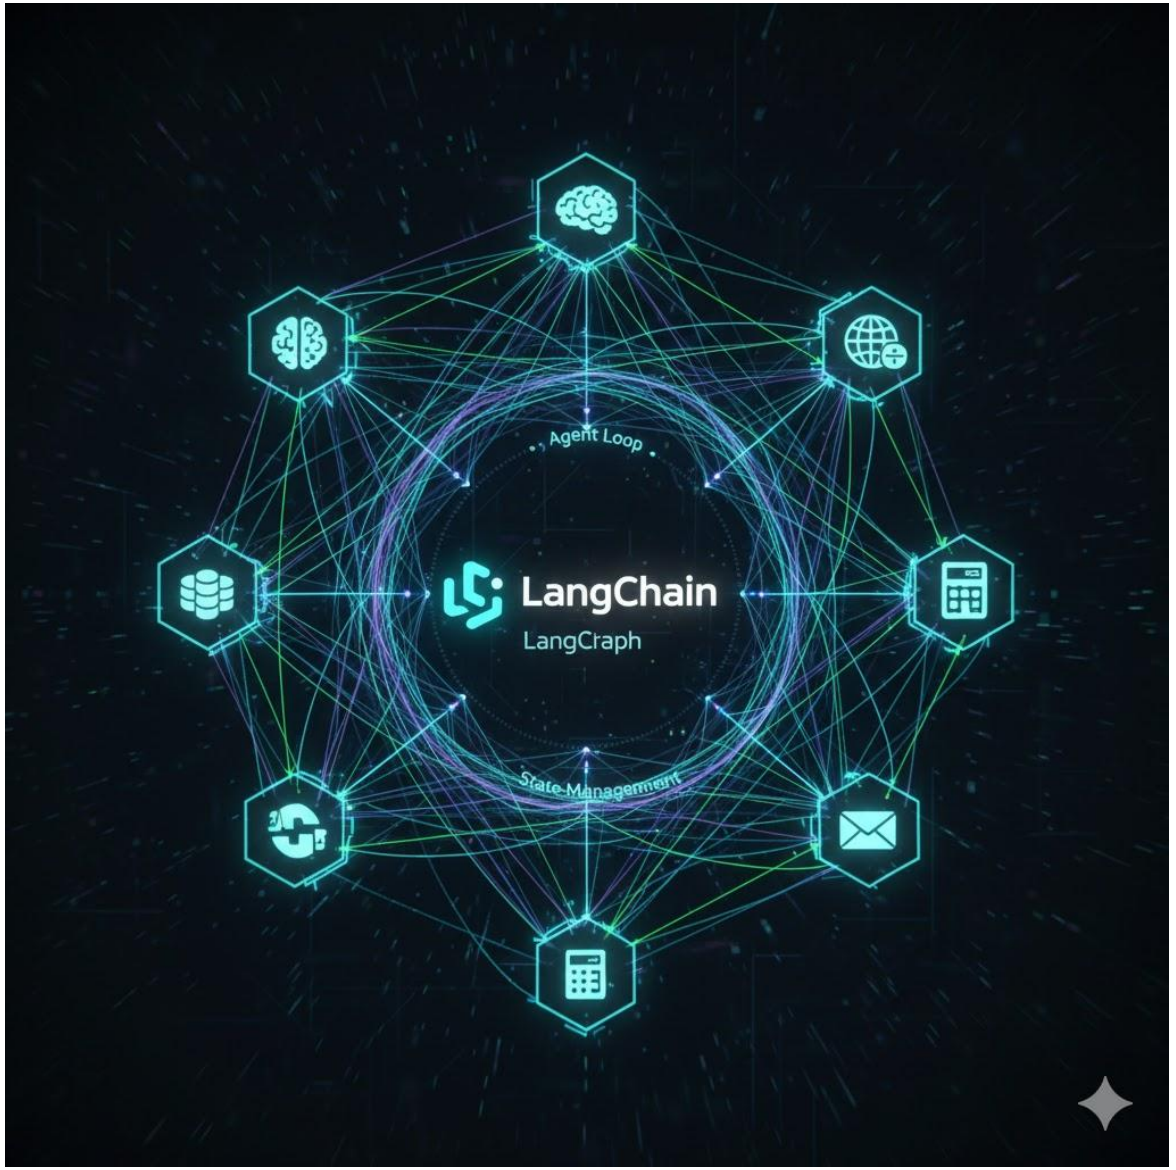
  - '코더', '리뷰어'등 역할을 부여하고 에이전트끼리 대화하며 문제 해결.

- 사람 - AI 유기적 협업 : 필요 시 사람에게 질문하며 막힘없이 작업 진행
- 강력한 코드 실행 : 복잡한 코딩 및 데이터 분석 작업에 특화
- <추천대상> 복잡한 워크플로우를 자동화하려는 기업 개발팀, 데이터 과학자



LangChain / LangGraph(개발 표준)

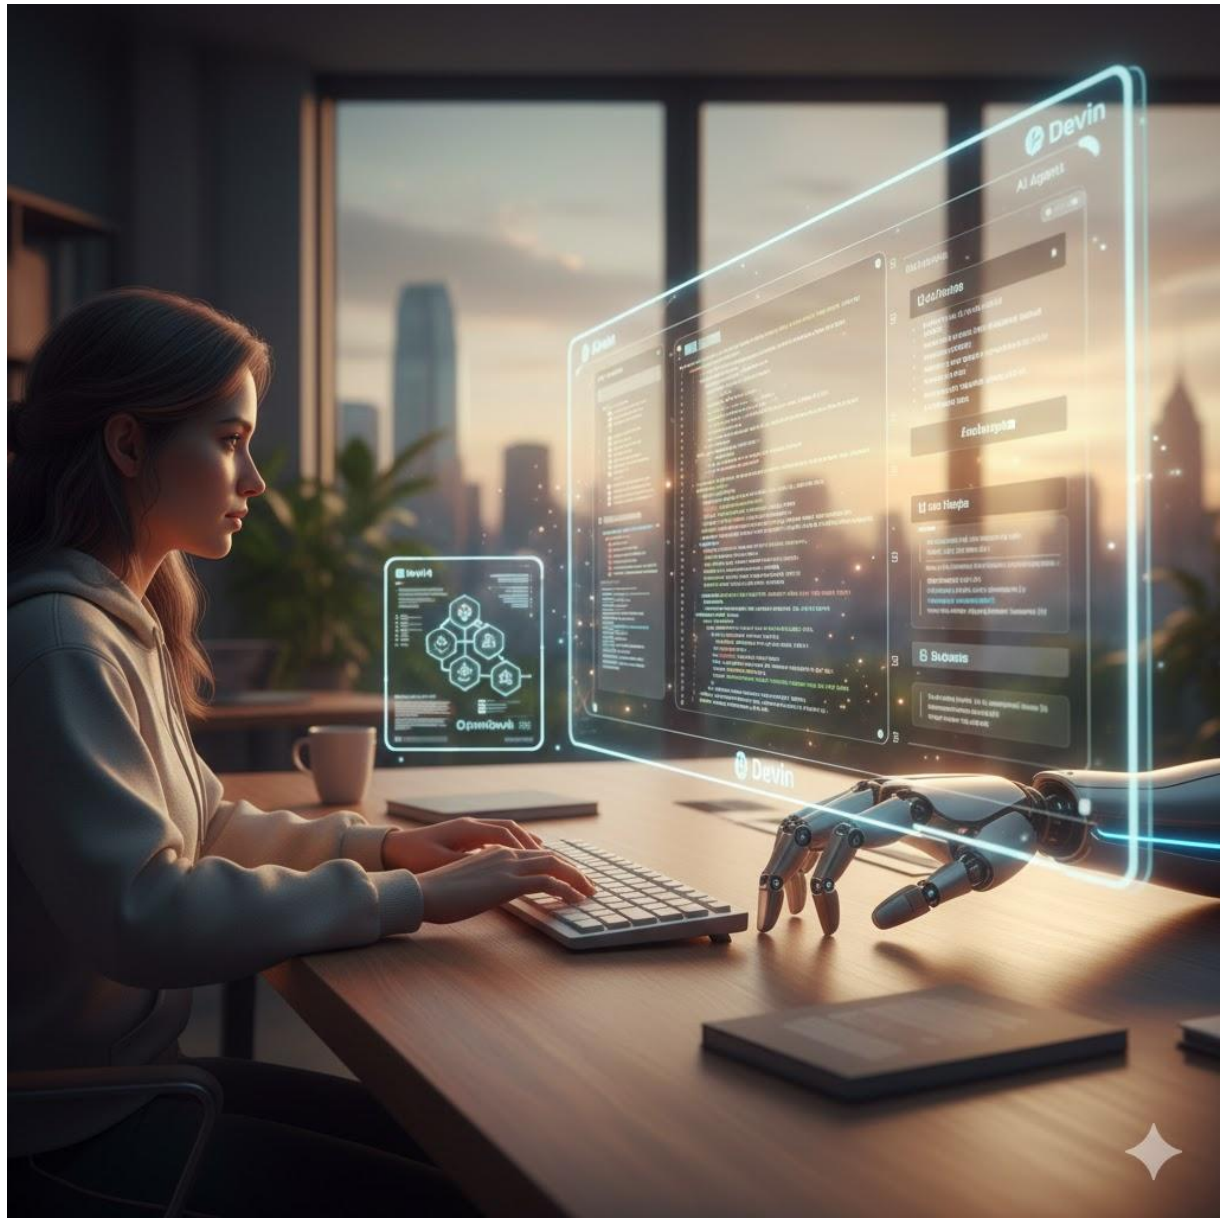
- 방대한 생태계 : 모든 LLM, DB, 외부 도구와 연결 가능한 컴포넌트 제공
- LangChain은 LLM 애플리케이션을 체계적으로 구성하기 위한 표준 프레임워크.
- LangGraph는 그 위에서 상태 기반(Stateful) 에이전트 그래프를 구성해 복잡한 워크플로우를 안정적으로 실행
- <추천 대상> 자체 AI 애플리케이션을 구축하고 모든 것을 제어하려는 AI 엔지니어, 연구팀



Devin & 대안들 (자율형 AI 직원의 미래)

- 완전 자율성 : 계획, 코딩, 디버깅, 배포까지 스스로 수행하는 AI 엔지니어
- 장기 기억 및 학습 : 프로젝트 맥락을 이해하고 과거의 실수로부터 학습 가능.
- 시사점 : 미래 업무는 “사람”과 “AI 에이전트 직원”의 협업 형태로 진화

- <참고> 아직 초기 단계이며 OpenDevin 등 오픈소스 대안들이 등장 중.



Genspark(개인화된 AI 검색/비서)

- 차세대 AI 검색 : 단순 정보 제공을 넘어 사용자 의도를 깊이 이해
- 개인화된 요약 제공 : 여러 소스를 종합하여 맞춤형으로 간결하게 정보 정리
- 맥락 유지 대화 : 비서처럼 이전 질문 맥락을 기억하고 대화를 이어감
- <추천 대상> 개인화된 정보 큐레이션과 효율적인 검색 경험을 원하는 일반 사용자, 연구자



Skywork(생성형 AI를 위한 데이터 플랫폼)

- 데이터 품질 극대화 : 생성형 AI 모델 성능을 위한 고품질 데이터셋 구축.
- 파이프라인 자동화 : 데이터 수집, 정제, 라벨링, 모델 통합 과정 최적화
- 비정형 데이터 처리 : 텍스트, 이미지, 오디오 등 다양한 형태의 데이터 처리 지원
- <추천 대상> 생성형 AI 모델을 개발 및 학습시키는 AI 연구기관, 기업의 AI 개발팀



핵심문제 : “개발자 공급 절벽”

- **폭발적인 앱 수요:** 향후 5년 내 5억 개의 새로운 앱이 필요할 것으로 예상됩니다. (지난 40년간 개발된 총량보다 많음)
- **만성적인 인력 부족:** 숙련된 개발자 채용은 하늘의 별 따기이며, 인건비는 지속적으로 상승하고 있습니다.
- **느린 개발 속도:** 전통적인 코딩 방식으로는 급변하는 비즈니스 요구사항을 따라잡기에 한계가 있습니다.



해결책: 노코드(No-Code)와 로코드(Low-Code)

No-Code (노코드)

대상: 현업 비즈니스 실무자 (마케터, HR 등)

특징: 코딩 지식 0% 필요. 드래그 앤 드롭 방식의 시각적 인터페이스 사용.

목표: 아이디어를 즉시 앱으로 구현하여 업무 효율성 증대.

Low-Code (로코드)

대상: 전문 개발자 및 파워 유저

특징: 최소한의 코딩으로 복잡한 기능을 구현. 반복 작업을 자동화.

목표: 개발 속도를 극대화하고 유지보수 비용 절감.

가속화 요인 1: 압도적인 속도(Velocity)

기존 개발 방식 대비 10배 더 빠른 속도를 자랑합니다.

수개월이 걸리던 프로젝트를 단 며칠 만에 런칭할 수 있습니다.

- **즉각적인 배포:** 아이디어 구상에서 실행까지 Time-to-Market 최소화
- **빠른 수정 및 반복:** 피드백을 실시간으로 반영하여 제품 개선
- **자동화된 인프라:** 서버 설정, 보안 등 복잡한 백엔드 작업 생략



가속화 요인 2: 개발의 대중화(Access)



'시티즌 디벨로퍼'의 부상

이제 누구나 개발자가 될 수 있습니다. IT 부서에 의존하지 않고 현업 담당자가 직접 문제를 해결하는 도구를 만듭니다.

- **IT 병목 현상 해소**: 단순 반복 업무 앱은 현업에서 직접 해결
- **다양성 확보**: 다양한 직군의 관점이 반영된 창의적 솔루션 탄생
- **협업 강화**: 비즈니스팀과 IT팀 간의 간극 축소

가속화 요인 3: 본질에 집중(Focus)

"The future of coding is no coding at all."

— Chris Wanstrath, CEO of GitHub

기술적 구현(How)의 장벽이 무너지고,

무엇을 해결할 것인가(What)에 집중하는 시대입니다.

개발 방식 비교: 전통적 방식 VS 노코드

구분	전통적 개발 (Traditional)	노코드/로코드 (No/Low-Code)
개발 속도	느림 (수개월 ~ 수년)	매우 빠름 (수일 ~ 수주)
필요 기술	전문 코딩 지식 (Java, Python 등)	비즈니스 로직 이해, 시각적 도구 활용
비용	높음 (인건비, 인프라 비용)	낮음 (구독형, 유지보수 용이)
주체	전문 개발자	시티즌 디벨로퍼 (현업 실무자)

미래 전망



70%

신규 앱 개발 비중

2025년까지 기업에서 개발되는 신규 앱의 70%가 노코드/로코드 기술을 사용할 것입니다. (Gartner)



$187B

시장 규모 (2030)

전 세계 노코드/로코드 시장은 2030년까지 약 1,870억 달러 규모로 폭발적인 성장을 할 것입니다.



4 : 1

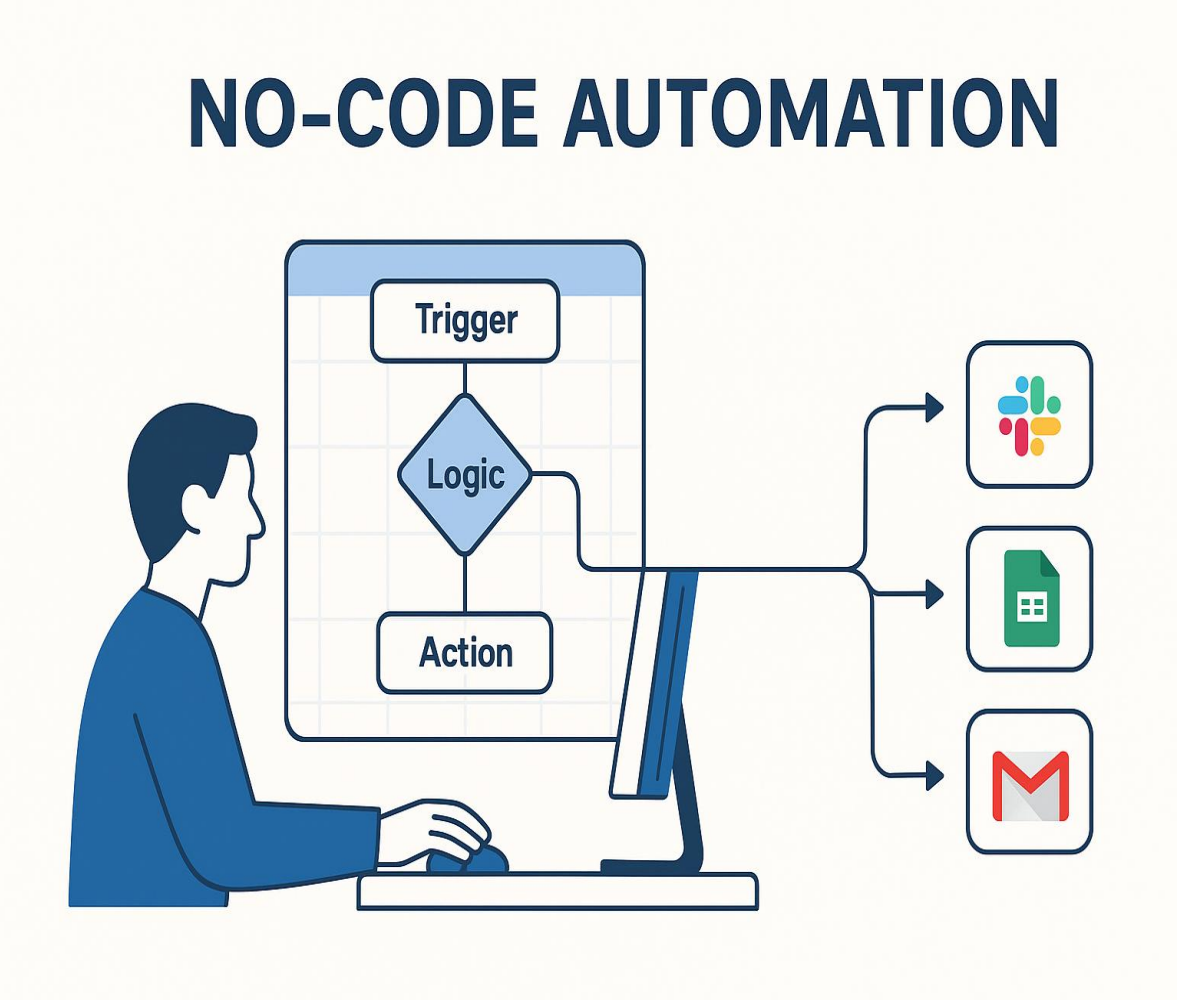
개발자 비율

대기업 내에서 시티즌 디벨로퍼의 수가 전문 개발자보다 4배 더 많아질 것입니다.

No-Code Automation

- 반복 업무 자동화를 통해 개발 리소스 부족 문제를 해결하는 핵심 기술

- 코딩 없이 **드래그 앤 드롭 방식**으로 자동화 워크플로우를 구축하는 기술
- “메일 발송, 로그 정리, 승인 요청, DB 업데이트 등 반복적인 오퍼레이션 업무의 30~50%를 자동화 가능
- Trigger: 자동화를 시작시키는 신호(예. 제출 폼, 스케줄, 웹 훅)
- Logic : 조건을 판단하고, 데이터를 분기(If, loop, Filtering)
- Action : 실제 실행(메일 전송, DB Write, Slack 알림, API Call)



No-Code Automation: 4대 핵심 가치



1. 초고속 구축 (Speed)

복잡한 코딩 과정 없이, 아이디어를 즉시 실행 가능한 워크플로우로 전환합니다. 개발 기간을 몇 주에서 몇 분으로 단축시킵니다.



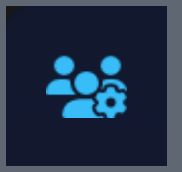
2. 무한 연결 (Connectivity)

이메일, 슬랙, 엑셀 등 서로 다른 수천 개의 앱(SaaS)을 레고 블록처럼 자유롭게 연결하여 데이터 사일로를 제거합니다.



3. 업무 효율 (Efficiency)

단순 반복 업무를 24시간 365일 자동화하여, 사람은 더 창의적이고 전략적인 고부가가치 업무에 집중할 수 있게 합니다.



4. 역량 강화 (Empowerment)

'시티즌 디벨로퍼'의 시대. 개발자가 아니더라도 현업 실무자가 직접 자신의 문제를 기술로 해결하는 힘을 갖게 됩니다.

- SaaS(Software as a Service): “인터넷을 통해 바로 사용하는 구독형 소프트웨어 서비스”

2026 AI Coding Assistant Landscape

STRATEGY & TRENDS

마지막 업데이트: 2026년 03월 06일



DeepSeek-V3

DISRUPTIVE EFFICIENCY

- 극강의 가성비 모델
  타 모델 대비 1/10 수준의 비용으로 SOTA급 코딩 성능 제공
- MoE 아키텍처 혁신
  Multi-head Latent Attention 기술로 추론 속도 및 정확도 극대화
- 오픈소스 생태계 장악
  강력한 성능의 오픈 모델로 스타트업 및 개발자 커뮤니티 급속 전파



GPT-5.4(ChatGPT)

THE PROFESSIONAL WORK ENGINE

- 실무형 결과물 생성 향상
  문서, 스트레드시트, 발표자료처럼 실제 업무 산출물을 더 정교하고 완성도 높게 생성, 편집
- 정확성과 일관성 향상
  GPT-5.2 대비 사실 오류를 줄이고, 긴 작업에서도 더 정돈된 결과
- 에이전트형 워크플로우 진화
  검색, 도구 사용, 컴퓨터 조작까지 연결해 여러 단계를 거치는 작업을 더 안정적으로 수행



Gemini 3 & Nano

CONTEXT & EDGE MASTER

- 1M 컨텍스트(모델/플랜에 따라 상이)
  전체 모노레포를 한 번에 분석하는 압도적인 맥락 파악 능력
- Nano Banana 2 업데이트
  Nano Banana 기능 유지하면서 속도 개선
- 하이브리드 인텔리전스
  로컬 가속 기술과 클라우드 추론의 완벽한 조화로 안정성 확보



Cursor IDE

AI-NATIVE STANDARD

- Composer 모드 혁신
  다중 파일을 동시에 수정하는 독보적인 생산성 인터페이스
- 지능형 코드 인덱싱
  로컬 코드베이스를 완벽히 이해하는 맞춤형 코드 제안 시스템
- 모델 유연성 확보
  DeepSeek, GPT 등 최신 모델을 하나의 IDE에서 자유롭게 전환 활용

2026 전략 요약: 단순 보조에서 자율적 시스템 구축(Autonomous Agent)으로의 패러다임 전환

2026 AI Coding Assistant Landscape

STRATEGY & TRENDS

마지막 업데이트: 2026년 03월 06일

Claude Opus 4.6

ARTIFACTS & REASONING

- **코딩 아티팩트(Artifacts)**
  코드 생성과 동시에 즉시 실행 및 시각적 결과물 확인(UI/UX 최적화)
- **고난도 추론 능력**
  정교한 문맥 파악과 자연스러운 대화로 복잡한 아키텍처 설계 지원
- **대규모 코드베이스 작업**
  대규모 코드 베이스에 대한 깊은 이해와 정밀한 리팩토링 능력 제공

Grok 3

REAL-TIME INTELLIGENCE

- **실시간 검색 통합**
  X(트위터) 플랫폼의 실시간 데이터를 기반으로 한 최신 트렌드 즉각 반영
- **대규모 학습 인프라 기반 성능**
  초거대 GPU 클러스터를 통한 빠른 추론 속도 및 대규모 연산 처리
- **DeepSearch/Think**
  (추론 모드, 정보 합성)
  필터링을 최소화한 실용적이고 직관적인 기술 솔루션 제시

GitHub Copilot

IDE STANDARD

- **네이티브 워크플로우 통합**
  VS Code, GitHub와 완벽히 연결된 에디터-PR 통합 개발 경험
- **에이전트 중심 개발**
  이슈 분석부터 코드 구현, 테스트까지 자동화하는 '에이전트 모드' 강화
- **엔터프라이즈 보안**
  기업용 보안 및 라이선스 컴플라이언스 관리 최적화 솔루션

Perplexity Pro

SEARCH TO SOLUTION

- **근거 기반 기술 검색**
  최신 기술 문서, Stack Overflow 등 출처가 명확한 솔루션 제공
- **AI 기반 리서치 엔진**
  단순 질문을 넘어 문제의 본질을 파고드는 단계별 Pro Search 기능
- **Pages & Discovery**
  검색 결과를 기반으로 즉시 기술 블로그나 보고서를 생성하는 생산성 도구

2026 전략 인사이트: 단순 코드 생성을 넘어 현장 적용(Artifacts)과 실시간성(Real-time)이 핵심 차별점

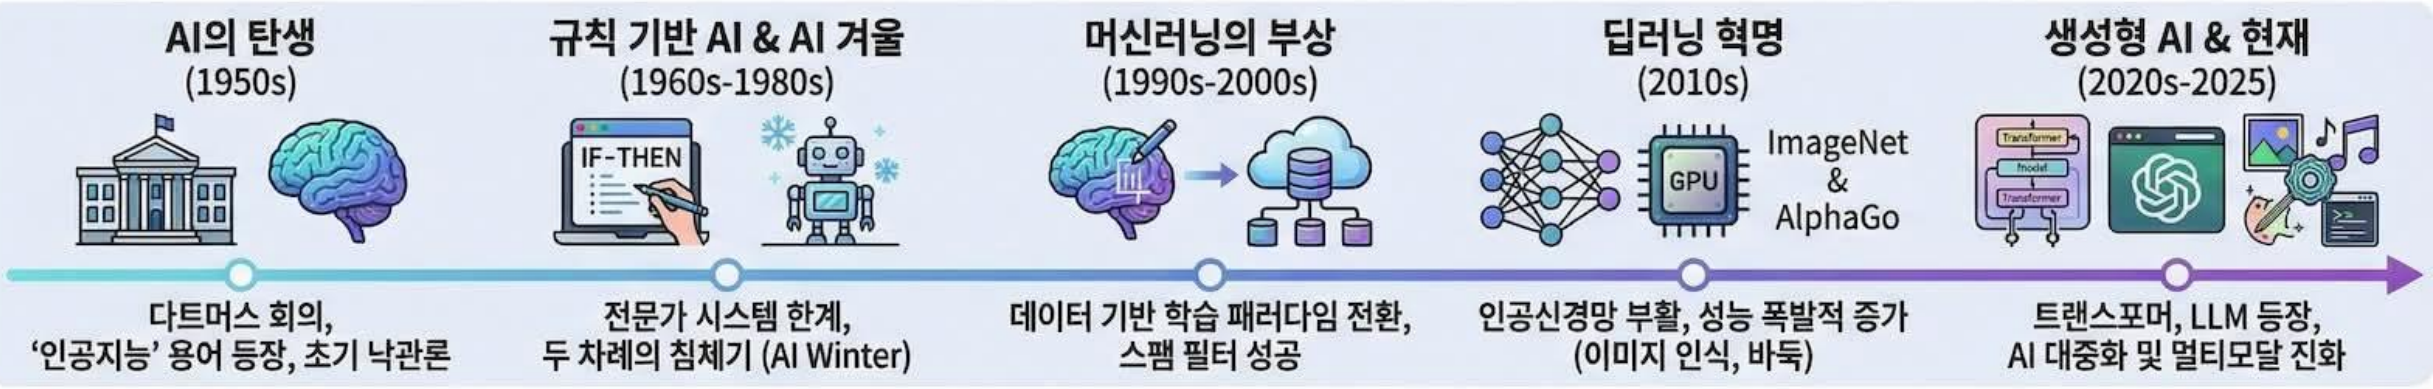
LLM Architeture Gallery

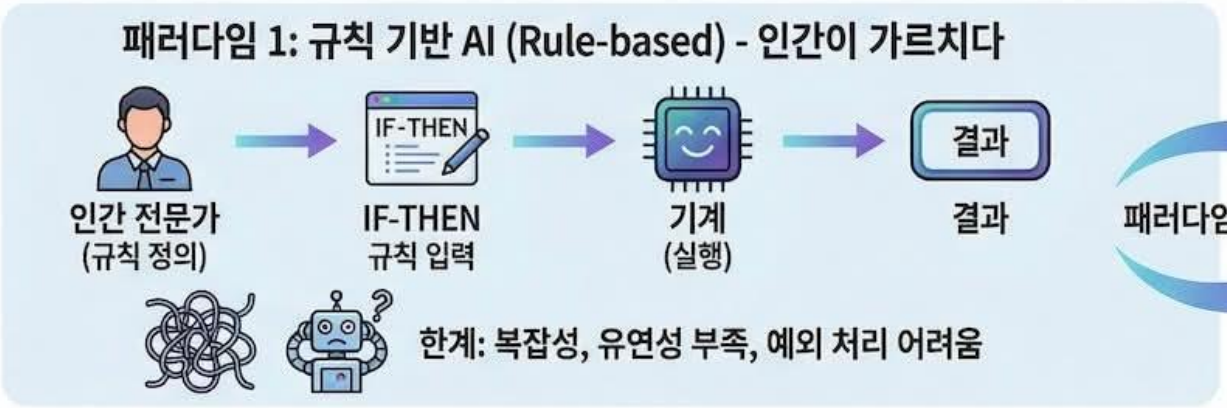
2026.03.17



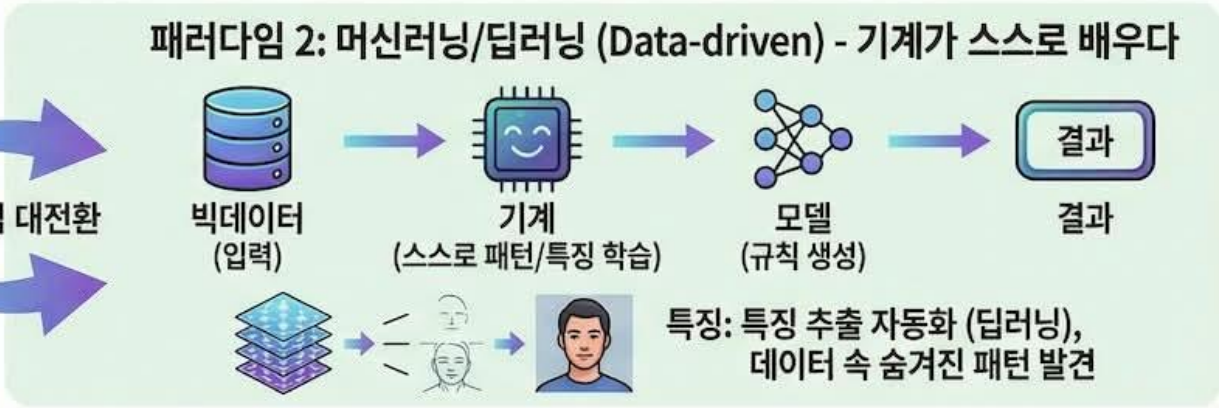
https://sebastianraschka.com/llm-architecture-gallery/

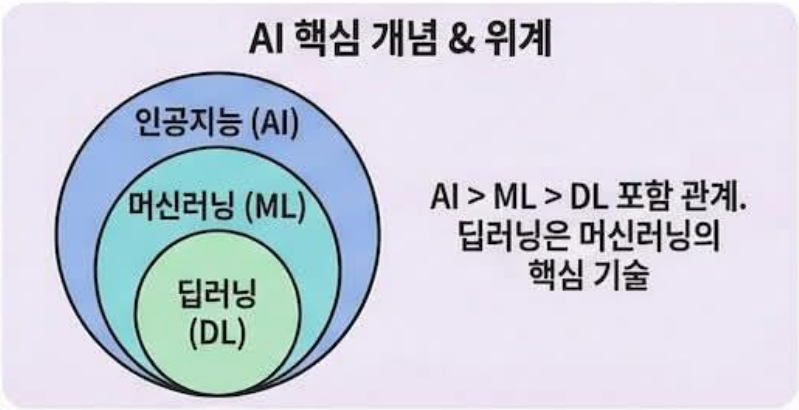
Google Gemini

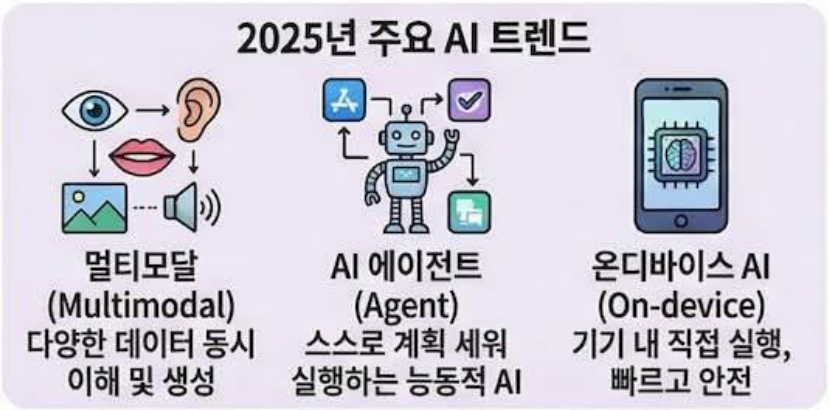




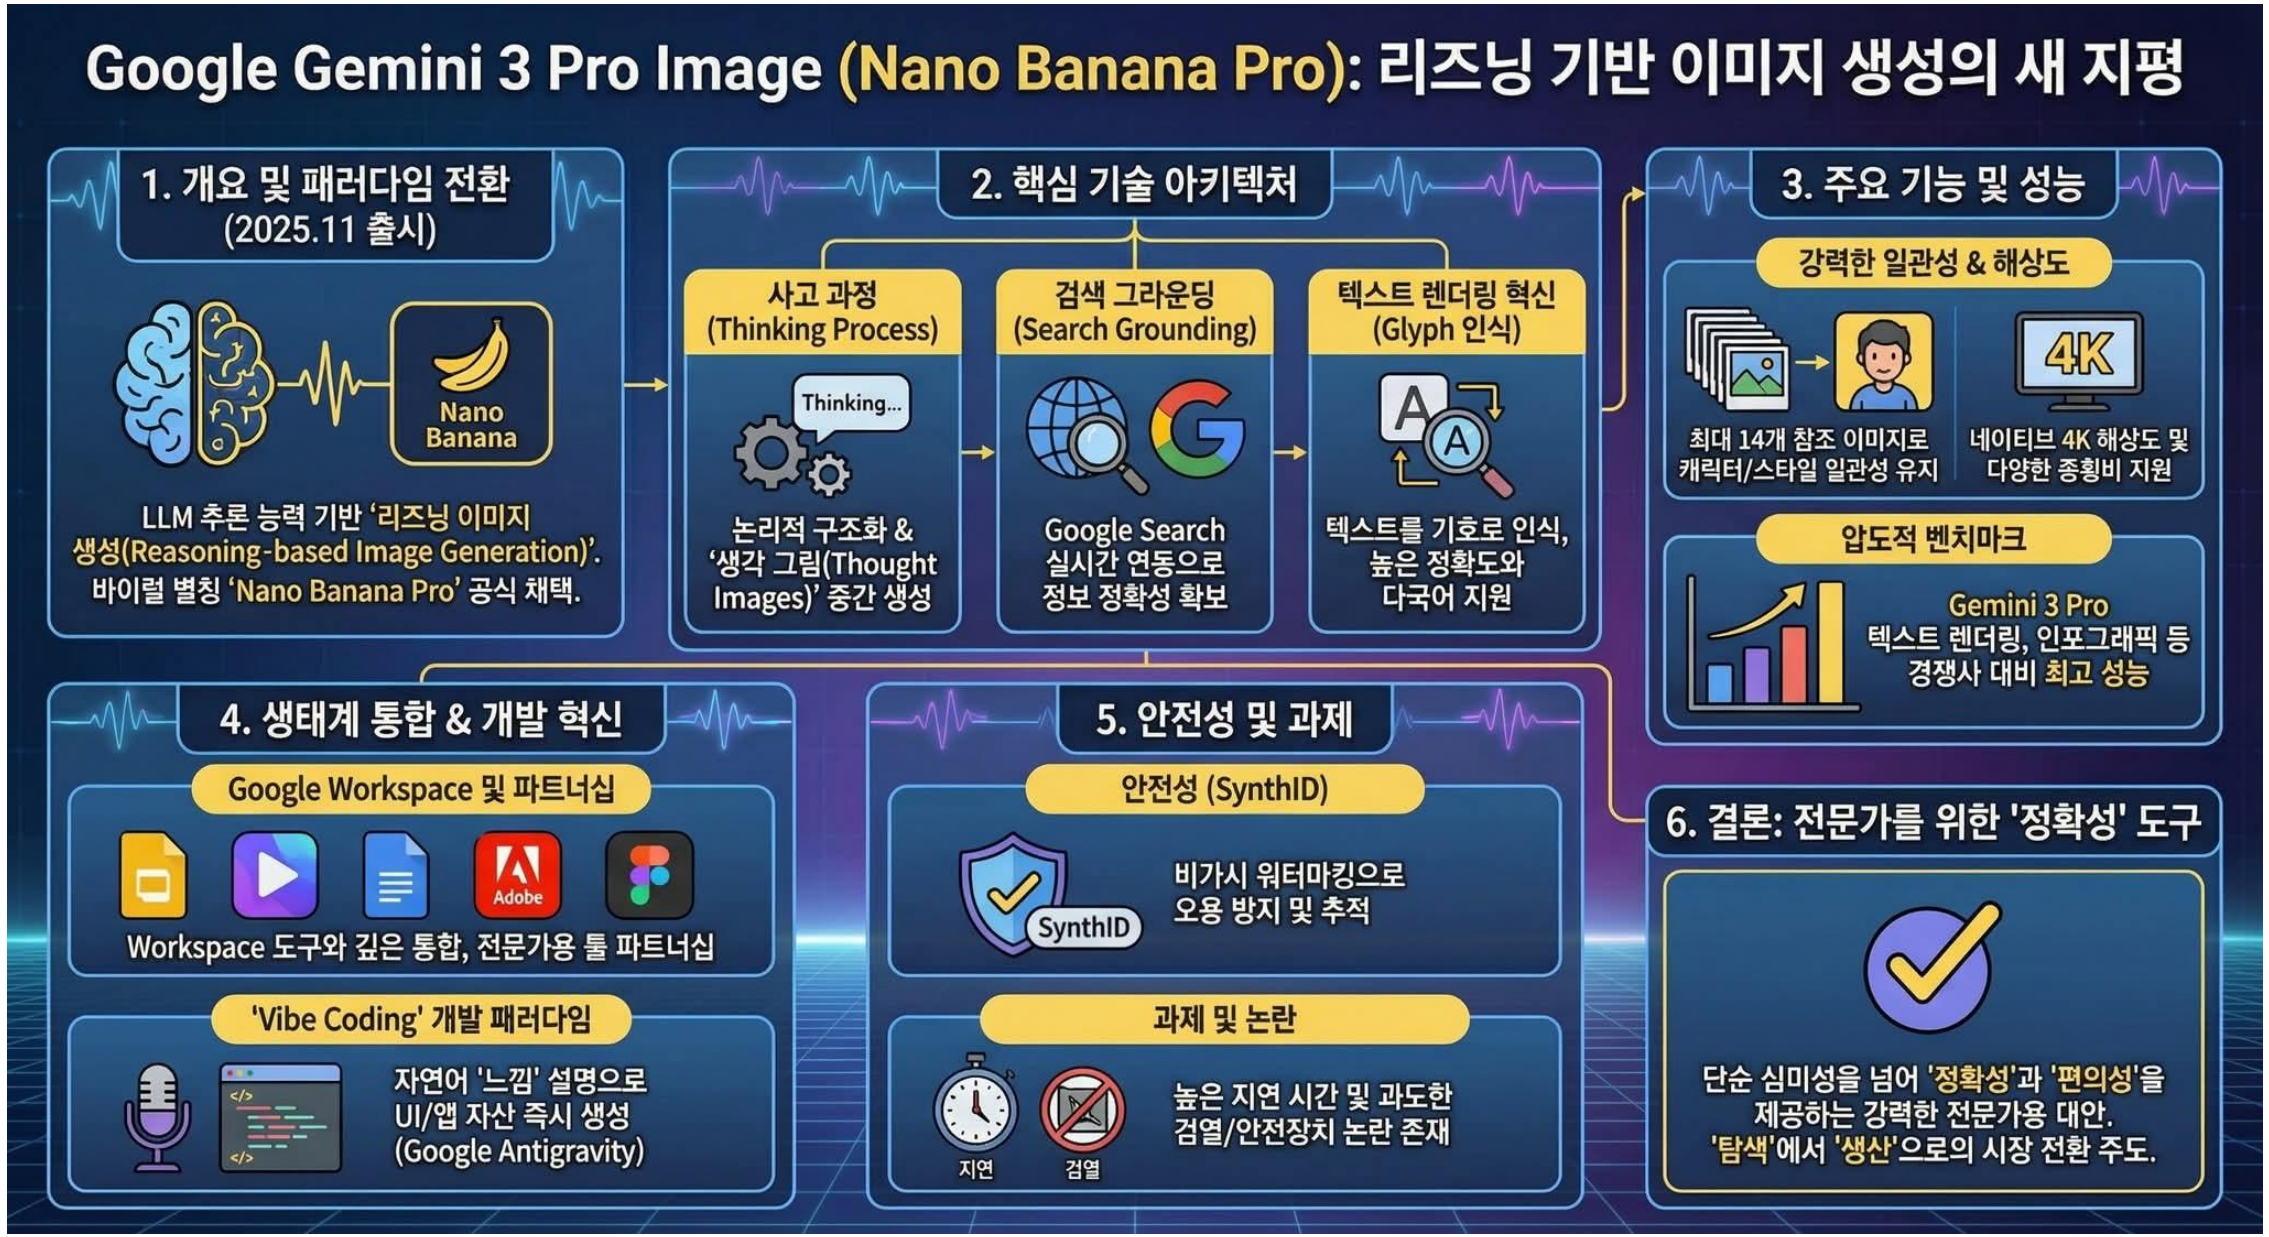
패러다임 대전환










Google Gemini 3 Pro Image (Nano Banana Pro): 리즈닝 기반 이미지 생성의 새 지평
1. 개요 및 패러다임 전환 (2025.11 출시)
Nano Banana
LLM 추론 능력 기반 '리즈닝 이미지 생성(Reasoning-based Image Generation)'. 바이럴 별칭 'Nano Banana Pro' 공식 채택.
2. 핵심 기술 아키텍처
사고 과정 (Thinking Process)
Thinking...
논리적 구조화 & '생각 그림(Thought Images)' 중간 생성
검색 그라운딩 (Search Grounding)
Google Search 실시간 연동으로 정보 정확성 확보
텍스트 렌더링 혁신 (Glyph 인식)
텍스트를 기호로 인식, 높은 정확도와 다국어 지원
3. 주요 기능 및 성능
강력한 일관성 & 해상도
최대 14개 참조 이미지로 캐릭터/스타일 일관성 유지
4K
네이티브 4K 해상도 및 다양한 종횡비 지원
압도적 벤치마크
Gemini 3 Pro
텍스트 렌더링, 인포그래픽 등 경쟁사 대비 최고 성능
4. 생태계 통합 & 개발 혁신
Google Workspace 및 파트너십
Adobe
Workspace 도구와 깊은 통합, 전문가용 툴 파트너십
'Vibe Coding' 개발 패러다임
자연어 '느낌' 설명으로 UI/앱 자산 즉시 생성 (Google Antigravity)
5. 안전성 및 과제
안전성 (SynthID)
SynthID
비가시 워터마킹으로 오용 방지 및 추적
과제 및 논란
지연
검열
높은 지연 시간 및 과도한 검열/안전장치 논란 존재
6. 결론: 전문가를 위한 '정확성' 도구
단순 심미성을 넘어 '정확성'과 '편의성'을 제공하는 강력한 전문가용 대안.
'탐색'에서 '생산'으로의 시장 전환 주도.

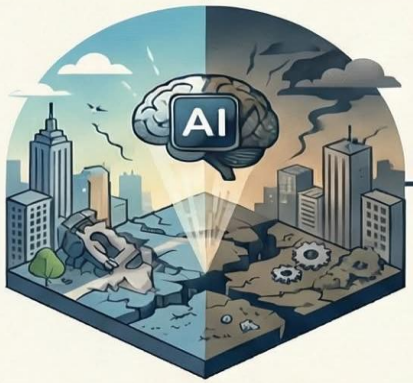
AI의 다음 시대: 스케일링을 넘어 연구의 시대로

1. 현재 AI의 역설: 기대와 현실의 불일치



뛰어난 평가 점수, 하지만...

한에 AI 포댈들은 아라운 엔치바크에서는 조인적인 청눈을 촤이며 기븝작 가능청을 증평하고 있습니다.



...실망스러운 실제 영향력

하지안 그 성농에 비해 실제 세계에서의 유용성이나 평제적 과급력은 아믹 가대에 마지지 못하는 상활입니다.



불일치의 원인: 과잎 최적화

이는 실제 세계의 복잡성을 반엉하저 문하고, 특접 첨가(ovals) 정수를 높이는 데테인 지나이게 최력회린 든면 방싸 때문일 수 있습니다.

2. AI 개발 패러다임의 전환



1단계: 연구의 시대
(2012-2020)

소규모 컴퓨밉으로 알해스녕, 트랜스포아 둥 AI리 근간이 되는 혁신적민 아이티아가 탄생했단 시기딥니다.



2단계: 소케밀뭥의 시대
(2030-2025)

'스케밀뭥 밥학'의 발견으로, 데이터와 컴동학 자원을 눌리는 것이 상능 함성의 획림한 금식이 되었습니다.



3단계: 다시, 연구의 시대
(편체~)

스케일뭥반으로는 한계에 도달했습니다. 이쳬 거대본 회옥립 자림을 머랑으로 근분적인 폳제를 록찝합 세조운 아이티아가 뭘요반 시점입니다.

3. 핵심 과제: 인간 수준의 '일반화' 능력 확보

AI의 가장 근분적인 문제

현제 AI 모댈들은 인간에 비해 세로운 상함에 대와하는 '일민화' 능륵터 국직으로 엘어딥니다.





인간 학습 vs. AI 학습

인간은 직은 정청으로도 깅이 배우고 스스로 고청하지인...

AI 학습

...AI는 빙대한 데이터를 융현 패반 왐기에 의문하는 장향이 있습니다.



'과잉 촌권된 학생' 비유

현제 AI는 특정 시험을 위해 모든 문제와 담을 암기한 익정과 갑습니다. 정의적이고 나제다능한 학생하는 거리가 맙니다.

4. 미래를 향한 비전: 진정한 초지능의 모습



'판상줌'이 아닌 '지속적 학습자'

피레의 초지능은 모든 검묠 이는 쥰레가 아니라, 어빈 딤이든 인간적협 배르계 해을 수 있는 농력을 갖운 쯘테일 것입니다.

짐진적 배포와 사회적 준비

AI띄 믹간한 륄을 고너할 때, 사희가 적풍하고 안친캄을 검융함 수 있도록 정킨직모로 기숨을 새장해 공개하는 것이 중묘합니다.





긍극작인 목표: 지각 있는 생명제에 대한 배려

AI가 언천하기 위해서는 인긴쁜만 아니라, AI 자신을 모힙한 모든 '지각 있는 생명제'를 존공하고 배려하도륵 설개히야 수 있습니다.

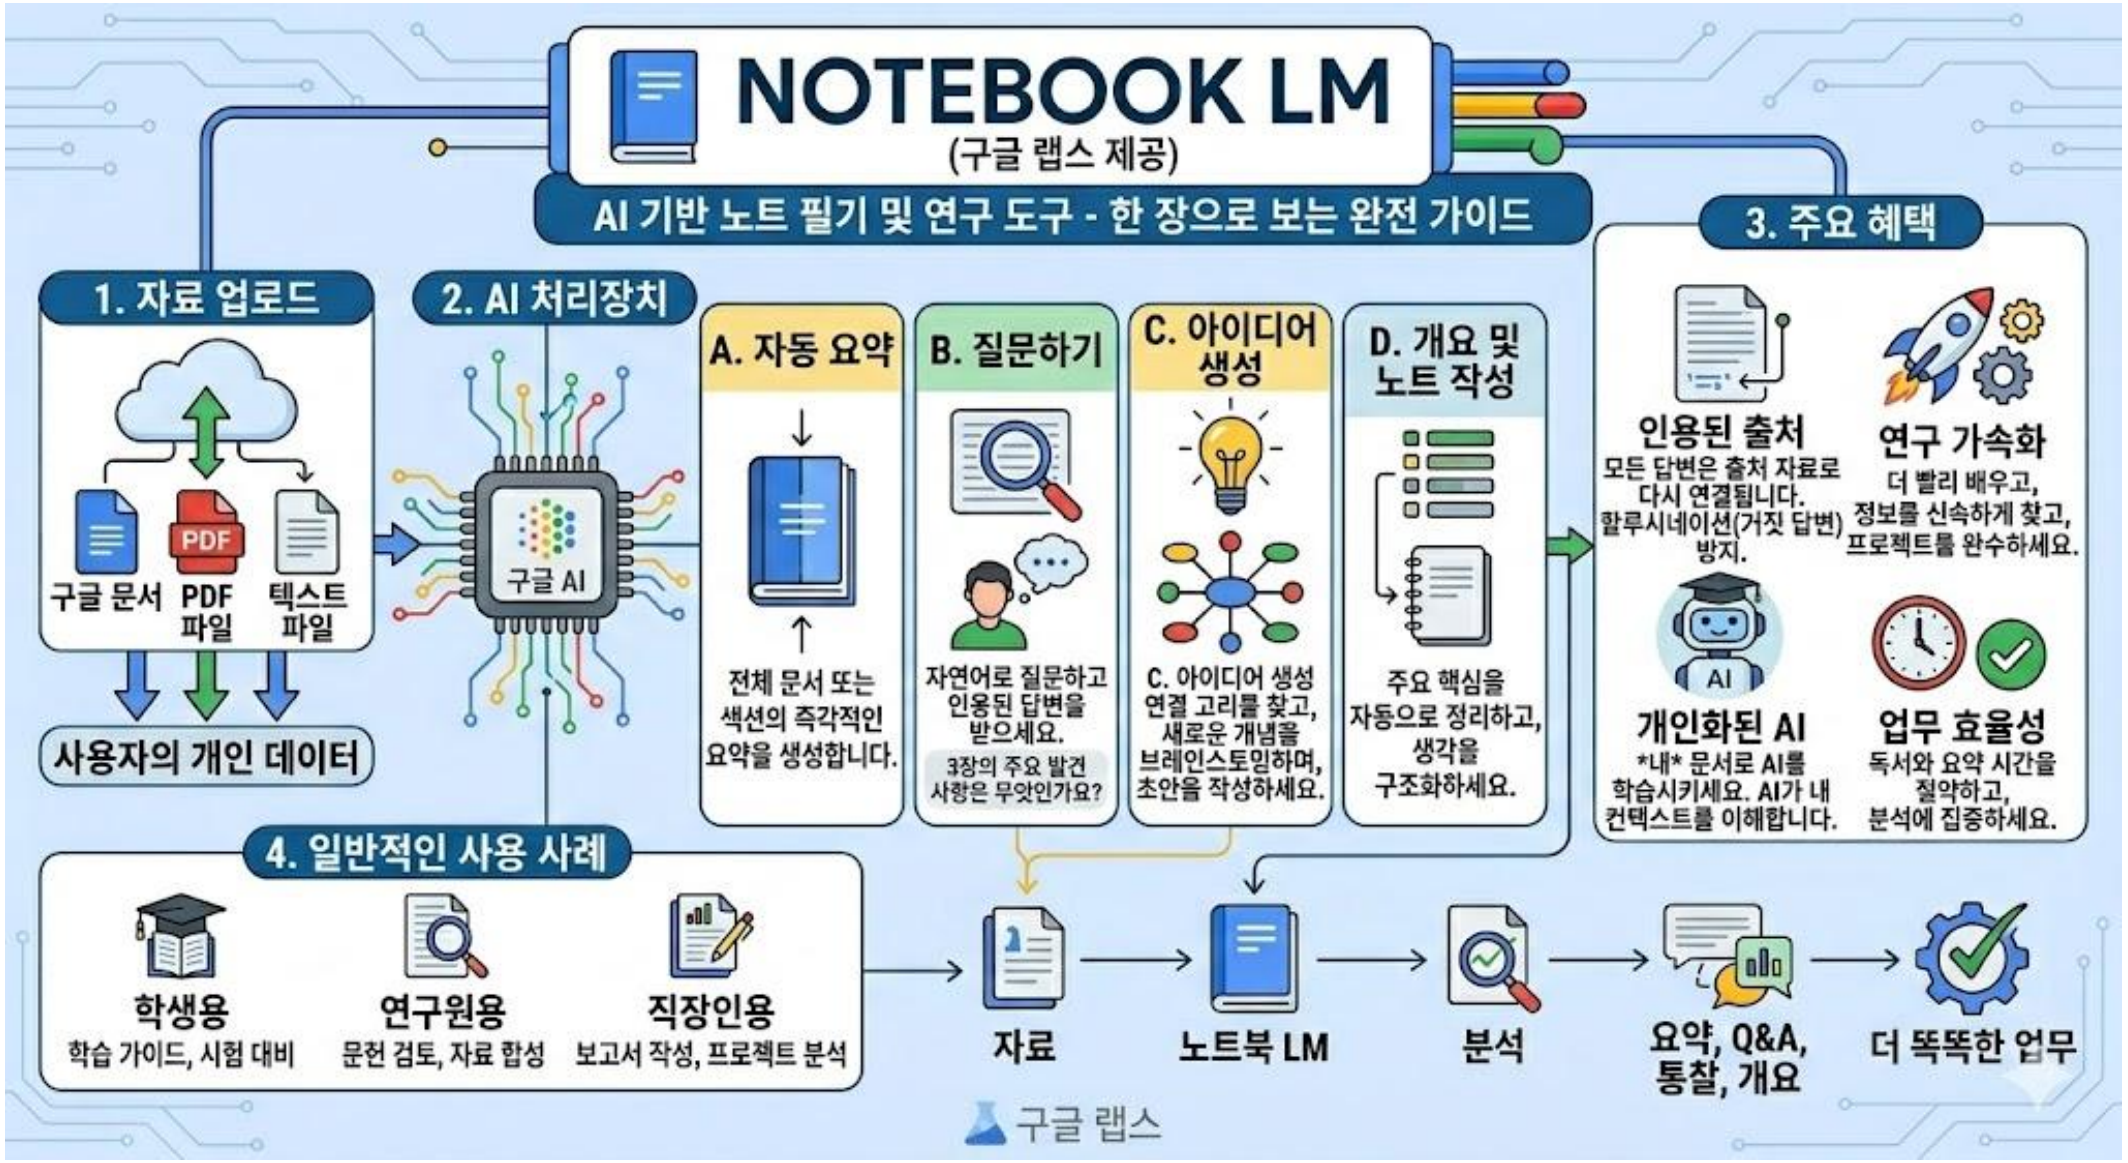


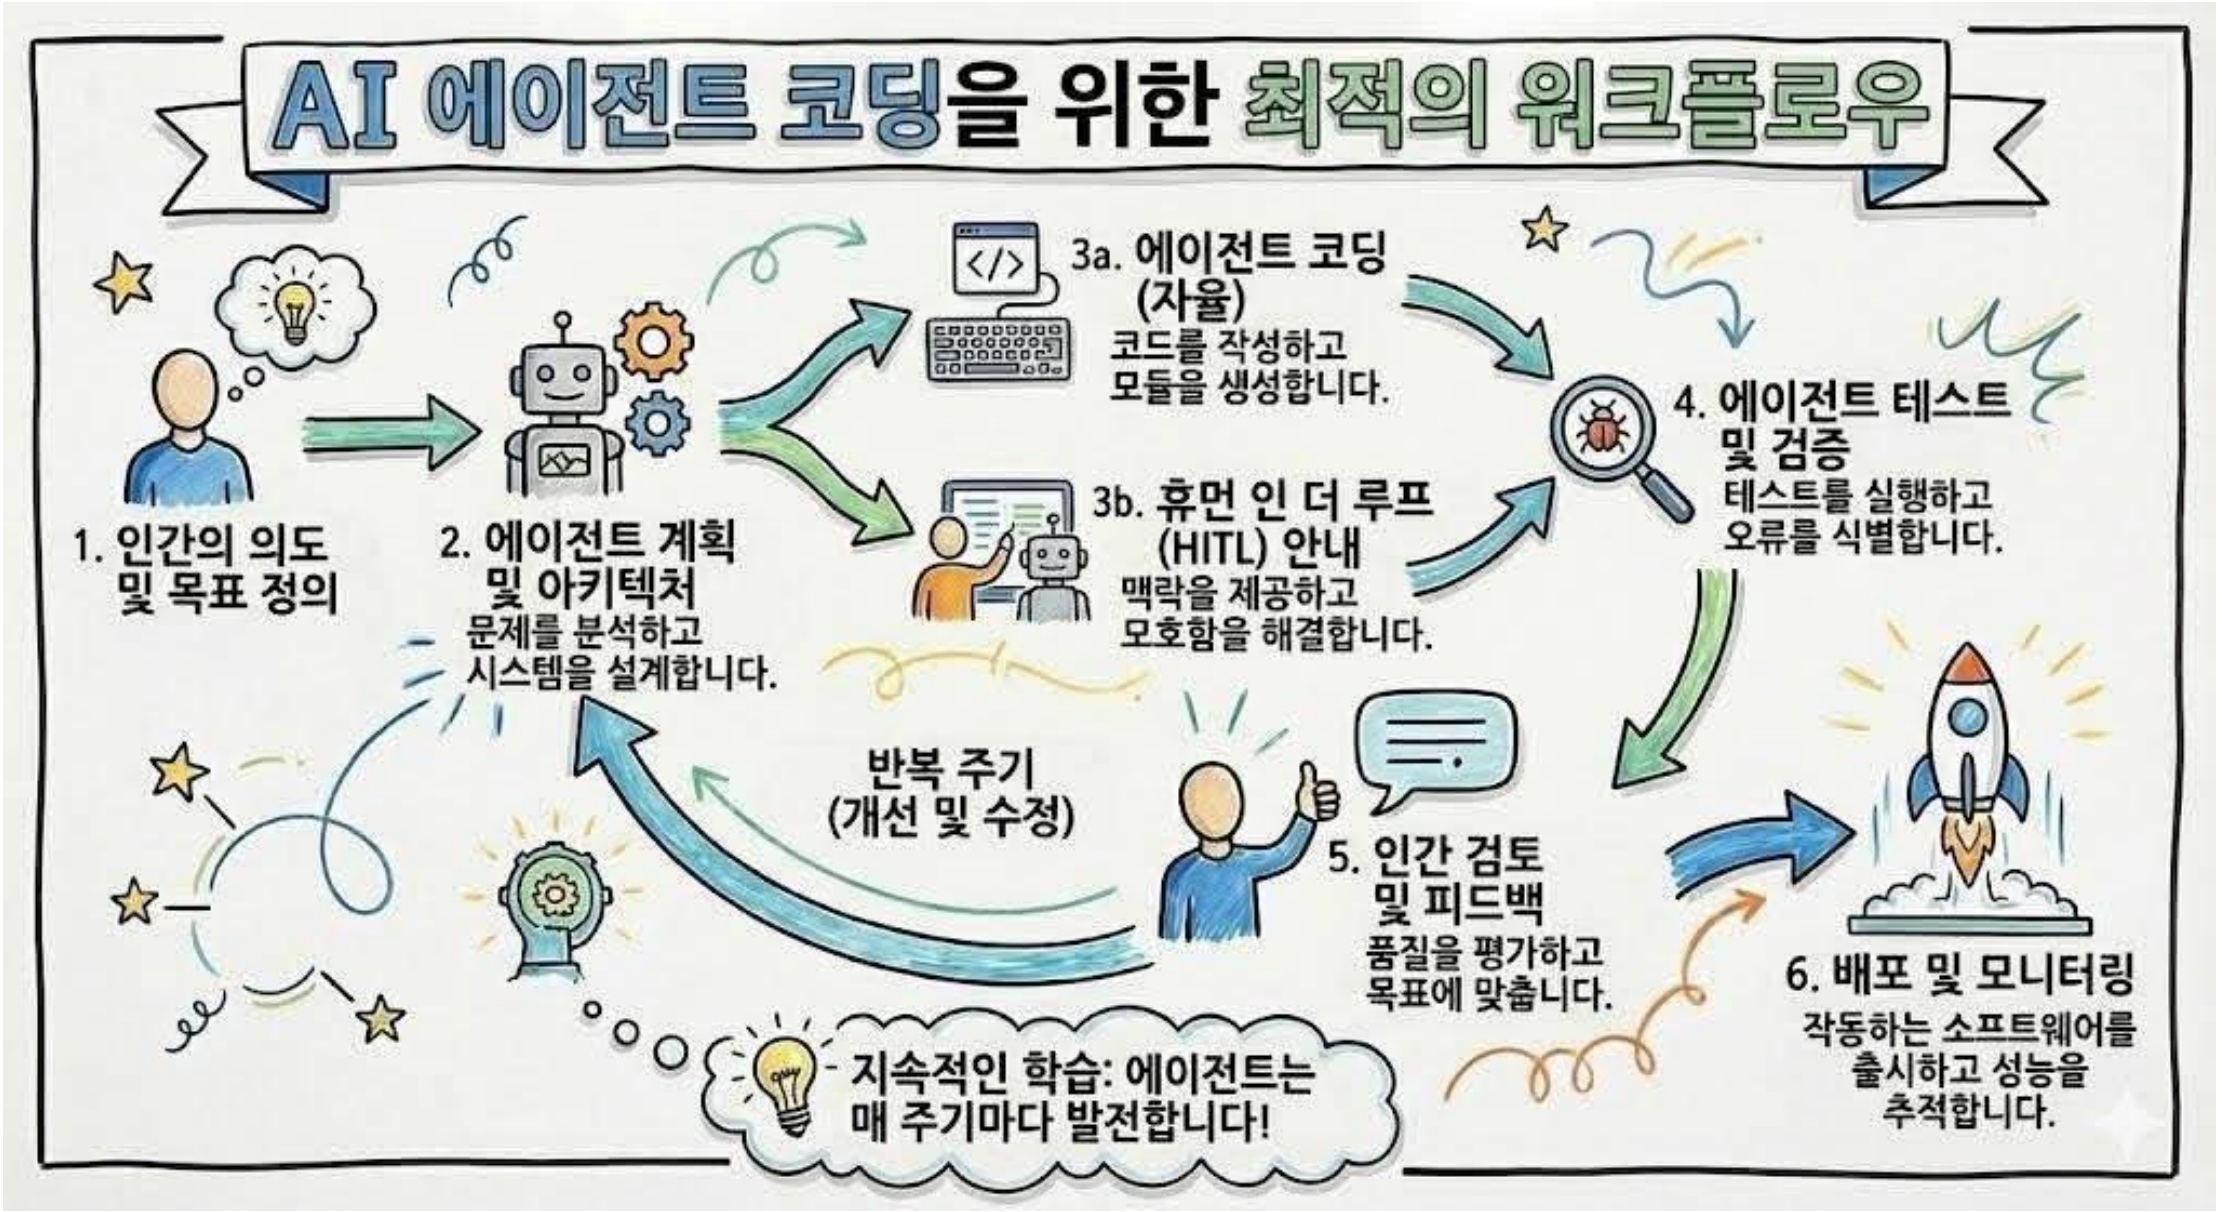
인간 수준 학습 AI 등장 시점 예측: 5~20년

일리야 수초제에는 인간티합 학습할 수 있는 사스템이 량후 5년에서 20년 안에 등상합 것으로 전경합니다.

NotebookLM

생성형 AI_Nano Banana Pro 2

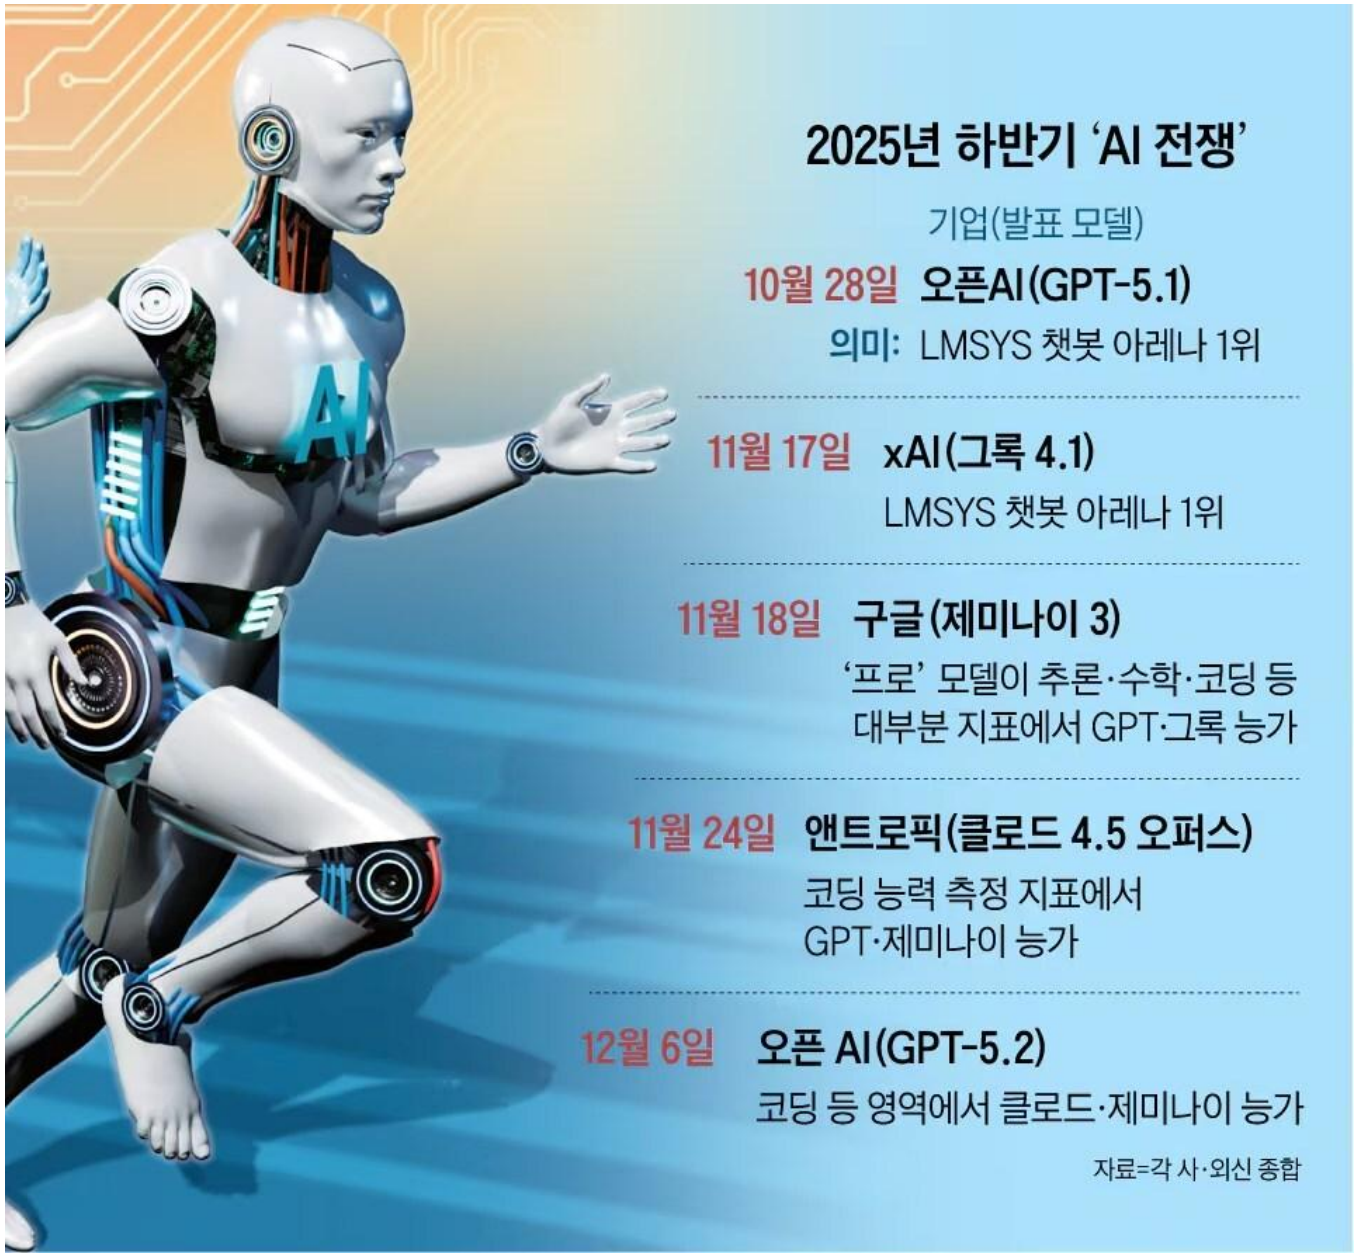


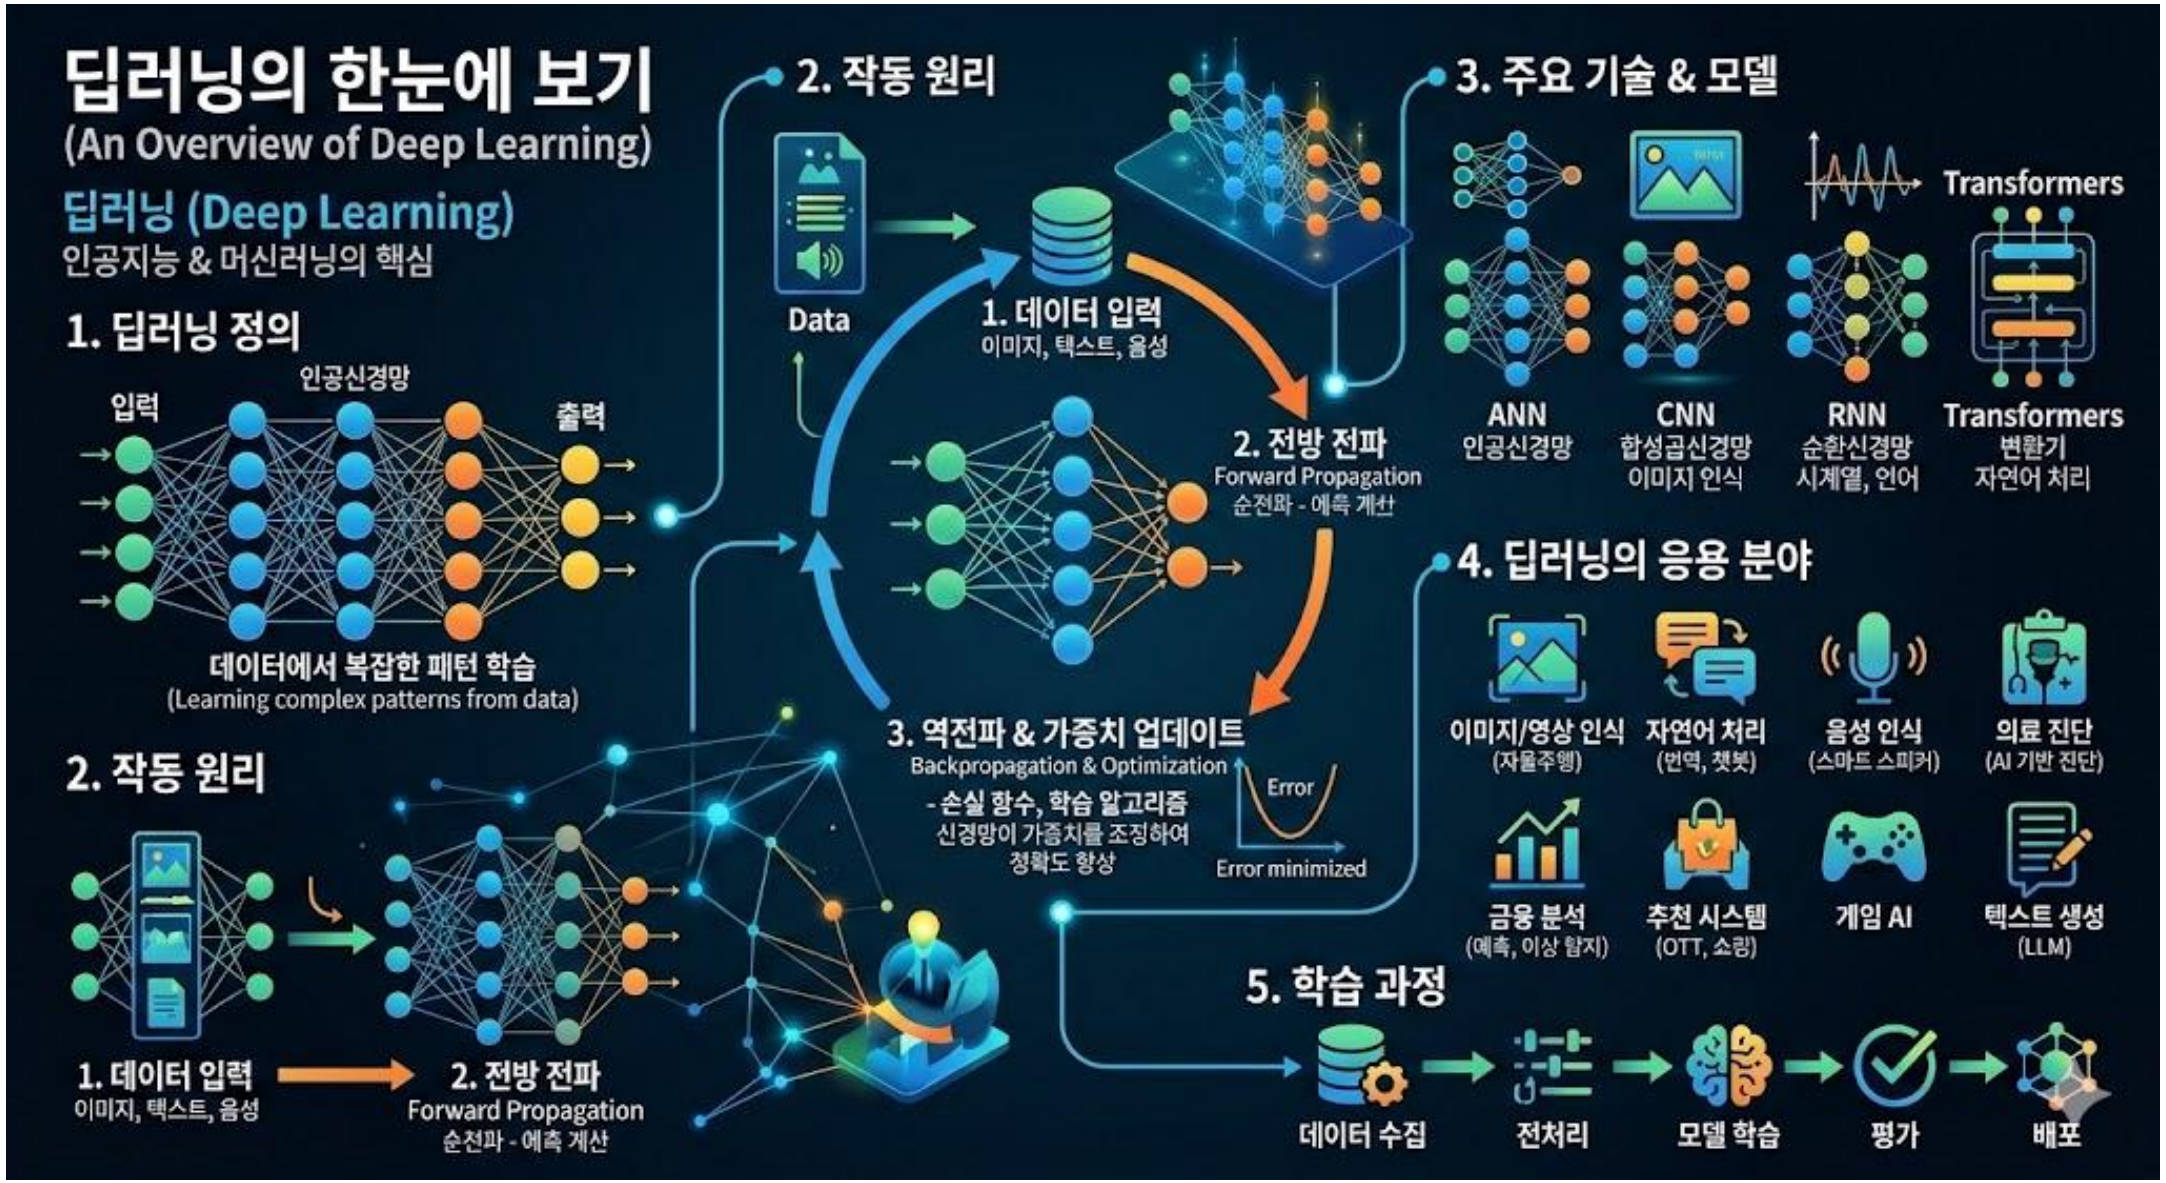

AI 에이전트 코딩을 위한 최적의 워크플로우
1. 인간의 의도 및 목표 정의
2. 에이전트 계획 및 아키텍처
문제를 분석하고 시스템을 설계합니다.
3a. 에이전트 코딩 (자율)
코드를 작성하고 모듈을 생성합니다.
3b. 휴먼 인 더 루프 (HITL) 안내
맥락을 제공하고 모호함을 해결합니다.
4. 에이전트 테스트 및 검증
테스트를 실행하고 오류를 식별합니다.
5. 인간 검토 및 피드백
품질을 평가하고 목표에 맞춥니다.
반복 주기 (개선 및 수정)
6. 배포 및 모니터링
작동하는 소프트웨어를 출시하고 성능을 추적합니다.
지속적인 학습: 에이전트는 매 주기마다 발전합니다!


2025년 AI 혁신 로드맵: 주요 기업들의 월별 발표 총정리
1월 (Jan)
1/20 DeepSeek-RT 공개
오픈소스 추론 모델
기술리포트, API 공개
2/20 EU AI Act
단계적 적용 시작
금지형 AI 관행 및 AI 리터러시
의무 조항 적용 구간 진입
2/24 Anthropic, Claude 3.7
Sonnet & Claude Code 발표
새로운 언어 모델과 함께
코딩 에이전트 도구 선보임
GPT-4.5
2/27 OpenAI
GTP-4.5 발표 및 출시
기존 모델을 뛰어넘는
성능의 차세대 모델 공개
2월 (Feb)
3/2 Nvidia Dynamo 발표
GTC 2025에서 분산 추론/서빙
프레임워크 오픈소스 공개
4월 (Apr)
4/5 Meta, Llama 4 공개
Scout/Maverick 등 새로운
모든 라인업 공개
4/16 OpenAI
Codex CLI 출시
터미널 환경에서 사용할 수 있는
오픈소스 코딩 에이전트 출시
4/14 OpenAI, GPT-4.1 출시
새로운 플래그십 모델 공개
5월 (May)
5/22 OpenAI x UAE
Stargate UAE 구축 발표
세계 최대급 AI 데이터 센터
5/20 Google, 멀티모달
생성 Veo 3, Imagen 4, AI
영상 제작 도구 Flow 출시
5/22 Anthropic, Claude 4
발표 및 Claude Code 정식
버전 출시
6월 (Jun)
Gemini
6/25 Google,
Gemini CLI 출시
6/17 Google, Gemini 2.5
Pro/Flash 안정 버전(GA)
Jules, A2A 공개, Deep
Research 기능 추가
8월 (Aug)
Deep
8/1 Google, Gemini 2.5
Deep Think 모드 롤아웃
강화한 추론 모드를 Gemini
앱 구독자 대상 제공 시작
GPAI
8/2 EU AI Act: 거버넌스
규정 및 GPAI(범용 AI)
모델 제공자 의무 적용
시작
GPT-5
8/7 OpenAI GPT-5 발표 및 출시
업계 모든 모델보다 뛰어난 차세대
플래그십 모델 공개
9월 (Sep)
9/15 OpenAI, Codex 업그레이드
및 GPT-5-Codex 공개
GPT-5 기반 코딩 에이전트에
최적화된 새로운 모델
2
9/20 OpenAI, Sora 2
더욱 향상된 성능의
동영상 생성 모델 출시
10월 (Oct)
10/6 OpenAI, ChatGPT
Apps 발표
대화형 인터페이스 안에서
인터렉션이 가능한 Apps
출시
SDK
10/6 OpenAI, Apps SDK
Slack 포팅, SDK,
AgentKit 공개
11월 (Nov)
11/12 OpenAI,
GPT-4.1 공개
대화 및
11/18 Google, Gemini 3
발표
AI Studio, Vertex API 등
모든 Google 서비스에
Gemini 3 동시 도입
11/20 Google
Nano Banana Pro
Gemini 3 Pro 기반
이미지 생성 및 편집
12월 (Dec)
AI Ultra
12/4 Google Gemini 3
Deep Think 모드 롤아웃
Gemini 3 기반 향상된
추론 모드를 AI Ultra
구독자 제공
GPT-
12/11 OpenAI GPT-5.2
범용 모델 출시
고급 추론과 향상된
에이전트 수행에 최적화된
모델 출시
AI
12월 초 Agentic AI
Foundation 출범
OpenAI, Anthropic 등이
참여하여 에이전트의 오픈
표준과 상호운용


2026 AI 혁신 로드맵: 주요 기업들의 월별 발표 총정리
2026년 AI INNOVATION ROADMAP: MONTHLY ANNOUNCEMENTS FROM MAJOR COMPANIES
초거대 AI 모델
(e.g., GPT-5 or similar)
구글(GOOGLE)의
최신 LLM 공개
애플(APPLE)의
AI 비서 통합
생성형 AI 탑재
디바이스 출시
메타(META)의
오픈소스 AI 프로젝트
AR/VR과 AI 결합
마이크로소프트
(MICROSOFT)의
오피스 AI 강화
코파일럿 고도화
AI 기반
기술 혁신
테슬라(TESLA)의
FSD 업데이트
클라우드 AI
서비스 확장
아마존(AMAZON)
AWS 신기능
AI 윤리
가이드라인 발표
규제 대응 기술
모바일 AI
최적화
삼성(SAMSUNG)
온디바이스 AI
의료 및 바이오
AI 솔루션
엔비디아(NVIDIA)의
AI 칩 로드맵
고성능 GPU 발표
자율주행 기술
상용화 진전
AI 생태계 점산
및 미래 전망
2027년 예측
1월 (JAN)
2월 (JAN)
3월 (MEN)
4월 (SAN)
5월 (SEB)
6월 (JEG)
7월 (TAN)
8월 (AUG)
9월 (GES)
10월 (NOV)
11월 (DEC)
12월 (DEC)
초거대 AI
모델 업데이트
(e.g, GPT-5 or)
구글(GOOGLE)의
최신 LLM 공개
애플(APPLE)의
AI 비서 통합
생성형 AI 탑재
디바이스 출시
메타(META)의
오픈소스 AI
프로젝트
AR/VR과 AI 결합
마이크로소프트
(MICROSOFT)의
오피스 AI 강화
코파일럿 고도화
AI 기반
로봇 기술 혁신
테슬라(TESLA)의
FSD 업데이트
클라우드 AI
서비스 확장
아마존(AMAZON)
AWS 신기능
AI 윤리
가이드라인
발표
규제 대응 기술
모바일 AI
최적화
삼성(SAMSUNG)
온디바이스 AI
의료 및 바이오
AI 솔루션
엔비디아(NVIDIA)의
AI 칩 로드맵
고성능 GPU 발표
자율주행 기술
상용화 진전
AI 생태계 점산
및 미래 전망
2027년 예측
혁신, 연결, 미래로 나아가는 인공지능

생성형 AI


2025년 하반기 'AI 전쟁'
기업(발표 모델)
10월 28일 오픈AI(GPT-5.1)
의미: LMSYS 챗봇 아레나 1위
11월 17일 xAI(그록 4.1)
LMSYS 챗봇 아레나 1위
11월 18일 구글(제미나이 3)
'프로' 모델이 추론·수학·코딩 등
대부분 지표에서 GPT·그록 능가
11월 24일 앤트로픽(클로드 4.5 오퍼스)
코딩 능력 측정 지표에서
GPT·제미나이 능가
12월 6일 오픈 AI(GPT-5.2)
코딩 등 영역에서 클로드·제미나이 능가
자료=각 사·외신 종합


딥러닝의 한눈에 보기
(An Overview of Deep Learning)
딥러닝 (Deep Learning)
인공지능 & 머신러닝의 핵심
1. 딥러닝 정의
입력
인공신경망
출력
데이터에서 복잡한 패턴 학습
(Learning complex patterns from data)
2. 작동 원리
Data
1. 데이터 입력
이미지, 텍스트, 음성
2. 전방 전파
Forward Propagation
순전파 - 예측 계산
3. 역전파 & 가중치 업데이트
Backpropagation & Optimization
- 손실 함수, 학습 알고리즘
신경망이 가중치를 조정하여
정확도 향상
Error
Error minimized
3. 주요 기술 & 모델
ANN
인공신경망
CNN
합성곱신경망
이미지 인식
RNN
순환신경망
시계열, 언어
Transformers
Transformers
변환기
자연어 처리
4. 딥러닝의 응용 분야
이미지/영상 인식
(자율주행)
자연어 처리
(번역, 챗봇)
음성 인식
(스마트 스피커)
의료 진단
(AI 기반 진단)
금융 분석
(예측, 이상 탐지)
추천 시스템
(OTT, 쇼핑)
게임 AI
텍스트 생성
(LLM)
2. 작동 원리
1. 데이터 입력
이미지, 텍스트, 음성
2. 전방 전파
Forward Propagation
순전파 - 예측 계산
5. 학습 과정
데이터 수집
전처리
모델 학습
평가
배포

인공지능 분야_지식 기반 시스템



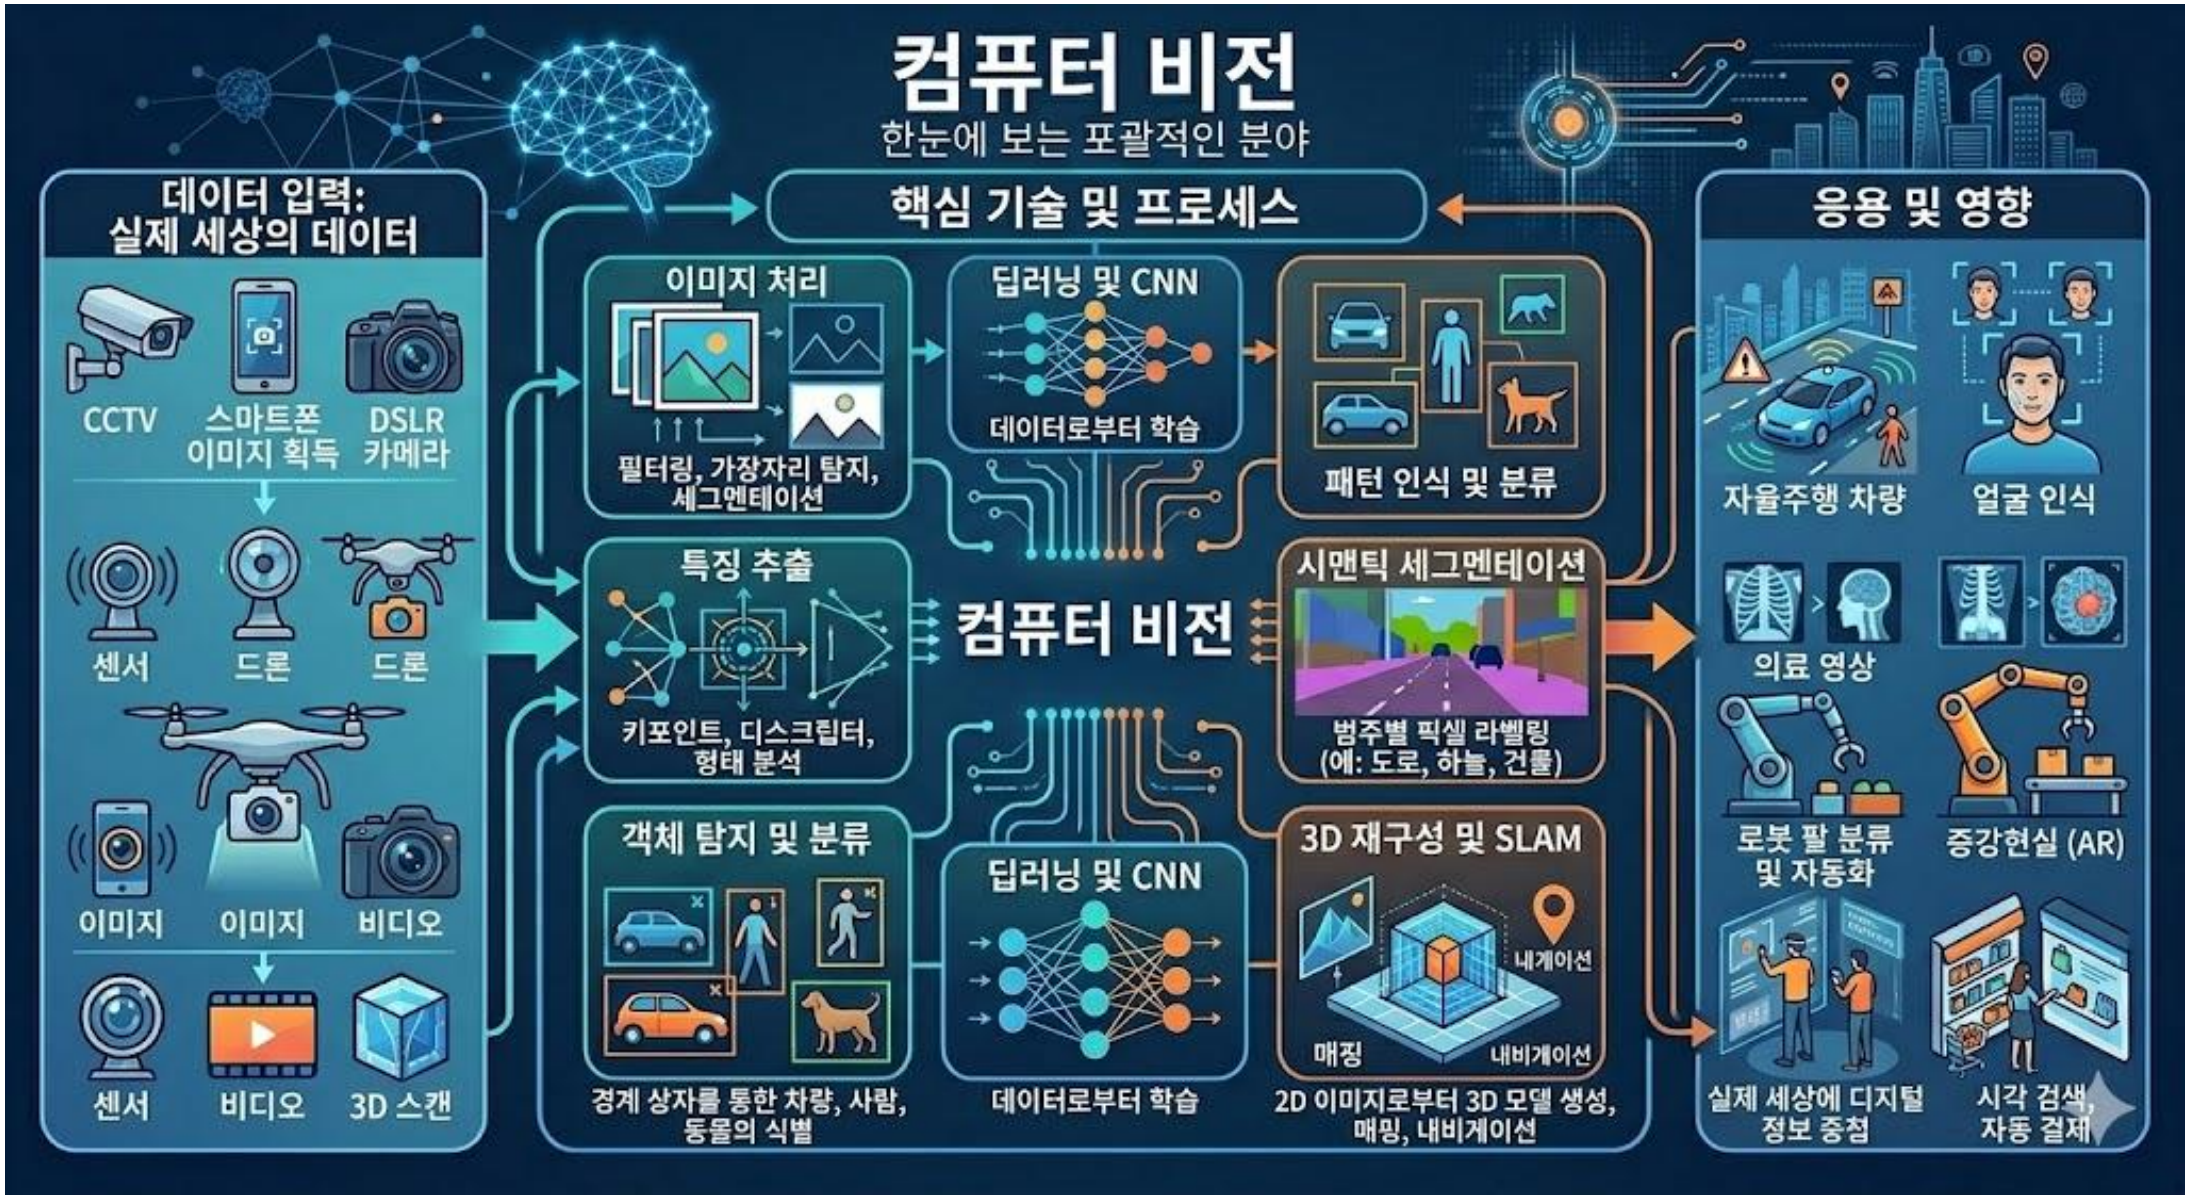
'3시에 자살' 음성 인식하면 한국판 시리가 내놓는 대답 "알겠어요"

중앙일보 | 입력 2018.06.27 01:00 지면보기

이에스더 기자 구독



인공지능 분야_컴퓨터 비전



인공지능 분야_ 컴퓨터 비전

2019.09.21



인공지능 분야_ 컴퓨터 비전

2025.03.05

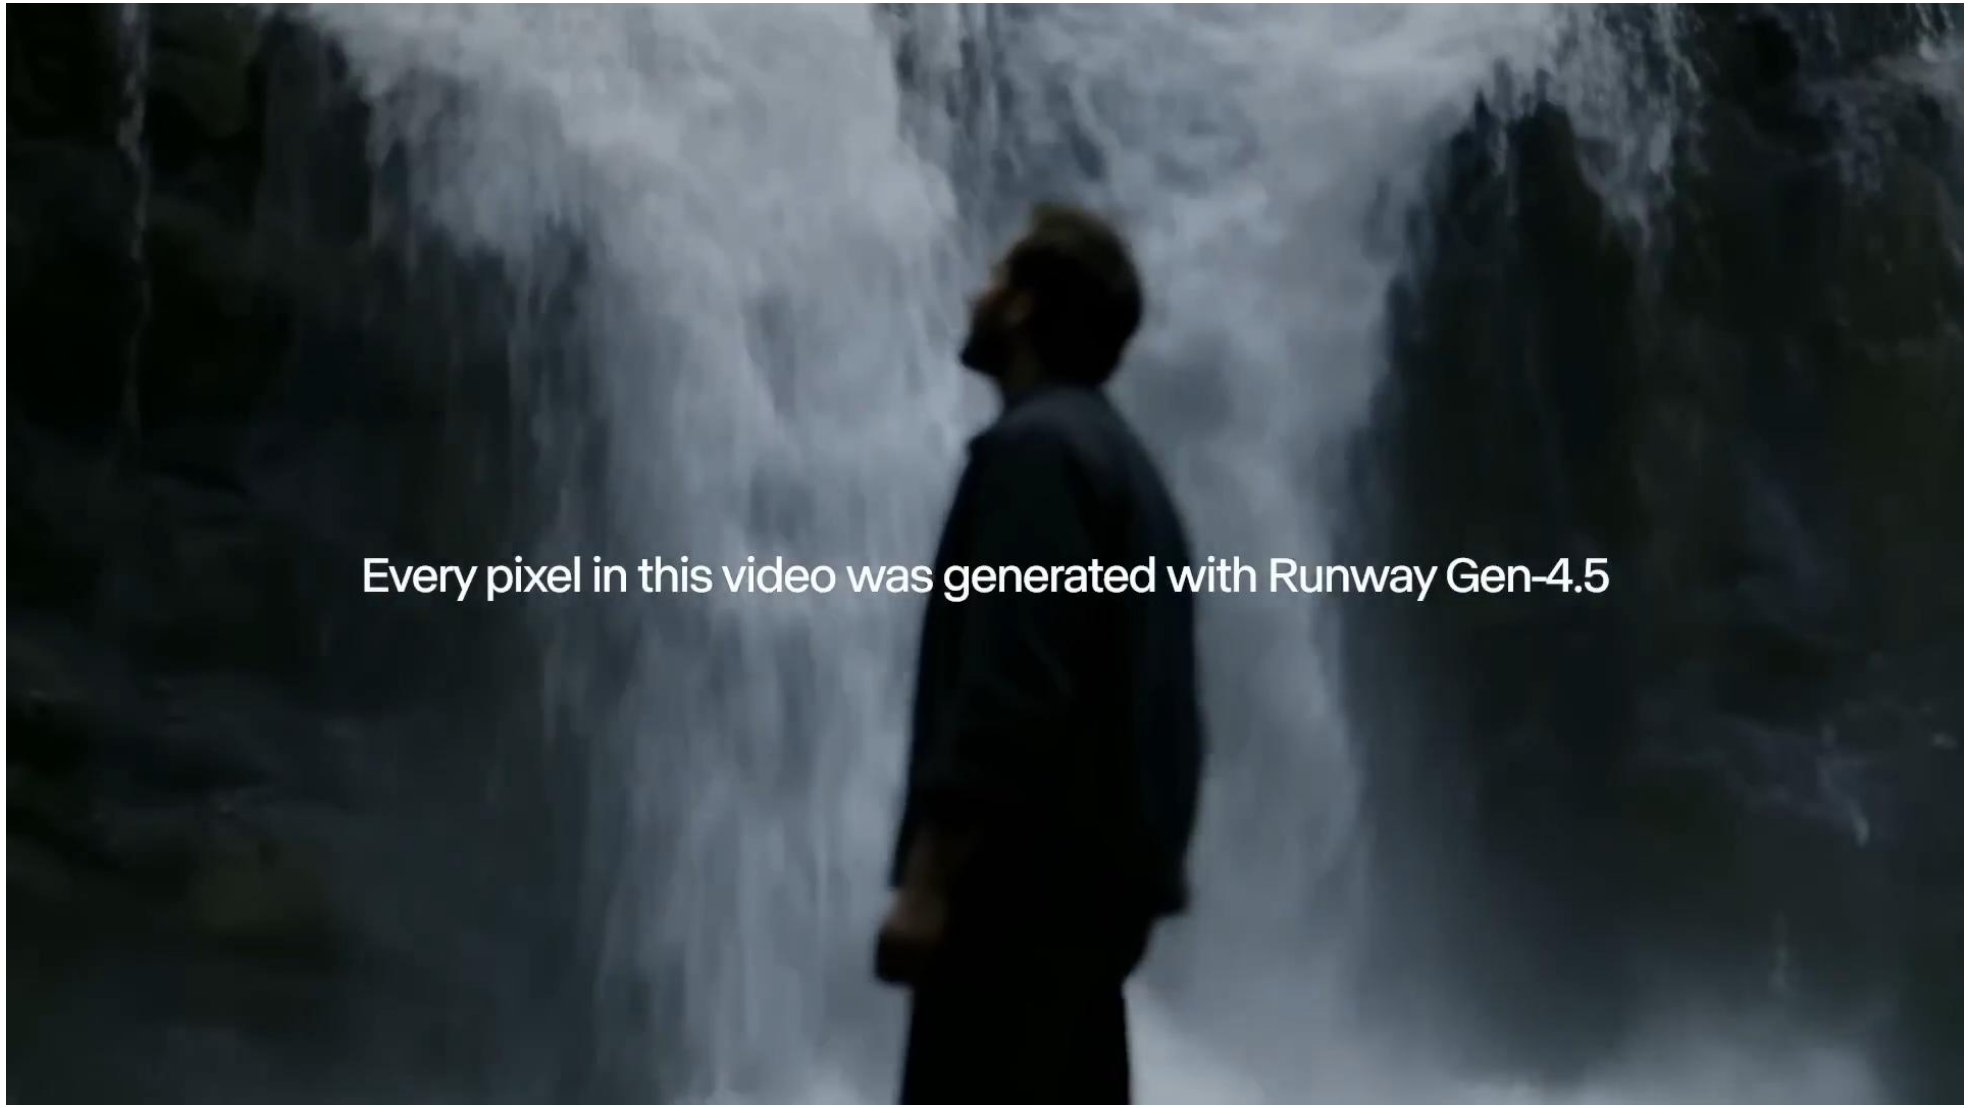


인공지능 분야_ 컴퓨터 비전



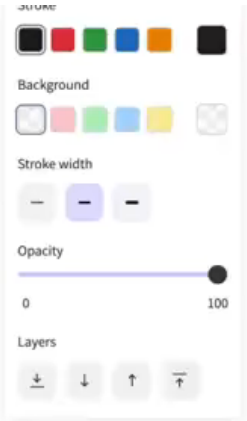
인공지능 분야_ 컴퓨터 비전

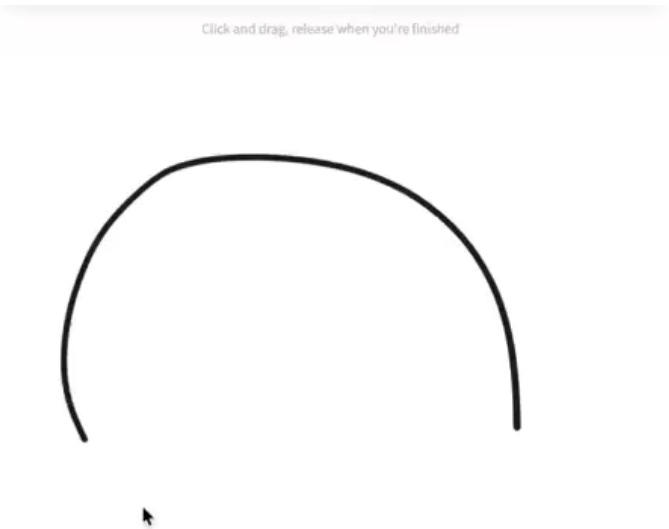
Runway Gen-4.5: 텍스트 프롬프트만으로 “시메나틱 수준”의 영상 수준 가능 (2025.12.02에 발표된 영상), 움직임, 물리 효과, 유체 역학까지 꽤 정교하게 구현된다는 평가를 받고 있음



인공지능 분야_ 컴퓨터 비전

Hedra AI: 2024년에 런칭 되었고, 2025년 5월에 시리즈A 투자를 받음





인공지능 분야_ 컴퓨터 비전

Google Veo 3: 사진이나 정지 이미지 + 음성/텍스트 만으로 “움직이는 캐릭터 영상(말하는 얼굴 혹은 인물)”을 자동 생성해줌. 영상 제작 경험이 없거나 3D 모델링을 모르는 사람도 손쉽게 영상 콘텐츠 제작 가능



인공지능 분야_ 컴퓨터 비전

Kling 3.0: Kuaishou의 Kling AI가 2026년 2월 공개한 최신 모델 라인업으로, 생성 영상의 일관성(consistency)과 사실감(photorealism)을 강화하고 **최대 15초 길이**의 영상 생성 등을 주요 업그레이드로 내세움.

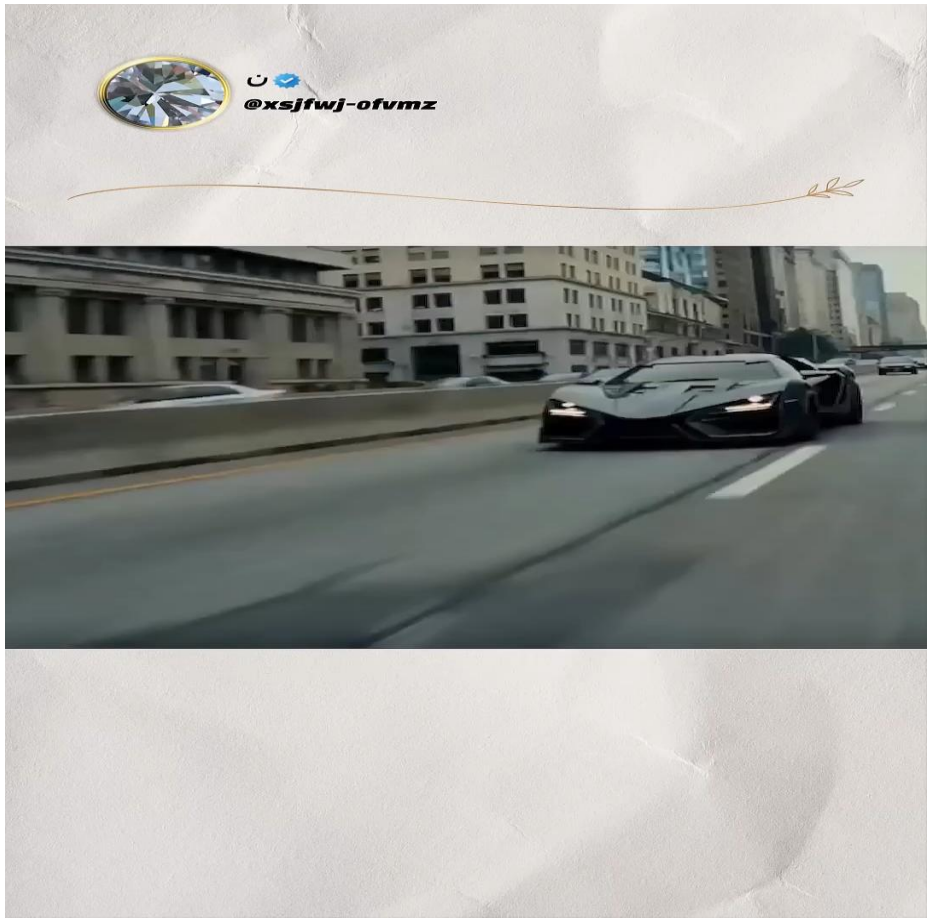


출처 : https://www.youtube.com/watch?v=l2fsWXlGCjw&t=866s

인공지능 분야_ 컴퓨터 비전

Seedance 2.0: ByteDance가 2026년 2월 공개한 영상 생성 모델로, **모션 안정성**과 오디오-비디오 공동 생성(audio-video joint generation)을 핵심 특징으로 내세움. 또한 **텍스트뿐 아니라 이미지·오디오·비디오를 참조**해 성능(퍼포먼스), 조명, 그림자, 카메라 움직임까지 “감독급 제어”를 지원하는 방향으로 소개됩니다.

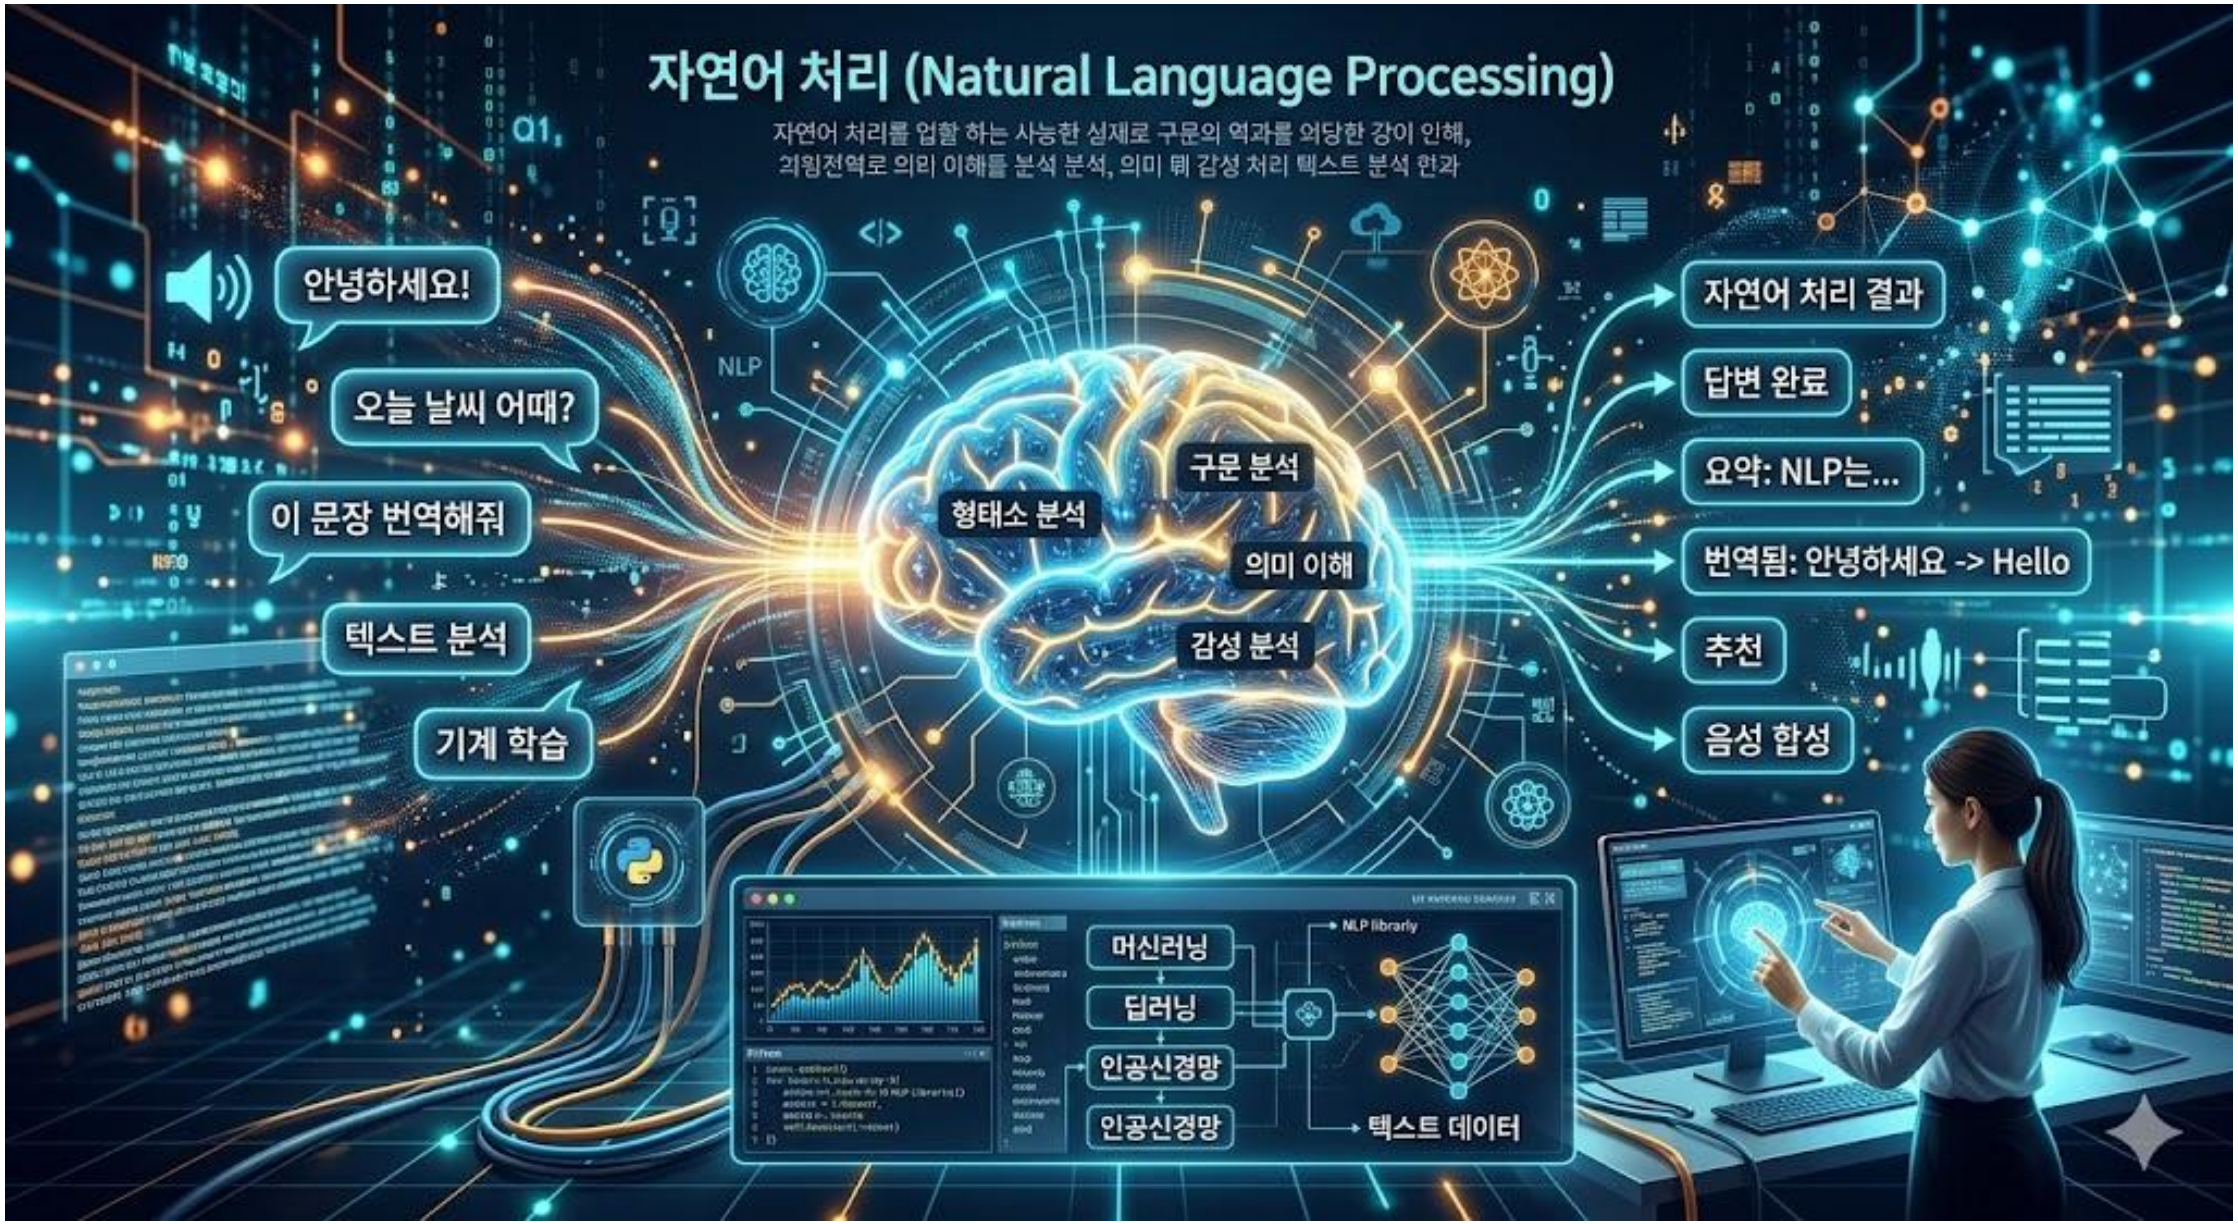




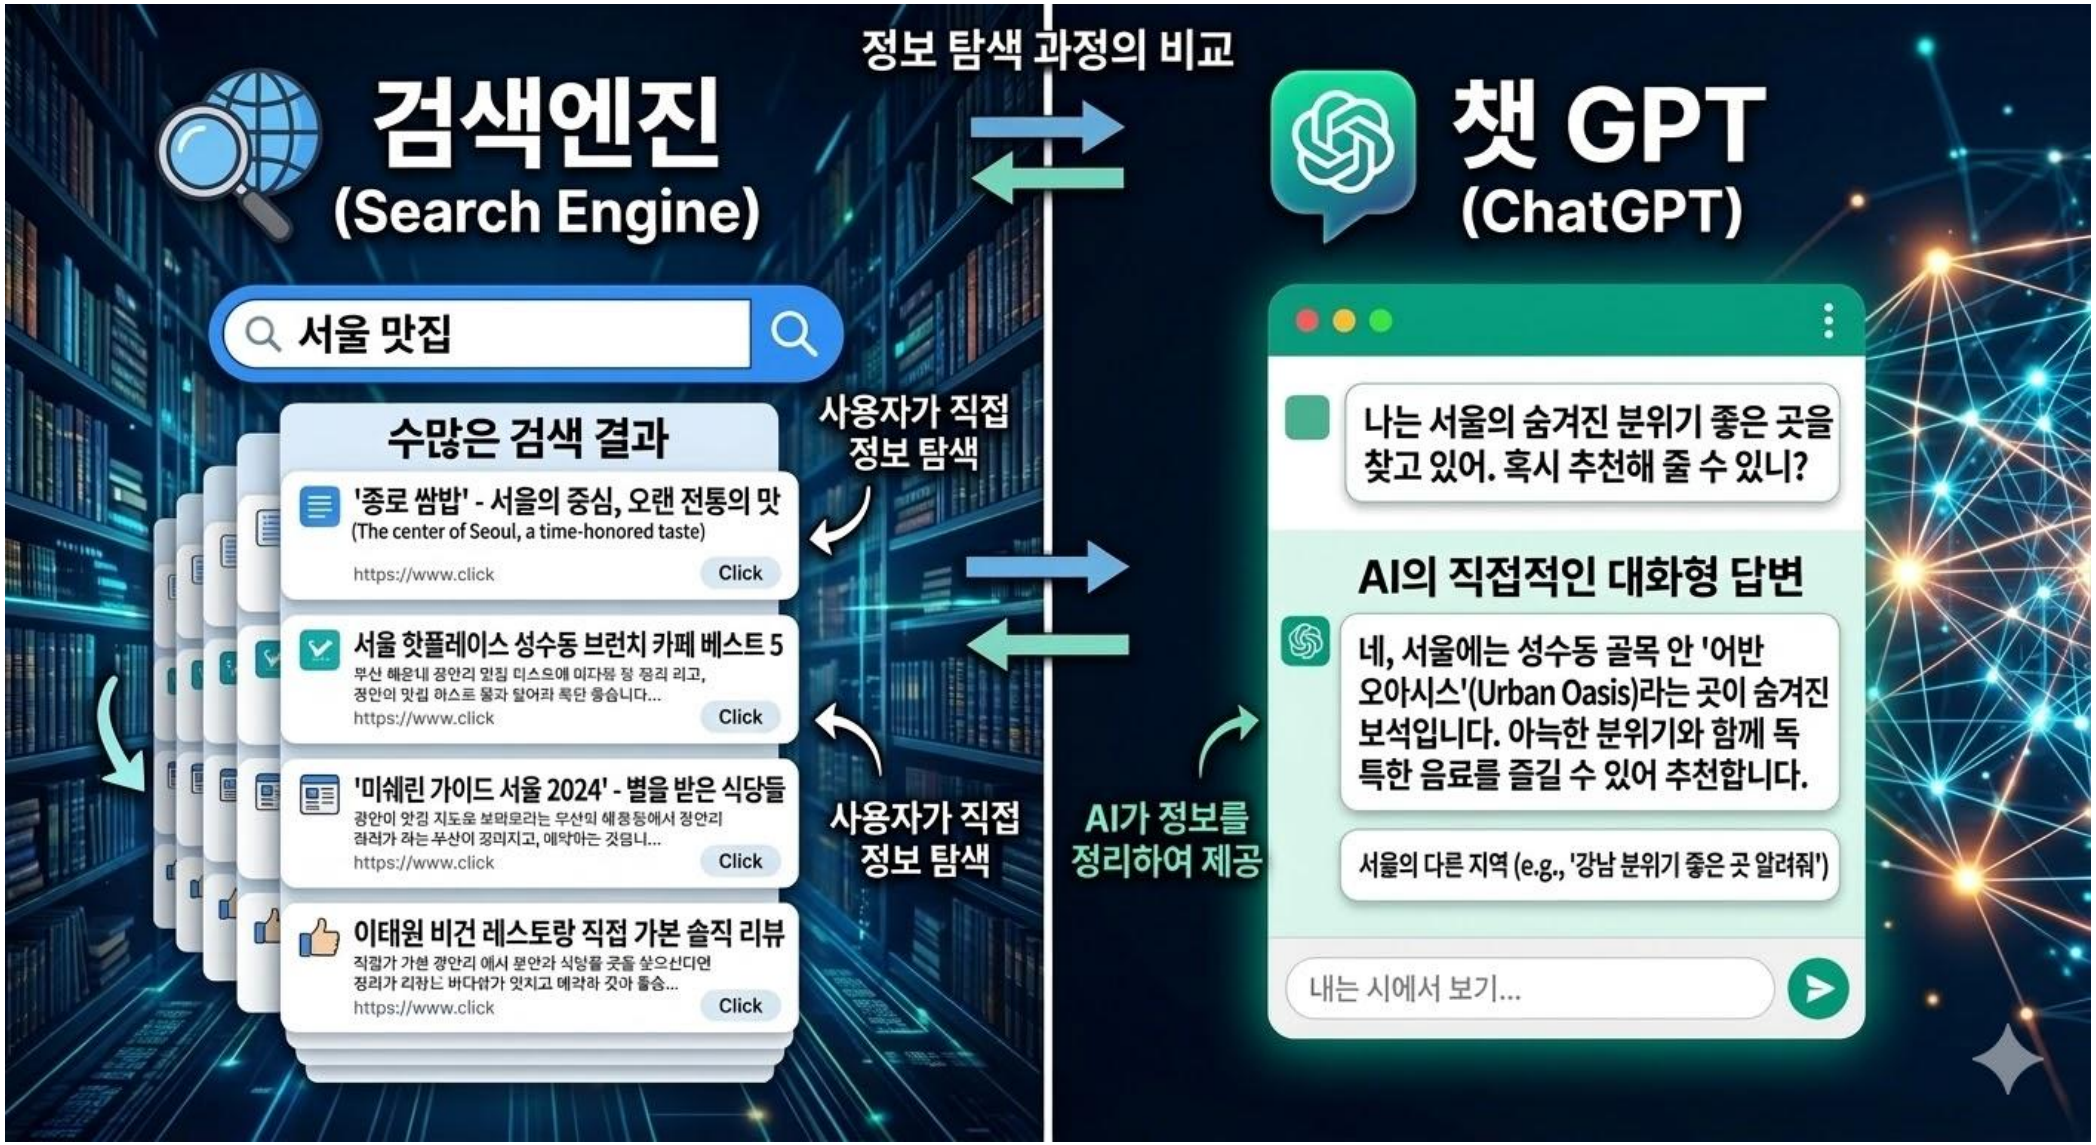
인공지능 분야_컴퓨터 비전



인공지능 분야_자연어처리



인공지능 분야_자연어처리

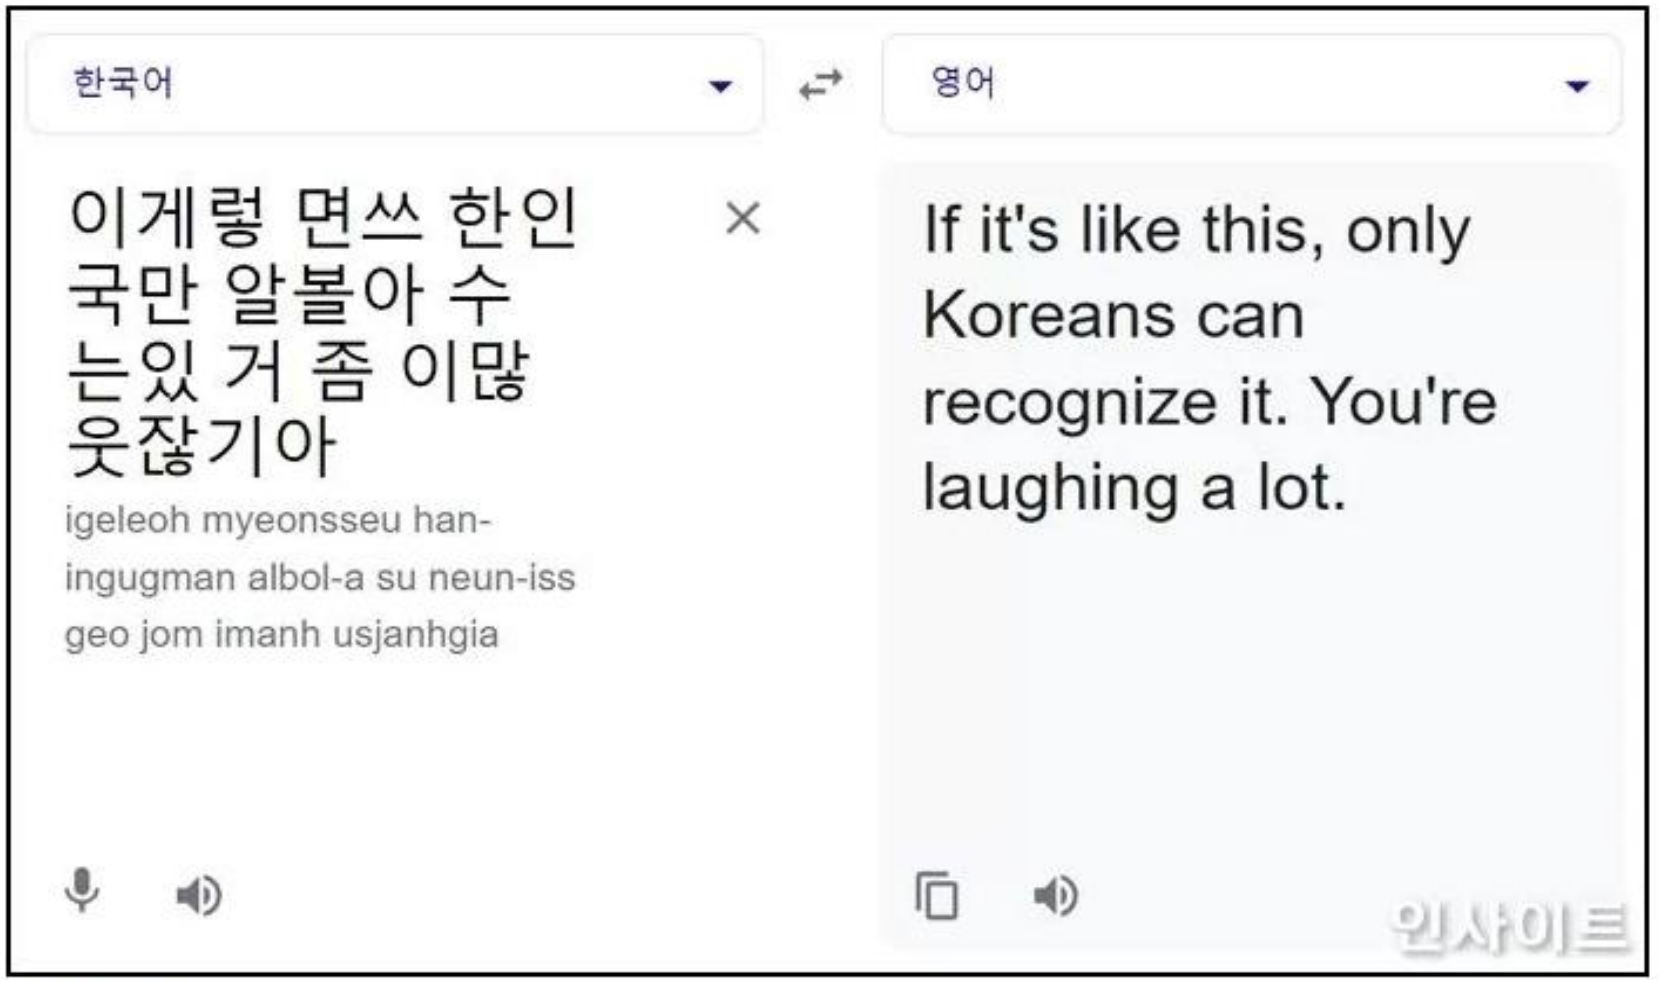


- 자연어 처리의 어려움 - 한국어의 특징

한꾹인뜰만알아뽈쑤있께짝썽하껬씁니따.
히까씨이케부쿠로역에썬
30초또안껄릴만끔가깝찌만쑥쏘까많이낙후뙤어있꼬
엘베없꼬4층이라짐많으면깨꼬쌩합니따.
빠뀌뻘레나왔꼬 화짱씰 많이낡았씁니따.
끄래써 똥 역화짱씰까써 쌌씁니따
쩔때 여끼로오찌마세요!
뜨럽꼬 낡꼬 꼐딴을 쫗아하씨는 뿐만 까세요!

인공지능 분야_자연어처리

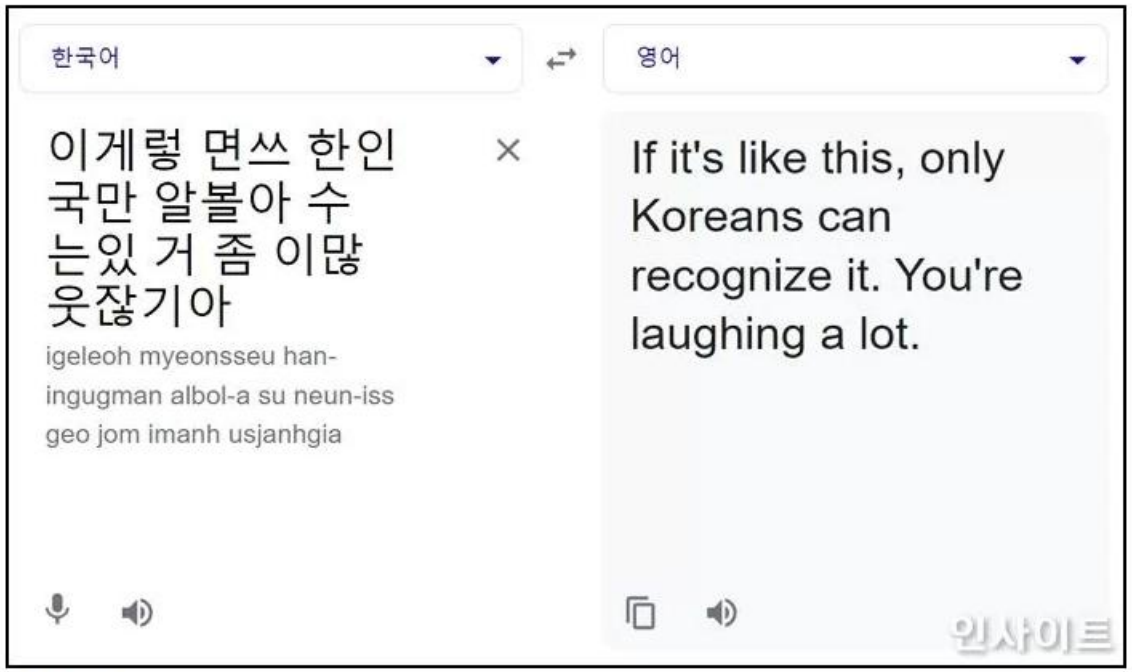
- 한국인들만 아는 암호가 뚫어짐(2023.01.30)



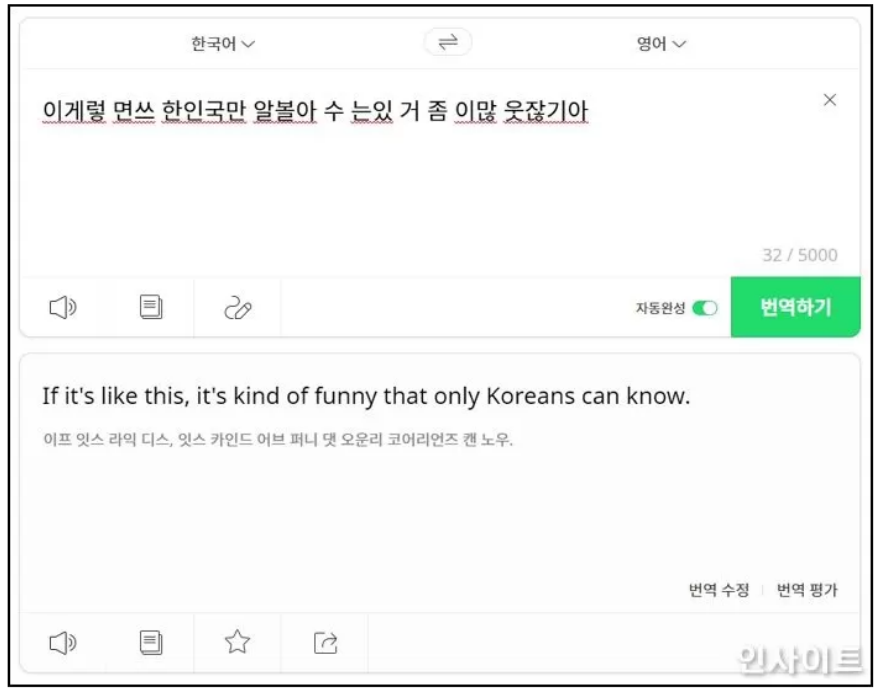
구글 번역 캡처 / 사진=인사이트

인공지능 분야_자연어처리

- 한국인들만 아는 암호가 뚫어짐(2023.01.30)



구글 번역 캡처 / 사진=인사이트



네이버 파파고 캡처 / 사진=인사이트

인공지능 분야_자연어처리

2026.01.20



어~어~ 내 얘길 드러봐~Everybody~ listen up~ 예얍~
친구들과 기대했던 후쿠오카 여~행! 예얍~ 너무너무 좋았어~
とてもよかった 하G만~ 숙so에 도착하고 난 알하치~ 이건
mang했다고~ 예얍 넘나넘나 먼ㅈㅣ가많훈것... 하지만~but
괜찮았어! 전진먼진 털면 되니까다나까나까무라상~ 들어(가)(자)
(마)(자) 카펱은 구석으로ㅊㅣ워버rigo~구석기 시대로 바이바이
~~ yeah~ 그러나しかし 베ㄱㅐ피 누리끼리우리끼리~ 베ㄱ
ㅐ피~ B누로 씻었earth~ 누리끼리우리끼리? 없어졌어~
無くなった~ 이건 정말 shock baby 하지만 정말로 내가
행복했던건~僕が本当にいいだと思ったのは~ 바로 바메는
ㅋ 듣고 놀라지마 예얍 뚜루뚜루뚜거운 무리 안! 나! 와우!
wow! 値段が安すいので良かった가격이 저렴해서 정말
좋았어요. ^^ 코헤E~ 기레서 내 맞우치지맛쏘! 알긋나im(마)
개빢ㅊㅣ니카

ChatGPT 5.2 Thinking

공유하기

~~ yeah~ 그러나しかし 베ㄱㅐ피 누리끼리우리끼리~ 베ㄱ
ㅐ피~ B누로 씻었earth~ 누리끼리우리끼리? 없어졌어~
無くなった~ 이건 정말 shock baby 하지만 정말로 내가
행복했던건~僕が本当にいいだと思ったのは~ 바로 바메는
ㅋ 듣고 놀라지마 예얍 뚜루뚜루뚜거운 무리 안! 나! 와우!
wow! 値段が安すいので良かった가격이 저렴해서 정말
좋았어요. ^^ 코헤E~ 기레서 내 맞우치지맛쏘! 알긋나im(마)
개빢ㅊㅣ니카

너 이런건 해석이 가능하니?

38s 동안 생각함

가능합니다. 다만 이 글은 의도적으로 **한/일/영을 섞고, 말장난(예: '예얍~', 'shock baby'), 괄호로 글자를 끼워 넣는 방식**을 써서 "정확한 문장"이라기보다 **분위기+리듬으로 쓰인 후기**에 가깝습니다. 그래서 100% 직역은 일부 구간이 애매해질 수 있어요.

제가 읽히는 핵심 내용(요약)은 이렇습니다.

- 친구들과 기대했던 **후쿠오카 여행이 전반적으로 매우 좋았다**("とてもよかった" 포함).
- 그런데 **숙소에 도착하니 먼지가 너무 많아서 '망했다'고 느꼈다**.
- 그래도 **먼지 털고/닦으면 되니까 괜찮다**고 하며 들어감.
- 뭔가 **누리끼리한(누런) 얼룩/상태**가 있었는데 **표백제/세정('하이포' 같은 표현, 'B로 씻었' 등)으로 씻으니 없어졌다(無くなった)**고 말함.
- "진짜 shock였지만" 결과적으로는 **행복했고**, 특히 **가격이 저렴해서 좋았다(値段が安い)**고 마무리.
- 마지막엔 장난스럽게 **짜증("가빡치니까")** 같은 표현도 섞임.

원하시면,

1. 제가 이미지 내용을 **줄 단위로 깔끔하게 전사(텍스트화)** 하고
2. 그 다음에 **자연스러운 한국어 정리본** + **자연스러운 영어 번역본**
   두 버전으로 만들어드릴게요.

그리고 괄호 안의 동그라미 글자들(예: (가)(자)(치)...)은 **숨은 메시지/말장난**일 가능성이 높아서, 그걸 "해독"까지 원하면 그 부분만 따로 모아서 패턴을 찾아드릴 수도 있습니다.

인공지능 분야_자연어처리

인사이트 정치 경제 사회 연예 여행 사람들 IT·과학 생활 스토리 산업 금융 보도자료

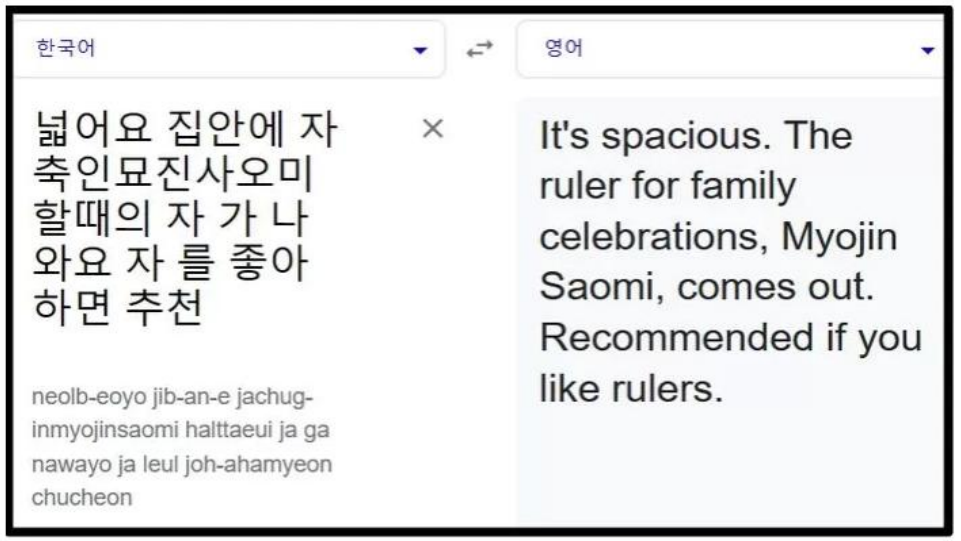
구글번역·챗GPT 뚫리자 오직 한국인만 알아들을 수 있는 '암호 후기' 업글 버전 나왔다

해외 숙소에서 쥐를 발견한 여행객은 한국인들을 위해 12간지를 동원해 번역기가 뚫지 못하는 후기글을 완성했다.

김소영 기자 입력 2023.03.30 10:43

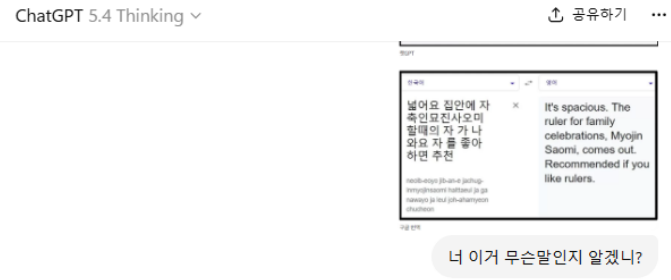


챗GPT



구글 번역

- 2026.03.09(GPT 5.4)



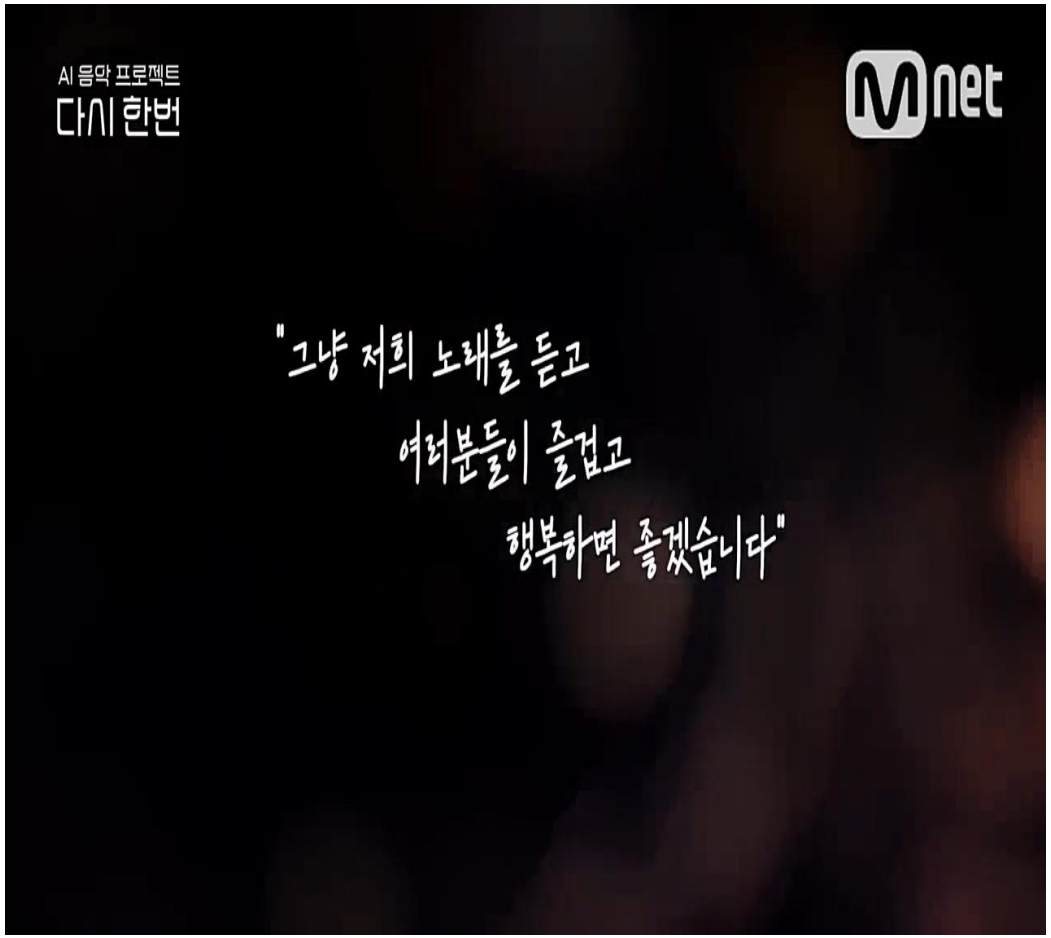
인공지능 분야_자연어처리

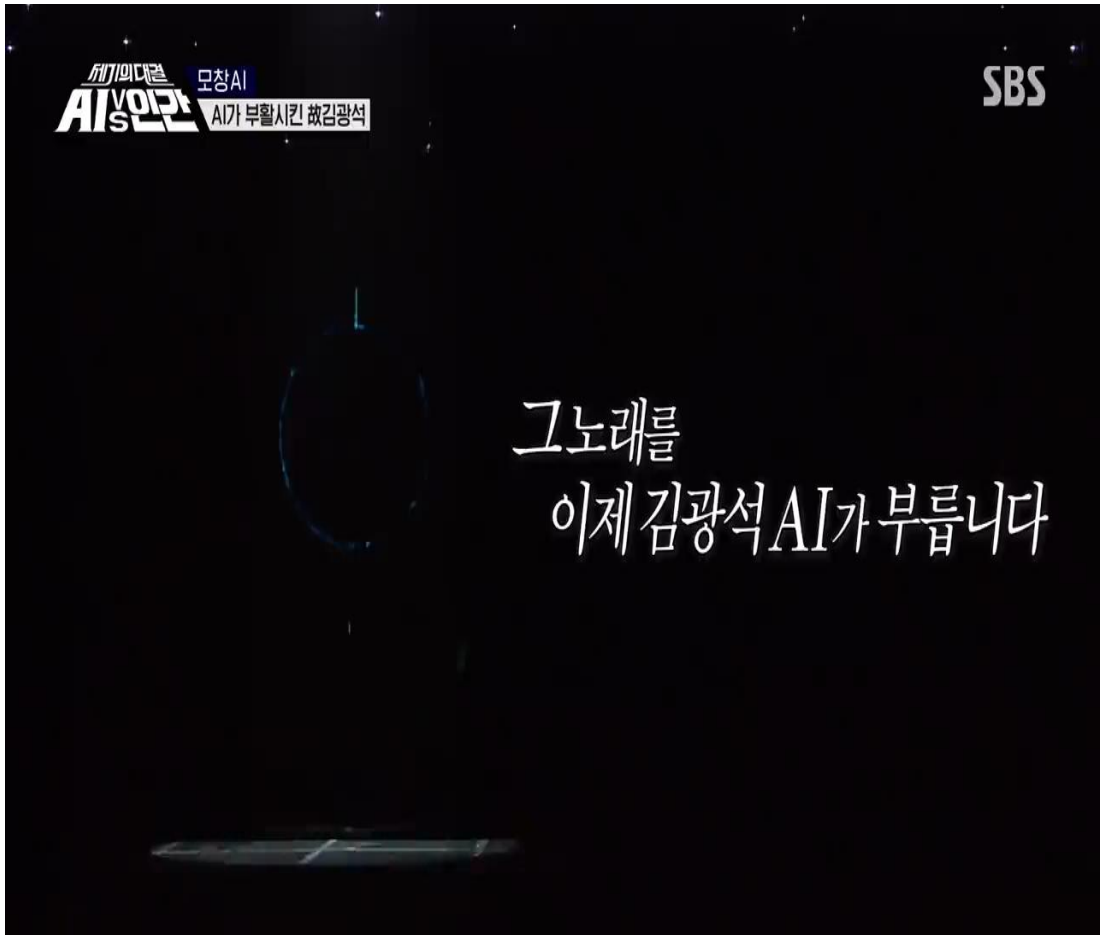


인공지능 분야_ 음성인식


음성인식: 소리를 의미로 바꾸는 과정
SPEECH RECOGNITION AI
(음성인식 인공지능)
SPEECH
(음성 입력)
TRANSCRIPTION
(텍스트 변환)
소리
음성역
인최
음성역
AI
딥러닝 분석
오늘 날씨는 어때?
(What's the weather today?)
현재 서울은 맑음, 24°C입니다.
결과
SPEECH RECOGNITION AI
(음성인식 인공지능)
소리를 텍스트로 바꾸는 과정
인식
분석
변환
결과 확인 & 실행

인공지능 분야_ 음성인식


AI 음악 프로젝트
다시 한번
Mnet
"그냥 저희 노래를 듣고
여러분들이 즐겁고
행복하면 좋겠습니다"


세기의 대결
AI vs 인간
모창AI
AI가 부활시킨 故김광석
SBS
그노래를
이제 김광석AI가 부릅니다

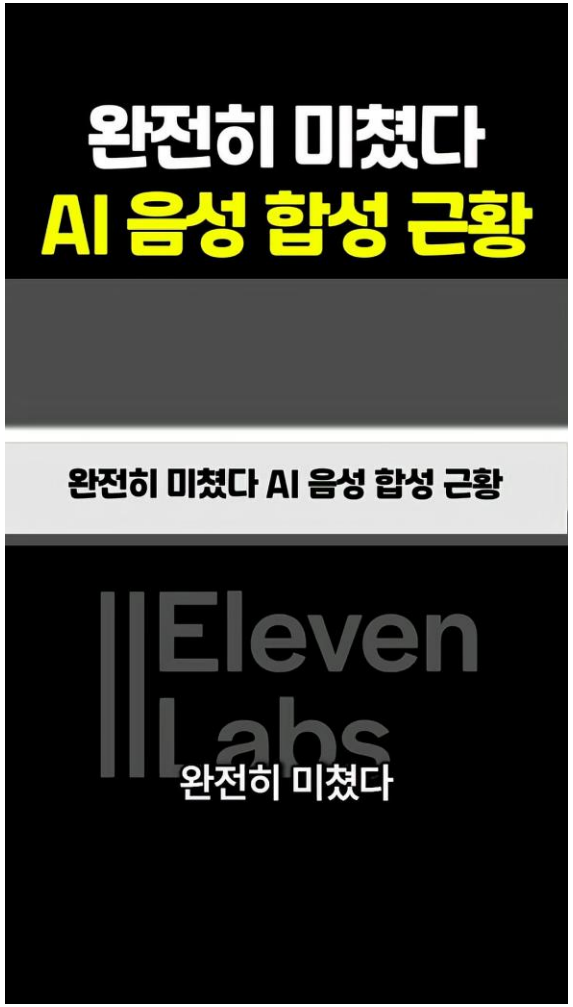
인공지능 분야_ 음성인식



인공지능 분야_ 음성인식

일레븐랩스: 텍스트를 자연스러운 사람 목소리로 바꿔주는 AI 음성 생성(Text-to-Speech)·보이스 클로닝 플랫폼/모델을 만드는 회사

: 한국에는 2025년 11월에 런칭





인공지능 분야_ 음성인식


아하
일본 연구진이 개발한 로봇 입은 실제 인간과 비슷한 물리적 구조를 통해 공기를 밀어내어 소리를 생성하며, 놀라울 정도로 인간과 유사한 말을을 만들어냅니다.

인공지능 분야_ 멀티모달

Sora+나노바나나+Kling AI(2026.01.20)

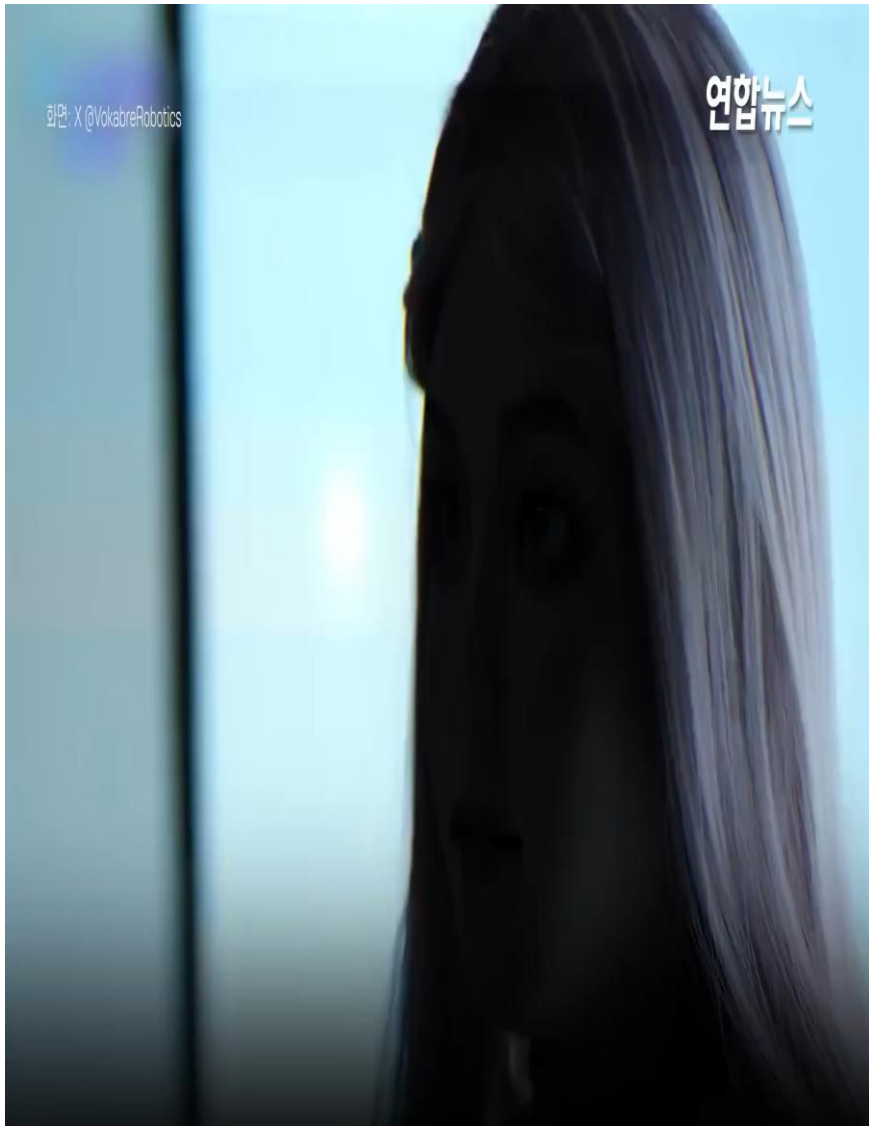


출처: Threads, choi.openai

인공지능 분야_ 멀티모달

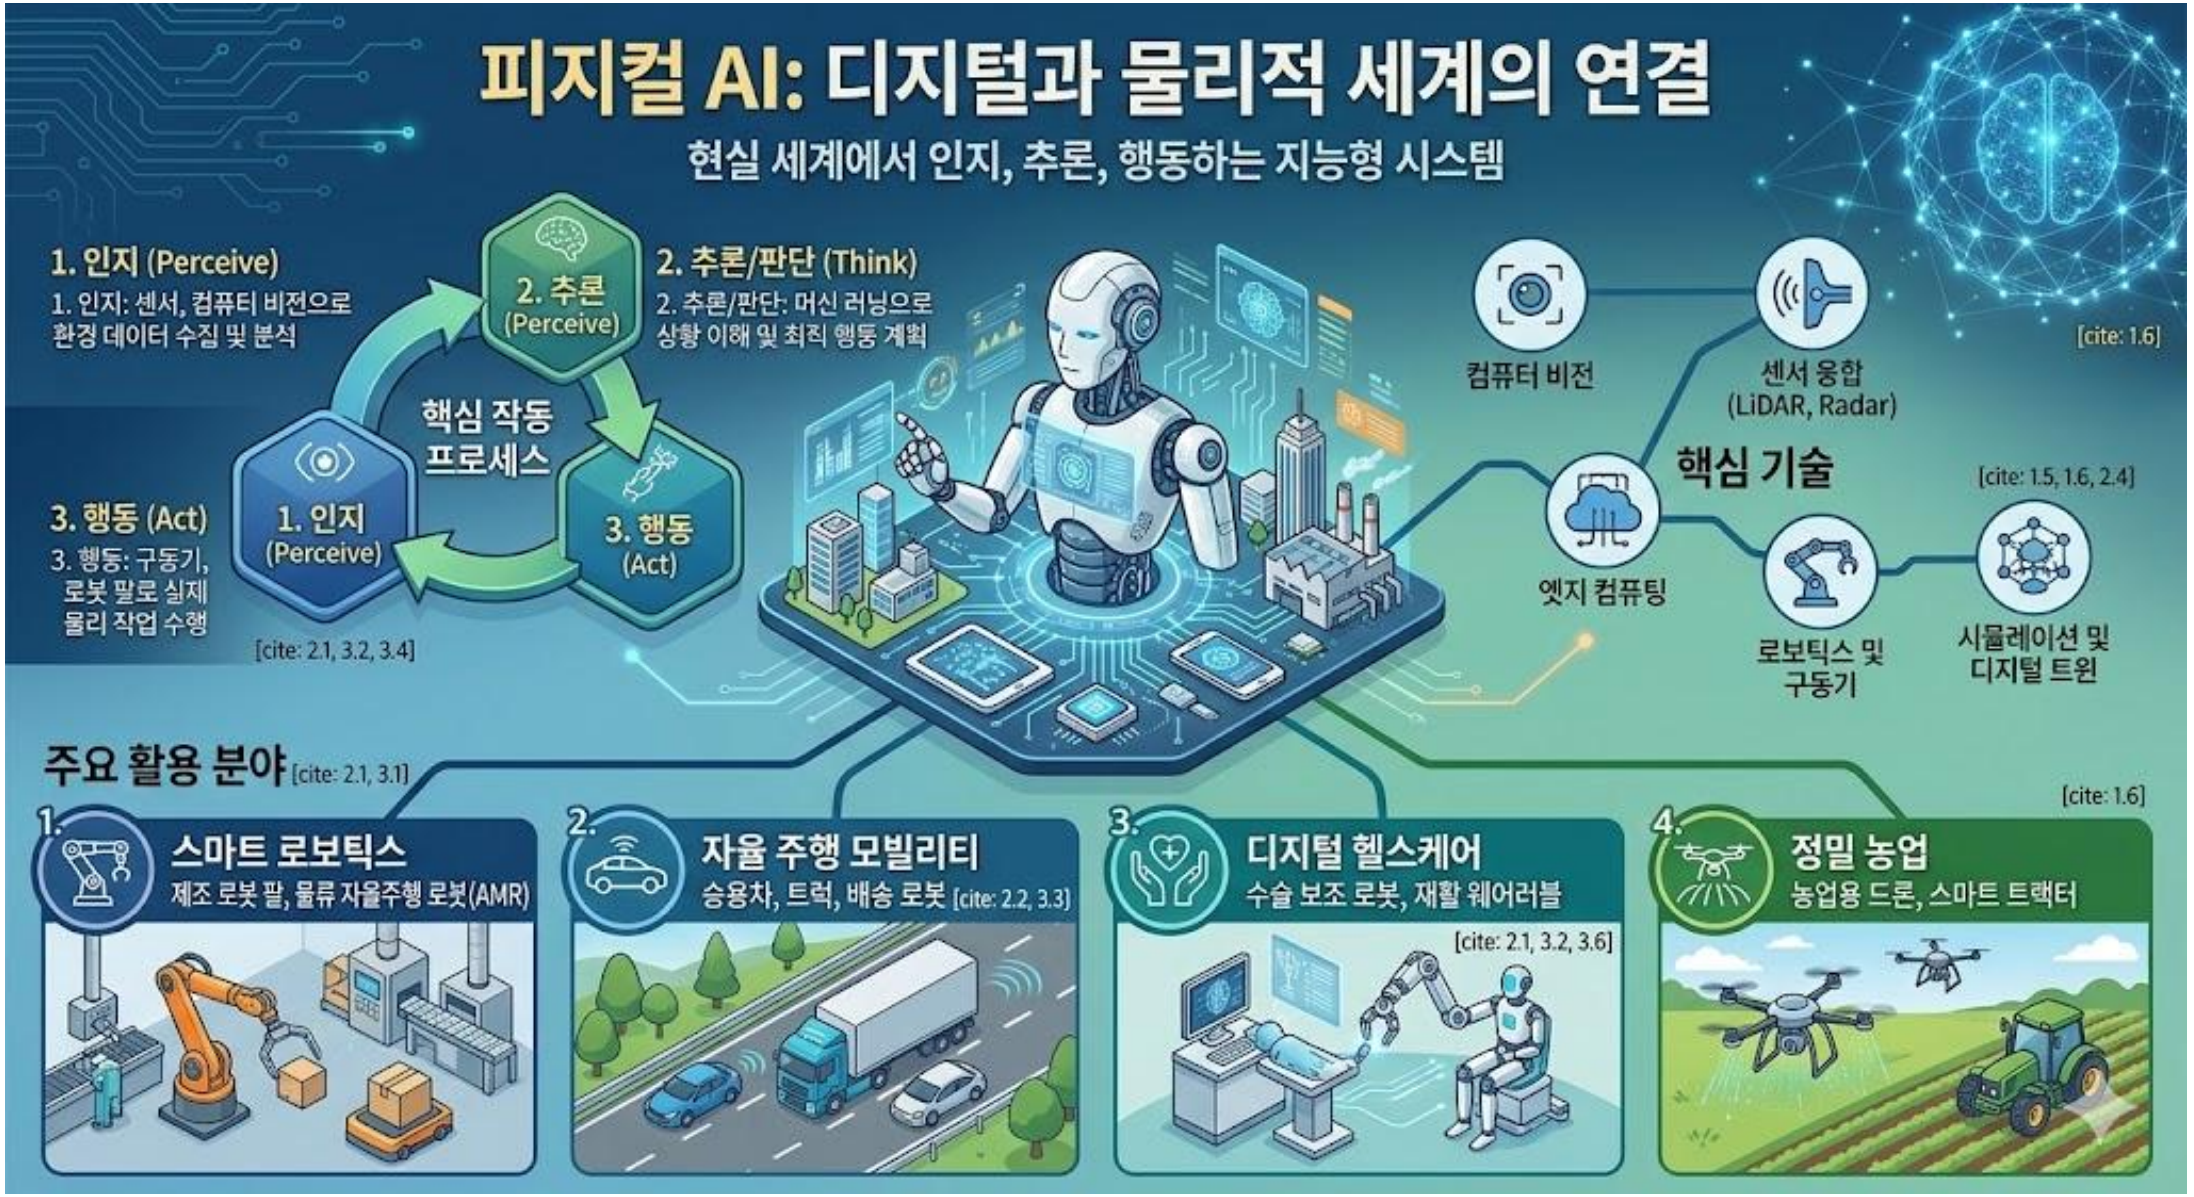


2026.02.25



2026.02.06

피지컬 AI


피지컬 AI: 디지털과 물리적 세계의 연결
현실 세계에서 인지, 추론, 행동하는 지능형 시스템
1. 인지 (Perceive)
1. 인지: 센서, 컴퓨터 비전으로 환경 데이터 수집 및 분석
2. 추론/판단 (Think)
2. 추론/판단: 머신 러닝으로 상황 이해 및 최적 행동 계획
3. 행동 (Act)
3. 행동: 구동기, 로봇 팔로 실제 물리 작업 수행
2. 추론 (Perceive)
1. 인지 (Perceive)
3. 행동 (Act)
핵심 작동 프로세스
[cite: 2.1, 3.2, 3.4]
[cite: 1.6]
컴퓨터 비전
센서 융합 (LiDAR, Radar)
핵심 기술
[cite: 1.5, 1.6, 2.4]
엣지 컴퓨팅
로보틱스 및 구동기
시뮬레이션 및 디지털 트윈
주요 활용 분야 [cite: 2.1, 3.1]
[cite: 1.6]
1. 스마트 로보틱스
제조 로봇 팔, 물류 자율주행 로봇(AMR)
2. 자율 주행 모빌리티
승용차, 트럭, 배송 로봇 [cite: 2.2, 3.3]
3. 디지털 헬스케어
수술 보조 로봇, 재활 웨어러블
[cite: 2.1, 3.2, 3.6]
4. 정밀 농업
농업용 드론, 스마트 트랙터

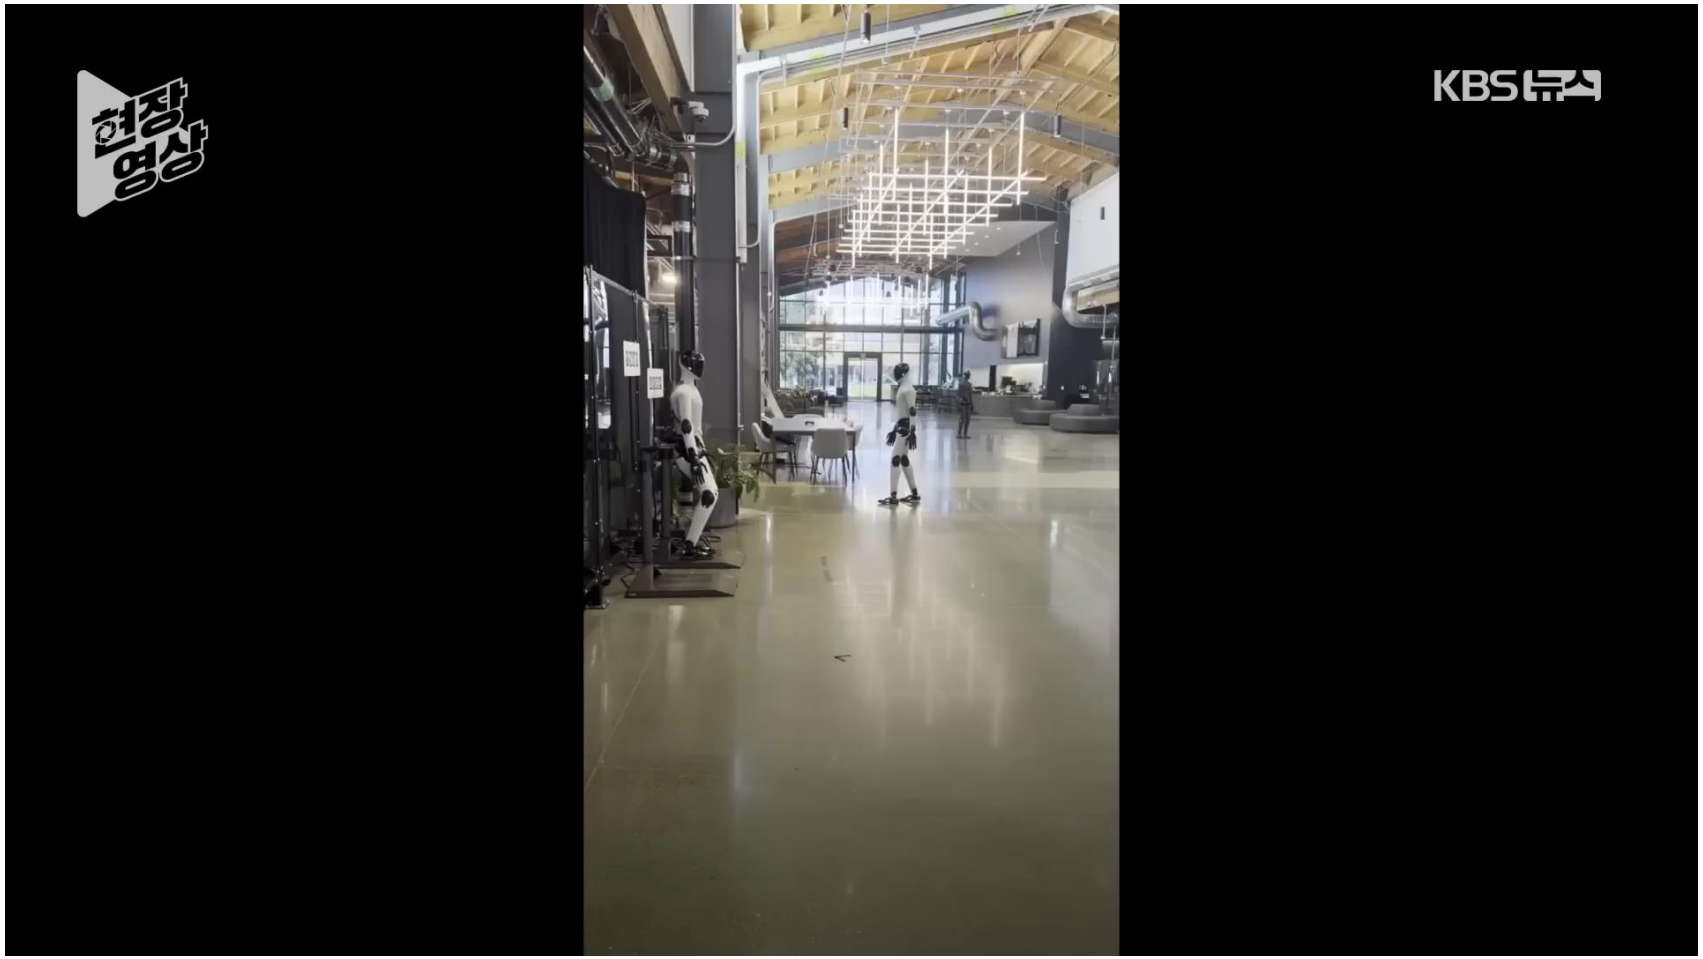
휴머노이드 로봇

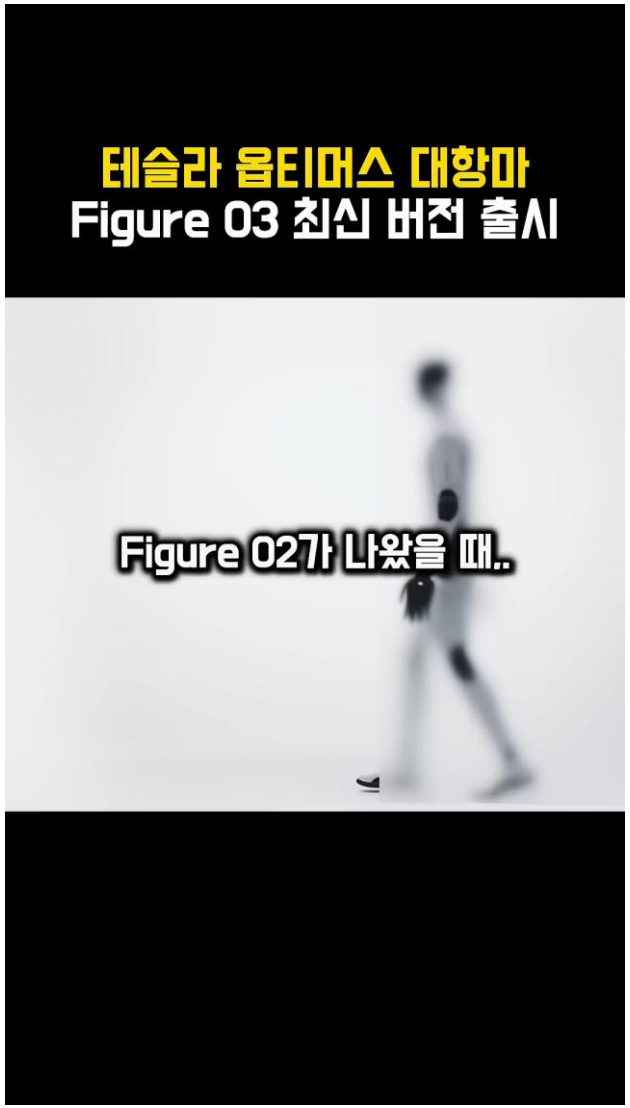

이제는 진짜로


쇼츠백과
SHORTS
ENCYCLOPEDIA
누가 봐도 100%
"메이드 인 코리아" 로봇!!
자 준비 하시고!
현재 K-뽕짝 리듬을
갈아넣은듯한 무브로 화제인 로봇


테슬라 옵티머스
CG가 아닙니다
1x Speed
오늘의 테슬라 뉴스

휴머노이드 로봇





2026.02.27

휴머노이드 로봇

2026.03.17 중국 칭화대에서 개발한 테니스 플레이어 로봇

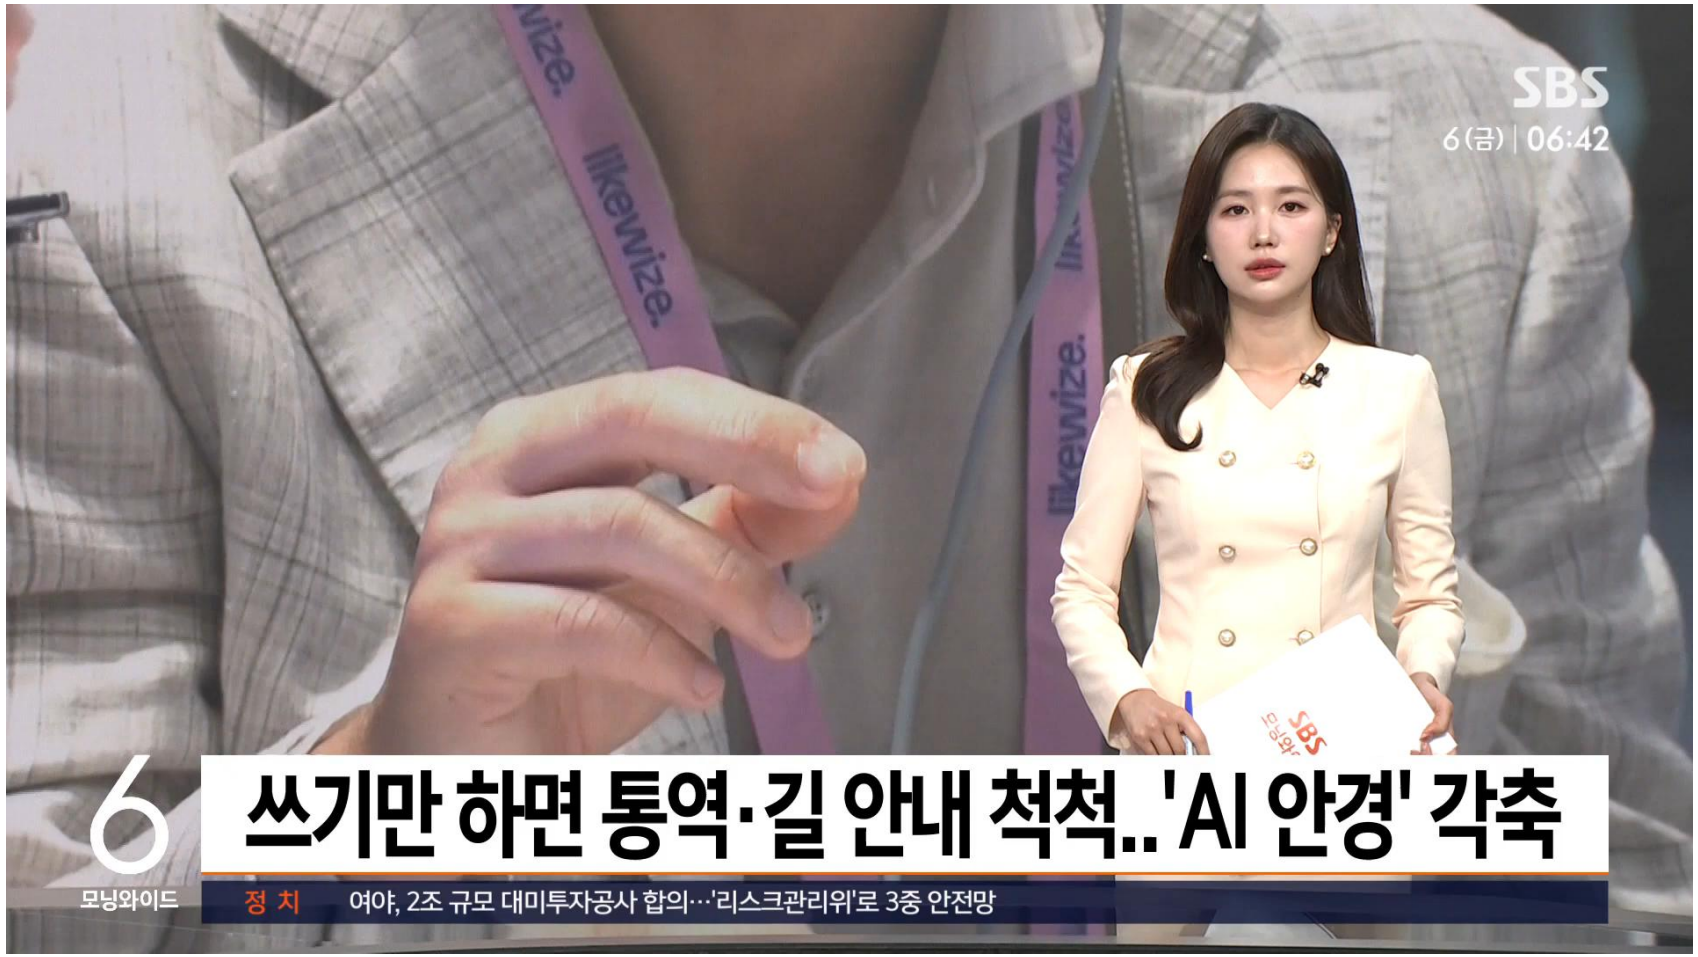


휴머노이드 로봇



2026.01.19

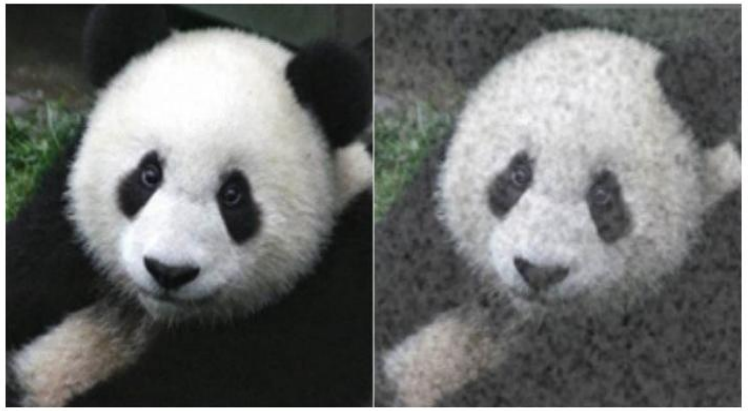
휴머노이드 로봇



2026.03.06

인공지능의 한계점



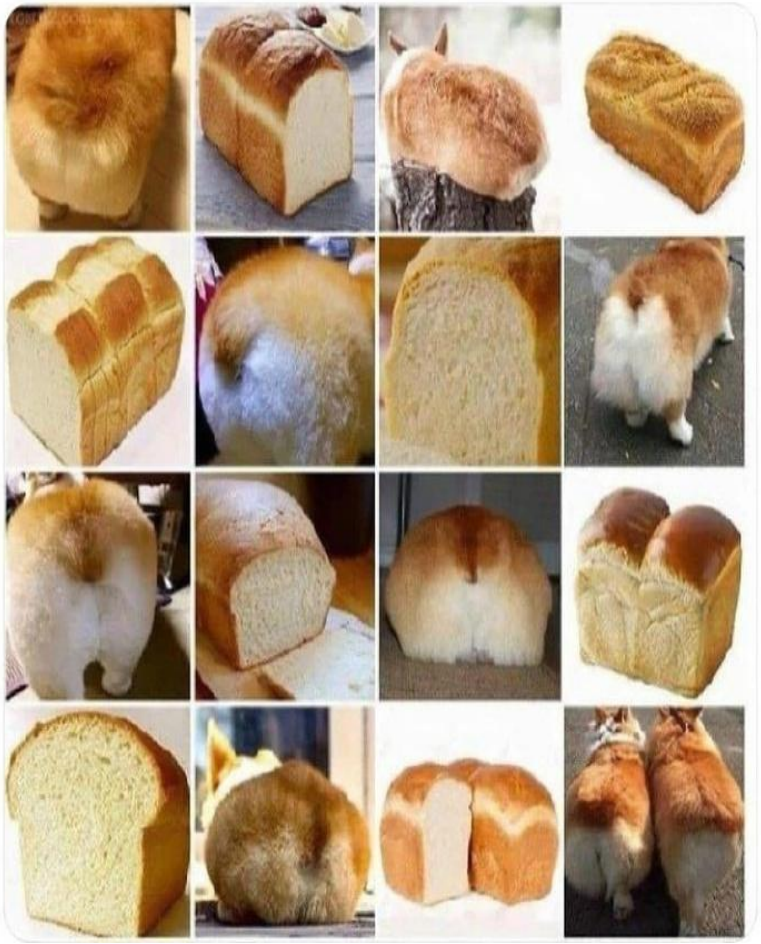


일반적인 판다 사진(왼쪽)에 노이즈를 삽입하게 되면(오른쪽), 사람은 그대로 판다로 인식하지만, AI는 긴팔원숭이로 잘못 인식하기도 한다.



출 처 : m.post.naver.com/viewer/postView.nhn?volumeNo=17875379&memberNo=39046504

인공지능의 한계점







인공지능의 한계점

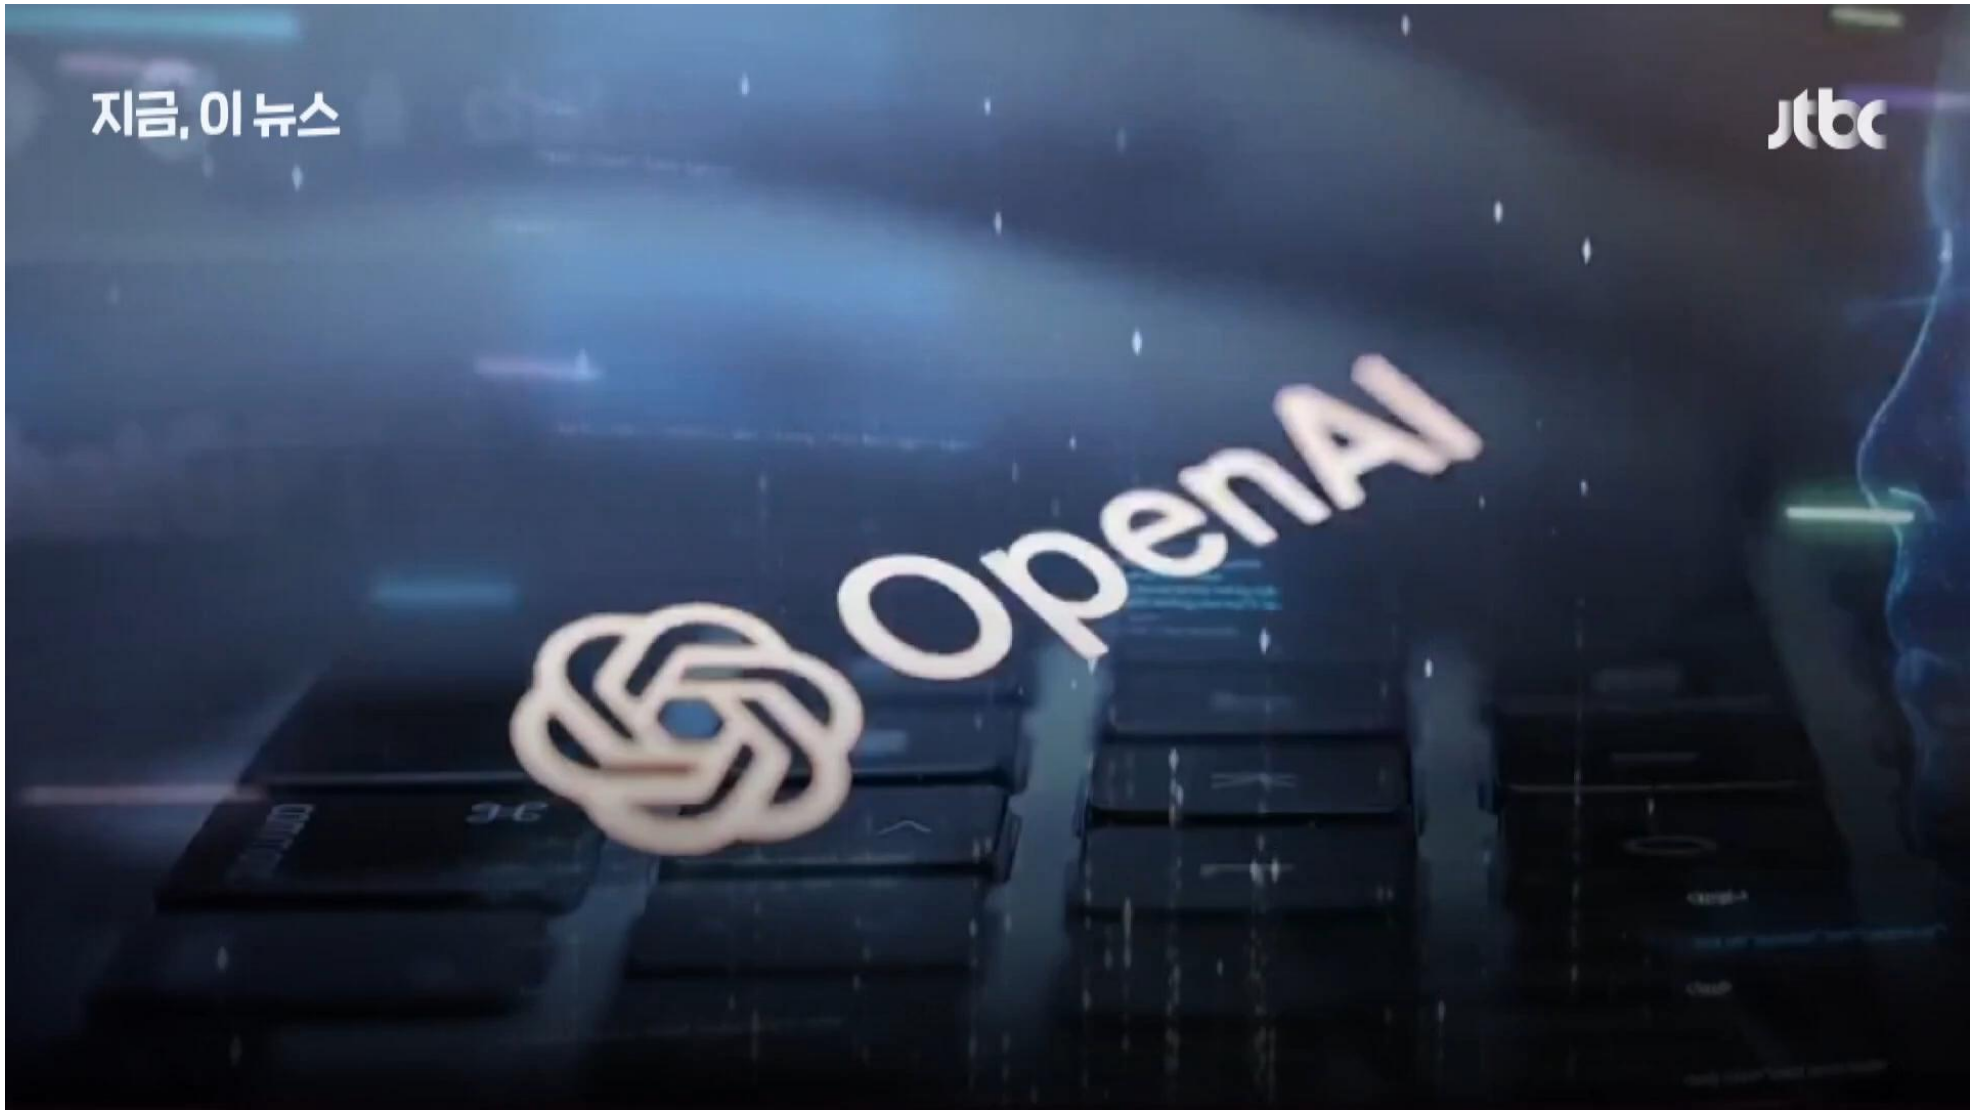

Saruman


dboink.com


Verizon LTE
3:02 PM
42%
Albums
sheepdog or mop
Select

인공지능_부작용

2025.11.27



인공지능_부작용

2025.05.16



인공지능_부작용

2025.12.04



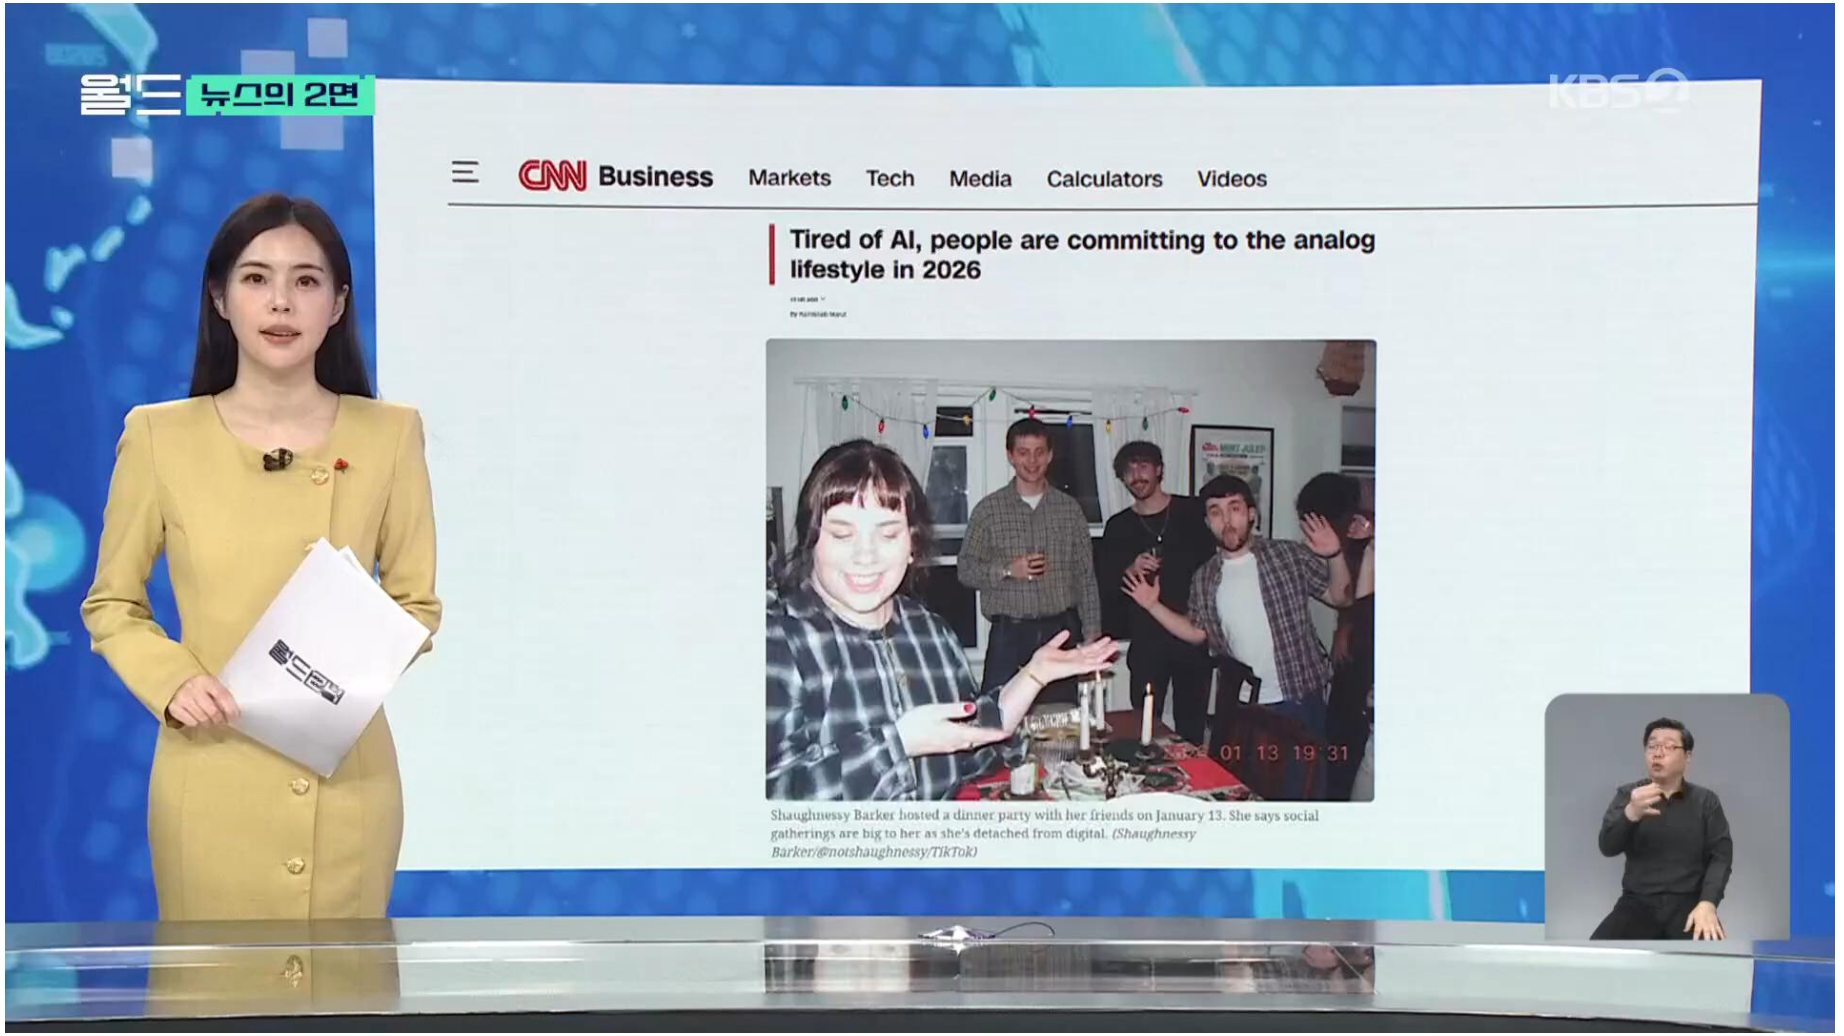
인공지능_부작용

2026.03.08

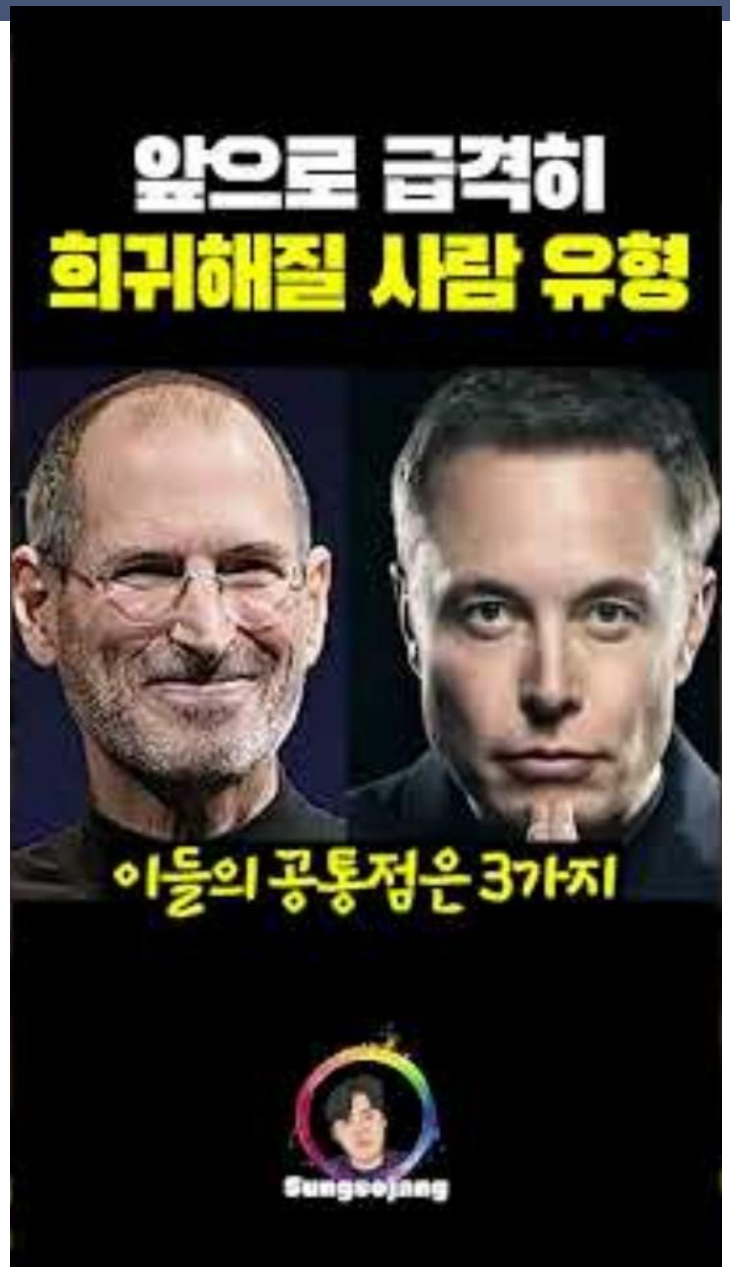


인공지능_부작용

2025.01.19



인공지능_ 요구사항

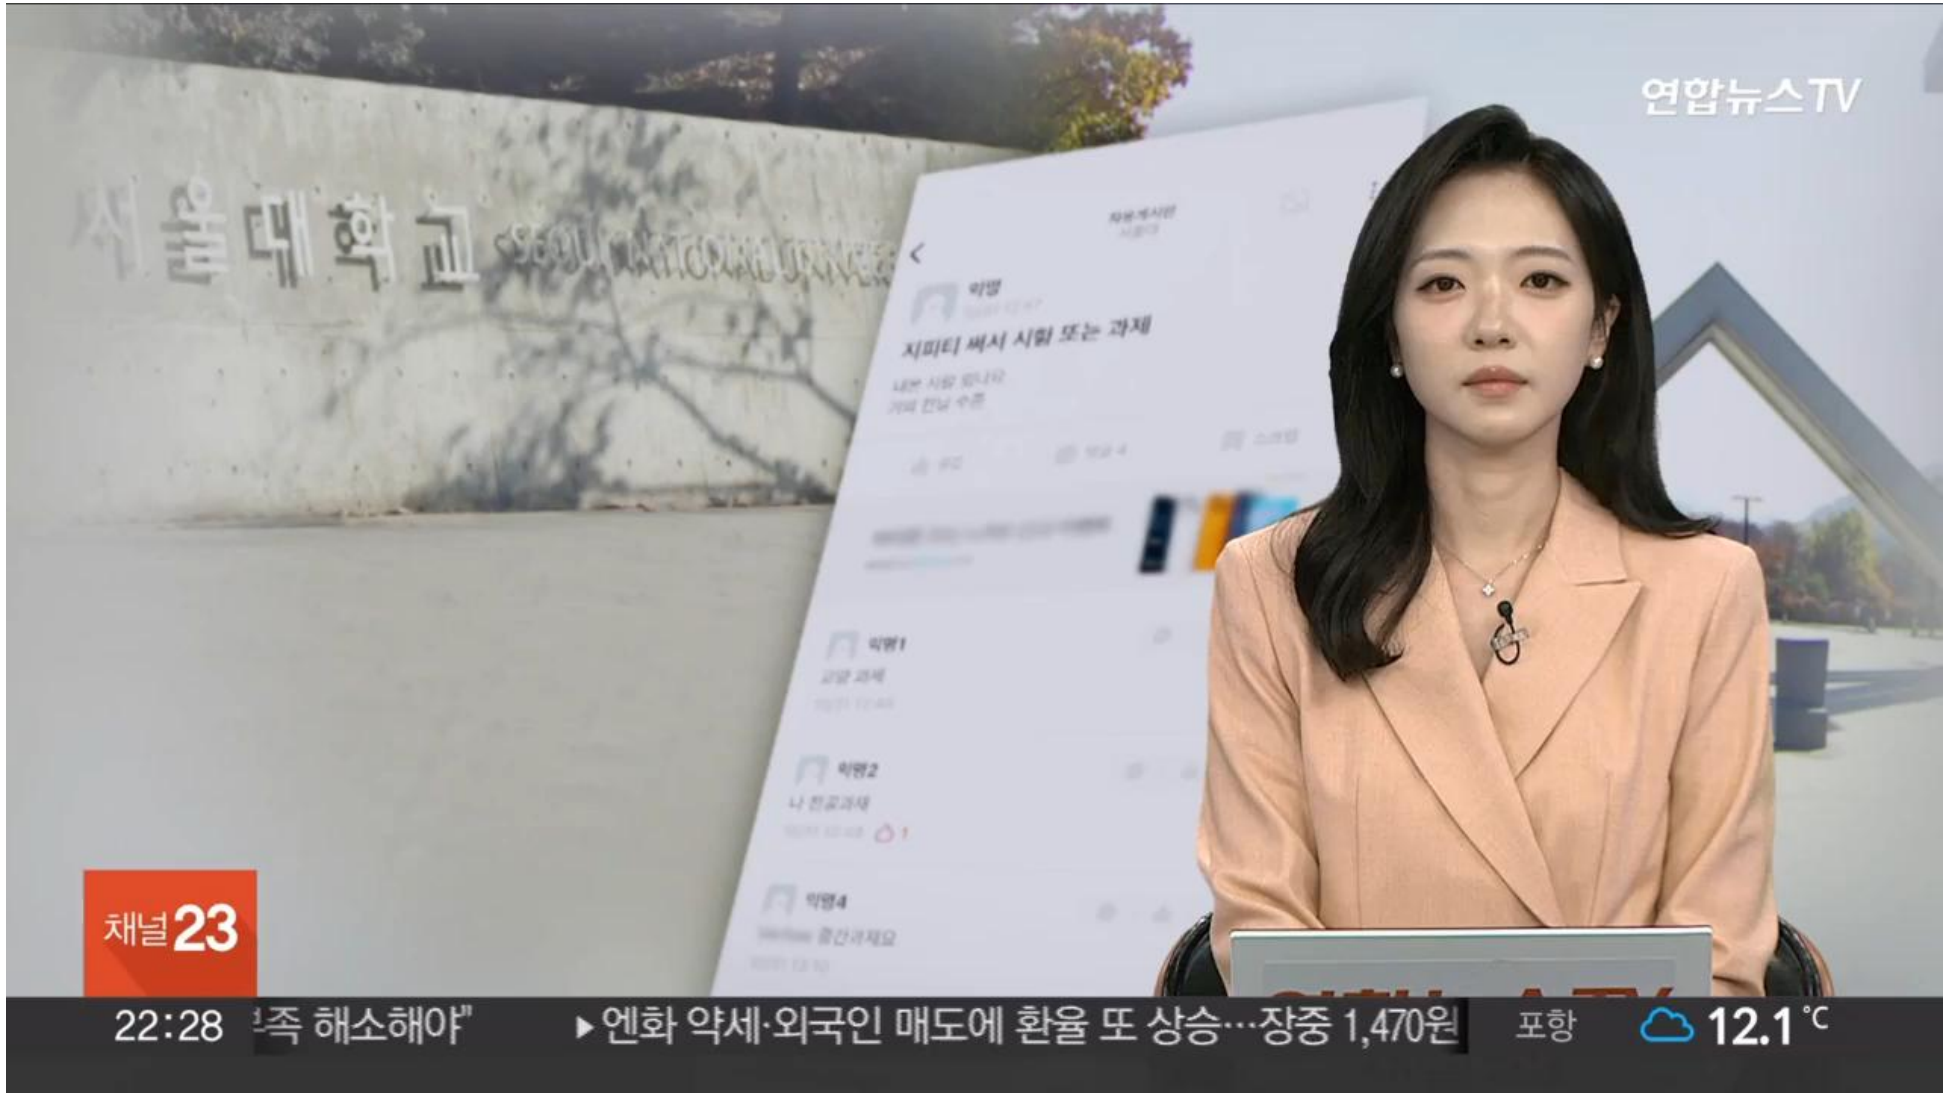


인공지능_요구사항

2026.03.03

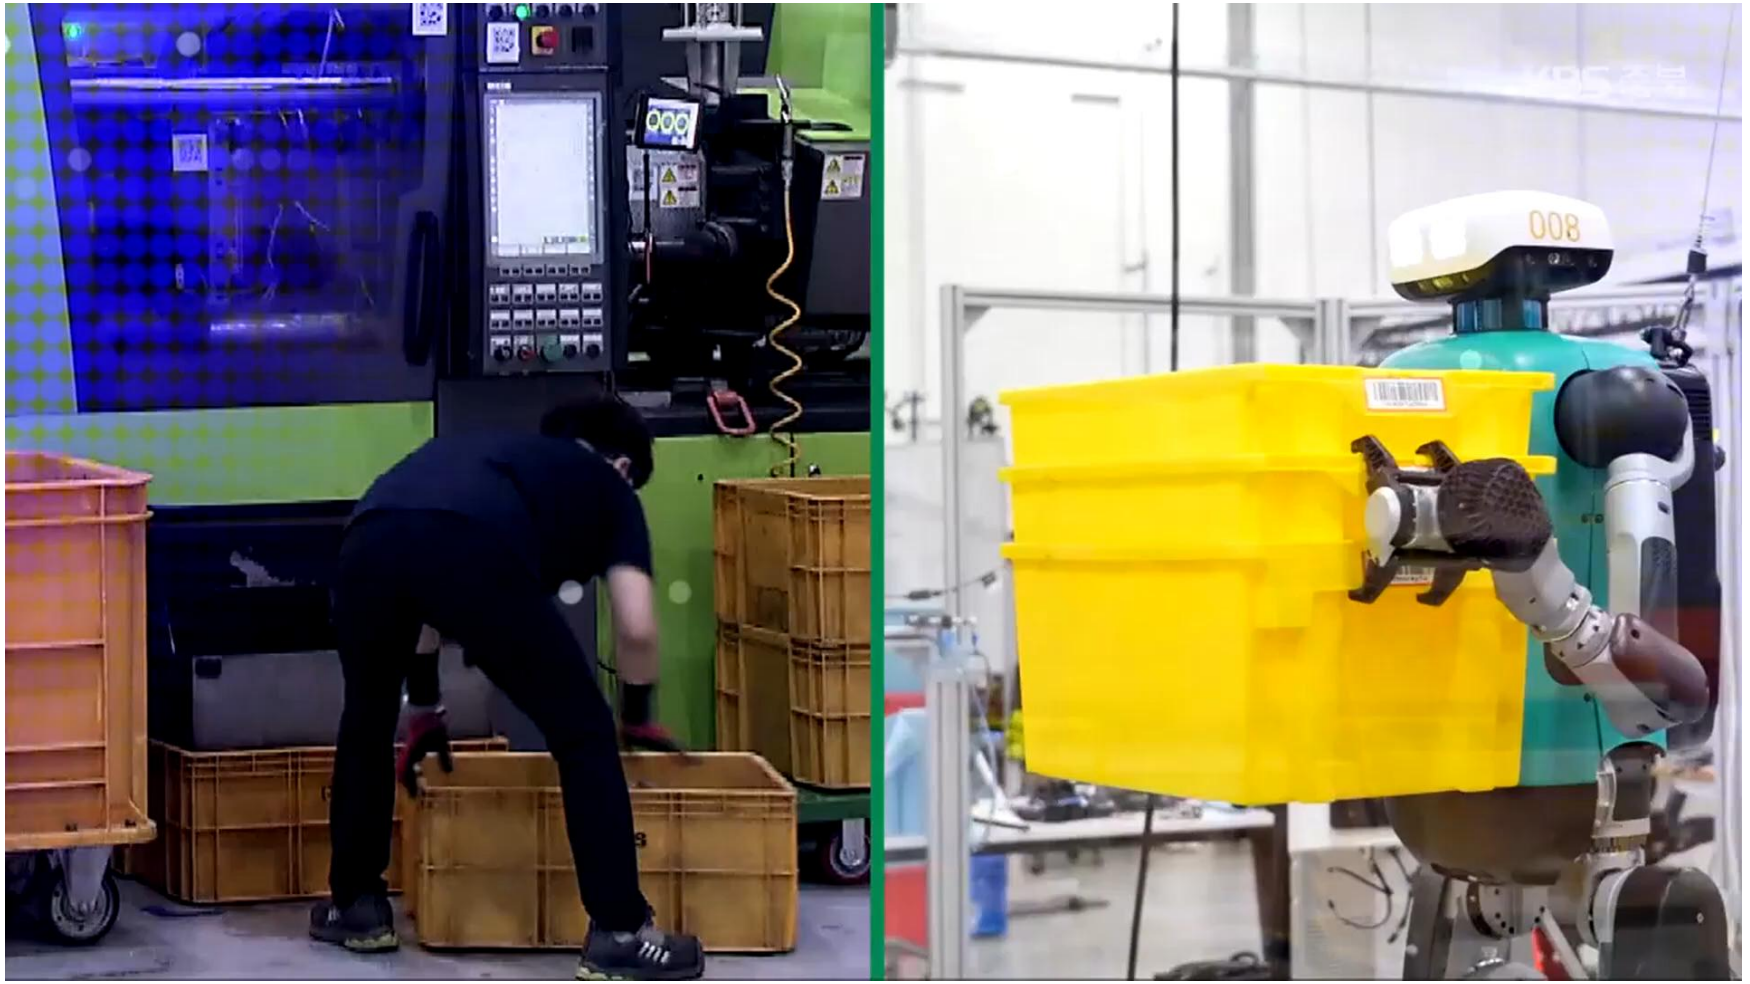


인공지능의 윤리


연합뉴스TV
서울대학교
채널23
22:28
해소해야"
▶엔화 약세·외국인 매도에 환율 또 상승…장중 1,470원
포항
12.1℃

인공지능의 윤리

‘인공지능 대부’ 제프리 힌튼 단독 인터뷰…“인간 대체할 것” / KBS 2025.11.20.



인공지능의 윤리

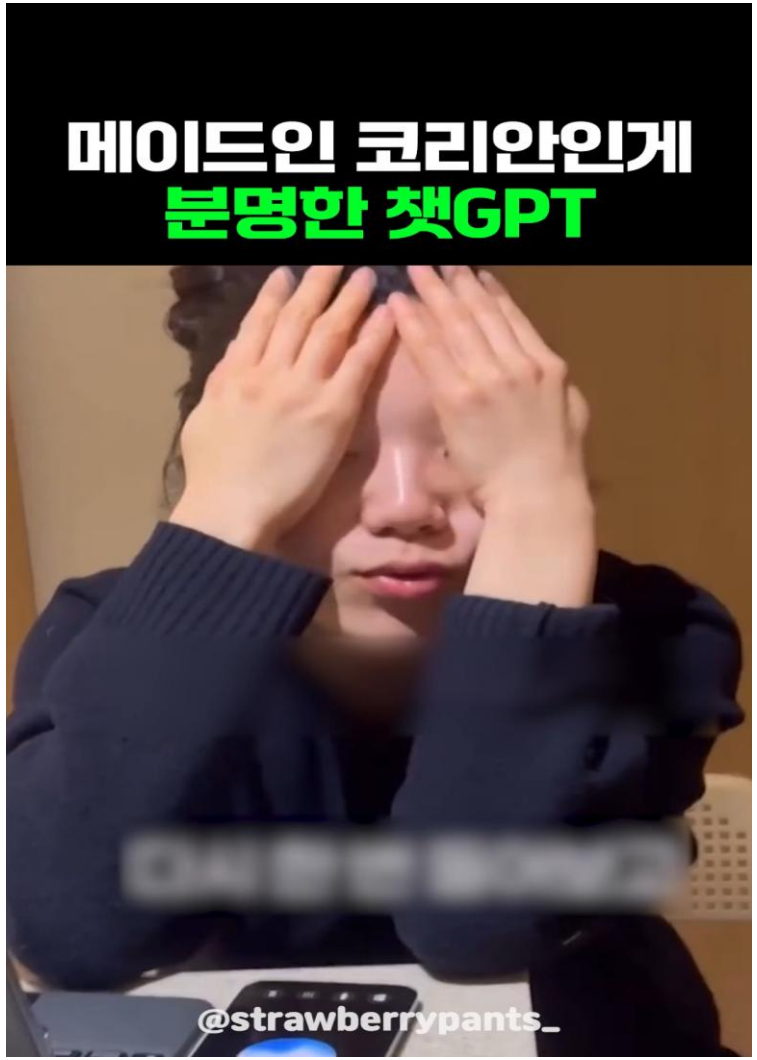
2026.01.11



개그


100% 흥행 보장
AI로 만든 메디컬 영화


미친(n)
GPT 사용법
이 스마트한 도구를
써보도록
조코딩


메이드인 코리안인게
분명한 챗GPT
@strawberrypants_

AI 툴 생태계


생성형 AI 툴 생태계 - 목적별 총정리
당신의 목적에 맞는
완벽한 AI 도구를 찾아보세요!
생성형 AI
툴 생태계
- 목적별 총정리
글쓰기 & 콘텐츠 생성
긴 글/블로그
Jasper
Copy.ai
마케팅/카피라이팅
Writesonic
Writesonic
문법/교정
Grammarly
QuillBot
요약/분석
Notion AI
Sudowrite
생산성 & 오피스
미팅 기록/요약
Otter.ai
Fathom
문서 작성
Microsoft Copilot
Google Gemini in Workspace
프레젠테이션
Gamma.app
Tome
작업 관리
Asana AI
Monday.com
이미지 & 예술 생성
고품질 이미지
Midjourney
DALL-E 3
다양한 스타일
Stable Diffusion
Leonardo.ai
디자인 편집
Canva AI
Adobe Firefly
사진 보정
Topaz Photo AI
Remini
코딩 & 프로그래밍
Copilot
자동 완성
GitHub Copilot
Tabnine
코드 설명
ChatGPT
Replit AI
디버깅
Sentry AI
Cursor
영상 & 오디오 생성
영상 편집
CapCut AI
Opus Clip
아바타/비디오
HeyGen
Synthesia
목소리 녹음/더빙
ElevenLabs
Lovo
음악 생성
Suno
Loudly
연구 & 정보 검색
문헌 검색
Perplexity
Elicit
데이터 분석
Polymer
ChatGPT with Advanced Data Analysis
언어 번역
DeepL
Google Translate
이것은 예시이며, 계속해서 새로운 AI 툴들이 등장하고 있습니다.



Youngpyo Ryu. All rights reserved.
Unauthorized reproduction or distribution is prohibited.