Regression

Regression Analysis

류영표 강사
ryp1662@gmail.com



© 2025 Youngpyo Ryu. All rights reserved.
Unauthorized reproduction or distribution is prohibited.

류 영 표

AI & Applied Mathematics Researcher · Lecturer

ryp1662@gmail.com
github/youngpyoryu



학력

- 동국대학교 일반대학원 응용수학 석사 수료 (2016-2019)
- 동국대학교 수학과 졸업 (2010-2016)

심사 및 전문가 자문 활동

- 인공지능 학습용 데이터 구축 사업 품질검증 전문가 자문위원 (2023)
- 2023 신뢰할 수 있는 인공지능 개발 안내서(안)_고도화 전문위원
- 2023 자율주행/의료/공공사회 분야 신뢰할 수 있는 인공지능 개발 안내서(안) 자문위원

연구 및 프로젝트

- 부산대학교 병원: 개인 맞춤형 당뇨병 예방·관리 인공지능 시스템 외주 프로젝트 (2022)
- 연세대학교 병원: 영상의학과 FLASK 고도화 연구 (2023, 2024)
- 산업수학 스터디 그룹 (국가수리과학연구소): 피부암/유방암 분류, 유전자 정보 분석
- 폐플라스틱 이미지 객체 검출 경진대회 3위 (2021)
- 동국대학교 수학과 연구원(2025.10 ~ / 양자 AI, XAI 연구 진행 중)

논문

- Quantum computing for the optimization of CT image reconstruction, IEEE ICTC 2022

강의 및 교육 활동

대학 강의

- 고려대학교, 인천대학교, 동양미래대학교, 목포대학교
- 이젠 아카데미: 파이썬/ADSP 과정

기업 교육

- 현대자동차 연구원
- 한화, 하나금융, 한전 KDN, IBK 기업은행, 아가방앤컴퍼니, IM증권

공공/국비 과정

- LG 헬로비전 DX 데이터 스쿨 (4기)
- 보건·바이오 AI 활용 전문가 양성과정 (1-3기)
- 공공데이터 청년 인턴 멘토
- 충청 ICT 취창업 역량강화 프로그램 (SQLD)
- 서울아이티고등학교

아카데미 & 부트캠프

- 모두의연구소 Aiffel 퍼실리테이터 (1기)
- Upstage AI Boostcamp 멘토 (1-6기)
- 패스트캠퍼스/멀티캠퍼스 조교 및 멘토
- 공개SW개발자대회 멘토

회귀 분석이란?

- 한번 돌아(일주하여) 원래로 돌아오는 것.
- 선형 분석은 영국의 유전학자 Francis Galton이 유전의 법칙을 연구하다 나온 것에 기인됨.
- 연구의 내용은 부모와 자녀의 키 사이의 관계였는데, 아버지와 어머니의 키의 평균을 조사하여 표로 나타낸 결과 자녀의 키는 엄청 크거나 작은 것이 아닌 그 세대의 평균으로 돌아가려는 경향이 있다는 것을 발견 → Galton은 이를 회귀분석이라고 함.

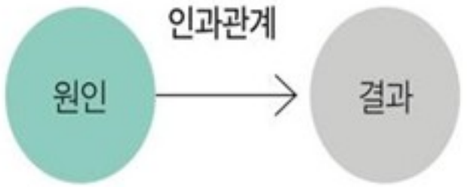
- 하나나 그 이상의 독립변수들이 종속변수에 미치는 영향을 추정할 수 있는 통계기법
- 변수들 사이의 인과관계를 밝히고 모형을 적합하여 관심있는 변수를 예측하거나 추론하기 위한 분석방법
- 종속변수와 독립변수 간에 선형관계가 존재하는지 알 수 있다.
- 종속변수에 영향을 미치는 독립변수가 유의 한지와 영향력의 정도를 알 수 있다.
- 추정된 회귀모형을 통해 종속변수의 예측치를 알 수 있다.

상관관계 VS 인과관계

상관관계	인과관계
두 변수 간 선형적 또는 비선형적 관계	하나의 사건이 다른 사건을 일으킬 때 그 두 사건의 관계



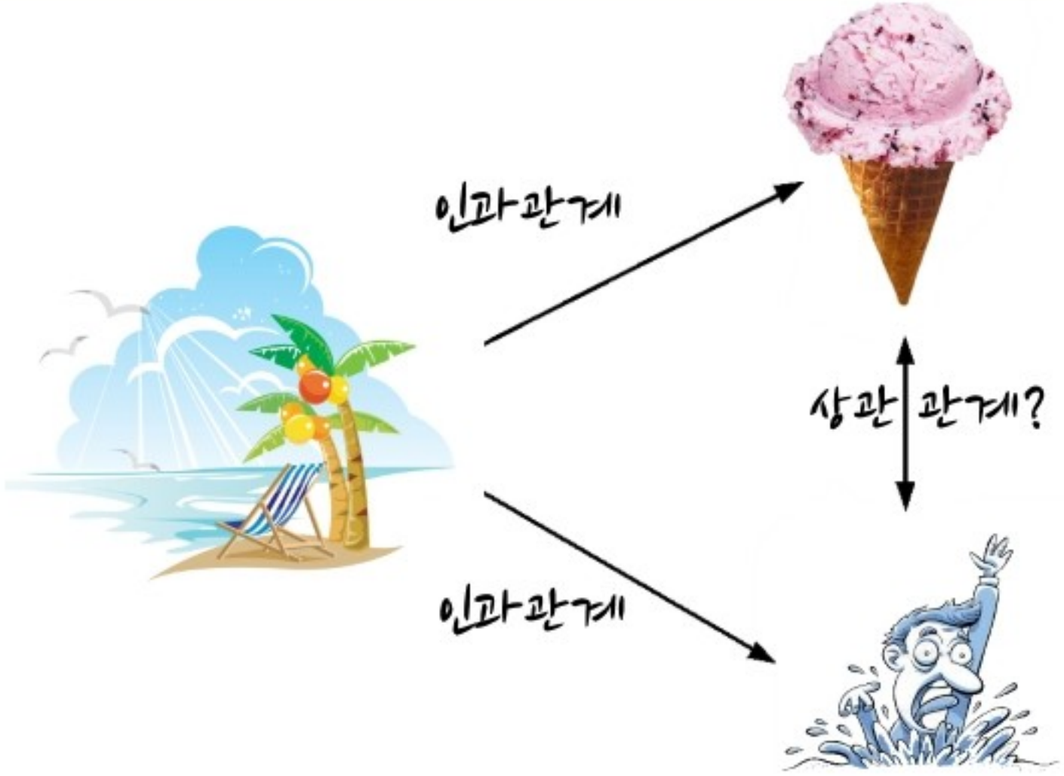
원인과 결과의 관계가 아니다.



원인이 있었기 **때문에** 결과가 생겨났다.





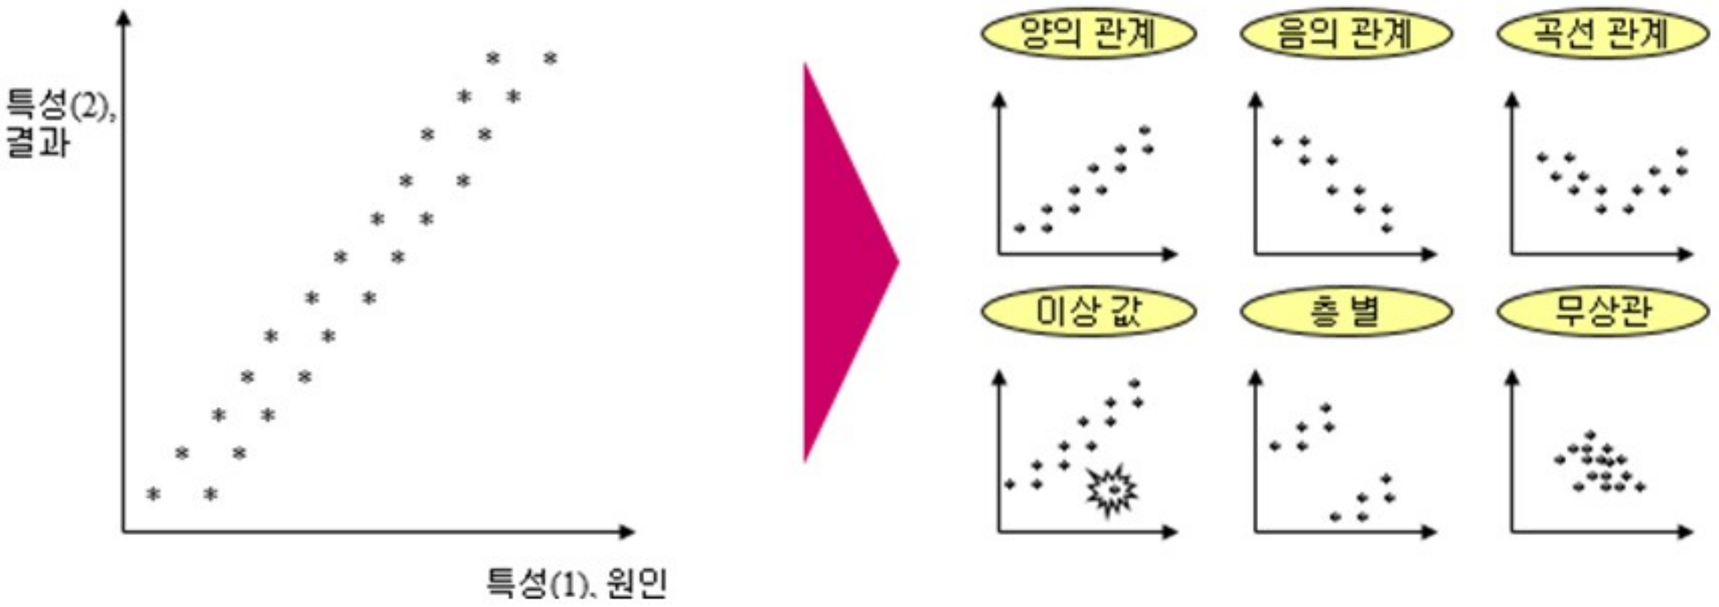


출 처 : https://www.wadiz.kr/web/campaign/detail/119644

산점도(Scatter Diagram)

- 두 종류의 특성을 동시에 측정하여 수집된 데이터의 특징을 보고

  두 특성 간에 어떠한 관계가 있는지를 파악하여 상관관계 도출.



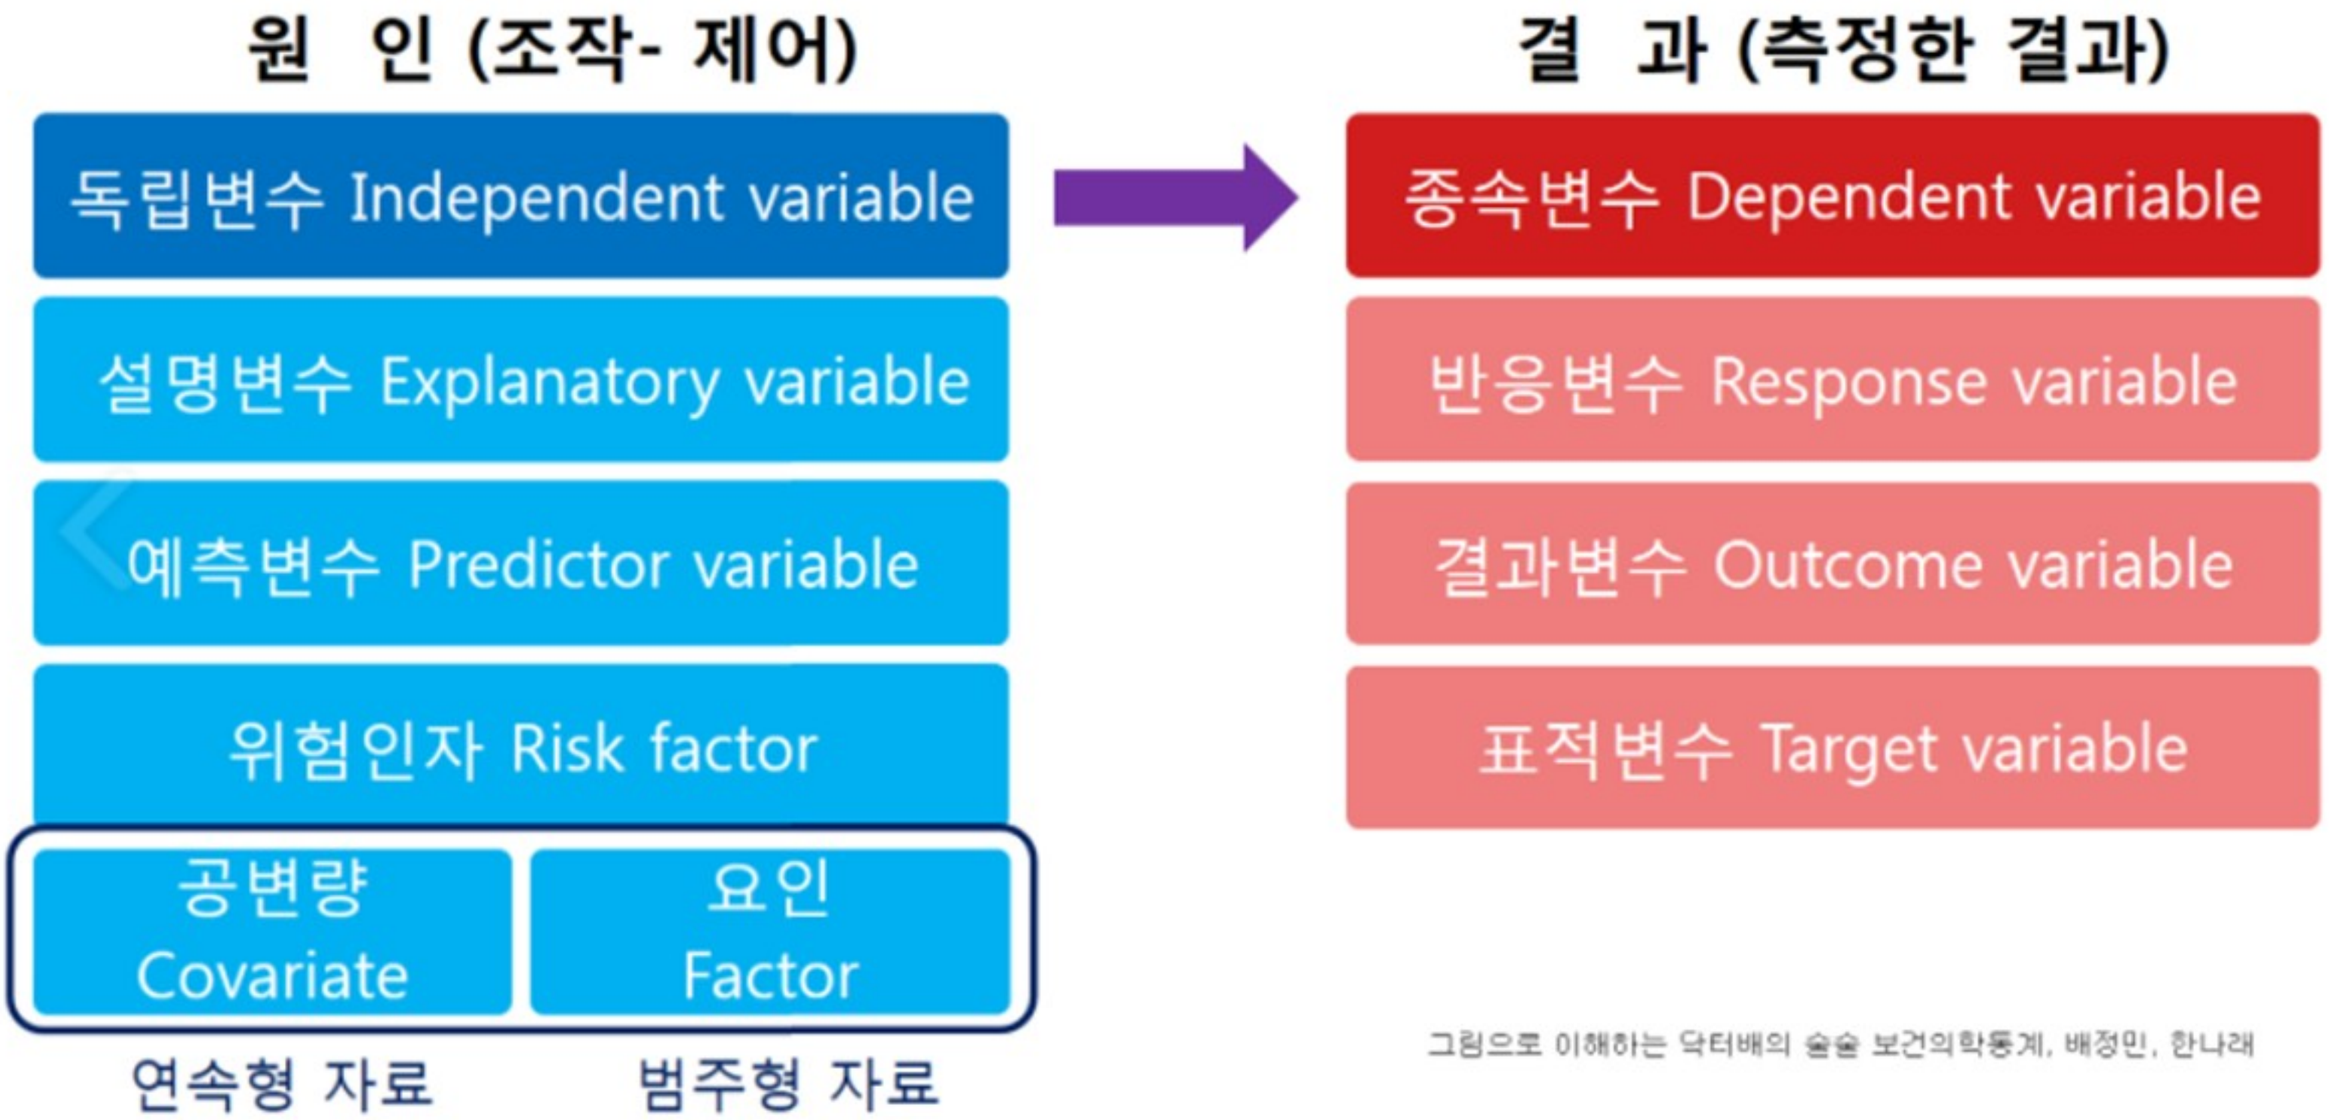
출 처 : https://m.blog.naver.com/PostView.naver?isHttpsRedirect=true&blogId=kvmcert&logNo=221413569303

데이터 유형



출 처 : https://medium.com/process-in-9-steps/%EB%8D%B0%EC%9D%B4%ED%84%B0-data-%EC%9D%98-%EC%A2%85%EB%A5%98-a9a4b7e21169

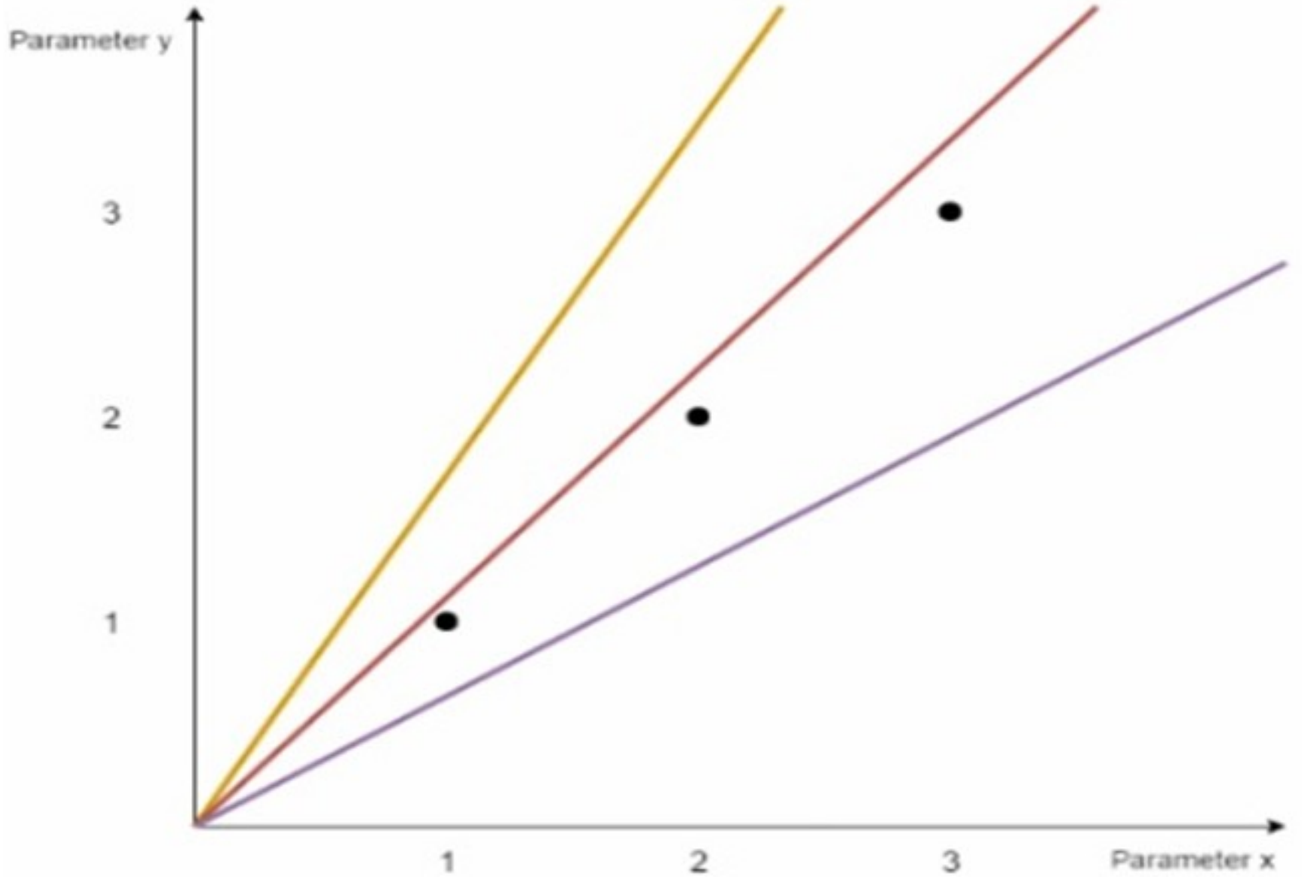
독립변수와 종속 변수



그림으로 이해하는 닥터배의 술술 보건의학통계, 배정민, 한나래

선형회귀의 목표

- 우리가 학습한 데이터를 통계로 어떤 임의의 점이 평면 상에 그려졌을 때 최적의 선형 모델(선)을 찾는 것이 목표.



회귀(Regression)

- 회귀는 여러 개의 독립변수와 한 개의 종속변수 간의 상관관계를 모델링 하는 기법을 통칭



$$Y = W_1X_1 + W_2X_2 + W_3X_3 + \cdots + W_nX_n$$

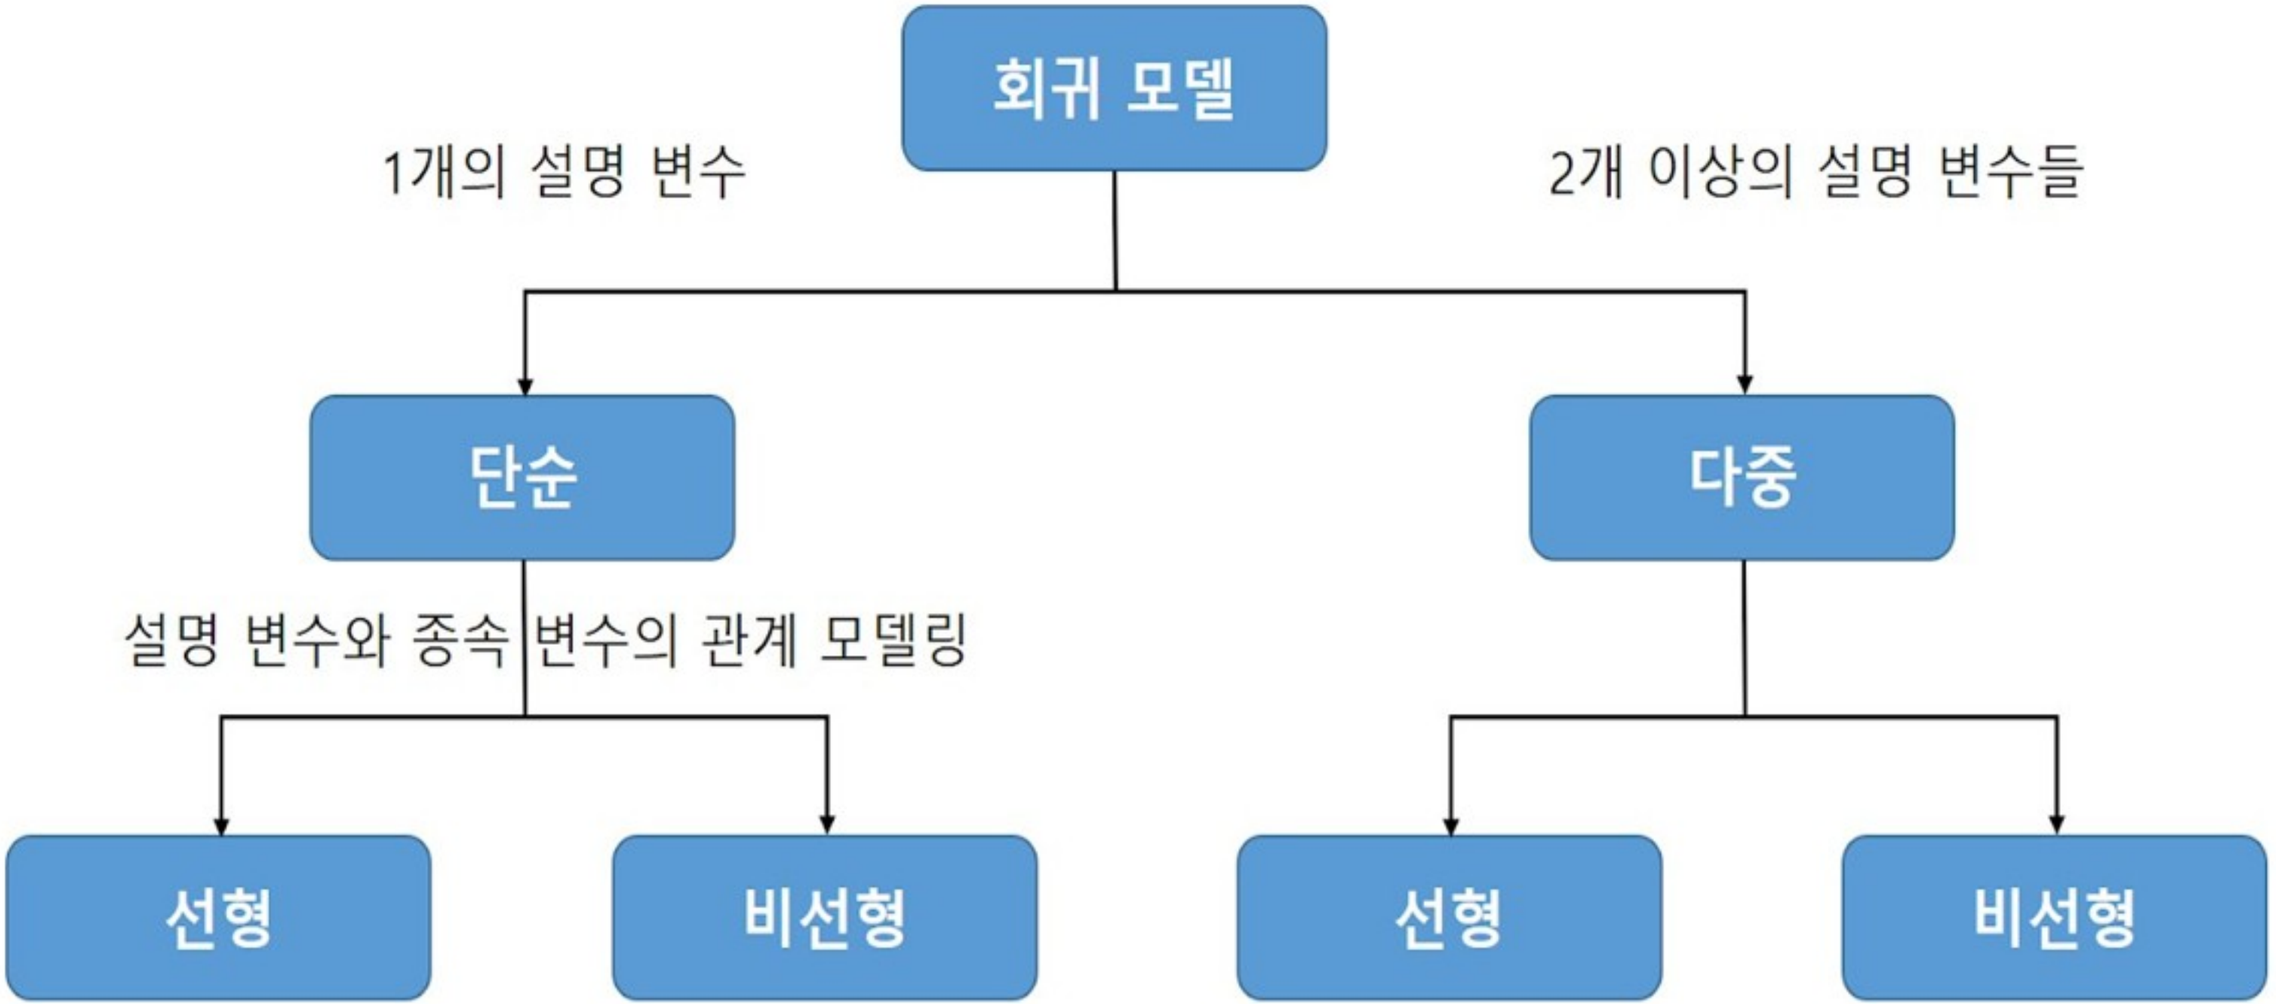
Y는 종속변수, 아파트 가격

$X_1, X_2, X_3 \cdots, X_n$ 은 방 개수, 아파트 크기, 주변 학군 등의 독립변수

$W_1, W_2, W_3 \cdots, W_n$ 은 이 독립변수의 값에 영향을 미치는 회귀 계수(Regression coefficients)

머신러닝 회귀 예측의 핵심은 주어진 피쳐와 결정 값 데이터 기반에서 학습을 통해 최적의 회귀 계수를 찾아내는 것

회귀의 유형


회귀 모델
1개의 설명 변수
2개 이상의 설명 변수들
단순
다중
설명 변수와 종속 변수의 관계 모델링
선형
비선형
선형
비선형

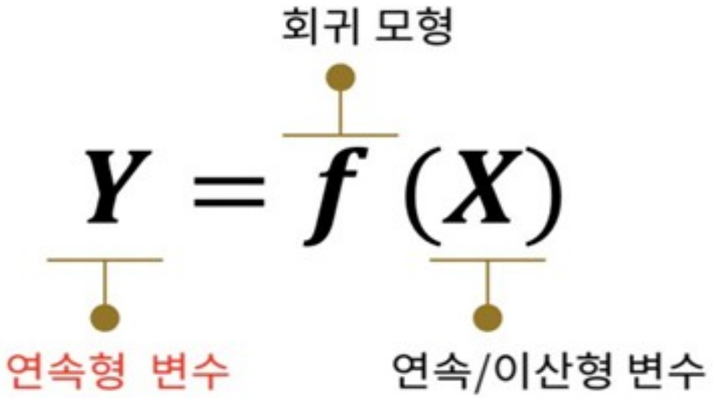
I 회귀분석이란

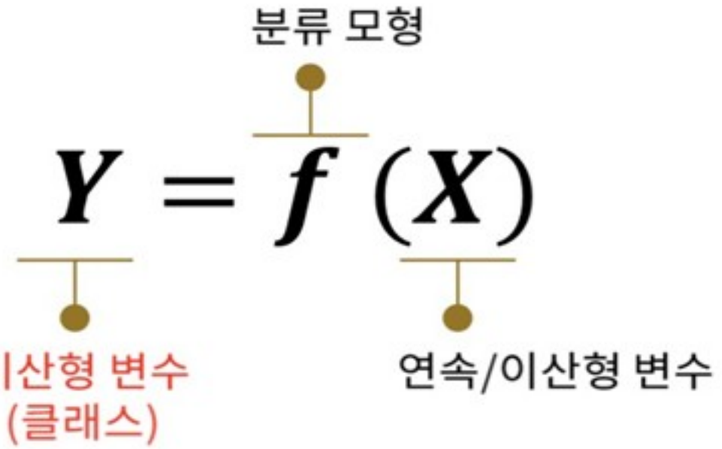
- 지도 학습(supervised learning)

  $Y = f(X)$ 에 대하여 입력 변수 (X)와 출력 변수 (Y) 의 관계에 대하여 모델링하는것

  (Y에 대하여 예측 또는 분류하는 문제)

  - 회귀 (regression): 입력 변수 X에 대해서 연속형 출력 변수 Y를 예측
  - 분류 (classification): 입력 변수 X에 대해서 이산형 출력 변수 Y(class)를 예측

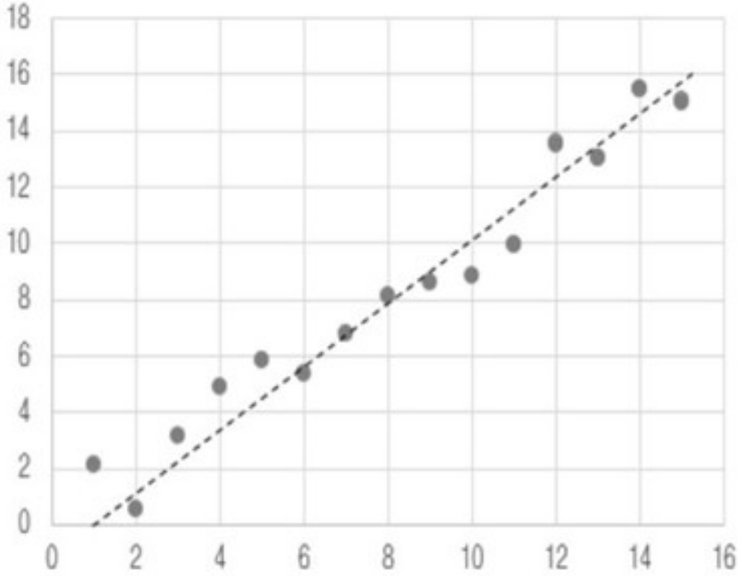




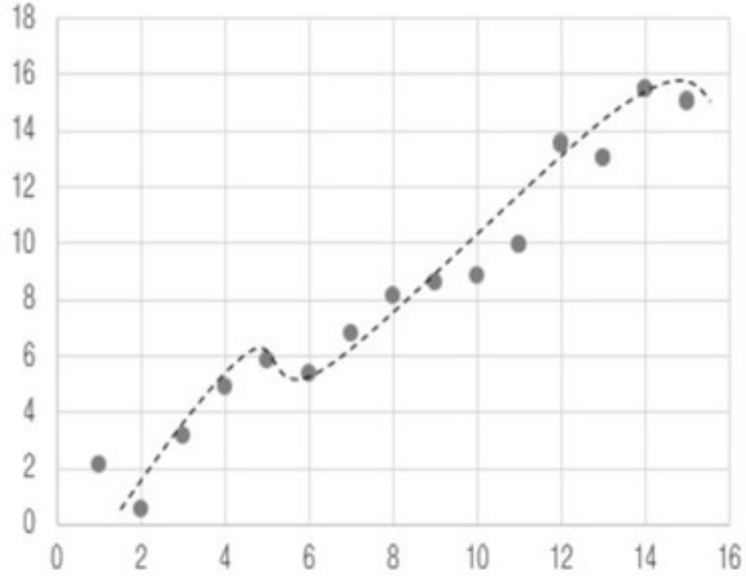
회귀분석

- 회귀분석

- 입력 변수인 X의 정보를 활용하여 출력 변수인 Y를 예측하는 방법
- 회귀분석 중 간단한 방법으로는 선형회귀분석(좌측 그림)이 있으며, 이를 바탕으로 더 복잡한 회귀분석(우측 그림)이 개발



선형회귀



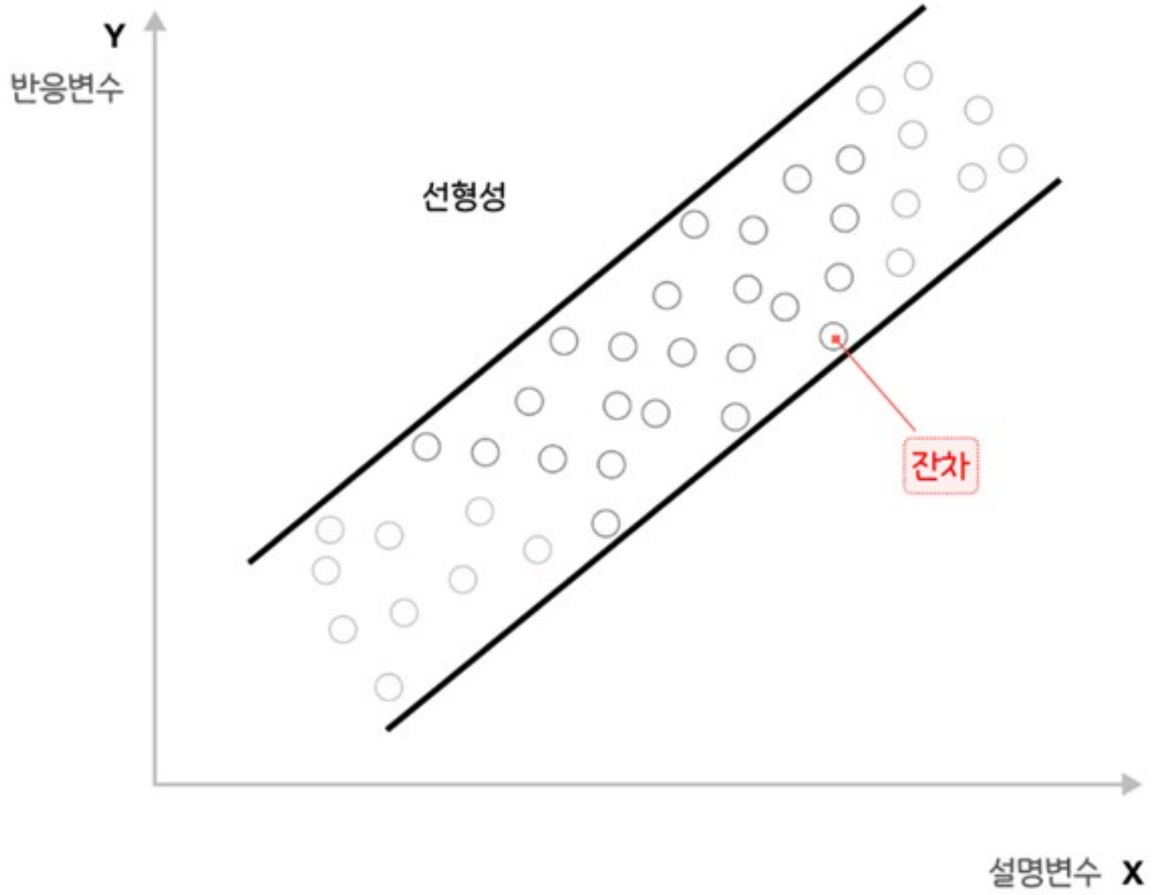
비선형회귀

대부분의 분류모델(SVM, Decision Tree 등)로도 회귀가 가능함.

선형회귀분석의 가정

- **선형성**

  : 선형회귀모형에서는 아래와 같이 설명 변수(x)와 반응변수(y)가 선형적 관계에 있음이 전제 되어야 함.

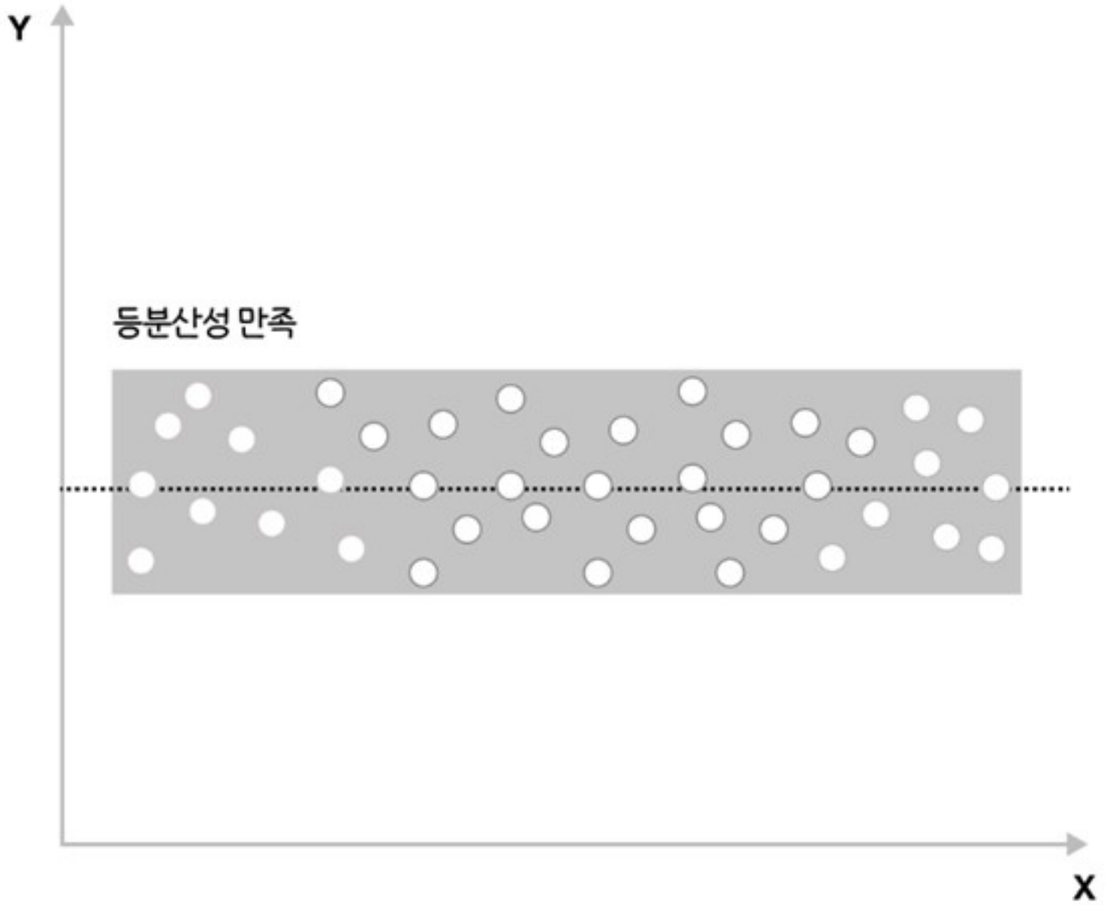


출처 : https://paper-garden.tistory.com/35

그래프를 활용한 선형회귀분석의 가정 검토

- **등분산성**

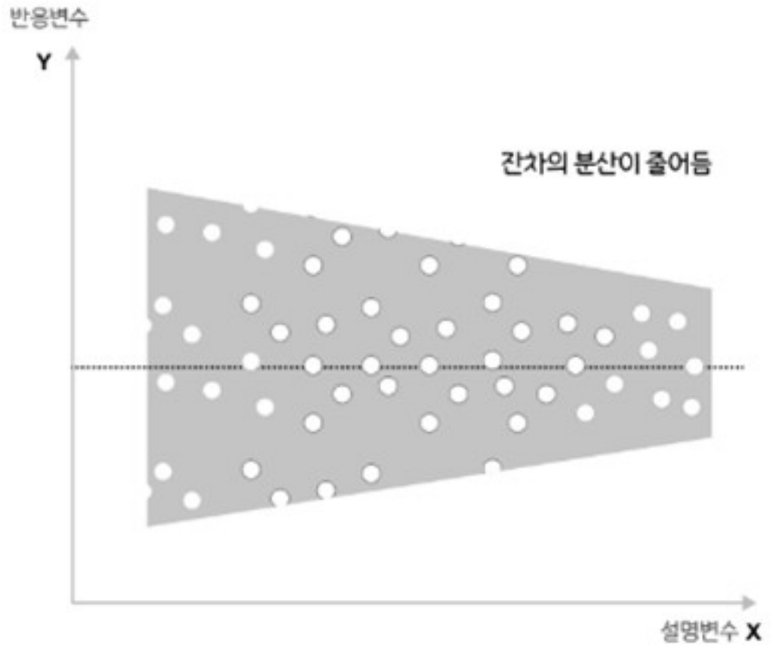
: 설명변수(x)에 대한 잔차의 산점도를 그렸을 때, 아래 그림과 같이 설명변수(x)값에 관계없이 잔차들의 변동성(분산)이 일정한 형태를 보이면 선형회귀분석의 가정중 등분산성을 만족한다고 볼 수 있다.

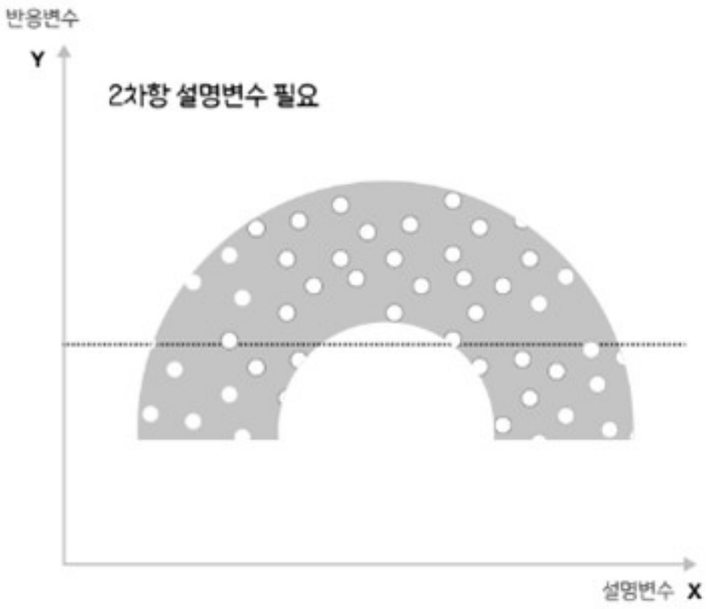


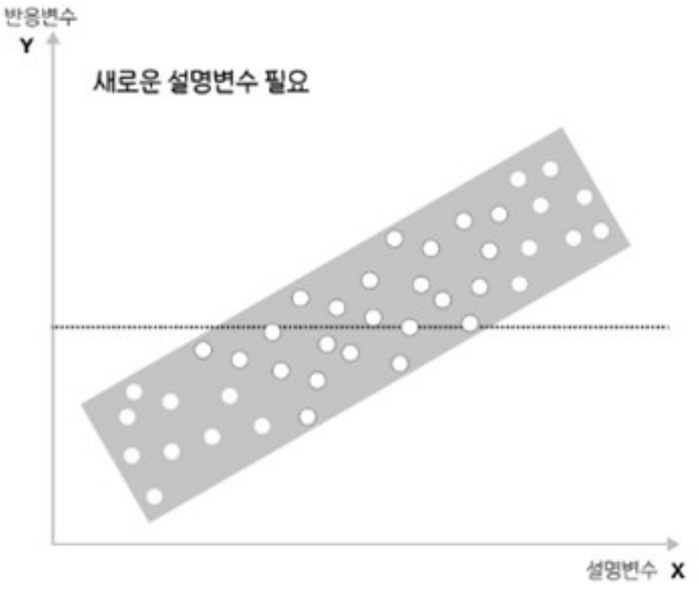
출처 : https://paper-garden.tistory.com/35

그래프를 활용한 선형회귀분석의 가정 검토

- 등분산성을 만족하지 못하는 경우





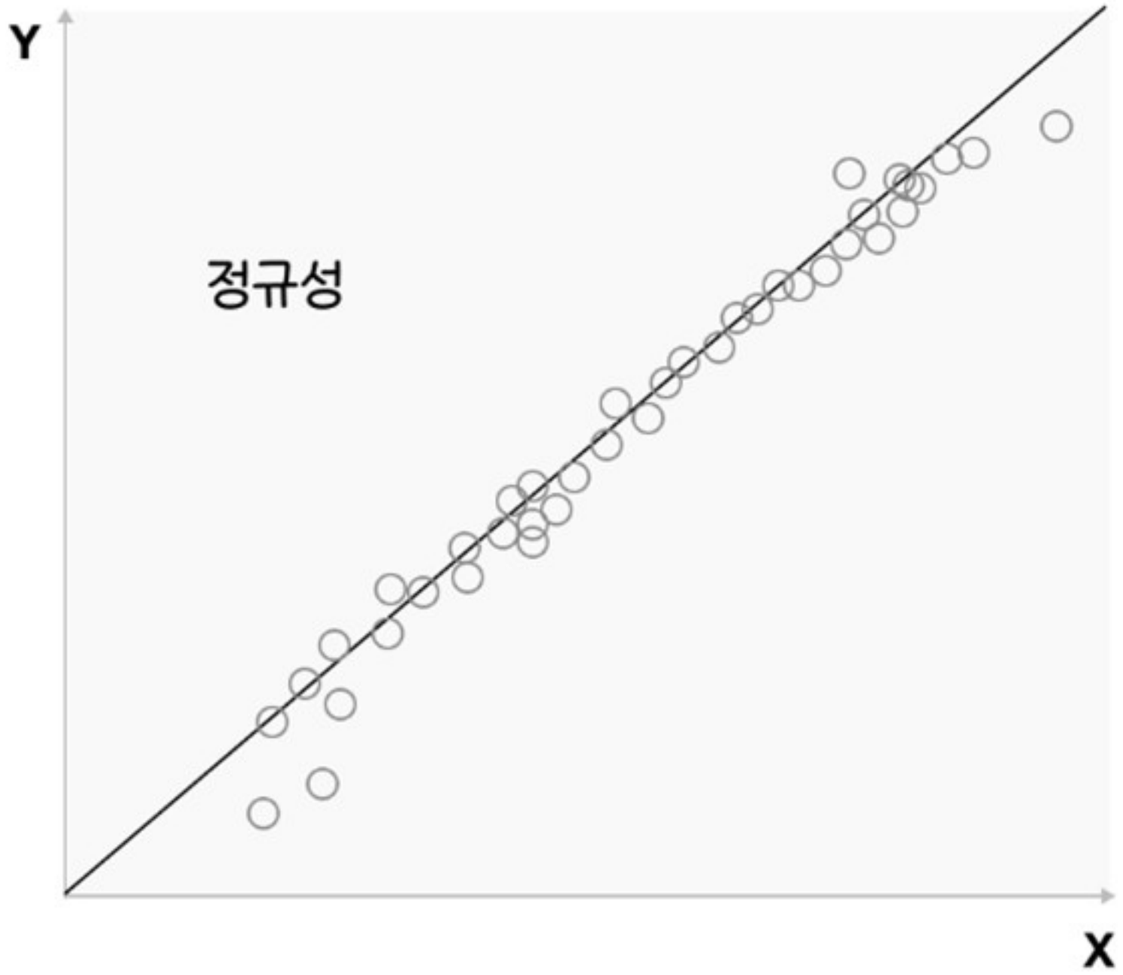


출처 : https://paper-garden.tistory.com/35

그래프를 활용한 선형회귀분석의 가정 검토

- **정상성(정규성)**

  : Q-Q plot 을 출력했을 때, 그림과 같이 잔차가 대각방향의 직선의 형태를 지니고 있으면 잔차는 정규분포를 따른다고 할 수 있다.



출처 : https://paper-garden.tistory.com/35

데이터의 정규성 검정

종류	설명
Q-Q plot	• 그래프를 그려서 정규성 가정이 만족되는지 시각적으로 확인하는 방법 • 대각선 참조선을 따라 값들이 분포하게 되면 정규성을 만족한다고 할 수 있음.
Histogram	• 구간별 도수를 그래프로 표시하여 시각적으로 정규 분포를 확인하는 방법
Shapiro-Wilk Test	• 오차항이 정규분포를 따르는지 알아보는 검정 • 귀무가설은 정규 분포를 따른다로 p-value가 0.05보다 크면 정규성을 가정하게 됨. • 회귀 분석에서 모든 독립변수에 대해 종속변수가 정규분포를 따르는지 알아보는 방법
Kolmogorov-Smirnov Test	• 두 모집단의 분포가 같은지 검정하는 것 • P-value가 0.05보다 크면 정규성을 가정하게 됨.

출처 : https://starrykss.tistory.com/1955

회귀분석

I 회귀분석이란

- 단순 선형 회귀분석

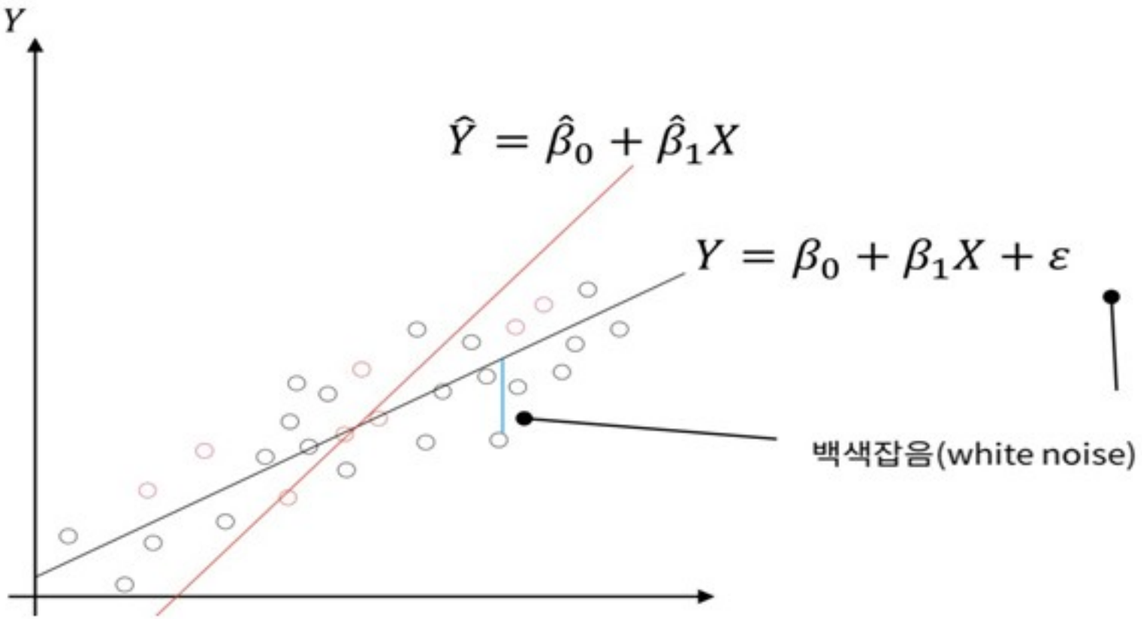
$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- 입력 변수가 X, 출력 변수가 Y일 때, 단순선형회귀의 회귀식은 검은 선으로 나타낼 수 있음
- β_0는 절편(intercept), β_1은 기울기(slope)이며 합쳐서 회귀계수(coefficients)로도 불림

- 검은 점: 모집단의 모든 데이터
- 빨간 점: 학습집합의 데이터
- 실제 β_0와 β_1은 구할 수 없는 계수로 데이터(학습집합)를 통해 이 둘을 추정해서 사용

- 가정 :

$\varepsilon_i \sim i.i.d\ N(0, \sigma^2)$, $Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$, X와 Y는 선형관계

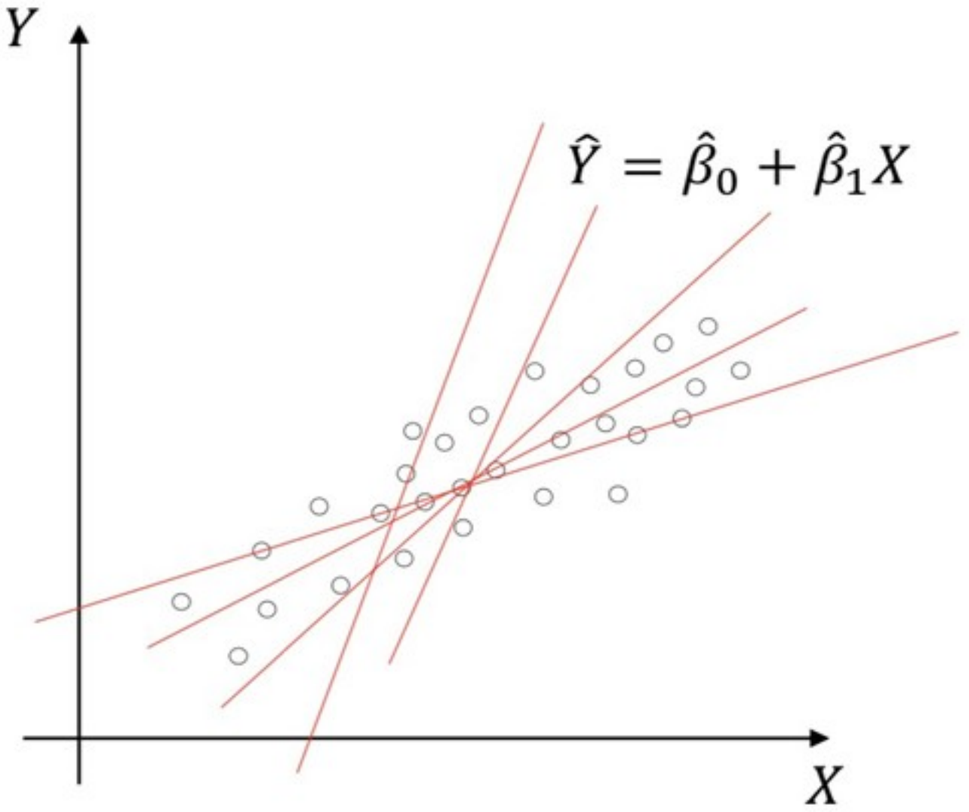


- 최적의 회귀 모델을 만든다는 것은 바로 전체 데이터의 잔차(오류 값)) 합이 최소가 되는 모델을 만든다는 의미.
- 동시에 오류 값 합이 최소가 될 수 있는 최적의 회귀 계수를 찾는다는 의미를 뜻함.

단순 선형 회귀

- 단순 선형 회귀분석
  - 어떻게 추정 할까?

    - 여러 개의 직선 중 가장 좋은 직선은?



➢ 직선과 데이터의 차이가 평균적으로 가장 작아지는 직선

오차 계산

- 어떻게 추정 할까?

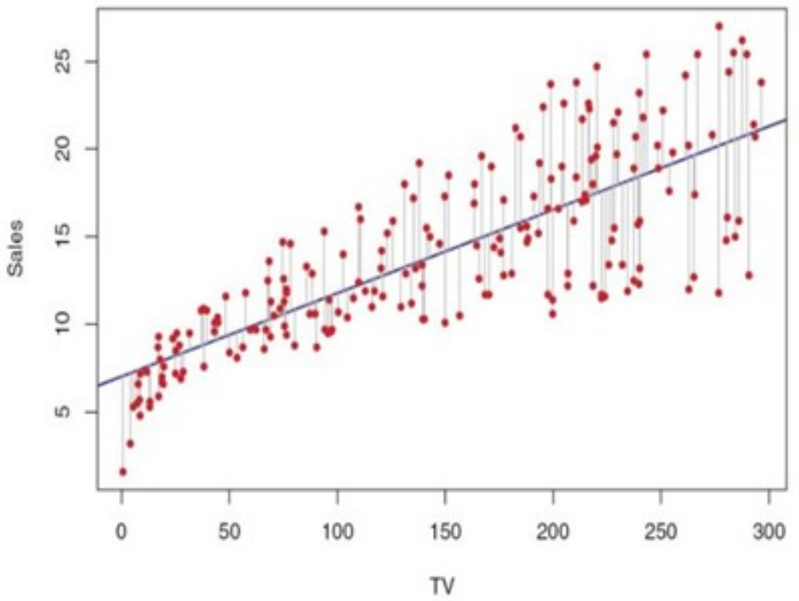
실제 값과 우리가 추정한 값의 차이가 적으면 적을 수록 좋을 것

$$e_i = y_i - \hat{y}_i$$

실제 값과 우리가 추정한 값의 차이를 잔차(residual)라고 하며 이를 최소화 하는 방향으로 추정

- 잔차를 그림으로 나타내면 오른쪽 그림과 같음
- 잔차의 제곱합(SSE; Error Sum of Squares)는 아래와 같이 표현 가능

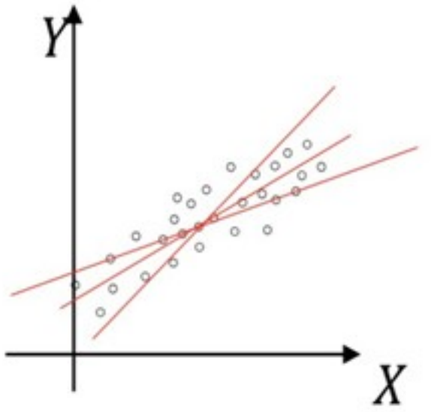
$$SSE = \sum_{i=1}^{n} e_i^2 = e_1^2 + e_2^2 + \cdots + e_n^2$$



오차 계산

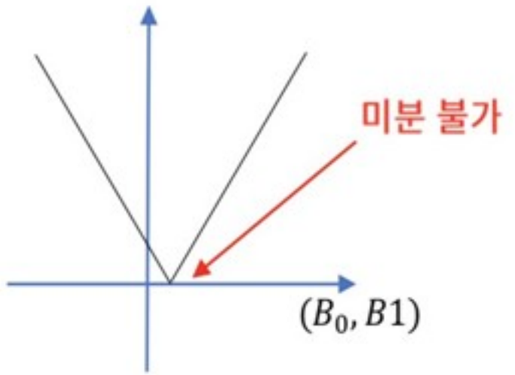
- 굳이 잔차의 제곱합을 최소화 시키는 이유
- 잔차의 합이 0이 되는 해는 무수히 많음 (유일한 해를 찾지 못함)

$$\sum_{i=1}^{n} e_i = e_1 + e_2 + \cdots + e_n = 0$$



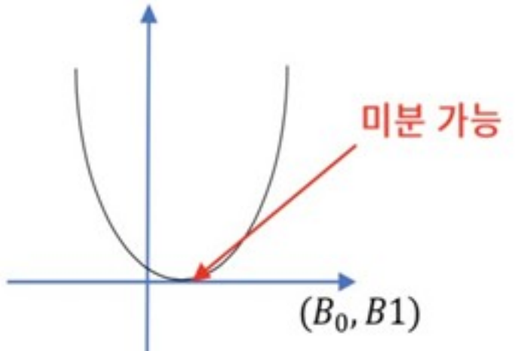
- 잔차의 절대값의 합은 미분이 불가능한 형태

$$\sum_{i=1}^{n} |e_i| = |e_1| + |e_2| + \cdots + |e_n|$$



- 잔차의 제곱 합은 미분이 가능한 형태로 유일한 해를 찾을 수 있음

$$SSE = \sum_{i=1}^{n} e_i^2 = e_1^2 + e_2^2 + \cdots + e_n^2$$

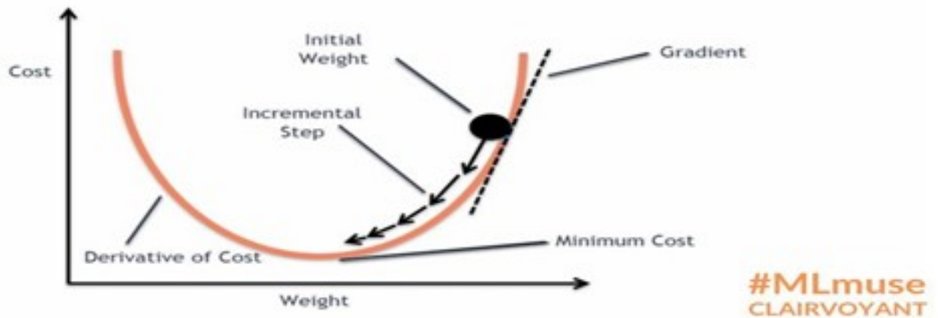


비용 최소화 하기- 경사 하강법(Gradient Descent) 소개

- W 파라미터의 개수가 적다면 고차원 방정식으로 비용 함수가 최소가 되는 W 변수값을 도출할 수 있겠지만, W 파라미터가 많으면 고차원 방정식을 동원하더라도 해결하기가 어려움. 경사 하강법은 이러한 고차원 방정식에 대한 문제를 해결해주면서 비용 함수 RSS를 최소화하는 방법을 직관적으로 제공하는 뛰어난 방식

> 많은 W 파라미터가 있는 경우에 경사 하강법은 보다 간단하고 직관적인 비용함수 최소화 솔루션 제공

$$RSS(\beta) = \sum_{i=1}^{N}(y_i - \hat{y})^2 = \sum_{i=1}^{N}(y_i - \beta^T x_i)^2$$



경사 하강법(Gradient Descent)

Learning Regression

$$\hat{y} = x_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

학습 집합을 이용해서 W를 어떻게 구하지?

$$\{(x_d, y_d)\}_{d=1,\cdots m}$$



경사 하강법(Gradient Descent)

Learning Regression

$$\hat{y} = x_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

방법 :

$$\boldsymbol{W_i \leftarrow W_i + \nabla W_i}$$



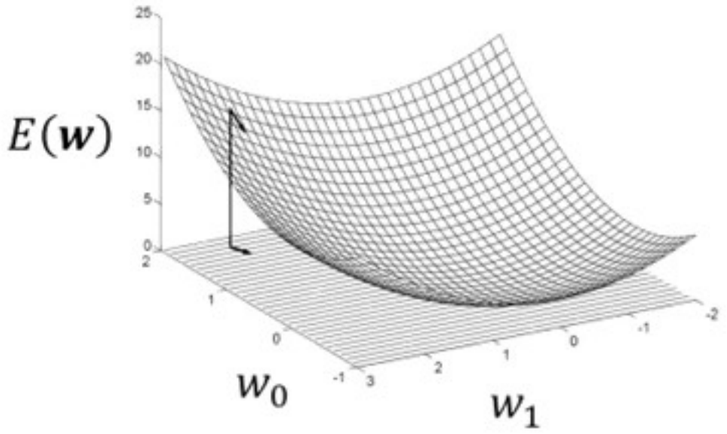
경사 하강법(Gradient Descent)

차이의 합을 구해보자

$$E(W) = \frac{1}{2} \sum_{d \in D} (y_d - \widehat{y_d})^2$$

y_d : Target

$\widehat{y_d}$: Output



이 식이 최소가 되도록 하는
그때의 W값을 구하면 된다.



경사 하강법(Gradient Descent)

Squared Loss :

$$E(W) = \frac{1}{2} \sum_{d \in D} (y_d - \widehat{y_d})^2$$

Mean Squared Loss :

$$E(W) = \frac{1}{2} \frac{1}{|D|} \sum_{d \in D} (y_d - \widehat{y_d})^2$$, $|D|$: 학습집합의 크기



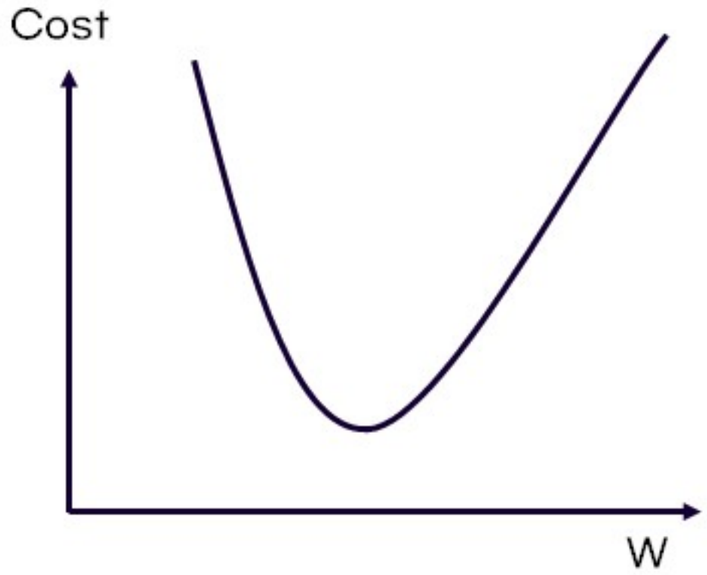
경사 하강법(Gradient Descent)

$$(Wx - y)^2$$

$$= W^2X^2 - 2WXY + Y^2$$

$$= AW^2 - BW + C$$

$$= \text{cost(error)}$$





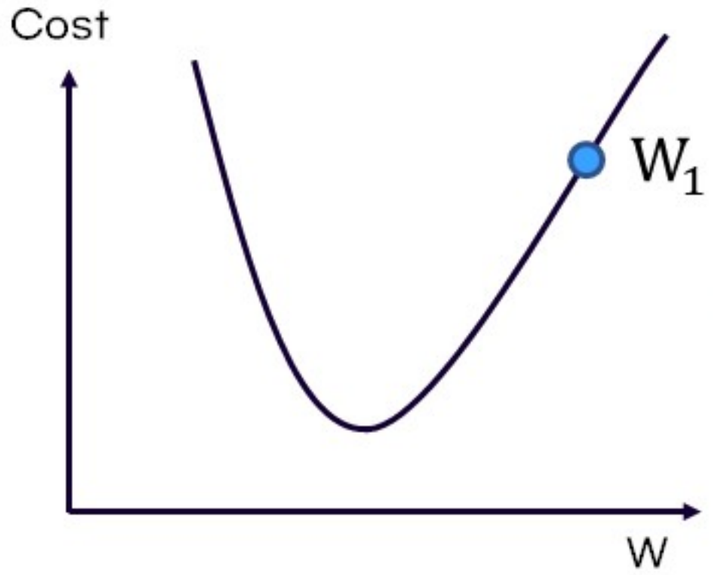
경사 하강법(Gradient Descent)

$$(Wx - y)^2$$

$$= W^2X^2 - 2WXY + Y^2$$

$$= AW^2 - BW + C$$

$$= \text{cost(error)}$$





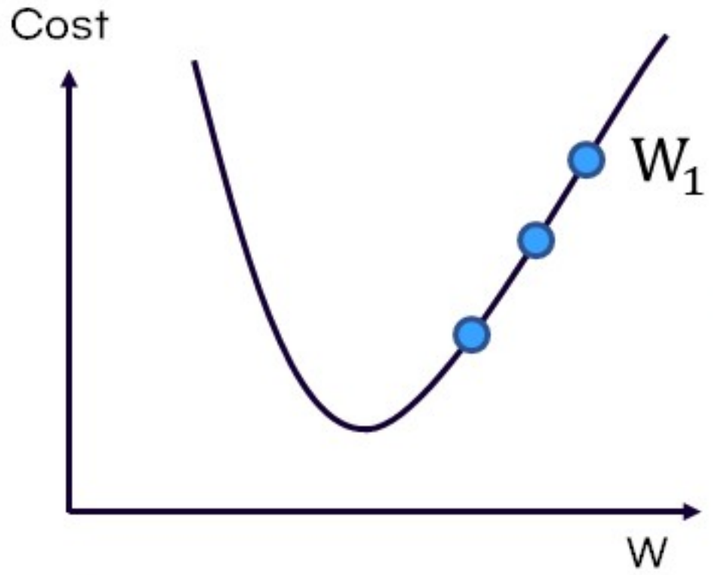
경사 하강법(Gradient Descent)

$$(Wx - y)^2$$

$$= W^2X^2 - 2WXY + Y^2$$

$$= AW^2 - BW + C$$

$$= \text{cost(error)}$$

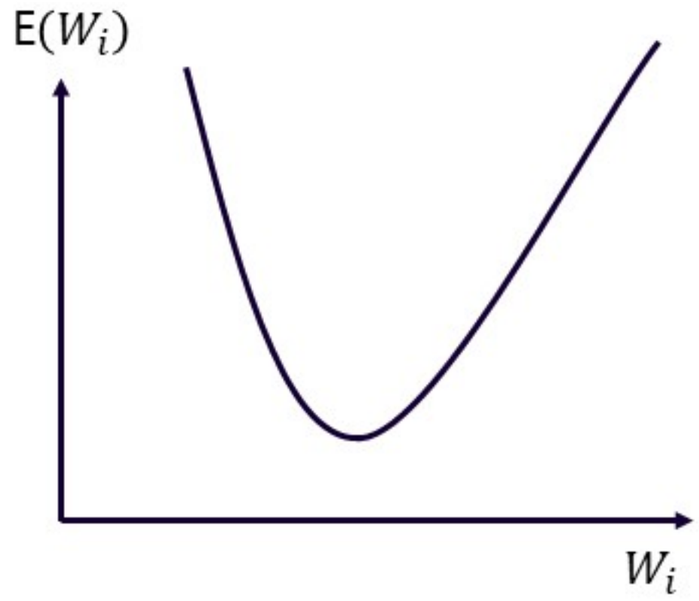


$$W_{update} = W_{old} - \frac{\partial}{\partial W} \text{cost}(W)$$

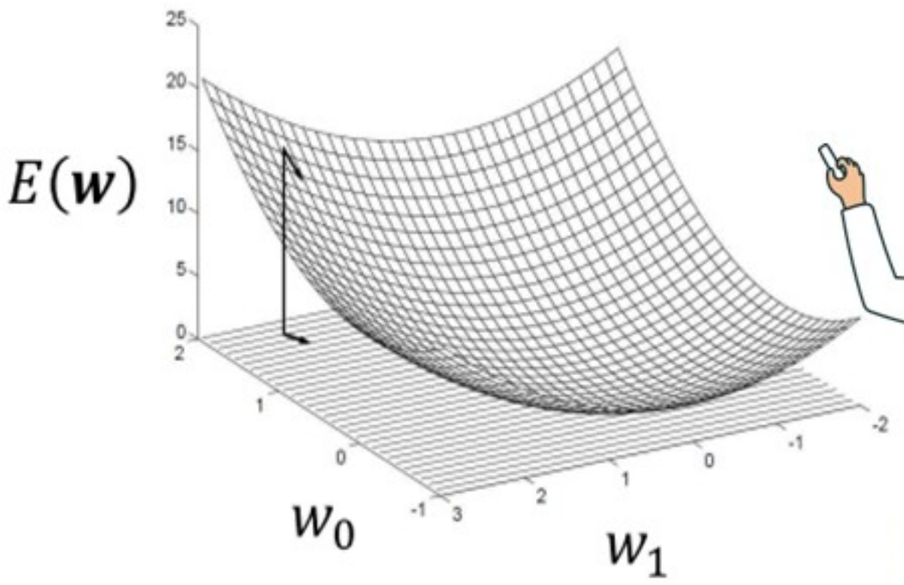


경사 하강법(Gradient Descent)

구해야 되는 W가 한 개 일 때,



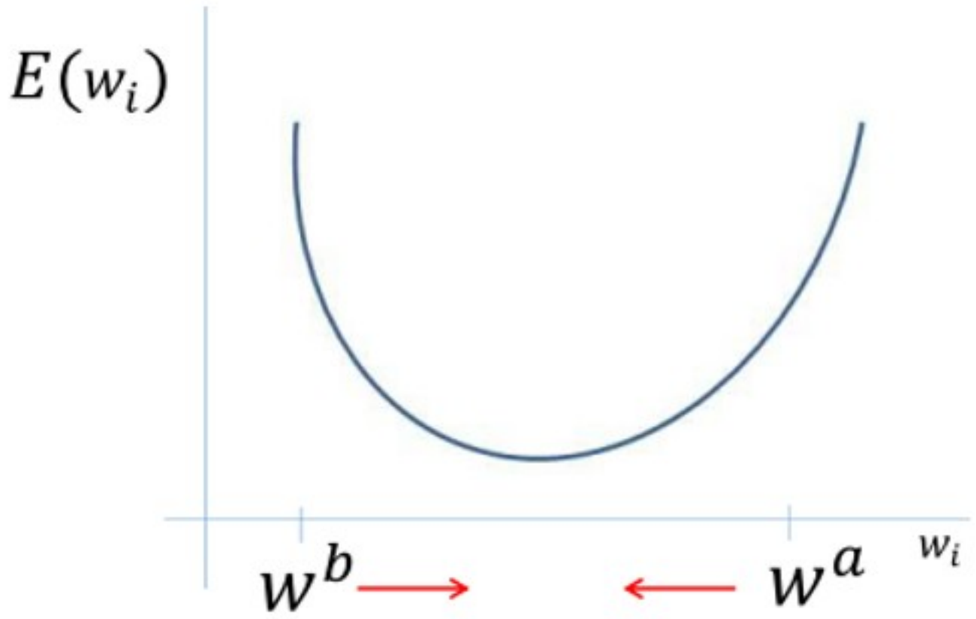
구해야 되는 W가 두 개 일 때,





경사 하강법(Gradient Descent)

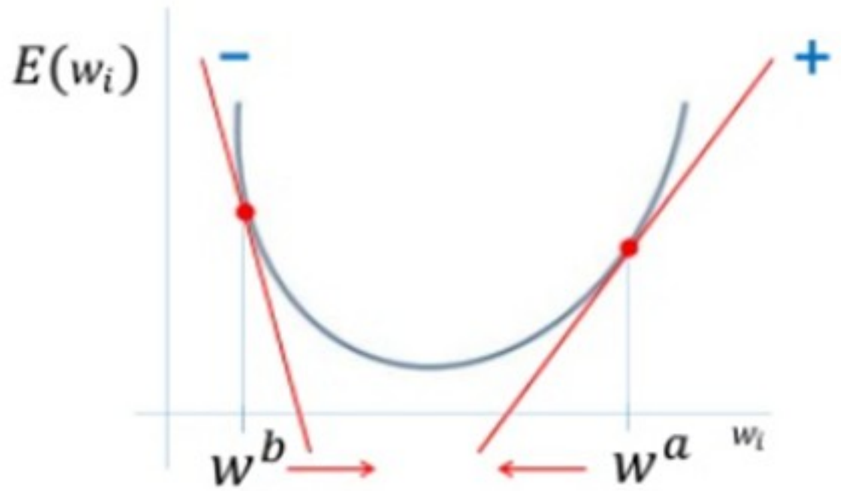
∇W_i 를 어떻게 결정할까?





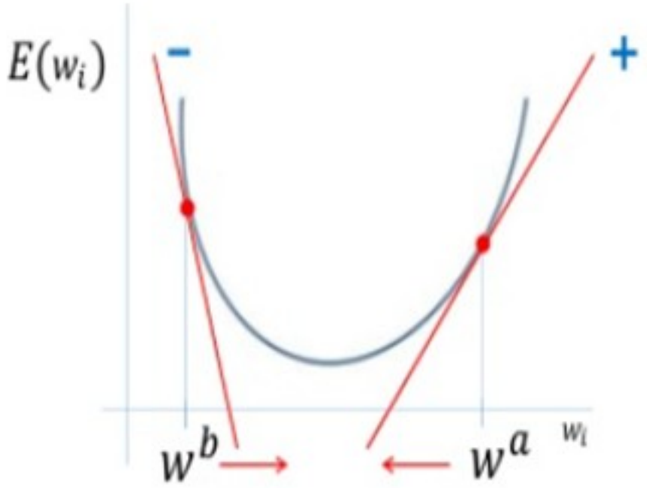
경사 하강법(Gradient Descent)

기울기: Gradient



위 경우에 기울기를 구해 보니 부호가 각각 -, + 이다.

갱신 방향 판정



$\nabla W_i = -$ 기울기

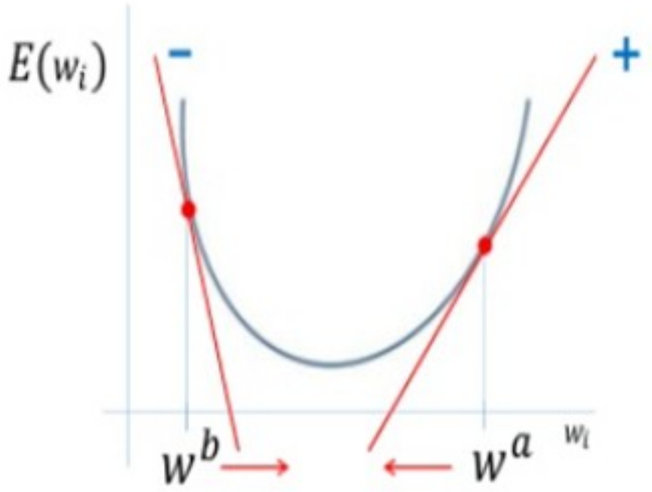


경사 하강법(Gradient Descent)

갱신 크기 결정

아주 조금씩 갱신되도록 하자.

갱신 값이 크면 최소값 주위에서 진동할 수 있다.

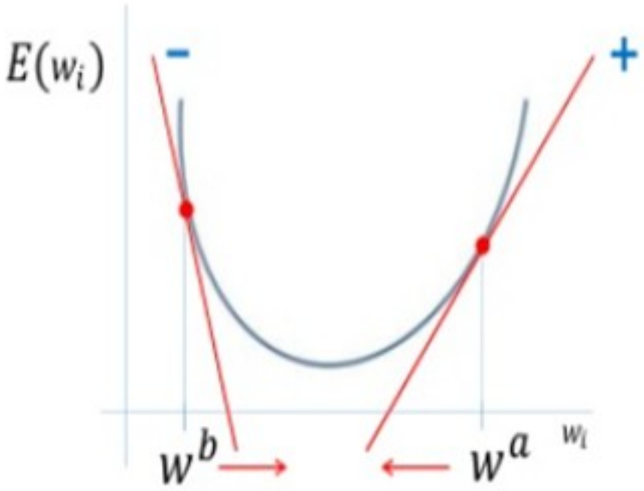


$$\nabla w_i = -\text{기울기} \times \text{아주 작은 값}$$



경사 하강법(Gradient Descent)

경사하강법: Gradient Descent Method



$$\nabla W_i = -\eta \frac{\partial E}{\partial W_i}$$



Linear regression : Gradient Descent method

$$\frac{df(x)}{dx}$$

$$\frac{\partial f(x,y)}{\partial x}$$

$$\frac{\partial f(x,y)}{\partial y}$$

$$\frac{\partial E}{\partial W_i} = \frac{\partial}{\partial W_i}\frac{1}{2}\sum_d (y_d - \widehat{y_d})^2$$

$$= \frac{1}{2}\sum_d \frac{\partial}{\partial W_i}(y_d - \widehat{y_d})^2$$

$$= \frac{1}{2}\sum_d 2\,(y_d - \widehat{y_d})\frac{\partial}{\partial W_i}(y_d - \widehat{y_d})$$

$$= \sum_d (y_d - \widehat{y_d})\frac{\partial}{\partial W_i}(y_d - w_0 - w_1 x_{d,1} - \cdots - w_i x_{d,i} - \cdots - w_n x_{d,n})$$

$$= \sum_d (y_d - \widehat{y_d})(-x_{d,i})$$

$$\frac{\partial E}{\partial W_0} = \sum_d (y_d - \widehat{y_d})(-1)$$



Linear regression : Gradient Descent method

$$\frac{\partial E}{\partial W_i} = \frac{\partial}{\partial W_i}\frac{1}{2}\sum_d (y_d - \widehat{y_d})^2$$

$$= \frac{1}{2}\sum_d \frac{\partial}{\partial W_i}(y_d - \widehat{y_d})^2$$

$$= \frac{1}{2}\sum_d 2\,(y_d - \widehat{y_d})\frac{\partial}{\partial W_i}(y_d - \widehat{y_d})$$

$$= \sum_d (y_d - \widehat{y_d})\frac{\partial}{\partial W_i}(y_d - w_0 - w_1 x_{d,1} - \cdots - w_i x_{d,i} - \cdots - w_n x_{d,n})$$

$$= \sum_d (y_d - \widehat{y_d})(-x_{d,i})$$

$$W_i = W_i + \Delta W_i$$

$$W_i = -\eta \frac{\partial E}{\partial W_i}$$

➡ Weight

$$W_0 = W_0 + \Delta W_0$$

$$W_0 = -\eta \frac{\partial E}{\partial W_0}$$

➡ Bias(coefficient)



경사 하강법 수행 프로세스

- Step 1: W_0, W_1 를 임의의 값(초깃값)으로 설정하고 첫 비용 함수의 값을 계산합니다.

- Step 2 : W_1을 $W_1 - \eta \frac{2}{N} \sum_{i=1}^{N} x_i(\text{실제값}_i - \text{예측값}_i)$, W_0을 $W_0 - \eta \frac{2}{N} \sum_{i=1}^{N} x_i(\text{실제값}_i - \text{예측값}_i)$ 으로 각각 업데이트 한 후 다시 비용 함수의 값을 계산합니다.

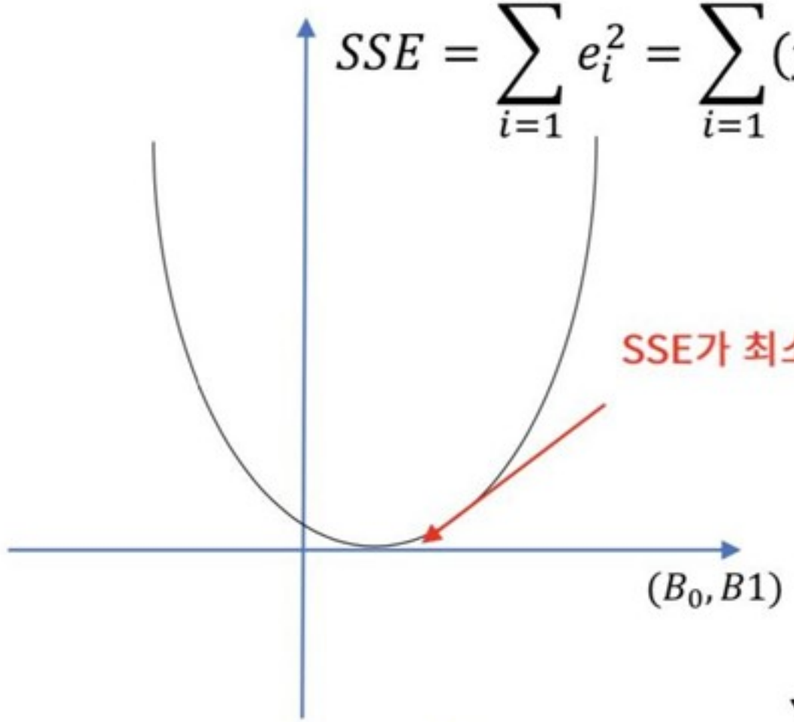
- Step 3: 비용 함수의 값이 감소했으면 다시 Step 2를 반복합니다. 더 이상 비용 함수의 값이 감소하지 않으면 그때의 W_1, W_0를 구하고 반복을 중지합니다.

회귀 계수

회귀 계수의 추정

- SSE $\hat{\beta}_0$과 $\hat{\beta}_1$로 편미분하여 연립방정식을 푸는 방법(Least Square Method)

$$SSE = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$



$$\frac{\partial L}{\partial \beta_0} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial L}{\partial \beta_1} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)x_i = 0$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

회귀 계수 추정

회귀 계수의 추정

$$\frac{\partial L}{\partial \beta_0} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial L}{\partial \beta_1} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)x_i = 0$$

$\sum_{i=1}^{n} y_i - \beta_1 \sum_{i=1}^{n} x_i - n\beta_0 = 0$ $\longrightarrow$ $\beta_0 = \frac{1}{n}\sum_{i=1}^{n} y_i - \beta_1 \frac{1}{n}\sum_{i=1}^{n} x_i$ $\longrightarrow$ $\therefore \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

$\sum_{i=1}^{n} x_i y_i - \beta_0 \sum_{i=1}^{n} x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0$

$\Rightarrow \sum_{i=1}^{n} x_i y_i - (\frac{1}{n}\sum_{i=1}^{n} y_i - \beta_1 \frac{1}{n}\sum_{i=1}^{n} x_i)\sum_{i=1}^{n} x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0$

$\Rightarrow \sum_{i=1}^{n} x_i y_i - \frac{1}{n}\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i + \beta_1 \frac{1}{n}(\sum_{i=1}^{n} x_i)^2 - \beta_1 \sum_{i=1}^{n} x_i^2 = 0$

$\Rightarrow \beta_1 \frac{1}{n}(\sum_{i=1}^{n} x_i)^2 - \beta_1 \sum_{i=1}^{n} x_i^2 = \frac{1}{n}\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} x_i y_i$

$$\therefore \hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

회귀 계수 추정

$y = \beta_0 + \beta_0 x + \epsilon$ 이라면,

위 식 양변에 기댓값을 적용해보자.

$E(y) = E(\beta_0 + \beta_1 x + \epsilon)$

-> $E(y) = E(\beta_0) + E(\beta_1 x) + E(\epsilon)$

오차항의 평균은 0이므로,

-> $E(y) = \beta_0 + \beta_1 E(x)$

따라서, $\beta_0 = E(y) - \beta_1 E(x)$

이제, 독립변수(x)와 종속변수(y)의 공분산을 구해보자.

$$Cov(x, y) = Cov(x, \beta_0 + \beta_1 x + \epsilon)$$

$$= \beta_0 Cov(x, 1) + \beta_1 Cov(x, x) + Cov(x, \epsilon)$$

$Cov(x, 1) = 0$ 이고, x와 ϵ는 서로 독립이므로 $Cov(x, \epsilon) = 0$ 입니다.

$$= 0 + \beta_1 Cov(x, x) + 0$$

$Cov(x, x) = Var(x)$이므로

$$= \beta_1 Var(x)$$

$$\therefore Cov(x, y) = \beta_1 Var(x)$$

$$\rightarrow \beta_1 = \frac{Cov(x, y)}{Var(x)}$$

한가지 알아야 할 것은 위에서 유도한 식을 모집단에 대한 자료를 바탕으로 구한 회귀계수이다.

회귀 계수 추정

정규방정식을 활용

$$\sum x_i(n\beta_0 + \sum x_i\beta_1) = \sum x_i \sum Y_i$$
$$n(\beta_0 \sum x_i + \beta_1 \sum x_i^2) = n \sum x_i Y_i$$

두식을 빼면

$$\rightarrow \beta_1((\sum x_i)^2 - n\sum x_i^2) = \sum x_i \sum Y_i - n \sum x_i Y_i$$
$$\beta_1 = \frac{\sum x_i \sum Y_i - n \sum x_i Y_i}{(\sum x_i)^2 - n \sum x_i^2}$$

$\sum x_i = n\bar{x}$ 이므로 분모는

$$n^2\bar{x}^2 - n\sum x_i^2 = n(n\bar{x}^2 - \sum x_i^2) = n(2n\bar{x}^2 - n\bar{x}^2 - \sum x_i^2)$$
$$= n(2\bar{x}\sum x_i - \sum \bar{x}^2 - \sum x_i^2) = n\sum(x_i - \bar{x})^2$$

분자는

$$\sum x_i \sum Y_i - n\sum x_i Y_i = (n\bar{x})(n\bar{Y}) - n\sum x_i Y_i$$
$$= n(n\bar{x}\bar{y} - \sum x_i Y_i) = n(2n\bar{x}\bar{y} - n\bar{x}\bar{y} - \sum x_i Y_i)$$
$$= n((\sum x_i\bar{Y} + \sum Y_i\bar{x}) - \sum \bar{x}\bar{Y} - \sum x_i Y_i)$$
$$= n\sum(x_i - \bar{x})(Y_i - \bar{Y})$$

따라서

$$\beta_1 = \frac{\sum(x_i - \bar{x})(Y_i - \bar{Y})}{\sum(x_i - \bar{x})^2}$$
$$\hat{\beta_0} = \bar{Y} - \beta_1\bar{x}$$

회귀 계수

- 회귀 계수의 해석

- $\hat{\beta}_1$의 해석 - X1이 1단위 증가할 때마다 y가 $\hat{\beta}_1$만큼 증가한다.

- 예시) radio광고 예산과 매출 간의 관계
- Radio광고 예산이 1증가 할 때 마다 매출은 0.2단위 만큼 증가한다. 그때의 유의성은 매우 높다.
- Radio광고 예산이 35 단위일 때 예상 매출액은 9.312+0.203*35=16.42단위이다

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X \qquad \hat{Y} = 9.312 + 0.203X$$

회귀 계수의 의성을 판단하는 통계치

회귀 계수의 표준 오차

회귀 계수

Simple regression of sales on radio

	Coefficient	Std. error	t-statistic	p-value
Intercept	9.312	0.563	16.54	< 0.0001
radio	0.203	0.020	9.92	< 0.0001

선형회귀 평가

- 선형 회귀의 정확도 평가

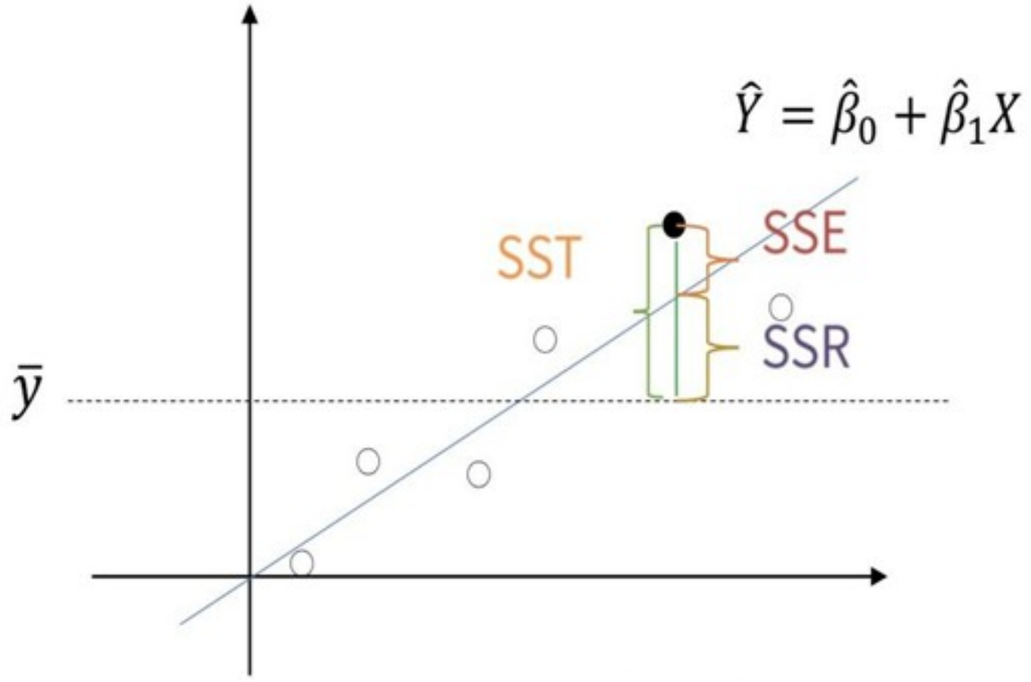
  - 선형회귀는 잔차의 제곱합(SSE : Error sum of squares)를 최소화 하는 방법으로 회귀 계수를 추정
  - 즉, SSE가 작으면 작을수록 좋은 모델이라고 볼 수 있음
  - MSE(Mean Squared Error)는 SSE를 표준화한 개념

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$MSE = \frac{1}{n-2} SSE$$

선형회귀 평가

- 선형 회귀의 정확도 평가



$$y_i - \bar{y} = y_i - \hat{y}_i + \hat{y}_i - \bar{y}$$

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$$

SST (Total sum of squares) | SSE (Error sum of squares) | SSR (Regression sum of squares)

$$\Sigma(y_i - \bar{y})^2 = \Sigma(y_i - \hat{y}_i)^2 + \Sigma(\hat{y}_i - \bar{y})^2 + 2(\ e_i)(\Sigma\hat{y}_i - \bar{y})$$

$$= \Sigma(y_i - \hat{y}_i)^2 + \Sigma(\hat{y}_i - \bar{y})^2$$

※ 회귀 계수 추정

$$\frac{\partial L}{\partial \beta_0} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial L}{\partial \beta_1} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)x_i = 0$$

Source of Variation	Sum of Squares	Degree of freedom	Mean Square
Regression	SSR	1	SSR
Error	SSE	N-2	MSE
Total	SST	N-1	

선형 회귀의 평가

- 선형 회귀의 정확도 평가

$$\underbrace{\sum_{i=1}^{n}(y_i-\bar{y})^2}_{\text{SST}}=\underbrace{\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}_{\text{SSE}}+\underbrace{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}_{\text{SSR}}$$

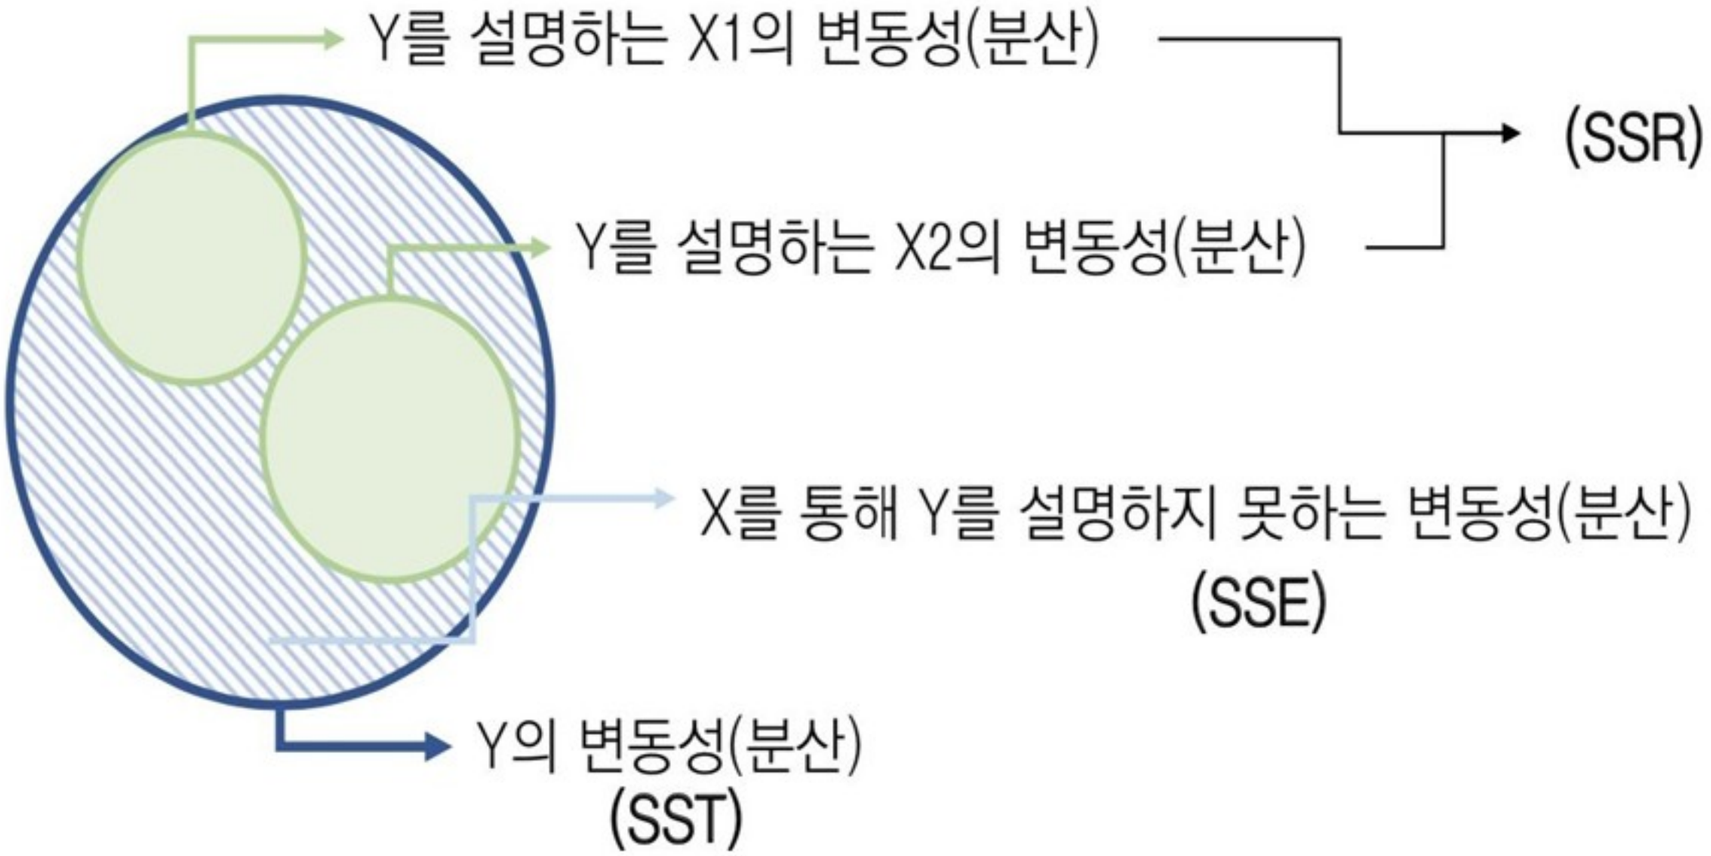
- Y의 총 변동은 회귀직선으로 설명 불가능 한 변동과 회귀직선으로 설명 가능한 변동으로 이루어져 있음
- R^2는 RSE의 단점을 보완한 평가지표로 0~1의 범위를 가짐
- R^2은 설명력으로 입력 변수인 X로 설명할 수 있는 Y의 변동을 의미
- R^2이 1에 가까울 수록 선형회귀 모형의 설명력이 높다는 것을 뜻함

입력 변수로 설명할 수 없는 변동 비율

$$R^2=\frac{SST-\boldsymbol{SSE}}{SST}=1-\frac{SSE}{SST}=\frac{SSR}{SST} \qquad where\ SST=\sum_{i=1}^{n}(y_i-\bar{y})^2$$

선형 회귀의 평가

- 선형 회귀의 정확도 평가
  - 회귀 분석은 결국 Y의 변동성을 얼마나 독립변수가 잘 설명하느냐가 중요
  - 변수가 여러 개일 때 각각 Y를 설명하는 변동성이 크면 좋은 변수 -> p-value자연스레 낮아짐



$$R^2 = \frac{SSR}{SST}$$

선형 회귀의 평가

$\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2+\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2$ 임을 증명하시오.

$\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}(y_i-\hat{y}_i+\hat{y}_i-\bar{y})^2$ ∵ $(a+b)^2=a^2+b^2+2ab$.

$=\sum_{i=1}^{n}\{(y_i-\hat{y}_i)^2+(\hat{y}_i-\bar{y})^2+2(y_i-\hat{y}_i)(\hat{y}_i-\bar{y})\}$

$=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2+\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2+\underbrace{\sum_{i=1}^{n}2(y_i-\hat{y}_i)(\hat{y}_i-\bar{y})}_{A}$

$A=\sum_{i=1}^{n}(y_i-\hat{y}_i)(\hat{y}_i-\bar{y})$

$=\sum_{i=1}^{n}e_i(\hat{y}_i-\bar{y})=\underbrace{\sum_{i=1}^{n}e_i\hat{y}_i}_{①}-\bar{y}\underbrace{\sum_{i=1}^{n}e_i}_{②}$

① $\sum_{i=1}^{n}e_i\hat{y}_i=\sum_{i=1}^{n}e_i(\beta_0+\beta_1x_i)=\beta_0\sum_{i=1}^{n}e_i+\beta_1\sum_{i=1}^{n}x_ie_i$ ①을 계산하기 앞서 ②를 계산.

② $\sum_{i=1}^{n}e_i=\sum_{i=1}^{n}(y_i-\hat{y}_i)=\sum_{i=1}^{n}(y_i-(\beta_0+\beta_1x_i))$ ∵ $\beta_0=\bar{y}-\beta_1\bar{x}$

$=\sum_{i=1}^{n}(y_i-(\bar{y}-\beta_1\bar{x}+\beta_1x_i))$.

$=\sum_{i=1}^{n}(y_i-\bar{y})+\beta_1\sum_{i=1}^{n}(x_i-\bar{x})=0$ ∵ 편차들의 합 $=0$

∴ ① $=\beta_0\cdot\sum e_i+\beta_1\sum_{i=1}^{n}e_ix_i=\beta_1\sum_{i=1}^{n}e_ix_i$ ∵ $\sum e_i=0$.

$=\beta_1\sum_{i=1}^{n}x_i(y_i-\hat{y}_i)=\beta_1\sum_{i=1}^{n}x_i(y_i-(\beta_0+\beta_1x_i))$

$=\beta_1\{\sum_{i=1}^{n}x_iy_i-\beta\sum_{i=1}^{n}-\beta_1\sum_{i=1}^{n}x_i^2\}$ 이 되는데,

★은 정규방정식의 그연계 성질으로.

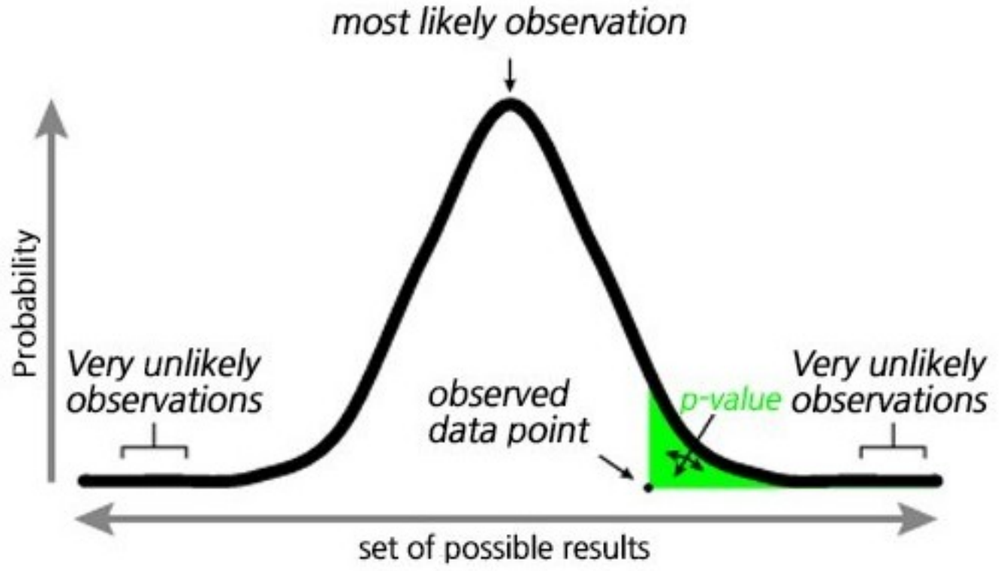
∴ ①$=0$, ②$=0$ ∴ $A=0$

P-Value

1. 귀무가설이 옳다고 가정했을 때 얻은 통계량이 귀무가설을 얼마나 지지하는지를 확률로 나타낸 것
2. 검정 통계량의 확률(검정통계량이 귀무가설을 따른다고 가정했을 때 검정통계량이 나올 확률)

유의할 점은 'value'이기 때문에 값이라고 착각할 수 있다는 점. 물론 값은 맞지만 그 값이 나타내는 것은 '확률'이라는 것에 유의하여야 한다.

- 검정 통계량 : 표본 데이터에서 계산되어 가설 검정에 사용되는 랜덤 변수입니다
- 귀무가설 : 모집단의 특성에 대해 옳다고 제안하는 잠정적인 자정
- 대립가설 : 귀무가설이 거짓이라면 대안적으로 참이 되는 가설



A p-value (shaded green area) is the probability of an observed (or more extreme) result arising by chance

다중 선형회귀

- 단순 선형 회귀분석 : 변수가 1개인 경우

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

- 다중 선형 회귀분석 : 변수가 여러개인 경우

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \cdots + \hat{\beta}_p X_p$$

- 다중 선형 회귀계수 추정
  - 회귀계수를 추정하는것은 단순선형회귀분석과 동일하게 SSE를 최소화 하는 방향으로 추정

$$SSE = \sum_{i=1}^{n} e_i^2 = e_1^2 + e_2^2 + \cdots + e_n^2$$

  - 위 식을 각각의 변수에 대해 편미분 하여 회귀계수를 추정

$$\frac{\partial L}{\partial \beta_0} = -2\sum_{i=1}^{n}(y_i - \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}) = 0$$

$$\frac{\partial L}{\partial \beta_1} = -2\sum_{i=1}^{n}(y_i - \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}) x_{1i} = 0$$

$$\vdots \qquad\qquad \vdots$$

$$\frac{\partial L}{\partial \beta_p} = -2\sum_{i=1}^{n}(y_i - \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}) x_{pi} = 0$$

다중 선형 회귀계수

- 다중 선형 회귀계수 추정(행렬)

$$
\begin{aligned}
y_1 &= \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \ldots + \beta_k x_{1k} + \varepsilon_1 \\
y_2 &= \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \ldots + \beta_k x_{2k} + \varepsilon_2 \\
&\vdots \qquad\qquad\qquad\qquad\qquad \vdots \\
y_n &= \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \ldots + \beta_k x_{nk} + \varepsilon_n
\end{aligned}
$$

$$
\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} \cdots x_{1k} \\ 1 & x_{21} & x_{22} \cdots x_{2k} \\ \vdots & \vdots & \vdots \quad \vdots \\ 1 & x_{n1} & x_{n2} \cdots x_{nk} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}
$$

$$
y = X\beta + \varepsilon \qquad \varepsilon = (\varepsilon_1, \varepsilon_2, \ldots, \varepsilon_n)'
$$

$$
\begin{aligned}
\sum_{i=1}^{n} \varepsilon_i^2 = \varepsilon'\varepsilon &= (y - X\beta)'(y - X\beta) \\
&= y'y + \beta' X' X\beta - 2\beta' X' y
\end{aligned}
$$

$$
\frac{\partial L}{\partial \beta} = 2X'X\beta - 2X'y = 0
$$

$$
\Rightarrow X'X\beta = X'y
$$

$$
\Rightarrow \beta = (X'X)^{-1}X'y
$$

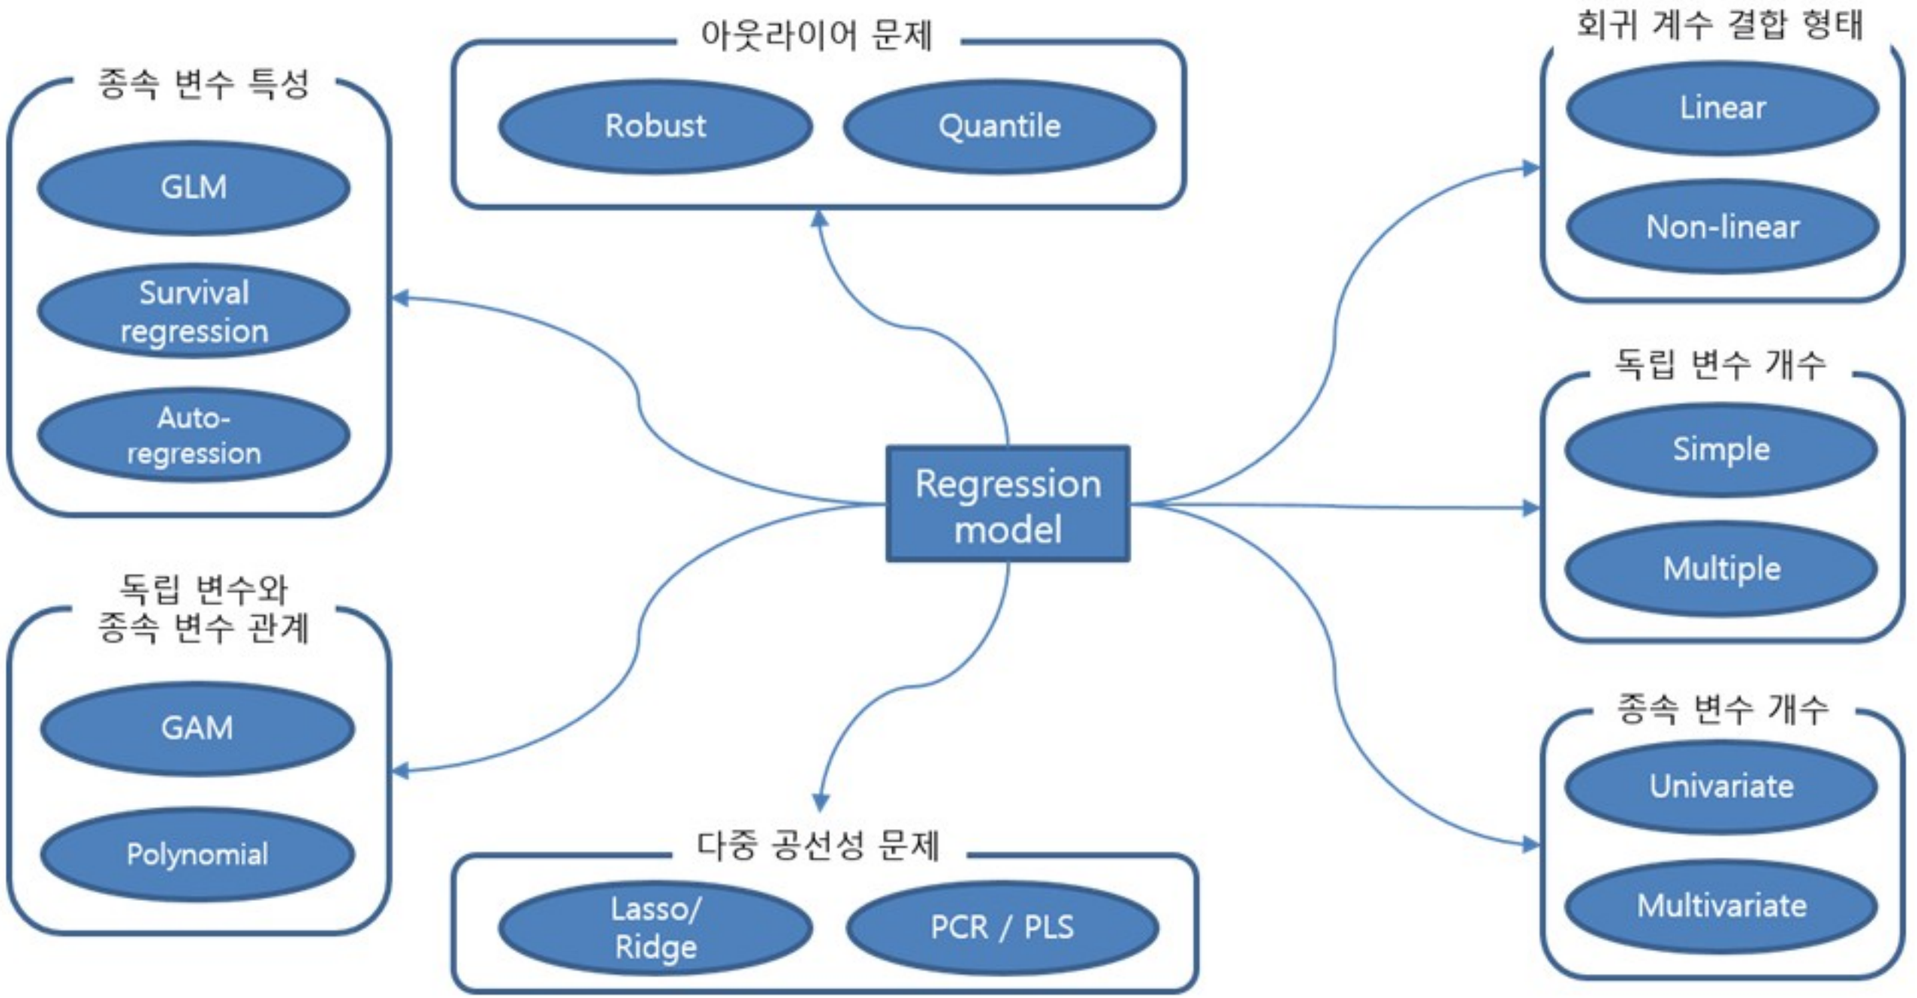
정규방정식(normal equation)

회귀의 종류

종 류	모 형	설 명
단순회귀	$Y=\beta_0+\beta_1X+\epsilon$	독립변수가 하나이고 종속변수 Y와의 관계가 직선
중회귀	$Y=\beta_0+\beta_1X_1+\beta_2X_2+\cdots+\beta_kX_k+\epsilon$	독립변수가 2개 이상 $(X_1, X_2, \cdots, X_k)$이고 Y와의 관계가 1차 선형 함수
곡선회귀	$Y=\beta_0+\beta_1X+\beta_2X^2+\cdots+\beta_kX^k+\epsilon$	독립변수가 하나이고 Y와의 관계가 2차 곡선 이상($k\geq2$)
다항회귀	$Y=\beta_0+\beta_1X_1+\beta_2X_2+\cdots+\beta_kX_k+\beta_{11}X_1^2+\beta_{22}X_2^2+\cdots+\beta_{kk}X_k^2+\beta_{12}X_1X_2+\cdots+\epsilon$	독립변수가 k개이고 2차 다항회귀모형인 경우
비선형회귀	$Y=\beta_0\log(\beta_1X_1)+\beta_2\sin(\beta_3X_2)+\epsilon$	회귀계수들이 선형으로 표현되지 않는 모형. 이에 비하여 위의 네 가지는 모두 선형회귀모형이다.

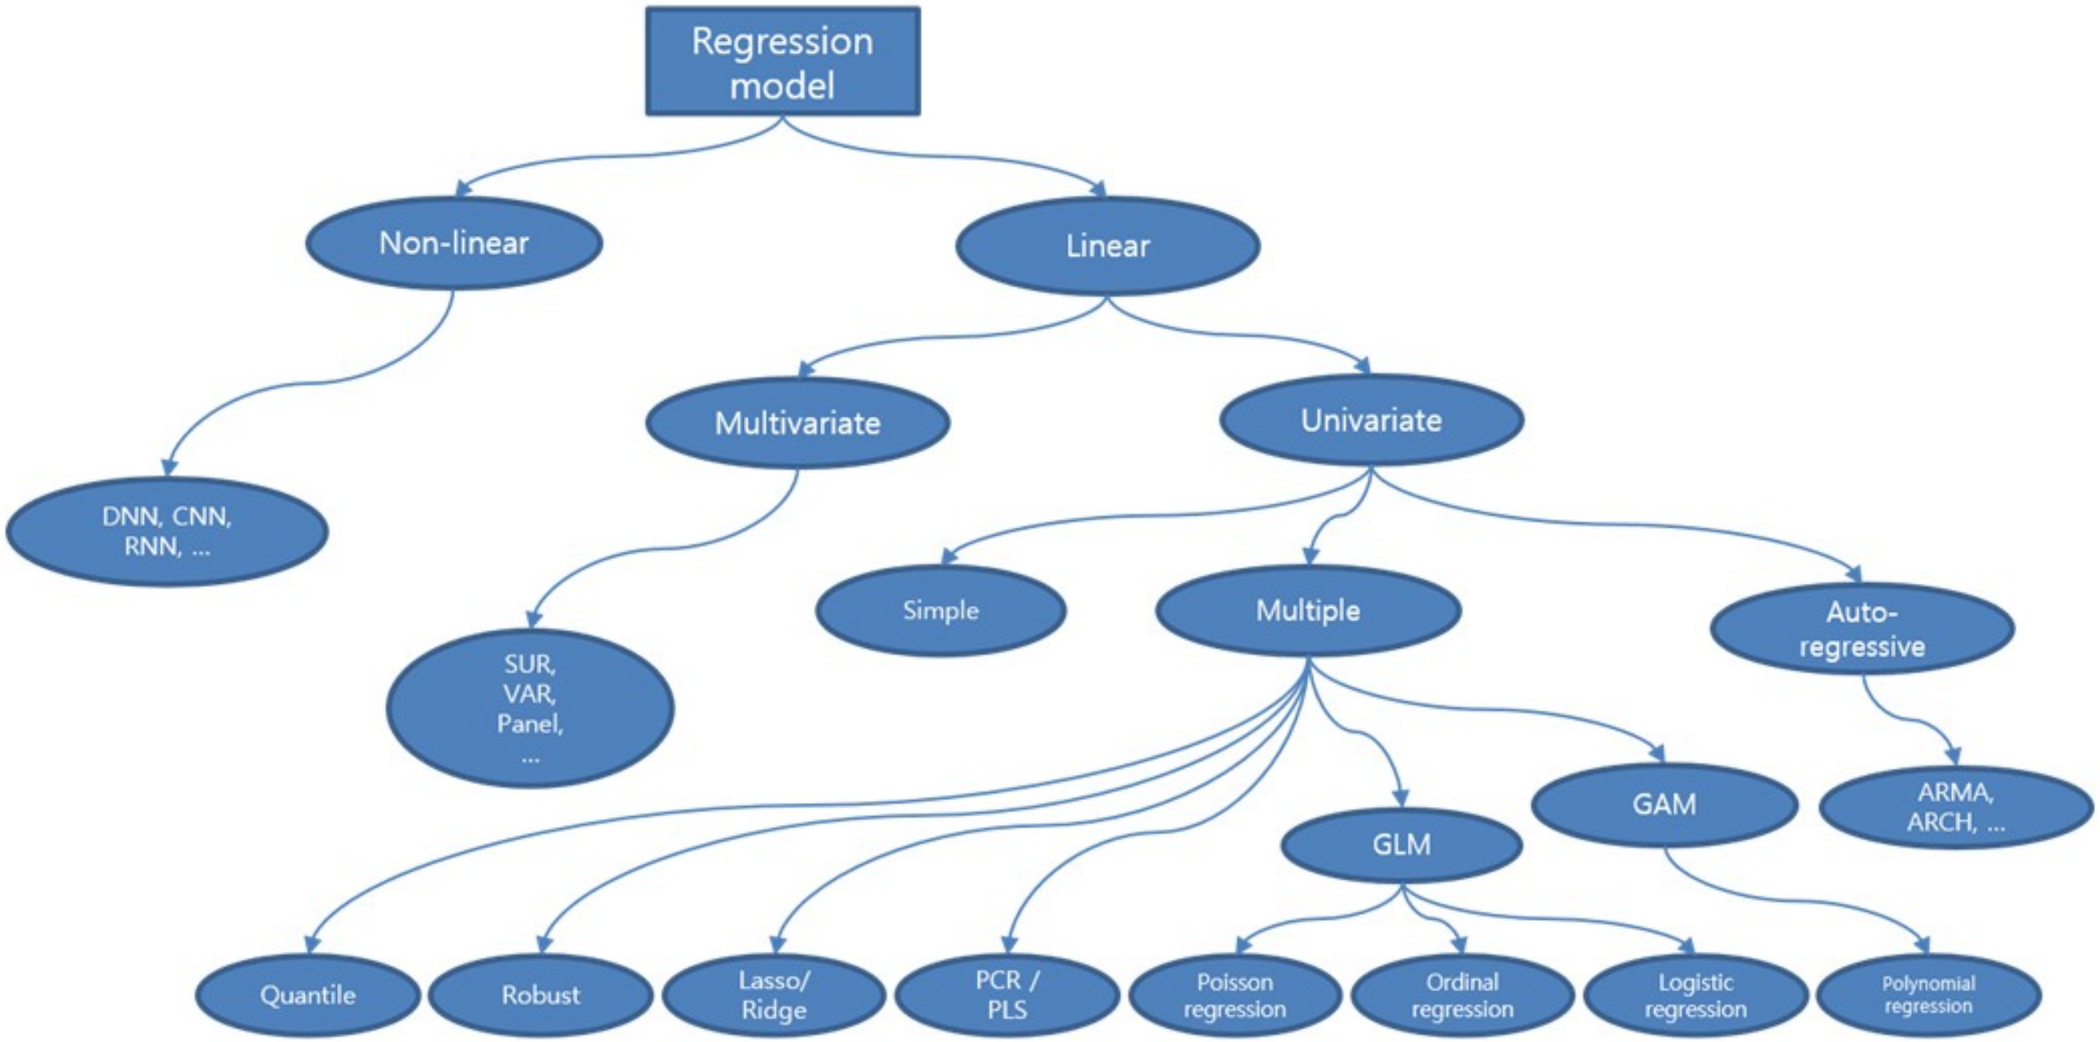
다항 회귀는 선형 회귀. 회귀에서 선형/비선형 회귀를 나누는 기준은 회귀 계수가 선형/비선형인지에 따른 것이라, 독립변수의 선형/비선형 여부와는 무관.

회귀의 종류



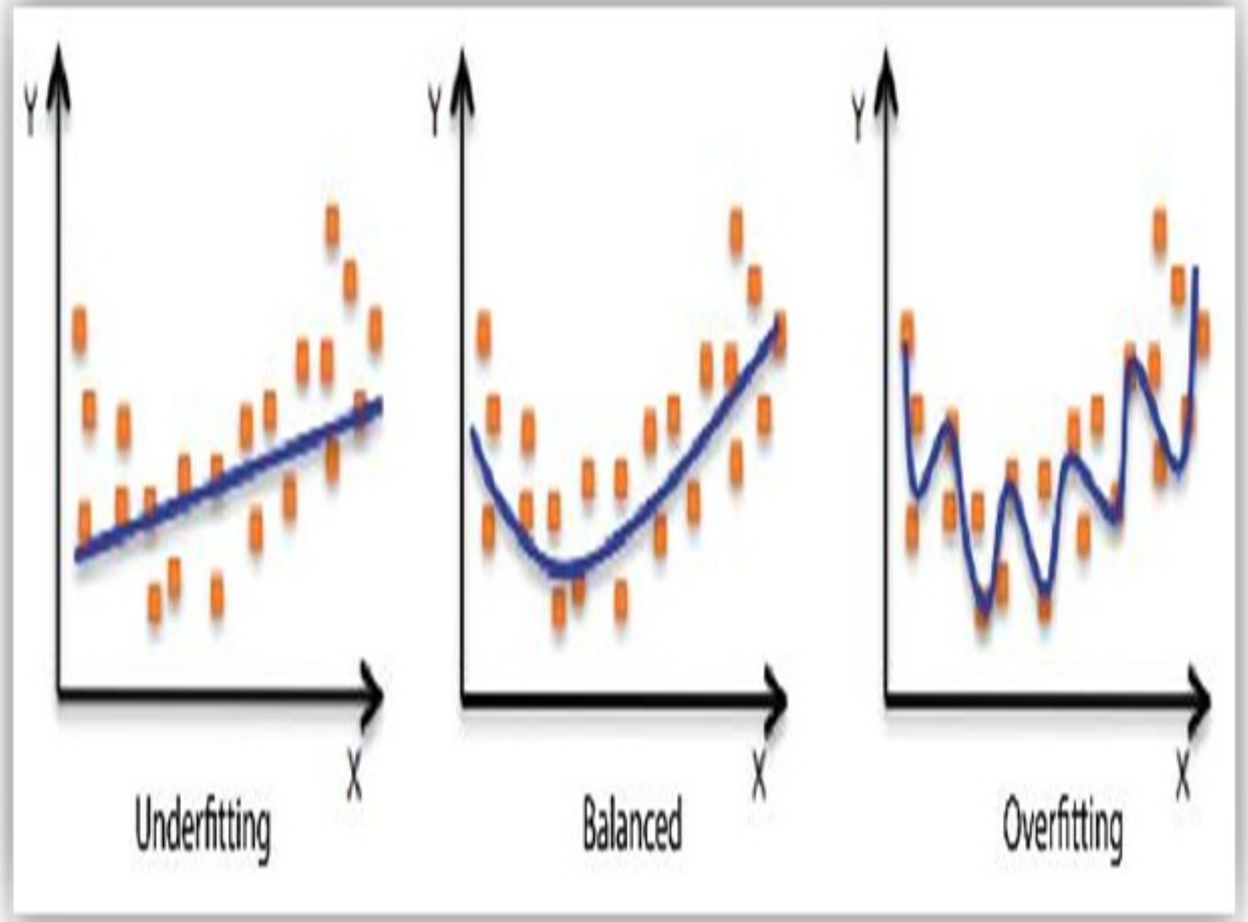
https://danbi-ncsoft.github.io/study/2018/05/04/study-regression_model_summary.html

회귀의 종류



https://danbi-ncsoft.github.io/study/2018/05/04/study-regression_model_summary.html

Bias VS Variance



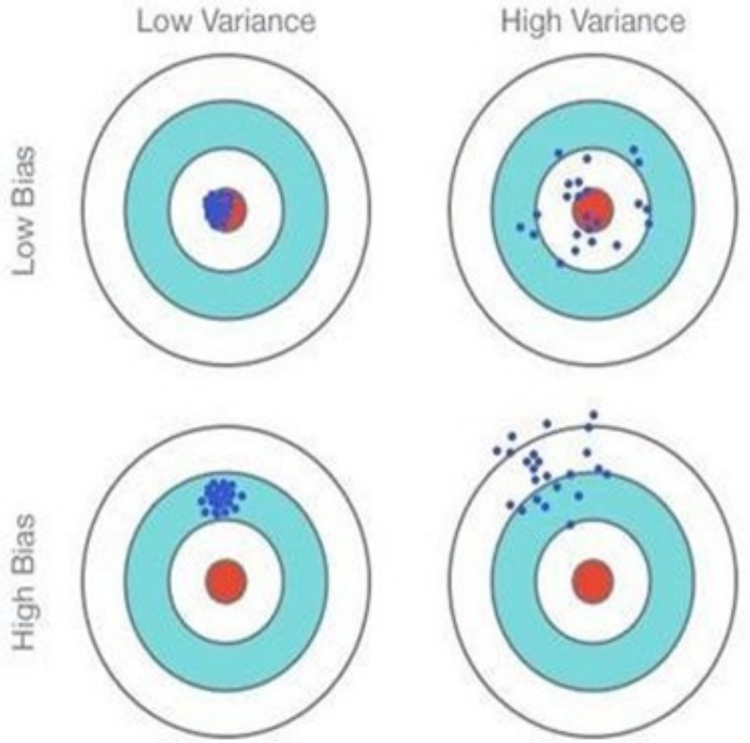


Fig. 1: Graphical Illustration of bias-variance trade-off , Source: Scott Fortmann-Roe., Understanding Bias-Variance Trade-off

http://scott.fortmann-roe.com/docs/BiasVariance.html

Bias VS Variance

- bias와 variance는 모델의 loss 또는 error를 의미

$$MSE = E[(y - \hat{y})^2] = Var(\hat{y}) + Bias(\hat{y})^2 + Var(\epsilon)$$

- 분산(variance)은 모델을 통해 예측한 값($\hat{y}$)이 예측값의 평균($E(\hat{y})$) 을 중심으로 얼마나 퍼져있는지를 보여줌. -> 모델에 실제 데이터(x)를 집어 넣어 나오는 예측값이 얼마나 큰 변동성을 가지는지 나타냄.

$$Var(\hat{y}) = E[(\hat{y} - E(\hat{y}))^2]$$

- 편향(Bias)은 예측한 값의 평균 ($E(\hat{y})$)과 실제값(y)의 차이로, 모델이 맞추지 못하는 부분을 나타냄. 모델에 데이터(x)를 집어 넣어 나오는 예측값이 '전반적으로 실제값을 얼마나 정확하게 예측하는지는 보여줌.

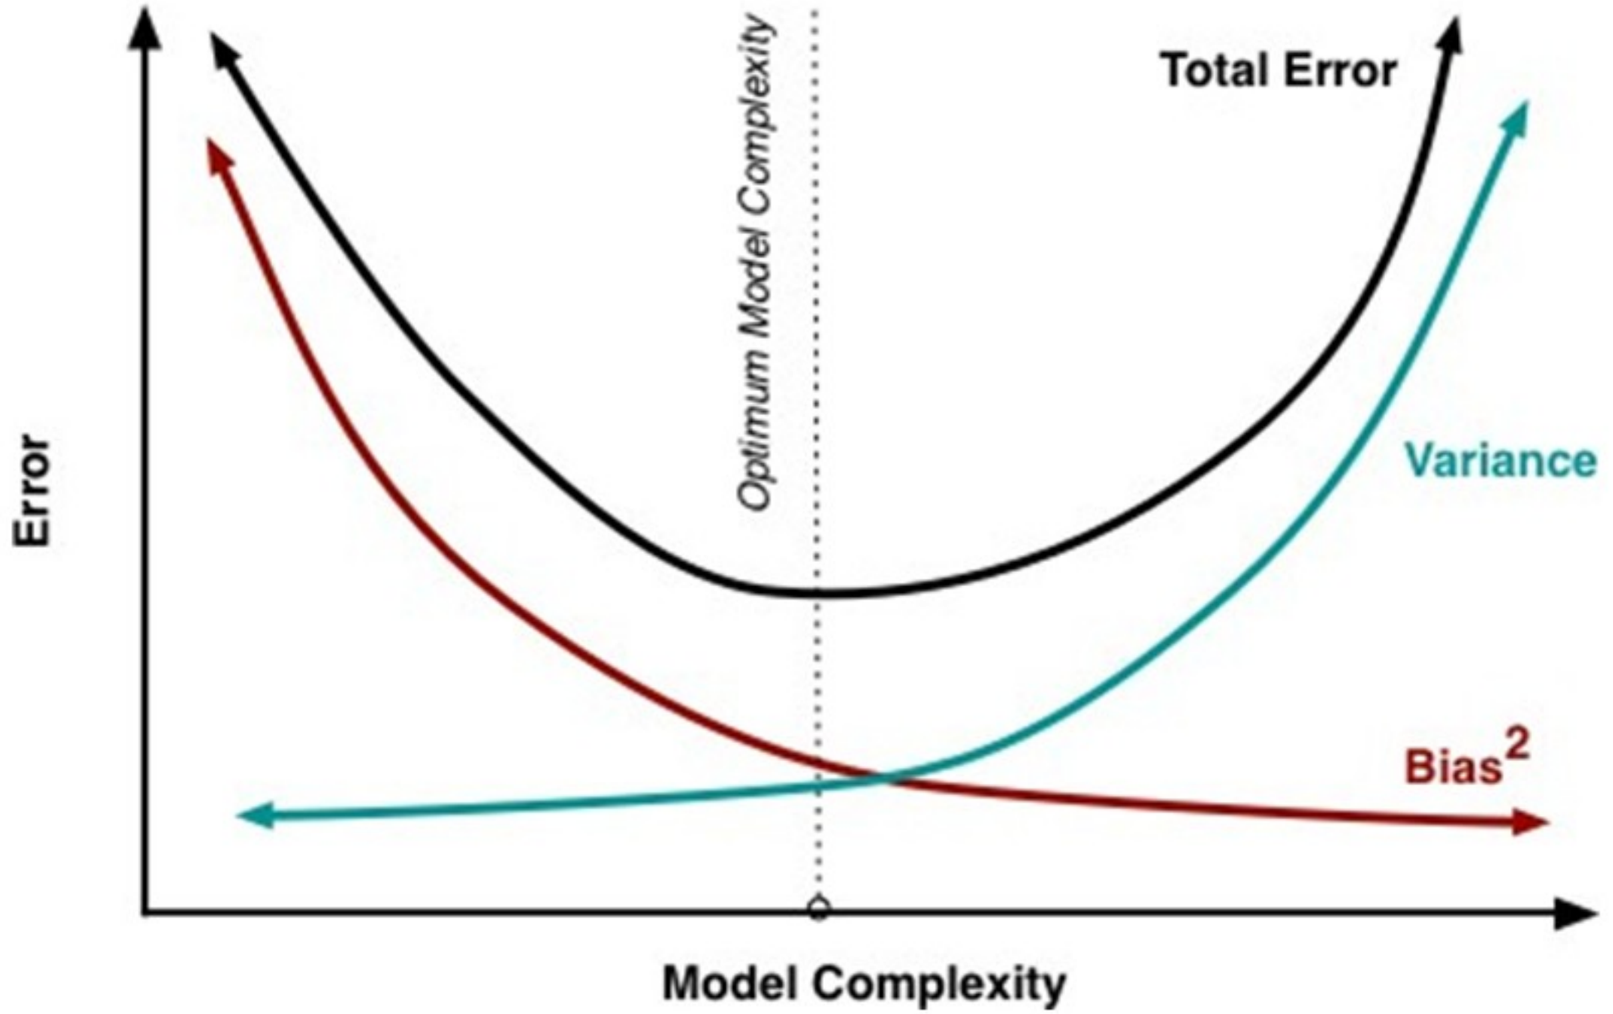
$$Bias(\hat{y})^2 = E[(E(\hat{y}) - y)^2]$$

Bias VS Variance

$$
\begin{aligned}
\mathrm{MSE}(\hat{\theta}) &= \mathbb{E}\left[(\hat{\theta}-\theta)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]+\mathbb{E}[\hat{\theta}]-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2+2\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)\left(\mathbb{E}[\hat{\theta}]-\theta\right)+\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2\right]+\mathbb{E}\left[2\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)\left(\mathbb{E}[\hat{\theta}]-\theta\right)\right]+\mathbb{E}\left[\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2\right]+2\left(\mathbb{E}[\hat{\theta}]-\theta\right)\mathbb{E}\left[\hat{\theta}-\mathbb{E}[\hat{\theta}]\right]+\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2 \qquad \mathbb{E}[\hat{\theta}]-\theta=\text{const.} \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2\right]+2\left(\mathbb{E}[\hat{\theta}]-\theta\right)\left(\mathbb{E}[\hat{\theta}]-\mathbb{E}[\hat{\theta}]\right)+\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2 \qquad \mathbb{E}[\hat{\theta}]=\text{const.} \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2\right]+\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2 \\
&= \mathrm{Var}(\hat{\theta})+\mathrm{Bias}(\hat{\theta},\theta)^2
\end{aligned}
$$

linearity: https://en.wikipedia.org/wiki/Expected_value

Bias and Variance tradeoff



http://scott.fortmann-roe.com/docs/BiasVariance.html

Regularization

L1 Regularization

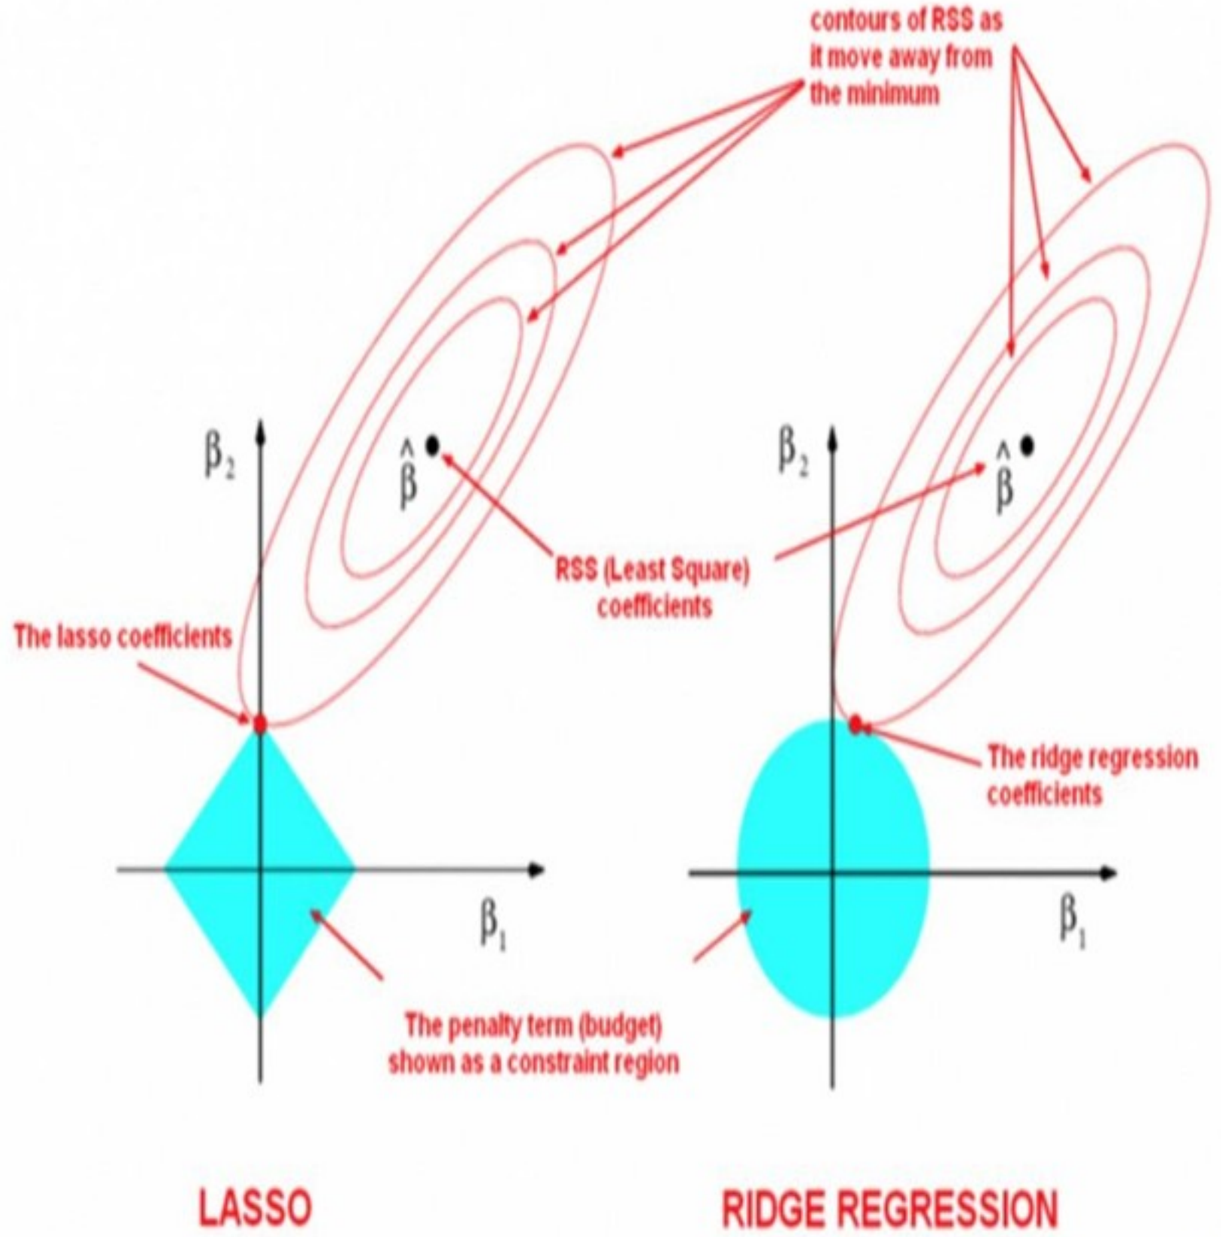
$$\text{Cost} = \sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} |W_j|$$

L2 Regularization

$$\text{Cost} = \sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} W_j^2$$

Loss function

Regularization Term



선형 회귀 모델을 위한 데이터 변환

회귀에서 타깃값은 반드시 정규 분포를 가져야 함.

- 타겟값의 경우 정규 분포 형태가 아니라 특정값의 분포가 치우친 왜곡된 형태의 분포도일 경우 예측 성능에 부정적인 영향을 미칠 가능성이 높음
- 선형 회귀 모델을 적용하기전에 먼저 데이터에 대한 스케일링/정규화 작업을 수행하는 것이 일반적이다. 하지만 이러한 스케일링/정규화 작업을 선행한다고 해서 무조건 예측 성능이 향상되는 것은 아니다. 일반적으로 중요한 피처들이나 타겟값의 분포도가 심하게 왜곡됐을 경우에 이러한 변환 작업을 수행한다.

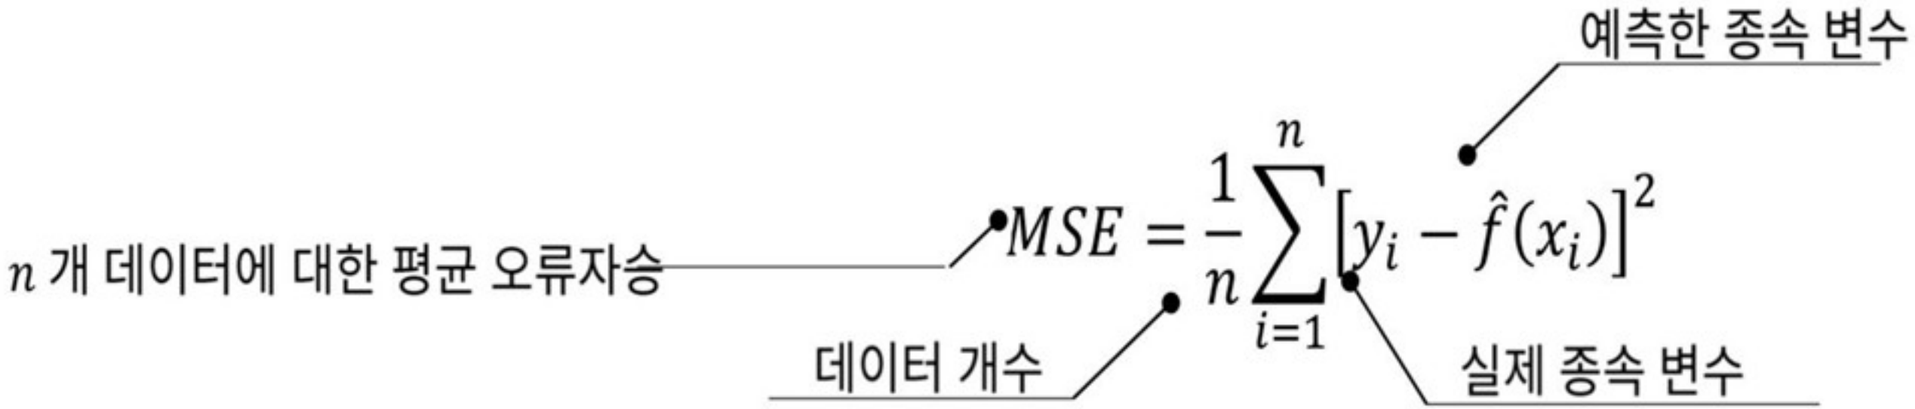
선형 회귀 모델을 위한 데이터 변환

- StandardScaler 클래스를 이용해 평균이 0, 분산이 1인 표준 정규 분포를 가진 데이터 셋으로 변환하거나 MinMaxScaler 클래스를 이용해 최소값이 0이고 최대값이 1인 값으로 정규화를 수행한다.

- 원래 값에 log 함수를 적용하면 보다 정규 분포에 가까운 형태로 값이 분포된다. 이러한 변환을 로그 변환이라 부른다.

회귀 평가지표 : MSE

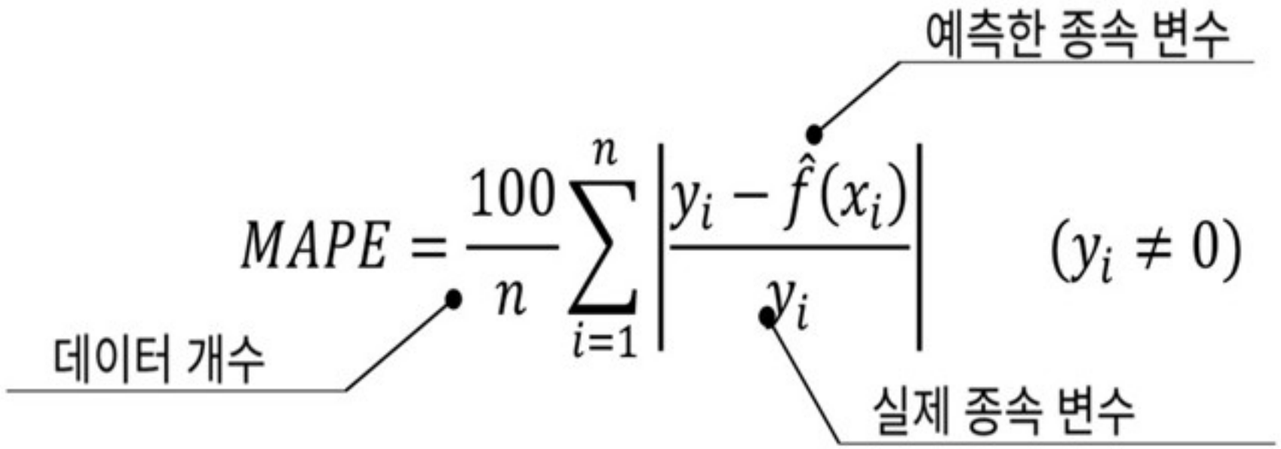
- MSE(Mean Squared Error)
  - f가 제대로 추정되었는지 평가하기 위해, 예측한 값이 실제 값과 유사한지 평가하는 척도가 필요함



- MSE는 실제 종속 변수와 예측한 종속 변수간의 차이
- MSE가 작을 수록 좋지만, MSE를 과도하게 줄이면 과적합의 오류를 범할 가능성이 있음
- 따라서, 검증 집합의 MSE를 줄이는 방향으로 f를 추정

평가지표 : MAPE

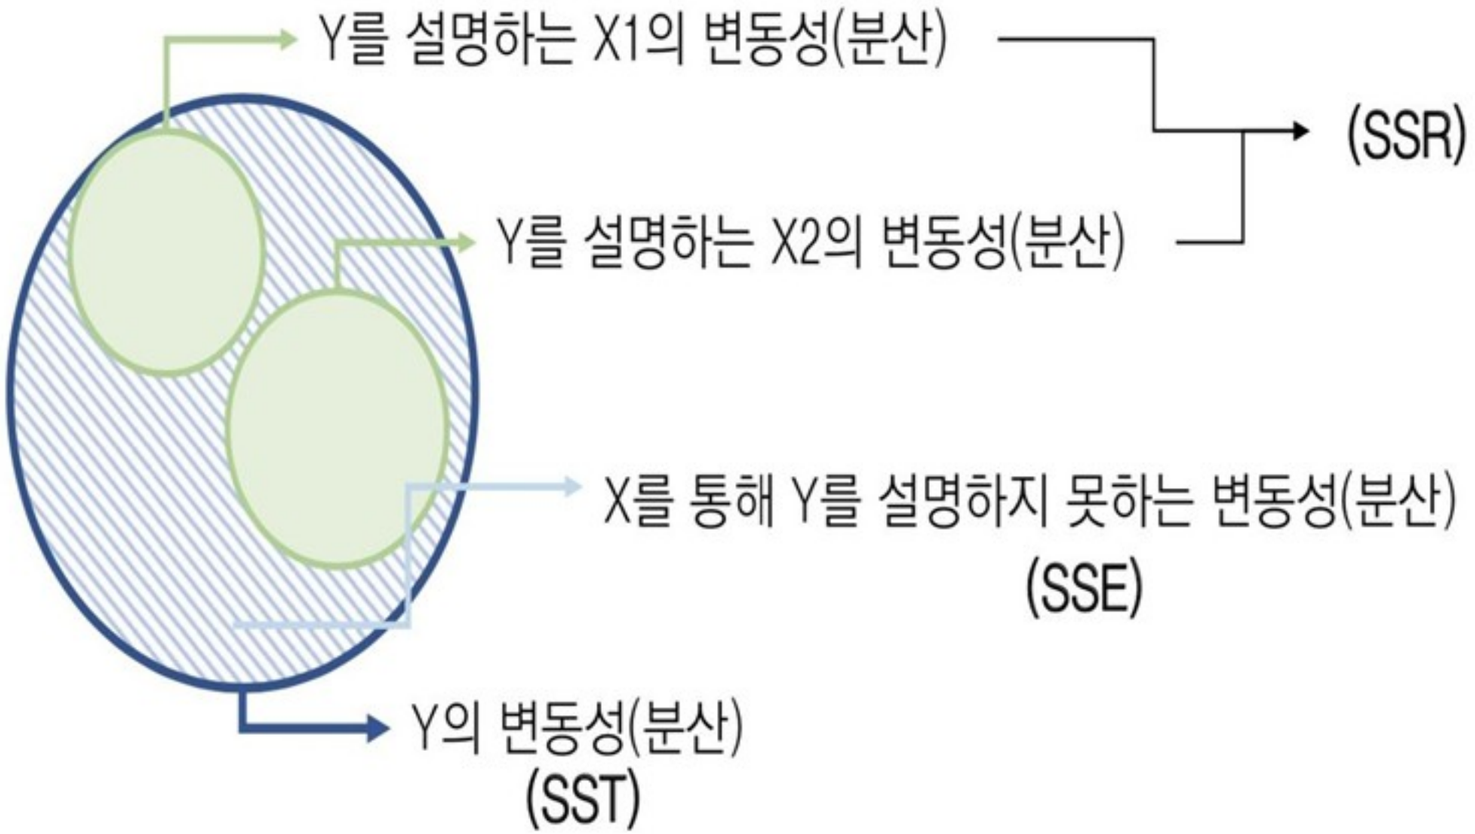
- MAPE(mean absolute percentage error)
  - f가 제대로 추정되었는지 평가하기 위해, 예측한 값이 실제 값과 유사한지 평가하는 척도가 필요함



- MAPE는 퍼센트 값을 가지며 0에 가까울수록 회귀 모형의 성능이 좋다고 해석할 수 있음
- 0%~100% 사이의 값을 가져 이해하기 쉬우므로 성능 비교 해석이 가능

R^2 Square

- R^2
  - 변수가 증가하면 증가할수록 R^2는 자연스레 증가



$$R^2 = \frac{SSR}{SST}$$

Adjusted R^2

- $Adjusted\ R^2$

  - 변수 수가 증가하면 자연스레 SSR이 증가하고 R2또한 자연스레 증가함

  - 회귀분석의 성능지표로서 R2가 큰 의미가 없음.

  - R2에 변수 수 만큼 penalty를 주는 지표가 Adjusted R2

- $R^2 = 1 - \frac{SSE}{SST}$

- $Adjusted\ R^2 = 1 - \frac{SSE/(n-p)}{SST/(n-1)}$

Akaike Information Criterion

- AIC (Akaike information criterion)

  - 모델의 성능지표로서 MSE에 변수 수 만큼 penalty를 주는 지표

  - 일반적으로 회귀분석에서 Model Selection할 때 많이 쓰이는 지표

$$AIC = n \ln\left(\frac{SSE}{n}\right) + 2(p+1)$$

Bayes Information Criteria

- BIC (Bayes Information Criteria)
  - AIC의 단점은 표본 n이 커질 때 부 정확해짐
  - 이를 보완한 지표가 BIC (AIC와 큰 차이는 없음)

$$BIC = n \ln\left(\frac{SSE}{n}\right) + (p+1)\ln n$$

가능도(Likelihood)

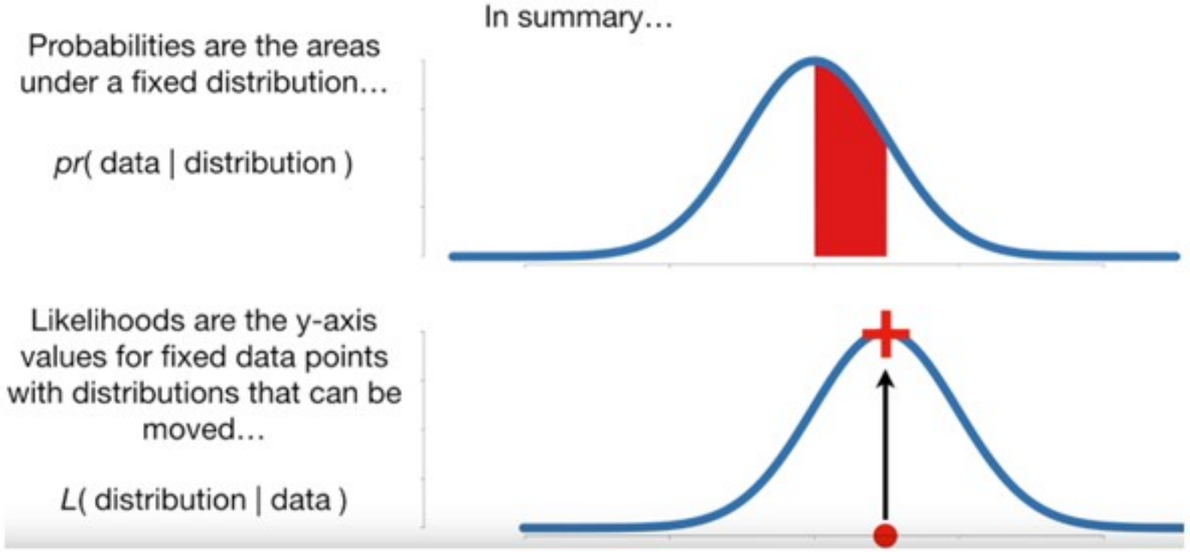
- 확률 : 주어진 확률분포에서 해당 관측값이 나올 확률
- 가능도 : 주어진 관측값이 특정 확률분포로부터 나왔을 확률(=연속확률밀도함수의 y값)

- 확률 : 주어진 확률분포가 있을 때, 관측값 혹은 관측 구간이 분포 안에서 얼마의 확률로 존재하는 지를 나타내는 값.

$$\text{확률} = P(\text{예측값 X} \mid \text{확률분포 D})$$

- 가능도 : 어떤 값이 관측되었을 때, 해당 관측값이 어떤 확률분포로부터 나왔는지에 대한 확률.

$$\text{가능도} = L(\text{확률분포 D} \mid \text{관측값 X})$$



출처 : https://data-scientist-brian-kim.tistory.com/91

선형회귀 가정

1. 독립변수와 종속변수 간의 선형적인 관계를 가정
2. 오차항은 정규분포를 따른다는 가정(Normality)
3. 오차항은 등분산성을 가정한다(Homoscedasticity)
4. 공분산성이 없다는 가정(no multicollinearity)

- 피쳐 간의 상관관계가 매우 높은 경우 분산이 매우 커져서 매우 민감해짐.

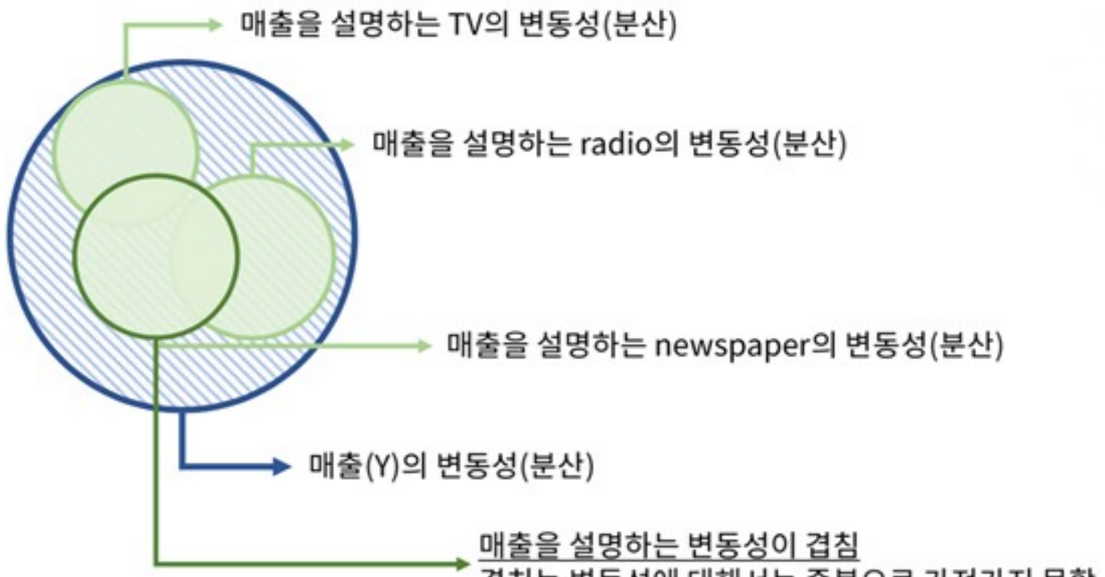
  -> 이러한 현상을 다중공산성(Multi-collinearity)

다중공선성(Multicollinearity)

- 모형의 일부 예측 변수가 다른 예측변수와 상관되어 있을 때 발생하는 조건
- 어떤 독립 변수가 다른 독립 변수들과 완벽한 선형 독립이 아닌 경우를 뜻함.
- 중대한 다중공선성은 회귀계수의 분산을 증가시켜 불안정하고 해석하기 어렵게 만들기 때문에 문제가 됨.
- VIF(Variance Inflation Factor)값이 4가 넘으면 다중공선성이 존재하다고 보고, 높은 상관관계가 있는 예측 변수를 모형에서 제거함.

$$VIF = \frac{1}{1 - R_i^2}$$

- 다중공선성(Multicollinearity)



이러한 현상에 대해서 변수들간의 다중공선성(Multicollinearity)이 있다고 한다.

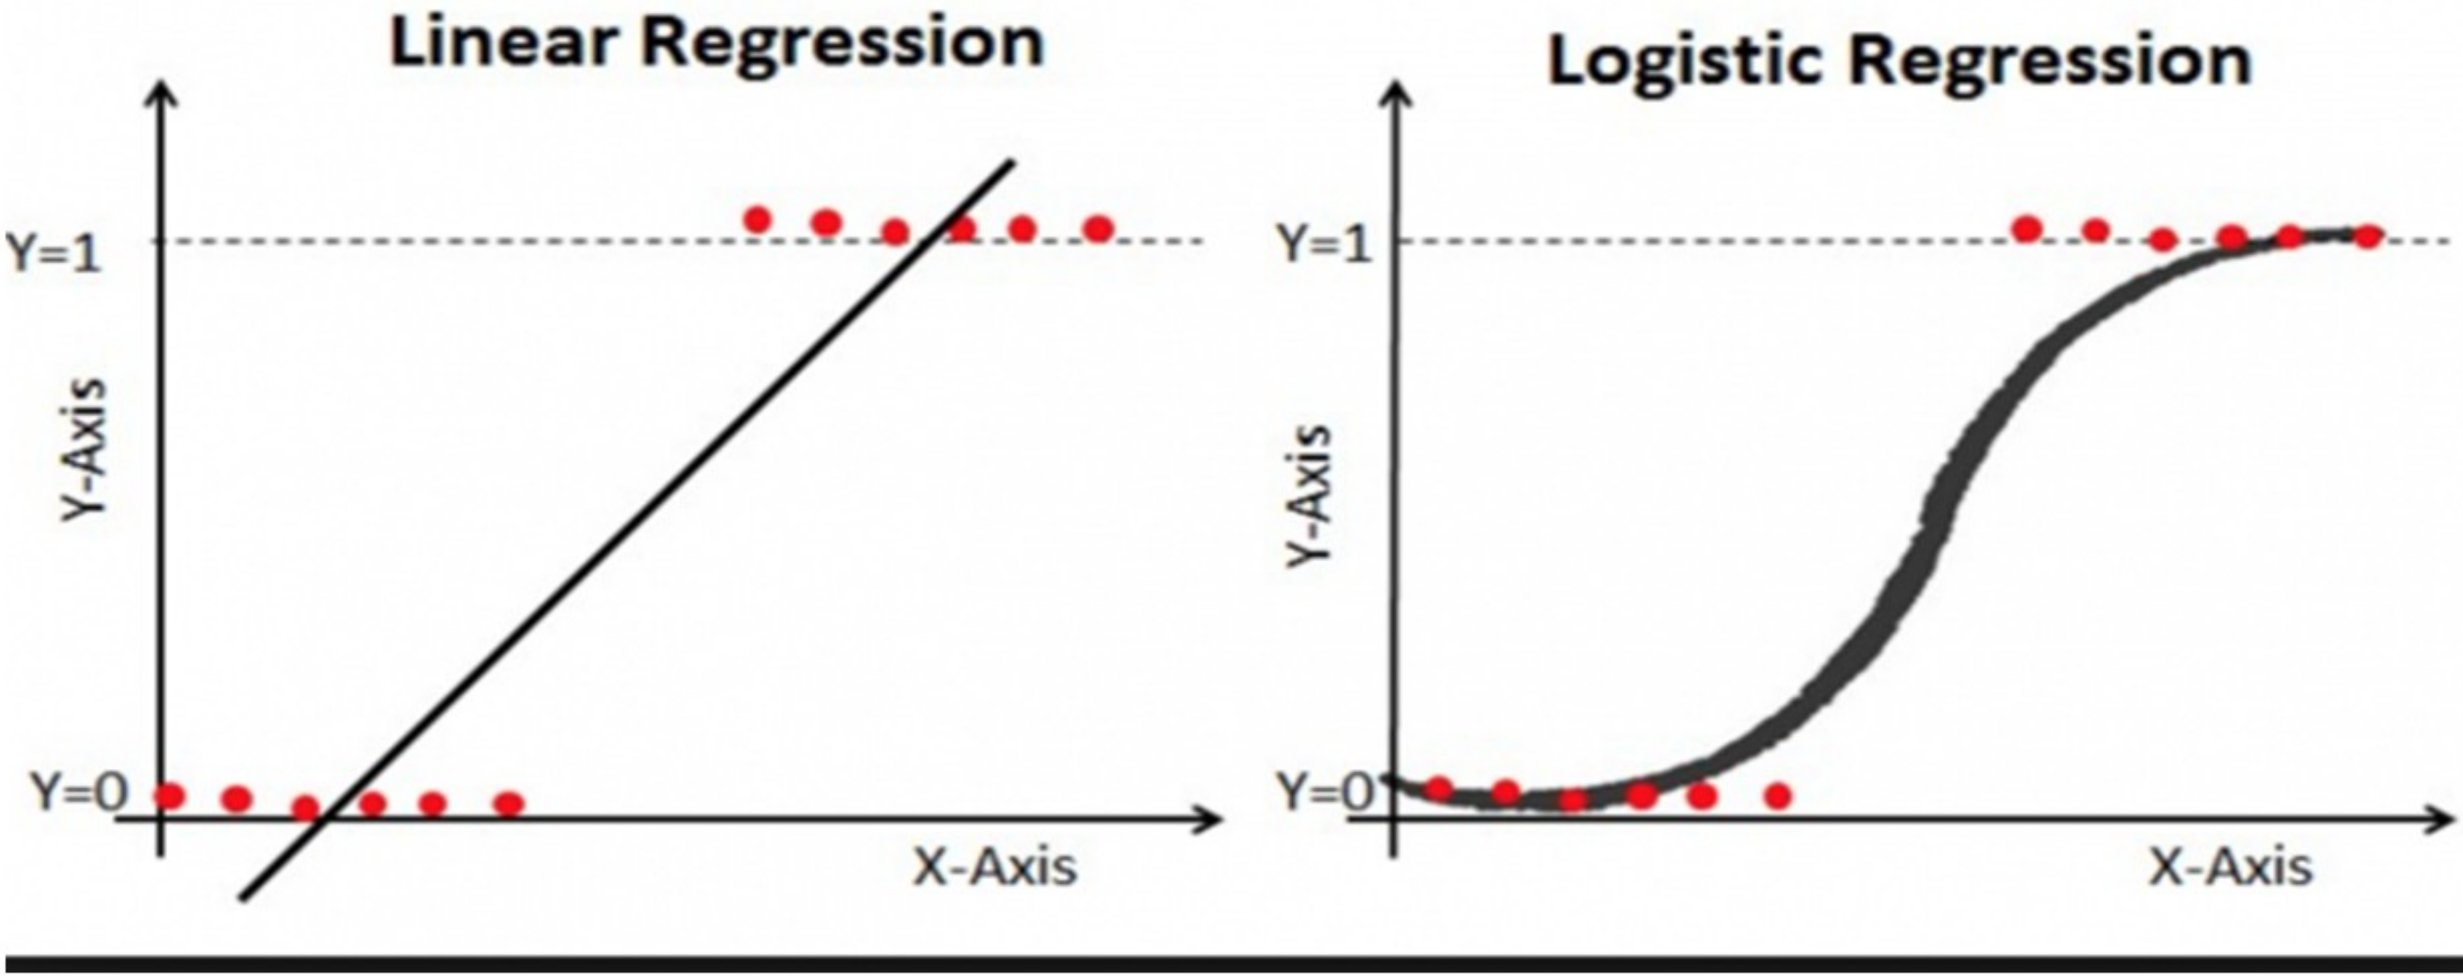
잘못된 변수해석, 예측 정확도 하락 등을 야기시킨다

출처 : https://heung-bae-lee.github.io/2020/01/08/machine_learning_02/

Logistic Regression

- 영국의 통계학자 D.R.Cox가 1958년에 제안한 확률 모델로서 독립변수의 선형 결합을 이용하여 사건의 발생 가능성을 예측하는데 사용되는 통계기법.
- 선형 회귀분석과는 다르게 종속변수가 범주형 데이터를 대상으로 하며, 입력 데이터가 주어졌을 때 해당 데이터의 결과가 특정 분류로 나뉘기 때문에 일종의 분류(Classification) 기법으로도 볼 수 있음.
- 종속 변수가 이항변수의 경우(ex) 성공/실패, 업/다운, 생존/죽음, Yes/No 등등)
- OLS로 해석 불가
- 종속변수가 0,1인데 logit을 하면 연속변수처럼 바꾸는 효과가 생겨서 OLS로 해석이 가능하고 확률개념이 생겨서 해석이 용이함.

Logistic Regression



출처 : https://medium.com/@ODSC/logistic-regression-with-python-ede39f8573c7

Logistic Regression

· 로그의 특성

$$\log(ab) = \log a + logb$$

$$\log\left(\frac{b}{a}\right) = logb - loga$$

· 로짓 변환

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n$$

$$\frac{p}{1-p} = e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n}$$

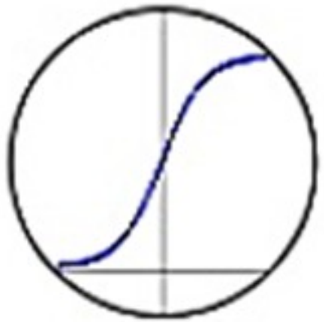
$$p = (1-p)\, e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n}$$

$$(1 + e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n})\mathrm{p} = e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n}$$

$$p = \frac{e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n}}{1 + e^{\beta_0+\beta_1 X_1+\cdots+\beta_n X_n}} = \frac{1}{e^{-(\beta_0+\beta_1 X_1+\cdots+\beta_n X_n)} + 1}$$

Logistic Regression

Logistic 함수 및 미분특성



$$f(x) = \frac{1}{1+e^{-x}} = \frac{e^x}{1+e^x}$$

$$\frac{d}{dx} f(x) = f(x)(1 - f(x))$$

Logistic Regression

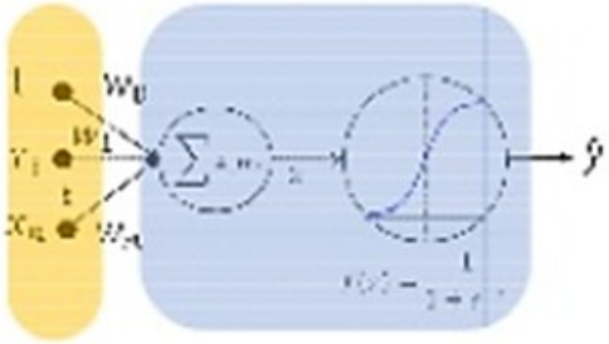
Logistic 함수 및 미분특성

$$\frac{d}{dx}f(x) = \frac{d}{dx}\frac{1}{1+e^{-x}} = \frac{1}{(1+e^{-x})^2}(e^{-x})$$

$$= \frac{1}{(1+e^{-x})^2}\left(1 - \frac{1}{(1+e^{-x})}\right)$$

$$= f(x)f\big(1-f(x)\big)$$

Logistic Regression



$$\hat{y} = f(z) = \frac{1}{1+e^{-z}}$$

$$z = \sum w_i x_i$$

$$\frac{\partial}{\partial z} f(z) = f(z)\big(1 - f(z)\big)$$

$$\frac{\partial E}{\partial w_i} = \frac{\partial}{\partial w_i}\frac{1}{2}\sum_d (y_d - \hat{y}_d)^2$$

$$= \frac{1}{2}\sum_d \frac{\partial}{\partial w_i}(y_d - \hat{y}_d)^2$$

$$= \frac{1}{2}\sum_d 2(y_d - \hat{y}_d)\frac{\partial}{\partial w_i}(y_d - \hat{y}_d)$$

$$= \sum_d (y_d - \hat{y}_d)\frac{\partial}{\partial w_i}(-\hat{y}_d)$$

$$= -\sum_d (y_d - \hat{y}_d)\frac{\partial \hat{y}_d}{\partial z}\frac{\partial z}{\partial w_i}$$

$$= -\sum_d (y_d - \hat{y}_d)\frac{\partial f(z)}{\partial z}\frac{\partial\left(w_0 + w_1 x_{1,d} + \cdots + w_n x_{n,d}\right)}{\partial w_i}$$

$$= -\sum_d (y_d - \hat{y}_d)\hat{y}_d(1 - \hat{y}_d)x_{i,d}$$

Logistic Regression

- 오즈(Odds)에 대해 알아보자.
- 오즈는 원래 경마장에서 도박 지불률을 정할 때 사용
- 경마장의 예제 : 3마리 말이 출전. 3마리 말의 승리할 확률이 다음과 같음
  - A말은 50%의 확률로 승리 ; B말은 30%의 확률로 승리 ; C말은 20%의 확률로 승리
  - 만약, 참가자에게 1000원의 마권을 사게 하고, 승자를 맞춘 사람에게 3000원씩 지불한다면
  - A말의 마권을 살 경우 기대값 = 3000원X 50% = 1500원
  - B말의 마권을 살 경우 기대값 = 3000원X 30% = 900원
  - C말의 마권을 살 경우 기대값 = 3000원X 20% = 600원
- 그러므로, 바보가 아닌 이상 A말의 마권을 사는 것이 비용 1000원을 초과하는 유일한 선택
- 주인의 입장 : 50%의 확률로 A말이 이기면, 판매된 마권의 개수 X 2000원 만큼 손해,
- 그러므로 주인은 망함.

Logistic Regression

・오즈(Odds)에 대해 알아보자.

・상금지급 기준 변경 1안

・경마장의 예제 : 전과 동일

- A말은 50%의 확률로 승리; B말은 30%의 확률로 승리; C말은 20%의 확률로 승리
- 만약, 참가자에게 1000원의 마권을 사게 하고, 예상 승률의 역수배로 상금 지불
- A말의 마권을 살 경우 기댓값 = 1000원 X(1/50%)X50% = 1000원
- B말의 마권을 살 경우 기댓값 = 1000원 X(1/30%)X30% = 1000원
- C말의 마권을 살 경우 기댓값 = 1000원 X(1/20%)X20% = 1000원
- 어느 쪽에 걸더라도 기대값 상금이 같아져 패자의 손실과 승자의 이익이 상쇄됨.

Logistic Regression

- 오즈(Odds)에 대해 알아보자.
- 상금지급 기준 변경 2안
- 경마장의 예제 : 전과 동일
  - A말은 50%의 확률로 승리; B말은 30%의 확률로 승리; C말은 20%의 확률로 승리
  - 만약, 참가자에게 1000원의 마권을 사게 하고, 오즈의 역수배로 상금 지불
  - 오즈(Odds) : 확률 ÷ (1-확률)을 의미
  - A의 오즈 = 50% ÷ (1-50%) = 1; 기댓값 = 1000원 X 1배 X 50% = 500원
  - B의 오즈 = 30% ÷ (1-30%) = 0.43; 기댓값 = 1000원 X2.33배X30% ≈ 700원
  - C의 오즈 = 20% ÷ (1-20%) = 0.25; 기댓값 = 1000원 X4X20% = 800원

$$\text{ODDS} = \frac{\text{Probability of winning}}{\text{Probability of losing}} = \frac{p}{1-p}$$

Where p = probability of winning (event occurring)

Logistic Regression

- 오즈 비 (Odds ratio)
  - 오즈비의 예제 : 극단적인 경우의 이항변수
  - 희귀질병의 발병여부
    - 종속변수 : 희귀질병의 발병여부
    - 독립변수 : 거주지역구분(도시지역 or 비도시지역)

	발병 Yes	발병 NO	합계
도심지역	1명	1,999명	2,000명
비도심지역	1명	7,999명	8,000명
합 계	2명	9,998명	10,000명

Logistic Regression

- 오즈 비 (Odds ratio)
  - 희귀질병의 발병여부

	발병 Yes	발병 NO	합계
도심지역	1명	1,999명	2,000명
비도심지역	1명	7,999명	8,000명
합 계	2명	9,998명	10,000명

- 도심지역 주민의 발병 오즈(odds) $\frac{\frac{1}{2000}}{1-\frac{1}{2000}} = \frac{1}{1999}$
- 비도심지역 주민의 발병 오즈(odds) $\frac{\frac{1}{8000}}{1-\frac{1}{8000}} = \frac{1}{7999}$
- 비도심지역 대비 도심 지역 발병 오즈비(odds ratio) $\frac{\frac{1}{1999}}{\frac{1}{7999}} \approx 4.0015$

Logistic Regression

- 오즈 비 (Odds ratio)
  - 왜 이런 복잡한 걸 쓸까?

    - 도심지역 주민의 발병 오즈(odds) $\frac{\frac{1}{2000}}{1-\frac{1}{2000}} = \frac{1}{1999}$
    - 비도심지역 주민의 발병 오즈(odds) $\frac{\frac{1}{8000}}{1-\frac{1}{8000}} = \frac{1}{7999}$
    - 비도심지역 대비 도심 지역 발병 오즈비(odds ratio) $\frac{\frac{1}{1999}}{\frac{1}{7999}} \approx 4.0015$
    - 도심지역 발병 확률 = $\frac{1}{2000}$; 비도심지역 발병 확률 = $\frac{1}{8000}$: 거의 차이 없음.

Logistic Regression

- 오즈 비 (Odds ratio)
- 왜 이런 복잡한 걸 쓸까?
  - 오즈(odds)와 단순 확률(P)는 거의 같음
  - 오즈를 오즈로 나누면 비교가 가능

  - 비도심지역 대비 도심지역 발병 오즈비(Odds ratio) = $\frac{\frac{1}{1999}}{\frac{1}{7999}} \approx 4.0015$

  - 비도심지역에 1명의 희귀질병 환자가 발병할 경우, 도심지역에는 4명 발생
  - 여기에 log를 붙이면 더 활용범위가 높아진다.
  - 0<p<1(여기서 p는 단순확률) & 0<1-p <1
  - p가 '0'에 가까울 수록 오즈비(odds ratio)는 '0'을 향해 접근
  - p가 '1'에 가까울 수록 오즈비(odds ratio)는 '무한대'을 향해 접근
  - 0<오즈비(odds ration) < 무한대 ->-무한대 <log(오즈비) = 로짓 <+무한대

Logistic Regression

· 결론)

- 로짓의 특징

$-\infty <$ 로짓(logit) = log(오즈비) $< +\infty$

- 이렇게 되면 우리의 종속변수는 0과 1로만 이루어진 문제에서 음의 무한대에서 양의 무한대까지 일반 연속변수처럼 바뀜

- 그러므로, 우리는 종속변수를 로짓으로 바꿔서 사용하면 우리가 아는 OLS로 회귀분석을 할 수 있음.

- 단점 : 해석방법이 기존의 OLS와 다소 다르다.

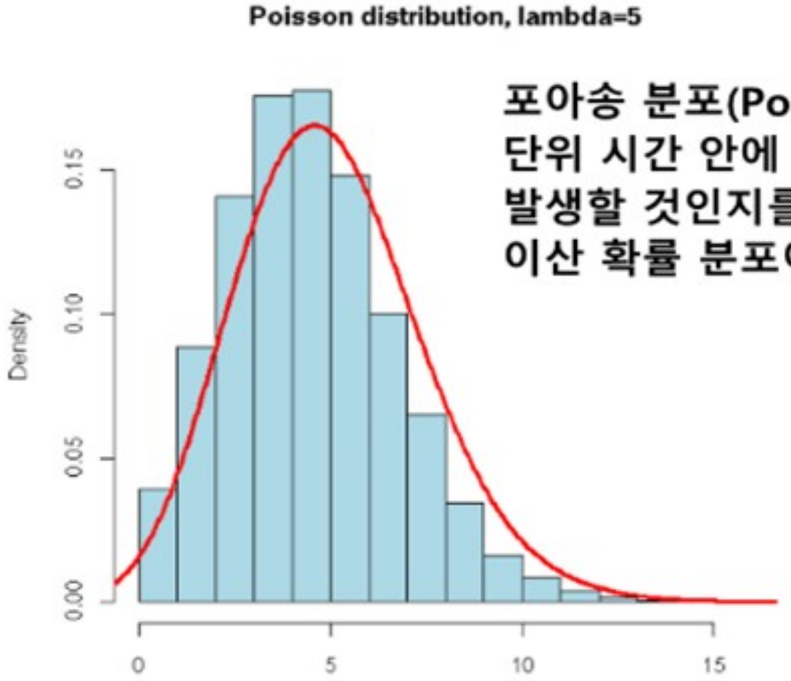
Poisson Regression

· 종속변수(Dependent variable)가 포아송 분포를 따른다고 가정하고, 일반화 선형모형의 회귀분석을 수행

- 특히 종속변수가 빈도자료(Count data)일 때 주로 사용

포아송 분포

- 단위 시간 안에 어떤 사건이 몇번 발생할 것인지를 표현하는 이산 확률 분포 구간에서 발생하는 사건의 횟수를 추정하는데 매우 유용.



포아송 분포(Poisson Distribution)는 단위 시간 안에 어떤 사건이 몇 번 발생할 것인지를 표현하는 이산 확률 분포이다.

출처 :
https://ssacstat.tistory.com/366

Poisson Distribution

$$f(k;\lambda) = \Pr(X{=}k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- Mean

$$E[X] = \lambda$$

- Proof:

$$E[X] = \sum_{k=0}^{\infty} kP\{X=k\} = e^{-\lambda}\sum_{k=0}^{\infty} k\frac{\lambda^k}{k!} = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{(k-1)!}$$

$$= e^{-\lambda}\lambda\sum_{j=0}^{\infty}\frac{\lambda^j}{j!} = e^{-\lambda}\lambda e^{\lambda} = \lambda$$

Poisson Distribution – Variance

$$E[X^2] = \sum_{i=0}^{\infty}\frac{i^2 e^{-\lambda}\lambda^i}{i!}$$

$$= \lambda\sum_{i=1}^{\infty}\frac{ie^{-\lambda}\lambda^{i-1}}{(i-1)!}$$

Let $j = i - 1$,

$$E[X^2] = \lambda\sum_{j=0}^{\infty}\frac{(j+1)e^{-\lambda}\lambda^j}{j!}$$

$$= \lambda\left[\sum_{j=0}^{\infty}\frac{je^{-\lambda}\lambda^j}{j!} + \sum_{j=0}^{\infty}\frac{e^{-\lambda}\lambda^j}{j!}\right]$$

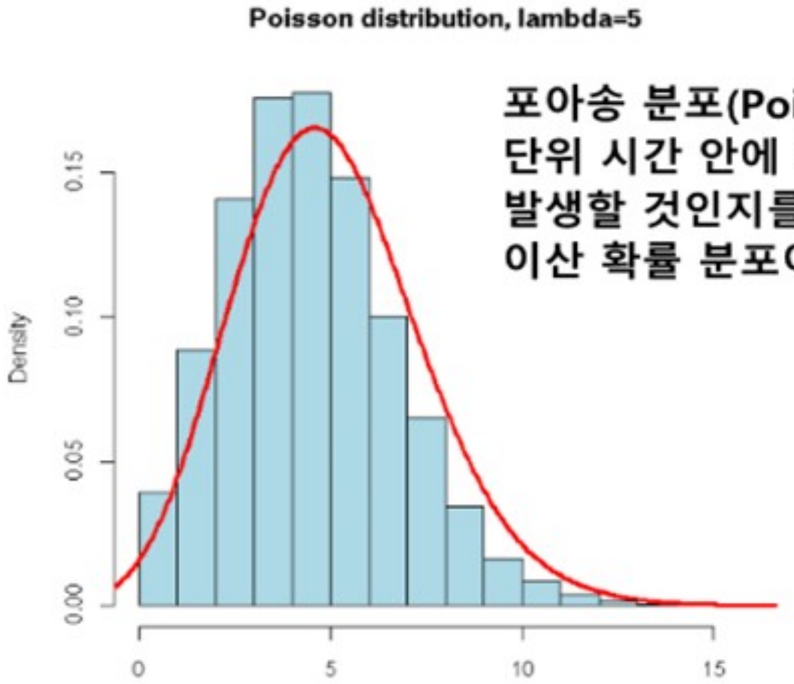
$$= \lambda(\lambda+1) = \lambda^2 + \lambda$$

$$\mathrm{Var}(X) = E[X^2] - (E[X])^2 = \lambda$$

Poisson Regression

· 전제조건

1. 동일한 길이의 어떤 두 구간에서 사건발생의 확률은 동일
2. 어떤 구간의 사건발생이나 사건 불발은 다른 구간에서의 사건 발생, 불발과는 무관하다.
3. 매우 짧은 시간이나 매우 작은 공간에 두 개 이상의 결과가 동시에 발생할 확률은 0이다.



포아송 분포(Poisson Distribution)는 단위 시간 안에 어떤 사건이 몇 번 발생할 것인지를 표현하는 이산 확률 분포이다.

Thank you.

회귀
ryp1662@gmail.com

© 2025 Youngpyo Ryu. All rights reserved.
Unauthorized reproduction or distribution is prohibited.